

Architectures for the Intelligent AI-Ready Enterprise

Building real-world solutions
with MongoDB

Boris Bialek | Sebastian Rojas Arbulu | Taylor Hedgecock

Foreword by:
Jim Scharf,
*Chief Technology Officer,
MongoDB, Inc.*

Arquitecturas para la Inteligencia Empresa preparada para la IA

Construyendo soluciones del mundo real con MongoDB

Boris Bialek, Sebastián Rojas Arbulu, Taylor
Erizo



Arquitecturas para la inteligencia artificial preparada Empresa

Copyright © 2025 Packt Publishing. Todos

los derechos reservados. Ninguna parte de este libro podrá reproducirse, almacenarse en un sistema de recuperación de datos ni transmitirse en ninguna forma ni por ningún medio sin la autorización previa por escrito del editor, excepto en el caso de citas breves incluidas en artículos críticos o reseñas.

En la preparación de este libro se ha hecho todo lo posible para garantizar la precisión de la información presentada. Sin embargo, la información contenida en este libro se vende sin garantía, ni expresa ni implícita. Ni los autores, ni Packt Publishing ni sus distribuidores serán responsables de ningún daño causado o presuntamente causado, directa o indirectamente, por este libro.

Packt Publishing se ha esforzado por proporcionar información sobre las marcas comerciales de todas las empresas y productos mencionados en este libro mediante el uso adecuado de mayúsculas. Sin embargo, Packt Publishing no puede garantizar la exactitud de esta información.

Directora de cartera: Sunith Shetty

Responsable de relaciones: Sathya Mohan

Gerentes de proyecto: Aniket Shetty y Sathya Mohan

Ingenieros de contenido: Siddhant Jain, David Sugarman y Divya Poliyath

Editor técnico: Aniket Shetty

Editor de copias: Safis Editing

Indexador: Pratik Shirodkar

Corrector: Siddhant Jain

Diseñador de producción: Deepak Chavan

Primera publicación: septiembre de 2025

Referencia de producción: 1290825

Publicado por Packt Publishing Ltd.

Casa Grosvenor

11 Plaza de San Pablo

Birmingham

B3 1RB, Reino Unido.

ISBN 978-1-80611-715-4

www.packtpub.com

Prefacio

Si me hubieran dicho hace unos años que escribiría el prólogo de un libro sobre IA, quizá me habría sorprendido. Y, sin embargo, aquí estamos, en medio de uno de los cambios tecnológicos más rápidos de la historia moderna.

A diferencia de los cambios tecnológicos anteriores, lo que diferencia esta vez es el ritmo. El cambio no se desarrolla durante años, sino en meses, semanas y, a veces, incluso días.

La pregunta a la que se enfrenta toda organización no es si la IA transformará su negocio, sino con qué velocidad podrá adaptarse y si liderará o se quedará atrás.

A lo largo de mi carrera, he visto qué diferencia a las empresas que prosperan en momentos como estos de las que se quedan atrás. Rara vez se trata solo de la tecnología. Es la mentalidad: la disposición a replantear cómo operan, cómo aportan valor y cómo utilizan los datos para obtener mejores resultados. La IA, especialmente los sistemas generativos y agénticos, exige precisamente ese tipo de replanteamiento.

En MongoDB, hemos colaborado estrechamente con miles de organizaciones de diversos sectores, como servicios financieros, salud, seguros, comercio minorista y manufactura, en su transición hacia la IA. Y el patrón es claro: las empresas que triunfan no empiezan con algoritmos ni modelos. Empiezan con la base. Esa base son los datos.

Considere una importante institución financiera que pasó de la detección tradicional de fraude por lotes a la monitorización en tiempo real con MongoDB Atlas, reduciendo los tiempos de implementación de semanas a minutos y ahorrando millones anualmente. O considere una empresa farmacéutica global que utilizó MongoDB e IA generativa para reducir la generación de informes clínicos de doce semanas a tan solo diez minutos. Estos sistemas basados en IA transformaron ambas empresas y fueron posibles gracias a una infraestructura moderna y flexible diseñada para soportar cargas de trabajo inteligentes a gran escala.

La lección es clara: si desea implementar IA con éxito, su base de datos debe ser lo primero.

Por eso es importante este libro.

No solo explica las posibilidades de la IA, sino que también te muestra cómo hacerla realidad. Encontrarás lecciones aprendidas con esfuerzo de quienes ya implementan IA en producción, además de planos arquitectónicos y estrategias de implementación que puedes aplicar de inmediato en cualquier sector.

También aprenderá por qué los modelos de datos basados en documentos se están volviendo rápidamente centrales para las aplicaciones de IA, cómo la búsqueda vectorial revela el significado de los datos no estructurados y por qué la combinación de capacidades operativas y analíticas crea un apalancamiento arquitectónico real.

Igualmente importante, este libro aborda las realidades a menudo ignoradas de la confianza, la gobernanza, la seguridad y la escala. Desarrollar una IA potente es una cosa. Hacerla responsable, resiliente y lista para producción es algo completamente distinto.

Ya sea que usted sea un líder tecnológico, arquitecto, ingeniero, científico de datos o cualquier persona responsable de implementar IA en su organización, este libro ofrece un camino claro y práctico a seguir.

Estoy emocionado por ver lo que construirás a continuación.

Jim Scharf

Director de Tecnología,

MongoDB, Inc.

Nota del autor

La aparición de los grandes modelos de lenguaje (LLM), basados en arquitecturas basadas en transformadores, comenzó en 2018. Simultáneamente, los avances en la tecnología de GPU facilitaron mayores capacidades computacionales paralelas, culminando en la Nvidia V100 y catalizando el dominio de la IA generativa (GenAI). El procesamiento del lenguaje natural superó la dependencia de sistemas basados en reglas y el entrenamiento en áreas temáticas específicas, beneficiándose de datos exhaustivos de Internet y generando avances significativos. La versión beta pública de ChatGPT en 2022, junto con la introducción de LLM de la competencia, en particular Google Gemini y Anthropic Claude (utilizado en AWS Bedrock), precipitó un cambio en los paradigmas del desarrollo de software.

El diseño de software, la codificación y los casos de uso comerciales se expandieron de maneras sin precedentes.

Mis investigaciones preliminares sobre la utilización de vectores para la búsqueda semántica y mejoras en la búsqueda de texto existente de MongoDB

La funcionalidad precedió a estos desarrollos. Los dominios de incrustaciones, modelos y vecinos más cercanos convergieron con el campo emergente de los LLM. Esta convergencia permitió el rápido desarrollo de una solución preliminar de recuperación-generación aumentada (RAG), que facilitó la interpretación de documentos PDF y la generación de respuestas basadas en consultas en lenguaje natural y datos de documentos vectorizados. El equipo de Soluciones Industriales de MongoDB reconoció el potencial innovador y aceleró la implementación a través de la plataforma MongoDB Atlas.

Las ventajas de una plataforma integrada sobre los sistemas multicomponente eran sustanciales. Sin embargo, la proliferación de componentes y permutaciones generó desafíos, en particular la excesiva dependencia de componentes singulares y emergentes. En consecuencia, el enfoque se desplazó hacia el diseño de soluciones con resultados de negocio específicos, conocido como el arte de lo posible. Las solicitudes de los clientes enfatizaban cada vez más los detalles de implementación (cómo) en lugar de la conceptualización (qué).

Durante 2023 y 2024 se desarrollaron arquitecturas de referencia y diseños establecidos, lo que justifica una mayor difusión.

Las soluciones derivadas de casos de uso específicos demostraron su aplicabilidad intersectorial. El concepto del almacén de datos consolidado se perfeccionó y requirió mayor documentación.

En el verano de 2025, se emitió una directiva al equipo para recopilar diseños de soluciones específicos de la industria, basados en patrones y plantillas de inteligencia artificial de agentes actuales, en una publicación completa.

Posteriormente se incorporaron capítulos fundamentales para dar cabida a distintos niveles de experiencia.

La colaboración con socios comerciales estratégicos ha aportado perspectivas diversas, enriqueciendo el contenido. También se han incorporado las perspectivas del equipo de Asesoría de CXO, centrado en la modernización de aplicaciones y el uso de herramientas de IA generativa para la optimización de sistemas heredados.

Se prevé que esta publicación sirva como un recurso valioso para aquellos interesados en soluciones industriales que aprovechen GenAI.

Boris Bialek

Vicepresidente y director de tecnología de campo,

MongoDB, Inc.

Expresiones de gratitud

Cada libro tiene su origen, y el nuestro comenzó con un desafío simple pero abrumador. Como equipo de Soluciones Industriales de MongoDB, nos especializamos en presentar MongoDB como una solución para industrias específicas. Hablamos el idioma de nuestros clientes y comprendemos las necesidades de su industria, sus obstáculos, las tendencias del mercado y su competencia.

A lo largo de los años, hemos dedicado incontables horas a documentar soluciones para la industria en nuestros blogs, la biblioteca de soluciones MongoDB y numerosos artículos y presentaciones que hemos creado con pasión para ayudar a desarrolladores y organizaciones a resolver sus problemas de datos más complejos. Pero cuando los clientes nos pidieron ayuda para explorar este vasto conocimiento, nos enfrentamos a una realidad incómoda:

Tener miles de enlaces dispersos, sin importar lo valioso que pudiera ser cada uno, se había vuelto abrumador en lugar de útil.

Fue Raghu Viswanathan, nuestro extraordinario líder en educación y documentación, quien identificó la oportunidad que todavía no habíamos visto. En una conversación que comenzó como una lluvia de ideas sobre cómo servir mejor a nuestra comunidad, sugirió algo que parecía obvio y audaz a la vez: "¿Por qué no plasmar todas estas ideas en un libro?". Sin su claridad y su constante apoyo, este proyecto habría quedado en meros apuntes de buenas intenciones en lugar de convertirse en algo real.

Escribir un libro sobre tecnología nunca es una tarea individual. Esto es especialmente cierto al analizar arquitecturas y soluciones del mundo real. Agradecemos profundamente a los equipos de Iguazio (adquirida por QuantumBlack, AI by McKinsey), Fireworks AI, Dataworkz, Encore, Cognigy y RegData, cuyas implementaciones y comentarios en el mundo real nos ayudaron a comprender qué funciona realmente en la práctica. Igualmente importantes son nuestros socios tecnológicos, como Amazon Web Services, Microsoft Azure, Google Cloud, Confluent, Capgemini y otros. Sus plataformas y experiencia hacen posibles las soluciones que presentamos.

También queremos agradecer a nuestros socios editoriales de Packt, quienes demostraron que las mejores colaboraciones surgen cuando la experiencia se une a la pasión. A través de innumerables ciclos de revisión, nos impulsaron a pensar en nuestros lectores en cada paso. Formularon las preguntas clave que ayudaron a transformar nuestra experiencia técnica en algo fiable y accesible.

Y a nuestros colegas de Soluciones Industriales, Producto y otros equipos internos, ustedes saben quiénes son. Sus huellas están en cada capítulo.

Este libro es para constructores, arquitectos y estrategas que buscan soluciones a los desafíos de la IA. Es para ti.

Colaboradores

Acerca de los autores

Boris Bialek ha trabajado en el sector de las TI desde la década de 1990 y fue uno de los impulsores iniciales de Linux en Europa, entregando la primera adaptación de SAP a Linux, realizando las primeras pruebas de rendimiento y consiguiendo los primeros clientes. Desde entonces, ha liderado equipos de producto y desarrollo en IBM y FIS, impulsando la innovación tanto para el producto final como para la productividad del desarrollo. Boris Bialek se unió a MongoDB en 2019, impulsando un enfoque en soluciones para el sector basadas en el modelo documental de MongoDB. Ascendido a director de tecnología global y vicepresidente de industrias, lidera el diseño técnico. Trabaja directamente con numerosos clientes, ayudándoles a aprovechar las ventajas de la plataforma de datos MongoDB Atlas. Boris tiene un máster en informática por el Instituto Tecnológico de Karlsruhe.

Sebastián Rojas Arbulu es especialista en soluciones para la industria en MongoDB, donde colabora con numerosos actores clave de diversas industrias para ayudar a los clientes a comprender el valor transformador de MongoDB mediante soluciones personalizadas basadas en datos, en particular para la integración de IA. Sebastián también lidera la estrategia de contenido de su equipo, incluyendo numerosas publicaciones como blogs, informes técnicos, revistas y otros artículos de liderazgo intelectual. Con experiencia en consultoría de TI, marketing y transformación digital, entre otras áreas, cuenta con una amplia experiencia en la identificación de las necesidades de los clientes y...

Desarrolla soluciones innovadoras que preparan datos para aplicaciones inteligentes y abren nuevas posibilidades. Es licenciado en Administración de Empresas.

Taylor Hedgecock es líder de programas estratégicos y socia de transformación que convierte la visión en velocidad. Con una trayectoria que abarca desde startups hasta multinacionales, aporta una combinación de rigor operativo, claridad narrativa y orquestación interfuncional. En MongoDB, ha liderado programas de alto impacto en IA, ecosistemas de socios y modernización de servicios, actuando a menudo como el nexo entre la visión y la ejecución. Su trabajo ha guiado las prioridades de la alta dirección, facilitado la preparación para la salida al mercado e impulsado cambios a gran escala, lo que la ha consolidado como una líder de confianza para alinear a las partes interesadas, traducir la estrategia en una historia y lograr resultados duraderos. Taylor actualmente se desempeña como gerente sénior de programas en el equipo de soluciones de la industria, colaborando con ISV e innovadores en IA para lanzar al mercado soluciones de última generación. Anteriormente, fue jefa de personal del equipo de liderazgo de servicios profesionales, donde ayudó a lanzar nuevas ofertas y guió la estrategia de modernización, dando forma a la visión de MongoDB para aplicar la IA a sus problemas más complejos.

Benjamin Lorenz ha sido un colaborador clave de MongoDB desde 2016, impulsando el crecimiento en la región de ventas de Europa Central. Con una amplia experiencia en iniciativas estratégicas para clientes, colabora con los responsables de la toma de decisiones para alinear soluciones personalizadas con los objetivos de negocio, aprovechando el potencial de la plataforma de datos para desarrolladores de MongoDB. Como director de soluciones para el sector de telecomunicaciones y medios de comunicación, Benjamin guía a clientes globales en su transformación digital, ayudándoles a generar fuentes de ingresos innovadoras basadas en datos.

Francesc Mateu es director de soluciones industriales en MongoDB, con más de 20 años de experiencia en innovación de TI y SaaS B2B, incluyendo 15 años en salud digital. Como fundador de startups y líder de producto, posee una mentalidad emprendedora orientada a ayudar a las organizaciones sanitarias a modernizar sus arquitecturas de datos. Su trabajo incluye el diseño de plataformas digitales que respaldan la atención centrada en el paciente y modelos basados en el valor, incluyendo soluciones de telemedicina para la captura de resultados informados por los pacientes. En MongoDB, trabaja globalmente con equipos de ventas, socios y productos para ayudar a los sistemas sanitarios a adoptar arquitecturas basadas en estándares y compatibles con IA, aprovechando tecnologías como FHIR y openEHR, para crear soluciones a medida que satisfagan las necesidades únicas de cada organización.

Genevieve Broadhead es la responsable global de soluciones para minoristas en MongoDB, con sede en Barcelona. Ayuda a minoristas globales y empresas de software para minoristas a modernizar sus arquitecturas de datos para lograr personalización en tiempo real, experiencias omnicanal y operaciones basadas en IA. Con un título en ingeniería informática por el Trinity College de Dublín y una década de experiencia en diseño de sistemas, Genevieve cuenta con una amplia experiencia en la integración de las necesidades empresariales con tecnología de vanguardia. Reconocida líder de opinión, participa regularmente como ponente sobre canales de datos nativos de la nube, adopción de IA y comercio componible. También forma parte del consejo tecnológico de MACH Alliance, donde define los estándares para las arquitecturas minoristas modernas.

El Dr. Humza Akhtar es el experto en fabricación inteligente y automoción de MongoDB. Antes de unirse a MongoDB, trabajó en Ernst & Young Canadá en su área de consultoría de operaciones digitales. Tras completar su formación en Singapur, trabajó durante muchos años en la industria manufacturera singapurense, en investigación y desarrollo de la Industria 4.0.

Implementación. Ha dedicado toda su carrera a facilitar fábricas y coches conectados para clientes globales de la industria y la automoción. Es autor de publicaciones sobre la Industria 4.0 y, actualmente, su interés reside en facilitar el uso de la IA generativa en el sector automotriz. Humza posee una maestría en sistemas embebidos y un doctorado en informática por la Universidad Tecnológica de Nanyang (Singapur).

Jeff Needham es el experto de MongoDB en la industria de seguros, con casi 30 años de experiencia en la entrega de software. Como exdirector sénior de arquitectura en Travelers, lideró una de las adopciones de MongoDB más exitosas de la industria. Su trayectoria profesional abarca el liderazgo en importantes empresas de software y gigantes de la salud como Aetna/CVS. La experiencia técnica y la visión estratégica de Jeff impulsan resultados excepcionales en los complejos proyectos empresariales de MongoDB, ayudando a las organizaciones a navegar la transformación digital. Tiene una maestría en estrategia política por la Universidad George Washington.

Ken Wiebke lleva más de 30 años trabajando en la industria del desarrollo de software, con una trayectoria que abarca desarrollo, arquitectura y liderazgo. A lo largo de su trayectoria, Ken ha impulsado el cambio en organizaciones desde pequeñas hasta grandes de la lista Fortune 500, incluyendo la transición del enfoque en cascada al ágil. Con más de 15 años de experiencia en puestos de liderazgo, Ken se ha centrado en impulsar la eficiencia y formar equipos de alto rendimiento que cumplan con los plazos y el presupuesto de forma constante. Ken se incorporó a MongoDB en diciembre de 2024 como asesor de CxO para ayudar a las organizaciones a aprovechar el potencial de MongoDB y transformar su software heredado en te

Luis Pazmino Díaz cuenta con más de dos décadas de experiencia en el sector tecnológico, particularmente en banca y finanzas.

Anteriormente, se desempeñó como arquitecto de estrategia global en Backbase, director de innovación en Temenos y asesor de soluciones en importantes empresas de software empresarial como SAP y Oracle. Como director de sector de MongoDB para servicios financieros, ofrece asesoramiento estratégico a clientes y socios de soluciones en Europa, Oriente Medio y Latinoamérica. Con sede en Madrid, España, Luis es ampliamente reconocido como experto en innovación financiera.

Peyman Parsi comenzó su carrera en ingeniería de software para servicios financieros en SS&C, centrándose en el desarrollo de software de gestión patrimonial para el sector bancario. En 2001, se incorporó a la Bolsa de Valores de Toronto (TSX), donde lideró el desarrollo de soluciones para el mercado de capitales. Durante sus más de 18 años en la TSX, Peyman impulsó varias transformaciones a gran escala y ocupó el cargo de director de entrega de tecnología. En 2020, emprendió una nueva trayectoria en FinTech, como director de tecnología en Blanc Labs, con un enfoque principal en soluciones bancarias y de préstamos digitales. Peyman es miembro del consejo asesor de la Asociación de CIO de Canadá y se incorporó a MongoDB en 2024 como director sénior de soluciones para el sector de servicios financieros en América.

Prashant Juttokonda es experto en arquitectura y modernización de datos empresariales en MongoDB. Anteriormente, ocupó puestos de liderazgo en EPAM, TCS e IBM, asesorando a clientes globales sobre la adopción de la nube, la transformación de datos y las arquitecturas compatibles con IA. Con más de 30 años de experiencia en los sectores bancario, minorista y energético, ha liderado programas de modernización a gran escala e impulsado la adopción de marcos como Data Mesh y Data Fabric. Es un colaborador frecuente

Orador y líder de opinión en estrategia de datos, con publicaciones. Se centra en impulsar la IA generativa y las plataformas de datos resilientes. Es licenciado en Matemáticas y cuenta con numerosas certificaciones en ciberseguridad y tecnologías en la nube.

Raphael Schor es ingeniero mecánico con más de 20 años de experiencia en desarrollo mecánico, ingeniería de planta y mantenimiento industrial. Se ha desempeñado como director de tecnología en las industrias automotriz y Industrias del embalaje, liderando la I+D y la transformación digital. Desde 2023, Raphael es director de fabricación y movimiento en MongoDB. En este puesto, conecta los desafíos de la ingeniería industrial con la arquitectura de datos moderna. Su enfoque incluye gemelos digitales, fábricas inteligentes e IA generativa. Raphael es licenciado en ingeniería mecánica y tiene un Máster en Estudios Avanzados en Gestión, Tecnología y Economía por la ETH de Zúrich.

Rodrigo Leal, , Con más de 20 años en la industria de la tecnología, es la director de soluciones para la industria retail de MongoDB en Latinoamérica. Antes de incorporarse a MongoDB, Rodrigo se desempeñó como especialista principal de soluciones sénior en Qualtrics, optimizando las experiencias de empleados, clientes, marcas y productos. Anteriormente, formó parte del equipo global de Walmart de NCR, donde participó en el lanzamiento de la tecnología de autopago en México y Centroamérica, y fue reconocido con dos premios del Club del Presidente de NCR. Anteriormente, trabajó con Oracle y MicroStrategy como gerente de cuentas e ingeniero de ventas. Conocido por su experiencia en ventas consultivas multiproducto, se dedica a identificar las necesidades de los clientes y a crear soluciones que a menudo revelan oportunidades inéditas.

Thorsten Walther cuenta con más de 25 años de experiencia en liderazgo tecnológico, combinando experiencia empresarial, iniciativa emprendedora y profundos conocimientos técnicos para impulsar la transformación digital. Fundó y dirigió INSPIFY, una plataforma SaaS basada en IA para el sector minorista de lujo. Su trayectoria profesional abarca puestos de liderazgo en Credit Suisse y SOFGEN Services, así como una amplia labor de asesoramiento en finanzas, comercio minorista, farmacia y software empresarial. Actualmente, como director general de asesoramiento para altos ejecutivos en Asia en MongoDB, asesora a altos ejecutivos en la transformación digital. Thorsten, por su parte, jugó como futbolista profesional en la Bundesliga alemana y en la Ligue 1 y la Ligue 2 francesas. Tiene un MBA por la Universidad de Liverpool.

Wei You Pan es el director global de soluciones para la industria de servicios financieros en MongoDB. Con más de 25 años de experiencia en tecnología financiera, arquitectura de datos y servicios financieros, ayuda a las instituciones a superar los complejos desafíos de los datos e impulsar la innovación. Su experiencia abarca el trading, la originación de préstamos, la gestión de riesgos y la sostenibilidad, con el respaldo de sus credenciales en arquitectura empresarial (SCEA), gestión de riesgos financieros (FRM) y riesgo climático (SCR). Su formación interdisciplinaria le permite conectar de forma única la tecnología y los negocios, ayudando a las organizaciones a aprovechar al máximo el valor de sus datos.

Acerca de los revisores

Coral Parmar es el gerente principal de producto del portafolio de búsqueda de MongoDB, con más de 20 años de experiencia en tecnología y sistemas para ayudar a los desarrolladores a afrontar los desafíos actuales de los datos en diversos sectores. Su trayectoria profesional abarca puestos de liderazgo en servicios técnicos de MongoDB, empresas de tecnología publicitaria y desarrollo de datos en UPS, donde aporta una amplia experiencia en la escalabilidad de soluciones para clientes para sistemas de datos complejos en las tecnologías de la cadena de suministro, logística y publicidad. A lo largo de su carrera, ha mantenido su pasión por resolver problemas complejos y capacitar a equipos para desarrollar soluciones eficaces y escalables en entornos técnicos en constante evolución. Tiene una maestría en sistemas de información del Instituto Tecnológico de Nueva Jersey.

James Osgood es arquitecto de soluciones en MongoDB con más de 30 años de experiencia en desarrollo de software y servicios financieros. Comenzó su carrera en la industria del audio y el vídeo antes de incorporarse al sector de los servicios financieros, donde se especializó en sistemas de comercio de baja latencia y vigilancia del mercado. Desde su incorporación a MongoDB en 2017, James ha colaborado con importantes clientes en Londres y Europa. Actualmente, se centra en ayudar a empresas globales a transformar sus sistemas financieros esenciales y a modernizar sus aplicaciones con soluciones de modernización específicas basadas en IA.

Jim Blackhurst es un destacado arquitecto de soluciones en MongoDB, con más de 20 años de experiencia en el diseño y la entrega de sistemas de datos distribuidos. Actualmente trabaja con el equipo de modernización de aplicaciones de MongoDB, ayudando a algunas de las empresas más grandes del mundo.

Las organizaciones modernizan sus activos mediante herramientas de modernización de IA diseñadas específicamente para ello, liberándolas del yugo de las tecnologías heredadas. Antes de unirse a MongoDB, Jim dedicó su carrera a la industria de los videojuegos, diseñando y operando sistemas backend para algunas de las marcas de videojuegos más emblemáticas del mundo, trabajando con datos a escala antes de que la escala se convirtiera en un concepto. Con sede en Londres, Jim continúa enfocándose en ampliar los límites del diseño de sistemas distribuidos y ayudar a las empresas a descubrir nuevas posibilidades con los datos.

Julia Pak es gerente de producto en MongoDB y forma parte del equipo de iniciativas y herramientas empresariales. Actualmente, se centra en el desarrollo de productos internos que mejoran la productividad organizacional mediante la centralización de datos y funciones basadas en IA. Antes de unirse a MongoDB, Julia trabajó en los sectores de seguros y tecnología publicitaria, desarrollando productos externos desde cero. Obtuvo su licenciatura en Historia en la Universidad de Princeton.

Shash Thakor es gerente sénior de producto en MongoDB, principalmente responsable de las redes Atlas. Cuenta con más de 15 años de experiencia en liderazgo de productos e ingeniería, desarrollando sistemas de software altamente distribuidos, escalables y seguros. Antes de incorporarse a la gestión de productos, trabajó como desarrollador de software en Cisco Systems y Juniper Networks, donde se encargó del desarrollo de sistemas de software de conmutación y enrutamiento implementados en numerosos centros de datos de todo el mundo y utilizados por hiperescaladores, grandes y pequeñas empresas. Posee múltiples patentes en sistemas distribuidos, seguridad y aprovisionamiento sin intervención. Tiene una maestría en informática por la Universidad de Maryland, College Park (UMCP).

Contenido

Nota del autor

Agradecimientos Prefacio

Cómo le

ayudará este libro A quién va ____

dirigido este libro Qué

cubre este libro Para

aprovechar al máximo este libro _____

Póngase en

contacto con nosotros Parte 1: IA ____

y conceptos clave 1. Modernización de la IA para la innovación

Comprender la innovación: crear nuevo valor Puntos de

inflexión estratégicos: la teoría de Andy Grove aplicada a la IA _____

Navegar por el punto de inflexión de la

IA Comprender la modernización: el prerequisite que a menudo
se pasa por

alto Estrategias comunes de modernización

Donde la innovación se encuentra con la modernización: la
intersección

de la IA La trampa de la implementación de la IA: cuando
la innovación carece

de base Plataformas de datos modernas: la columna vertebral
de la transformación

preparada para la IA Por qué son necesarias las ____ .

plataformas de datos modernas Habilitar la innovación ____

mediante agilidad y velocidad Simplificar la modernización

sin empezar de cero _____

Potenciar la

IA a escala _____

Resumen Referencias 2. Qué diferencia a GenAI. RAG y ____

Agentic AI Cómo evolucionó la IA: de la teoría a ____

ChatGPT Un pequeño paseo por la historia

AlphaGo y el punto de inflexión en la IA

El surgimiento de los LLM

GenAI: Creando nuevo contenido a partir de patrones

Cómo funciona GenAI

Limitaciones y desafíos de GenAI

De datos a vectores

Los modelos de incrustación y los “incrustadores”

Bases de datos vectoriales y su importancia

Estrategias de fragmentación para aplicaciones de IA

Búsqueda semántica: Poniendo los vectores a trabajar

Más allá de la coincidencia de palabras clave

Aplicaciones multimodales de la búsqueda semántica

RAG: Mejorar los LLM con datos contextuales

Cómo funciona RAG

Más allá de RAG: Enfoques de búsqueda híbridos

Reranking: Refinar los resultados de búsqueda

IA: Automatizar la toma de decisiones y el razonamiento

Fundamentos de la IA

¿Qué es un agente?

Expertos digitales o sistemas multiagente: resolución colaborativa de

problemas

Cómo funciona la IA agencial

Resumen

Referencias

3. El sistema de acción

Construir una base de datos preparada para IA

¿Qué es un sistema de acción?

Arquitectura de acceso a datos unificada

Garantizar la calidad y la consistencia de los datos

Contexto en tiempo real y RAG

Escalabilidad, disponibilidad y rendimiento

Gobernanza, seguridad y cumplimiento

Entrenamiento y ajuste de modelos

Consideraciones prácticas para el diseño de datos de IA

Una buena estructura de datos es fundamental

Flujo de datos

Operacionalización de un sistema de base de datos de
acción Patrones de
implementación Monitoreo y optimización del
rendimiento Administración de costos y asignación de
recursos Flujos de trabajo de mantenimiento y administración del ciclo de
vida de los datos Estrategias de migración desde
sistemas heredados Capacitación de equipos y

consideraciones

de adopción Resumen Referencias 4. IA confiable, cumplimiento y
gobernanza de datos Por qué

es importante la IA ética Los crecientes riesgos de
la implementación de IA Definición

de los conceptos centrales Marcos éticos: de los principios a

la práctica Vinculación de principios e implementación
Auditorías de

sesgo Juntas de revisión

ética Documentación transparente

Participación de las partes

interesadas Navegando por el panorama
regulatorio

Servicios financieros

Cuidado de la salud Construcción de IA confiable y
responsable Salvaguarda

de datos Requisitos de protección y privacidad

Construcción de una gobernanza de datos de

IA sólida Gestión de riesgos: estrategias de evaluación y mitigación
Evaluación de riesgos

Enfoques prácticos de gestión de riesgos

Transparencia en acción: mecanismos de explicabilidad

Transparencia de IA

Explicabilidad de IA

El caso comercial para una IA explicable

Operacionalización de una IA confiable a través de la gobernanza El
camino por delante: tendencias emergentes y direcciones futuras

Evolución de la gobernanza de la IA

Desafíos y oportunidades persistentes Resumen

Referencias

5. _____

Modernización mediante IA El

desafío de la modernización _____

Motivaciones para la modernización

Imperativos de negocios: Presión competitiva e
innovación

Limitaciones técnicas: La creciente carga de la
arquitectura heredada

Por qué la IA por sí sola no es la

respuesta Desbloquear la innovación con la modernización

impulsada por IA Comience con la base

de datos correcta Automatizar el proceso de modernización

de la fábrica Orquestación: cómo se automatiza la

fábrica Dónde la IA acelera el proceso

Análisis

Generación de

pruebas Transformación y prueba de

código Implementación y

migración Establecer un proceso de modernización repetible

Resumen

Referencias

Parte 2: Estudios de casos e implementaciones del mundo real 6.

Aplicaciones prácticas de Agentic y GenAI en la fabricación –

Parte 1

El camino hacia el éxito en la fabricación de IA

Optimización de la cadena de suministro impulsada por GenAI

Enfoques de planificación multinivel

Enfoques de clasificación y optimización de inventarios

El análisis ABC y sus limitaciones

MCIC y la necesidad de GenAI

IA y MongoDB para la optimización del inventario

Clasificación de inventario impulsada por GenAI

Metodología para implementar la clasificación de inventario
impulsada por GenAI

Atlas: Infraestructura de IA unificada

Demostración de clasificación de inventario de GenAI: un recorrido visual

Paso 1: Comenzando con la clasificación básica

Paso 2: Generar nuevos criterios basados en IA

Paso 3: Integración de nuevos criterios en la clasificación

Paso 4: Ponderación y análisis en ejecución

Gestión de materias primas mediante inteligencia

artificial (IA) de Agentic Previsión de la demanda y

optimización del inventario Beneficios de MongoDB para la

gestión del inventario Reimaginar la gestión del inventario para

la Industria

5.0 Resumen

Referencias 7. Aplicaciones prácticas de Agentic y GenAI en la fabricación – Parte 2

Mantenimiento predictivo y colaboración entre múltiples agentes

Estrategia de mantenimiento óptima

Estado actual y desafíos

Cómo ayudan la IA y MongoDB

Etapas 1: Priorización de máquinas

Etapas 2: Predicción de fallas

Etapas 3: Generadores de planes de reparación

Etapas 4: Generación de guías de mantenimiento

Sistema de colaboración multiagente

Optimización de un entorno de producción

Gestión y preservación del conocimiento

El desafío del conocimiento institucional y las soluciones impulsadas por IA

Aplicación del conocimiento en tiempo real

Experiencias en cabina hiperpersonalizadas

Desafíos y soluciones basadas en IA para asistentes de voz en el automóvil

GenAI: transformando los asistentes en el coche

Arquitectura de la solución: MongoDB Atlas y Google

Integración en la nube

[Arquitectura de agencia avanzada: MongoDB Atlas y](#)

[Integración de Google Cloud](#)

[Desafíos de la implementación del RAG para los manuales de vehículos](#)

[Google Cloud y MongoDB: Mejor juntos](#)

[Ventajas estratégicas de los sistemas en cabina integrados con IA](#)

[Gestión y optimización de flotas](#)

[Agente programador para operaciones de flotas](#)

[Arquitectura lógica y física](#)

[MongoDB para el programador de flotas](#)

[Perfil del agente e instrucciones](#)

[Memoria a corto y largo plazo](#)

[Asesor de incidentes de flotas conectadas](#)

[Arquitectura del asesor de incidentes](#)

[Tipos de datos y almacenamiento](#)

[Ventajas de MongoDB para la gestión de flotas](#)

[El papel cada vez más importante de la IA en la fabricación](#)

[Resumen](#)

[Referencias](#)

8. [Estrategias impulsadas por IA para medios y telecomunicaciones](#) [Industrias](#)

[Panorama evolutivo de los medios y las telecomunicaciones](#)

[Descubrimiento y personalización de contenido](#)

[Plataforma de sugerencias de contenido y personalización](#)

[Sugerencias de contenido y personalización](#)

[Resumen y reformato de contenidos](#)

[Extracción de palabras clave y entidades](#)

[Creación automática de insights y resúmenes](#)

[Experiencias generativas de búsqueda \(SGEs\)](#)

[Interfaces conversacionales inteligentes](#)

[Experiencias de aprendizaje gamificadas](#)

[Garantía de servicio](#)

[Agentic AIOps para la gestión de redes](#)

[Construcción de sistemas de redes impulsados por IA para telecomunicaciones](#)

[La próxima era de las operaciones impulsadas por IA](#)

[Detección y prevención de fraudes](#)

El papel cada vez más importante de la IA en los medios y las telecomunicaciones

Precios diferenciales

Búsqueda y recorte de vídeos

Resumen

Referencias

9. La voz y los chatbots de Cognigy en la era de la IA agencial La

evolución de la IA basada en reglas a la IA orientada a objetivos

Estudio de caso: Cómo respondió una aerolínea de primer nivel a la crisis

Las limitaciones que nos frenaron

El avance de la IA agente

Por qué los datos son el elemento vital de la IA agencial

El alcance de los requisitos de datos modernos

El papel de MongoDB en la habilitación de inteligencia en tiempo real

Aplicación en el mundo real: transformar la experiencia del cliente minorista

La base técnica para una integración perfecta

Rendimiento en tiempo real en momentos críticos

Cuando los sistemas se llevan al límite

La complejidad detrás de las solicitudes simples

Escalando la excelencia, no los errores

Las matemáticas de la transformación

Resultados demostrados en todas las industrias

La base para un crecimiento sostenible

La personalización no es magia, es dominio de los datos.

La arquitectura de la personalización inteligente

La base técnica para la excelencia en la personalización

Lo que está en juego en la precisión

Los requisitos integrales para la excelencia en IA

Marco de gobernanza y cumplimiento

Resumen

Referencias

10. Aprovechar la IA para transformar la industria minorista

Búsqueda semántica impulsada por búsqueda vectorial

Transformar la búsqueda minorista

Crear una visión unificada del cliente

Evolucionar de reactivo a proactivo

Marketing personalizado y generación de contenidos

Satisfacer las demandas de contenido del comercio minorista moderno con GenAI

Acelerando el contenido personalizado con GenAI y LLMs

Aprovechar bases de datos modernas para un marketing escalable impulsado por IA

Cómo la IA agente está revolucionando el marketing adaptativo en el comercio minorista

Previsión de la demanda y análisis predictivo

Previsión de demanda impulsada por IA para una gestión más inteligente del inventario y la cadena de suministro

Cómo GenAI está transformando el análisis predictivo en el comercio minorista

Transformando el análisis predictivo con IA agente en el comercio minorista

Digitalizar las interacciones en tienda con inteligencia

Del papel al conocimiento: recibos digitales como catalizador de datos

Crear un perfil de cliente omnicanal en tiempo real

Personalización en el punto de venta

IA con agente: del conocimiento a la acción inteligente

Chatbots conversacionales y con agente

Cómo los chatbots GenAI están revolucionando la interacción en el comercio

minorista

Impulsar conversaciones inteligentes con búsqueda e IA

De guionizado a inteligente: transformación de los chatbots minoristas con IA con agente

El rol en expansión de la IA en el comercio minorista

Prevención proactiva de pérdidas

Ejecución de comercialización impulsada por IA

Operaciones de tienda con autorreparación

Orquestación dinámica de la fuerza laboral

Optimización de la sostenibilidad en tiempo real

Resumen Referencias 11.

Servicios financieros y la próxima ola de IA

La evolución de la IA en finanzas

[El poder de las integraciones específicas de finanzas](#)

[Transformando las solicitudes de crédito con IA](#)

[Construyendo un sistema de crédito más inteligente con MongoDB](#)

[Revolucionando la gestión del conocimiento empresarial en la banca con GenAI](#)

[Desafíos de los sistemas EKM tradicionales en la banca](#)

[Cómo GenAI está transformando los sistemas EKM en la banca](#)

[Casos de uso de GenAI para sistemas EKM internos en bancos](#)

[Consideraciones arquitectónicas para sistemas impulsados por GenAI](#)

[Sistemas EKM](#)

[El impacto de GenAI en los sistemas EKM](#)

[Mejores experiencias de banca digital a través de interacciones impulsadas por IA](#)

[Mejorando la experiencia del cliente con GenAI](#)

[Fundamentos de datos bancarios digitales impulsados por IA](#)

[Arquitectura de solución de referencia para la atención al cliente impulsada por IA](#)

[Mitigación y cumplimiento de delitos financieros mejorados mediante IA](#)

[Fortalecimiento de la mitigación de delitos financieros con IA](#)

[Tendencias emergentes que redefinen el futuro de la IA en el cumplimiento normativo](#)

[IA para inteligencia regulatoria y automatización de políticas](#)

[El papel de MongoDB en KYC y AML](#)

[Beneficios empresariales estratégicos](#)

[Análisis ESG multimodal e impulsado por IA](#)

[El papel de MongoDB en la gestión de datos ESG](#)

[Política ESG impulsada por IA y cumplimiento normativo](#)

[Procesamiento de pagos directos impulsado por IA](#)

[Perspectivas de negocio](#)

[El papel de GenAI](#)

[El camino por delante](#)

[Mercados de capitales](#)

[Reimaginando la gestión de carteras de inversión con IA de agencia](#)

[Gestión inteligente de carteras de inversión](#)

[Cómo MongoDB desbloquea la gestión de carteras impulsada por IA](#)

[Gestión inteligente de carteras de inversión con agentes de IA El papel en](#)

[expansión de la IA en los servicios financieros Resumen](#)

[Referencias](#)

[12. RegData,](#)

[MongoDB y Voyage AI: Protección de datos semánticos](#)

[El](#)

[dilema de la protección de datos en la IA financiera](#)

[Comprender el enfoque de MongoDB, RegData y Voyage AI para la protección de datos semánticos ¿Qué es la](#)

[protección de datos semánticos?](#)

[Técnicas clave en la protección de datos semánticos](#)

[Tokenización con preservación de formato](#)

[Protección semántica contextual Partición](#)

[semántica con clases de tokens Tokens deterministas](#)

[Construcción de una arquitectura integral de protección semántica](#)

[MongoDB como base de la plataforma de seguridad de datos de RegData](#)

[Puerta de enlace API con MongoDB y decoración de indicaciones de RegData](#)

[Búsqueda de vectores protegidos con MongoDB Atlas y](#)

[Inteligencia artificial de viajes](#)

[Representación de salida segura](#)

[Inteligencia específica del dominio para mejorar la seguridad y el rendimiento](#)

[Aprovechar las integraciones financieras específicas para una mayor protección](#)

[Innovación en el mundo real: banca interactiva](#)

[Construyendo el futuro con técnicas avanzadas y estándares emergentes](#)

[MCP](#)

[Estrategias de protección híbrida](#)

Consideraciones regulatorias y de cumplimiento Alineación
del marco regulatorio Auditabilidad y
explicabilidad Resumen Referencias 13.

Impulsar el
éxito del cliente

en la banca con GenAI Copilots La paradoja de la gestión de relaciones patrimoniales

Escalar una gestión de relaciones exitosa
Copiloto GenAI
Cómo funciona el copiloto de gestión de relaciones GenAI bajo el capó

Fábrica GenAI: Impulsando copilots, agentes y apps GenAI Cómo la fábrica de IA
aborda las necesidades de ingeniería de FSI Casos de uso líderes de FSI
donde GenAI aporta valor real Caso práctico: Una aplicación de análisis de
centros de llamadas inteligentes impulsada por GenAI ¿Y ahora qué? Cómo
las empresas

pueden tener éxito con GenAI Resumen 14. Generando valor empresarial
con IA en

seguros La evolución de las arquitecturas de datos La gestión de
sinistros como ejemplo El espectro de la IA en

seguros Aprendizaje automático tradicional
GenAI y LLM Sistemas de IA agentic Flujos
de trabajo agentic en seguros Arquitectura
para aplicaciones

El almacén de datos convergente
Gestión de datos operativos estructurados y no estructurados

Características de la arquitectura para sistemas de agentes
Entidad de dominio raíz y esquema de dominio
Búsqueda unificada en todos los tipos de datos
Arquitectura basada en eventos para acciones autónomas

Mejoras impulsadas por IA en la gestión de reclamaciones para obtener
mejores resultados comerciales

[Estrategia de implementación y madurez de la IA](#)

[Las tres capas de GenAI](#)

[Implementación de IA impulsada por dominios](#)

[Trabajando juntos: aplicaciones, datos e IA](#)

[Modernización y arquitectura orientada a la IA](#)

[Arquitectura orientada a la IA](#)

[Suscripción y gestión de riesgos](#)

[Análisis avanzado](#)

[Procesamiento de reclamaciones](#)

[Experiencia del cliente](#)

[Ejemplos reales de IA de dominio específico](#)

[Casos prácticos de uso de IA en seguros](#)

[Gestión de reclamaciones mediante LLMs y Vector Search para](#)

[TRAPO](#)

[Ajuste de reclamaciones de seguros de automóviles mejorado con IA](#)

[Aplicación de búsqueda de PDF con Vector Search y LLMs](#)

[El futuro de la IA en los seguros](#)

[Análisis predictivo para la interacción con el cliente](#)

[Seguro de cosechas y agricultura de precisión](#)

[Mantenimiento predictivo para seguros de propiedad](#)

[Seguro basado en el uso \(UBI\) para flotas comerciales](#)

[Resumen](#)

[Referencias](#)

15. [Automatización de la suscripción de seguros con Fireworks AI y](#)

[MongoDB](#)

[Entendiendo la importancia de la velocidad](#)

[El flujo de trabajo roto](#)

[La visión](#)

[Configuración de los componentes técnicos principales](#)

[Arquitectura del documento](#)

[El proceso de IA de 10 pasos: del correo electrónico a la cotización](#)

[La ventaja de RAG](#)

[Uso de MongoDB Atlas para una infraestructura de bases de datos moderna](#)

[Implementación de la capa de inferencia: Fireworks AI](#)

[Explorando los resultados](#)

Impacto cuantitativo

Transformación cualitativa

Profundizando en la innovación técnica

Implementación de RAG de nivel de producción Aplicación

en el mundo real: un recorrido de solicitud de cotización Transformación

de las operaciones diarias Impacto e

implicaciones de la industria Adopción de

tecnología más amplia Consideraciones

regulatorias Resumen Referencias 16.

Transformación

impulsada por IA

de la atención médica y las ciencias biológicas

Comprender la revolución de la IA en la atención médica

Por qué las soluciones tradicionales se quedan cortas

Desmitificando la terminología de la IA

La oportunidad transformadora de GenAI

Construyendo la arquitectura adecuada para la IA en el sector sanitario

El desafío de las arquitecturas de datos de atención médica

Preparándose para las necesidades de datos sanitarios del futuro

Un enfoque basado en documentos y preparado para IA

Mejorar la flexibilidad y la interoperabilidad con el modelo de fachada

La nueva pila para la IA en el ámbito sanitario

Patrones de arquitectura de implementación

Coordinación de atención impulsada por IA

Orquestación de roles de agentes especializados en flujos de trabajo clínicos

Inteligencia clínica del lenguaje natural

Comprensión del contexto clínico

Capacidades de búsqueda semántica

Uso de GenAI para el diagnóstico visual

Preguntas y respuestas visuales médicas

Aplicación de incrustaciones vectoriales

Extendiendo la inteligencia a las ciencias de la vida

Revolucionando las relaciones con los clientes con GenAI y MongoDB

Mirando hacia el futuro de la atención sanitaria inteligente

[Resumen](#) .

[Referencias](#)

[Parte 3: El futuro de la empresa inteligente 17.](#) _____

[Gestión de documentos empresariales con MongoDB e IA La era de los](#) _____

[archivadores digitales Los costos](#) _____

[ocultos de los sistemas heredados](#) _____

[Restricciones arquitectónicas heredadas](#)

[Cuando las promesas digitales no se cumplieron](#)

[El desafío de los datos no estructurados](#)

[Redefinir la gestión de documentos con Encore](#) _____

[Procesamiento de](#) _____

[reclamaciones Soporte](#) _____

[del centro de llamadas Preparación para](#)

[el cumplimiento y la auditoría Crear una plataforma para la nueva EDM](#) _____

[con MongoDB y Encore El caso urgente de la](#) _____

_____ .
[modernización de EDM Resumen Referencias](#)

18. [Democratizar la IA agente para empresas con Dataworkz y MongoDB](#) _____

[Adaptación de la IA a cada organización](#) _____

[Caso práctico 1: Client Insight Engine: IA agéntica para asesores financieros Caso](#) _____

[práctico 2: DevOps Efficiency Agent: potencia la productividad de los desarrolladores Caso](#) .

[práctico 3: Brand Messaging Agent: garantiza comunicaciones de marca a escala Implementación de](#) _____

[soluciones de IA eficaces con Dataworkz y MongoDB Convertir su estrategia](#) _____

[de IA en acción Direcciones futuras para la](#)

[IA agéntica empresarial Resumen 19. Perspectiva:](#)

[más allá de.](#)

[la IA actual De las herramientas al](#) _____

[contexto: el auge de las arquitecturas inteligentes MCP: bloques de construcción para la inteligencia contextual IA causal: más allá de la predicción. hacia el impacto](#) _____

Arquitecturas de memoria: contexto persistente para agentes
inteligentes

IA constitucional: Gobernar la inteligencia con principios

Sistemas multiagente: de modelos individuales a inteligencia cooperativa

Mirar atrás para mirar hacia adelante: Patrones en el campo

Arquitectura fundacional: de la teoría a la práctica

Aplicaciones industriales: Validación a través de la diversidad

Ecosistema de socios: Excelencia especializada sobre bases unificadas

Patrones universales en todos los dominios

Reflexión final: La arquitectura es la inteligencia

Referencias

Epílogo

Lo que aprendimos

Perspectivas arquitectónicas

Más allá de los estudios de caso

¿Qué sigue?

Índice

Otros libros que te pueden gustar

Prefacio

Este libro explica cómo las organizaciones pueden ir más allá de la adopción superficial de la IA e implementarla como un verdadero motor de transformación empresarial. Explica la importancia estratégica de distinguir entre modernización e innovación, y cómo ambas son esenciales para una implementación exitosa de la IA. A través de implementaciones reales, casos de éxito y marcos prácticos, proporciona una hoja de ruta para navegar el punto de inflexión de la IA, alinear la infraestructura de datos con los objetivos de la IA y construir sistemas de IA confiables, escalables y sensibles al contexto.

El libro se organiza en tres partes. La primera establece las bases, abarcando conceptos clave de IA, arquitecturas de sistemas, gobernanza y enfoques de modernización que preparan a las organizaciones para su adopción a gran escala. La segunda parte explora las aplicaciones industriales, mostrando cómo la IA generativa y agente (GenAI) puede transformar sectores como la manufactura, los medios de comunicación, el comercio minorista, los servicios financieros, los seguros y la atención médica. La última parte mira hacia el futuro, presentando patrones de implementación avanzados, modelos de gobernanza y tecnologías emergentes como el Protocolo de Contexto de Modelo (MCP) y la IA causal, dotando a los lectores de estrategias para mantener la innovación y adaptarse a la próxima ola de sistemas int

Cómo le ayudará este libro

En este libro, aprenderá los patrones fundamentales para construir arquitecturas inteligentes, con especial atención a GenAI, la generación aumentada por recuperación (RAG) y los sistemas agénticos impulsados por agentes de IA. Verá cómo se aplican estas capacidades en diferentes industrias, con el apoyo de arquitecturas de referencia mapeadas y una guía detallada de implementación. El libro también explora nuevas tendencias como la inteligencia causal, MCP y patrones avanzados de diseño multiagente. Tanto si está modernizando su infraestructura heredada como creando nuevas plataformas, le proporciona el vocabulario, los marcos de trabajo y el contexto práctico necesarios para avanzar con mayor rapidez, reducir las conjeturas y construir sistemas de IA fiables, escalables y sensibles al contexto.

Para quién es este libro

Este libro es para:

- Los responsables de la toma de decisiones de TI exploran dónde realizar apuestas estratégicas en IA
- Los arquitectos empresariales y de soluciones están repensando sus pilas de datos y aplicaciones
- Oídos técnicos y constructores curiosos que quieran entender
Cómo se estructuran e implementan los sistemas inteligentes
- Estrategas comerciales y propietarios de dominios que buscan traducir el entusiasmo por la IA en resultados específicos del dominio

No necesitas experiencia profunda en IA para sacarle provecho a este libro, pero deberías sentirte cómodo pensando en términos de sistemas de datos, capas de aplicación y arquitectura empresarial. Si ya tienes experiencia con los conceptos de IA que se tratan aquí, puedes saltarte los primeros capítulos y pasar directamente a los casos prácticos del mundo real y al contenido orientado al futuro.

Qué cubre este libro

[Capítulo 1](#), Modernización de la IA hacia la innovación , describe la diferencia Entre la modernización y la verdadera innovación y cómo estructurarla equipos, datos y procesos para convertir los experimentos de IA en negocios resultados.

[Capítulo 2](#), Lo que diferencia a GenAI, RAG y Agentic AI, define GenAI, RAG y sistemas agenticos, y explica cuándo usar cada uno acercarse.

[Capítulo 3](#), El Sistema de Acción El , describe el documento orientado sistema de acción y por qué un acceso unificado y de baja latencia a la comunicación multimodal Los datos y las incrustaciones son fundamentales para las cargas de trabajo de IA.

[Capítulo 4](#), Inteligencia artificial confiable, cumplimiento y gobernanza , de datos resume la gobernanza, la privacidad, la explicabilidad y el riesgo. Prácticas de gestión necesarias para la IA de producción.

[Capítulo 5](#), Modernización mediante IA, ofrece patrones prácticos para Utilizar IA para acelerar la modernización del legado y preservarlo corrección y gobernanza.

[Capítulo 6](#), Aplicaciones prácticas de Agentic y GenAI en Fabricación – Casos de la , Se centra en la cadena de suministro y el uso del inventario. Parte 1, que incluyen clasificación impulsada por incrustación y sistemas autónomos ayudantes de adquisiciones

[Capítulo 7](#), Aplicaciones prácticas de Agentic y GenAI en Manufactura – Parte II , se centra en las operaciones de la planta de producción,

incluyendo mantenimiento predictivo, inspección de calidad y orquestación de producción de múltiples agentes.

[Capítulo 8](#), Estrategias impulsadas por IA para medios y telecomunicaciones Industriales, Cubre personalización, experiencias de búsqueda, operaciones de IA, y detección de fraudes adaptada a los sectores de medios y telecomunicaciones.

[Capítulo 9](#) La voz y los chatbots de Cognigy en la era de la IA agencial, Examina los sistemas de voz y chat para un alto rendimiento y orientado a objetivos. interacciones con los clientes.

[Capítulo 10](#) Aprovechar la IA para transformar la industria minorista explica la personalización, la previsión de la demanda y el inventario Optimización y toma de decisiones en tiempo real en el comercio minorista.

[Capítulo 11](#), Servicios financieros y la próxima ola de IA la, contornos próxima transformación de IA del sector, desde el conocimiento del cliente y automatización del cumplimiento hasta la gestión de riesgos mejorada con IA y modelos de servicio.

[Capítulo 12](#) RegData, MongoDB y Voyage AI: datos semánticos Protección en FSI, describe la protección semántica y la auditoría Enfoques que permiten el uso compatible de modelos lingüísticos de gran tamaño (LLMs) en finanzas.

[Capítulo 13](#) Impulsando el éxito del cliente en la banca con GenAI Copilots muestra cómo los copilotos bancarios pueden automatizar las tareas de los asesores, la superficie Investigar y apoyar comunicaciones compatibles con los clientes.

[Capítulo 14](#), Delivering Business Value with AI in Insurance, describe almacenes de datos convergentes y patrones de IA para mejorar suscripción, reclamaciones y resultados del cliente.

[Capítulo 15](#) Automatización de la suscripción de seguros con Fireworks AI y MongoDB, detalla un proceso de suscripción de extremo a extremo utilizando IA basada en la recuperación para una recepción de políticas más rápida y precisa y citando.

[Capítulo 16](#), Transformación de la atención médica y la vida impulsada por IA Ciencias , aborda la sobrecarga de los médicos con patrones de fachada FHIR, RAG clínico y coordinación de atención con múltiples agentes para lograr una mejor resultados del paciente.

[Capítulo 17](#) Gestión de documentos empresariales con Encore y MongoDB, Demuestra cómo convertir una empresa no estructurada en una organización oscura. datos convertidos en conocimiento enriquecido y buscable para uso operativo y de inteligencia artificial.

[Capítulo 18](#) Democratizando la IA agente para empresas con Dataworkz y MongoDB, proporciona orientación arquitectónica y gobernanza. prácticas y casos reales para implementar sistemas seguros, observables y IA agente eficaz.

[Capítulo 19](#), Perspectivas: más allá de los , mira hacia el MCP, agentes impulsados por la memoria de la IA actual y la IA causal como impulsores de la próxima ola de sistemas inteligentes.

Para aprovechar al máximo este libro

No se requieren conocimientos específicos de herramientas, aunque un conocimiento práctico de los sistemas empresariales y la arquitectura de datos le ayudará a profundizar en el material. Los lectores interesados en los detalles de implementación pueden explorar:

- Biblioteca de soluciones MongoDB:

<https://www.mongodb.com/docs/atlas/architecture/current/solutions-library/>

MongoDB para inteligencia artificial: <https://>

- www.mongodb.com/solutions/use-cases/

artificial-intelligence

Descarga las imágenes a color. También proporcionamos un archivo PDF con imágenes a color de las capturas de pantalla/diagramas utilizados en este libro. Puedes descargarlo aquí: <https://packt.link/gbp/9781806117154>.

Convenciones utilizadas

A lo largo de este libro se utilizan varias convenciones textuales.

CodeInText : Indica palabras clave en el texto, nombres de tablas de bases de datos, nombres de carpetas, nombres de archivos, extensiones de archivo, rutas de acceso, URL ficticias, entradas o solicitudes del usuario y cuentas de Twitter. Por ejemplo: "En el modelo relacional, los campos usan nombres como **FIRST NAME**".

Un bloque de código se establece de la siguiente manera:

```
{ "_id": "67c20cf886f35bcb8c71e53c",  
  "agent_id": "default_agent", "profile":  
    "Perfil de agente predeterminado",  
  "instructions": "Seguir los procedimientos de diagnóstico meticulosamente",  
  "rules": "Garantizar la seguridad; validar los datos del sensor;  
  documentar " "goals": "Proporcionar diagnósticos precisos y respuestas  
  procesables "}
```

Negrita: Indica un término nuevo, una palabra importante o palabras que aparecen en pantalla. Por ejemplo: «Los términos «incitación» e «ingeniería de incitación» se utilizan frecuentemente en la misma línea que «LLM» y «GenAI».



Las advertencias o notas importantes aparecen así.



Los consejos y trucos aparecen así:



Las historias de clientes y otros ejemplos del mundo real aparecen así.



Ponte en contacto con nosotros

Los comentarios de nuestros lectores siempre son bienvenidos.

Comentarios generales: si tiene preguntas sobre cualquier aspecto de este libro o tiene algún comentario general, envíenos un correo electrónico a customercare@packt.com y mencione el título del libro en el asunto de su mensaje.

Errata: Aunque hemos tomado todas las precauciones para garantizar la precisión de nuestro contenido, pueden producirse errores. Si encuentra algún error en este libro, le agradeceríamos que nos lo comunicara. Visite <http://www.packt.com/submit-errata>, haga clic en Enviar erratas, y rellena el formulario.

Piratería: Si encuentra copias ilegales de nuestras obras en internet, en cualquier formato, le agradeceríamos que nos proporcionara la dirección o el nombre del sitio web. Por favor, contáctenos en copyright@packt.com con un enlace al material.

Si está interesado en convertirse en autor: si hay un tema en el que es experto y está interesado en escribir o contribuir a un libro, visite <http://authors.packt.com/>

.

Comparte tus pensamientos

Una vez que haya leído "Arquitecturas para la Empresa Inteligente Preparada para IA", ¡nos encantaría conocer su opinión! Haga [clic aquí para ir directamente a la página de reseñas de Amazon](#) y [compartir](#) sus comentarios.

Su reseña es importante para nosotros y para la comunidad tecnológica y nos ayudará a garantizar que ofrecemos contenido de excelente calidad.

Descargue una copia gratuita en PDF de este libro

¡Gracias por comprar este libro!

¿Te gusta leer mientras viajas pero no puedes llevar tus libros impresos a todas partes?

¿Tu compra de libro electrónico no es compatible con el dispositivo que eliges?

No te preocupes, ahora con cada libro de Packt obtendrás una versión PDF de ese libro sin DRM sin costo.

Lee en cualquier lugar, en cualquier dispositivo. Busca, copia y pega código de tus libros técnicos favoritos directamente en tu aplicación.

Los beneficios no terminan ahí, puedes obtener acceso exclusivo a descuentos, boletines informativos y excelente contenido gratuito en tu bandeja de entrada todos los días.

Siga estos sencillos pasos para obtener los beneficios:

1. Escanea el código QR o visita el siguiente enlace:



<https://packt.link/libro-e-gratuito/9781806117154>

2. Envíe su comprobante de compra.
3. ¡Listo! Te enviaremos tu PDF gratuito y otros beneficios directamente a tu correo electrónico.

Parte 1:

IA y conceptos clave

El siguiente conjunto de capítulos establece las bases conceptuales y arquitectónicas base para construir sistemas inteligentes con capacidades generativas y IA agencial. Introduce la transición de la modernización a la innovación. También explica la importancia de los datos basados en documentos en tiempo real. modelos y describe el nuevo pensamiento arquitectónico necesario para Implementar IA a escala de forma segura y responsable.

Esta parte del libro incluye los siguientes capítulos:

- [Capítulo 1](#), Modernización de la IA hacia la innovación
- [Capítulo 2](#), ¿Qué diferencia a GenAI, RAG y Agentic AI?
- [Capítulo 3](#), El sistema de acción
- [Capítulo 4](#), Inteligencia artificial confiable, cumplimiento y gobernanza de datos
- [Capítulo 5](#), Modernización mediante IA

1

Modernización de la IA hacia la innovación

Muchos lectores se encuentran en diferentes etapas de su experiencia con la IA, desde la exploración inicial hasta la planificación activa de la implementación. Algunos lideran equipos encargados de implementar algo con IA. Otros observan cómo la competencia anuncia iniciativas de IA mientras se preguntan cuál debería ser su próximo paso. Otros han probado pilotos de IA que mostraron resultados prometedores en las demostraciones, pero que, por alguna razón, nunca llegaron a producción. Si algo de esto le resulta familiar, ha encontrado el recurso adecuado.

Si bien innumerables publicaciones teorizan sobre la promesa de la IA, este libro adopta un enfoque diferente: es una guía de campo creada por profesionales para profesionales, diseñada para ayudarlo a superar la interminable fase de prueba y avanzar hacia la implementación de IA en el mundo real a escala.

En diferentes industrias, hemos recopilado lecciones aprendidas con esfuerzo de equipos que realmente han realizado el trabajo. No se trata de marcos abstractos ni presentaciones de proveedores; son manuales forjados en el caldo de cultivo de las limitaciones empresariales, las realidades de la integración y las expectativas de rendimiento. También miramos más allá de las palabras de moda. Si bien abordamos la IA generativa (GenAI) y los agentes de IA, también analizamos las arquitecturas de datos, los modelos de gobernanza y los patrones de diseño que hacen que esta tecnología realmente funcione. Porque, en definitiva, la transformación de la IA no se tra

adoptar nuevas herramientas; se trata de repensar cómo sus sistemas, equipos y estrategia comercial encajan entre sí.

Este enfoque práctico es ahora más importante que nunca. Si bien la revolución de la IA promete un potencial de crecimiento de la productividad sin precedentes, la realidad es que la mayoría de las organizaciones siguen atrapadas en un ciclo de modernización sin innovación. Casi todas las empresas invierten en tecnologías de IA, pero pocas las han integrado lo suficiente como para generar resultados revolucionarios. La diferencia radica en su enfoque [1].

¿Cómo cerrar esta brecha? Comienza distinguiendo dos conceptos que a menudo se confunden: modernización e innovación. En este capítulo, comprender la desenredaremos estas definiciones y mostraremos por qué la diferencia es estratégica. Aprenderá cómo la modernización sienta las bases para el éxito de la IA, cómo la innovación amplía su alcance y cómo ambos se vuelven esenciales al afrontar un momento de rápida disrupción.

Al final de este capítulo, tendrá una comprensión más clara de las dinámicas centrales que dan forma a la adopción exitosa de la IA, que incluyen:

- Las diferencias fundamentales entre innovación y Modernización y por qué ambas son importantes en las implementaciones de IA
- Cómo se aplica la teoría de los puntos de inflexión estratégicos de Andy Grove a la revolución de la IA actual
- Por qué modernizar los sistemas heredados y la infraestructura de datos es esencial para una implementación exitosa de la IA
- Cómo evitar los errores comunes que enfrentan las organizaciones cuando implementan iniciativas de IA sin las bases adecuadas

- Cómo implementar enfoques prácticos para equilibrar la innovación y la modernización en su estrategia de IA

Entendiendo la innovación: Creando nuevo valor

Antes de poder aprovechar eficazmente la IA para modernizar o innovar, necesita una comprensión práctica de lo que realmente significan estos términos y cómo difieren tanto en ejecución como en impacto.

Innovación , En esencia, es el proceso de crear e implementar nuevas Ideas, métodos, productos o servicios que aportan valor o mejoran los existentes. Implica convertir conceptos creativos en soluciones prácticas que satisfagan necesidades reales o resuelvan problemas con mayor eficacia.

La innovación puede adoptar muchas formas, incluidas las siguientes:

- **Innovación de productos:** Desarrollo de bienes o servicios nuevos o significativamente mejorados. Piense en la transición de los mapas de papel al GPS.
aplicaciones.
- **Innovación de procesos:** Introducción de nuevas formas de producir o entregar productos. La automatización robótica de procesos (RPA) ha revolucionado los procesos estandarizados y la toma de decisiones, dando lugar a innovaciones como la suscripción autónoma o la gestión de siniestros en tiempo real para las aseguradoras.
- **Innovación en el modelo de negocio:** Redefinir cómo una empresa crea y captura valor. Probablemente la innovación más famosa fue la innovación multinivel de Netflix, cuyo primer lanzamiento...

DVD a los hogares de las personas, en lugar de recogerlos en
Éxito de taquilla , y luego entregar el contenido vía streaming para que sea aún más
fácil que el correo electrónico.

- Innovación social: Uso de nuevas tecnologías para abordar las
necesidades ambientales y sociales. La IA está acelerando el
progreso ambiental, social y de gobernanza (ESG). Esto abarca desde sistemas
de energía inteligentes hasta el seguimiento automatizado del carbono. En
lugares como Brasil, plataformas como PicPay están ampliando el acceso
a herramientas financieras y programas sociales para comunidades
desfavorecidas.

Cada uno de estos ejemplos surgió de una idea, pero se convirtió en innovación
solo al aplicarse para resolver un problema a gran escala. En este sentido, la innovación
requiere más que invención. Requiere ejecución.

Puntos de inflexión estratégicos: La teoría de Andy Grove aplicada a la

IA. Pocos marcos explican mejor lo que está en juego en la
carrera actual de la IA que la teoría de los puntos de inflexión estratégicos de Andy
Grove, presentada en su libro "Solo los paranoicos sobreviven". Grove describe estos
momentos como momentos en los que los fundamentos de una empresa (o
de toda una industria) experimentan cambios drásticos e irreversibles. Estos cambios
pueden ser provocados por nuevas tecnologías, cambios regulatorios, presión
competitiva o por las tres cosas a la vez.

¿La idea central de Grove? No se ve claramente un punto de inflexión hasta que
se está en él. Y para entonces, suele ser demasiado tarde para recuperarse. Empresas

Quienes se adaptan pronto pueden dar un salto adelante. Quienes dudan, se resisten o se aferran a viejos modelos a menudo no sobreviven.

Los puntos de inflexión estratégicos exigen que el liderazgo haga más que simplemente optimizar; exigen reinención. Grove afirmó: «Solo los paranoicos sobreviven». En su opinión, el éxito requiere vigilancia constante, cuestionamiento constante de las suposiciones y la valentía de apostar por la transformación antes de que el camino esté claro.

¿El ejemplo más conocido? Intel.

En la década de 1980, Intel dominaba el negocio de chips de memoria. Pero la competencia japonesa comenzó a producir alternativas más rápidas, económicas y de mayor calidad. Grove y el entonces director ejecutivo, Gordon Moore, tomaron una decisión audaz: abandonaron su negocio tradicional y se dedicaron por completo a los microprocesadores. En aquel entonces, este mercado era pequeño e incierto. Pero la apuesta dio sus frutos. Los chips de Intel se convirtieron en la columna vertebral de la revolución de la informática personal, transformando a la compañía en uno de los actores tecnológicos más importantes de la era moderna.

Hoy en día, la IA presenta un punto de inflexión similar. La introducción de grandes modelos de lenguaje (LLM), la generación aumentada por recuperación (RAG) y los sistemas agénticos podrían resultar tan fundamentales para la era de la IA como lo fueron los primeros microprocesadores para la era de las PC. Estas tecnologías no son solo nuevas funciones; son nuevos fundamentos para la gestión empresarial.

A diferencia de la revolución de los microprocesadores, que se desarrolló durante décadas, la IA evoluciona a una velocidad sin precedentes. Las expectativas aumentan más rápido de lo que la infraestructura puede seguir el ritmo. Y muchas organizaciones ni siquiera han comenzado a modernizar sus cimientos.

Si sientes la urgencia, deberías sentirla. Así se siente un punto de inflexión.

Navegando el punto de inflexión de la IA. Las organizaciones que reconocen este momento como un verdadero punto de inflexión pueden preparar su infraestructura y capacidades para el futuro impulsado por la IA. Más allá de las nuevas herramientas, el éxito exige un replanteamiento fundamental de cómo los datos, la tecnología y los procesos de negocio interactúan.

En el centro de esta transformación se encuentran cinco capacidades críticas:

- **Infraestructura de datos flexible y preparada para el futuro:** Los sistemas heredados se enfrentan a importantes desafíos con los requisitos de IA. Los esquemas de bases de datos rígidos y las arquitecturas monolíticas a menudo no admiten aplicaciones de IA dinámicas. Las organizaciones necesitan una infraestructura que se adapte a la rápida evolución de las capacidades de IA sin necesidad de reestructuraciones completas del sistema. Esto implica adoptar plataformas que admitan la flexibilidad de esquemas y puedan gestionar diversos tipos de datos, desde bases de datos estructuradas hasta documentos no estructurados. Contenido multimedia, y puede escalar tanto vertical como horizontalmente a medida que aumentan las cargas de trabajo de IA. La infraestructura también debe soportar el procesamiento y la transmisión de datos en tiempo real, ya que muchas aplicaciones de IA requieren acceso inmediato a la información más actualizada.
- **Fluidez en incrustaciones vectoriales y tecnologías de búsqueda semántica:** Estas tecnologías constituyen la base de muchas aplicaciones modernas de IA. Las incrustaciones vectoriales permiten a los sistemas de IA comprender y procesar el lenguaje humano, las imágenes y otros tipos de datos complejos al convertirlos en datos matemáticos.

Representaciones con las que las máquinas pueden trabajar. Si bien muchas implementaciones de IA pueden tener éxito sin un profundo conocimiento técnico de incrustaciones, las organizaciones que buscan soluciones de IA más sofisticadas o diferenciadas se beneficiarán de equipos que comprendan cómo generar, almacenar y consultar estas incrustaciones eficazmente. Esto incluye el conocimiento de diferentes modelos de incrustación, la comprensión de cuándo usar incrustaciones preentrenadas o personalizadas, y la experiencia en bases de datos vectoriales y algoritmos de búsqueda por similitud. Esta experiencia resulta especialmente valiosa al desarrollar aplicaciones de IA que realmente puedan comprender y razonar sobre datos complejos y específicos del dominio.

- Arquitecturas que conectan la IA con las operaciones: Con demasiada frecuencia, las iniciativas de IA se construyen independientemente de las fuentes de datos y los sistemas empresariales que pretenden mejorar. Esto genera silos de datos, problemas de sincronización y aplicaciones de IA que trabajan con información obsoleta o incompleta. Las organizaciones exitosas diseñan arquitecturas donde las capacidades de IA están profundamente integradas con los sistemas operativos, lo que permite obtener información en tiempo real y una toma de decisiones automatizada basada en datos empresariales actualizados. Esta integración requiere una consideración cuidadosa del flujo de datos, el diseño de API y las arquitecturas impulsadas por eventos que pueden propagar cambios en los sistemas tradicionales y de IA.
- Estrategias para mantener la coherencia de datos entre sistemas: Esto se vuelve crucial cuando las aplicaciones de IA necesitan trabajar junto con sistemas heredados durante los períodos de transición, aunque este sigue siendo uno de los aspectos más desafiantes de la implementación de la IA. Las organizaciones normalmente no pueden reemplazar todos sus...

Los sistemas se actualizan de la noche a la mañana, por lo que necesitan estrategias para gestionar la sincronización de datos en múltiples plataformas, incluso cuando no se pueda lograr una consistencia perfecta. Esto incluye la implementación de mecanismos de captura de datos modificados, el diseño de procesos de validación de datos y el establecimiento de políticas claras de gobernanza de datos. La estrategia también debe tener en cuenta que los sistemas de IA pueden procesar y transformar los datos de forma diferente a las aplicaciones tradicionales, lo que requiere nuevos enfoques para el linaje de datos y la gestión de la calidad. Las organizaciones deben prever que esto sea un desafío constante, no un problema con soluciones sencillas.

- Barreras para una IA responsable: A medida que aumenta la presión para avanzar con rapidez, crece la tentación de tomar atajos. Sin embargo, sin marcos de gobernanza sólidos, las organizaciones corren el riesgo de implementar sistemas sesgados, frágiles o incumplidos. Una gobernanza práctica de la IA implica codificar políticas de privacidad y seguridad de datos, sesgo y equidad algorítmica, explicabilidad y transparencia de los modelos, y cumplimiento normativo en diferentes jurisdicciones. El marco de gobernanza debe ser aplicable y proporcionar directrices claras para los equipos de desarrollo de IA, sin ralentizar innecesariamente la innovación. Si se implementa correctamente, la gobernanza se convierte en un catalizador, no en una limitación.

Estos enfoques abordan un desafío crítico en el punto de inflexión de la IA:

la necesidad de unir los datos operativos y las capacidades de IA sin crear nuevos silos de datos o arquitecturas excesivamente complejas.

Las organizaciones que superen con éxito este punto de inflexión se encontrarán con importantes ventajas competitivas, mientras que aquellas que no se adapten corren el riesgo de quedarse atrás a medida que la IA transforma sus

Industrias. La clave es empezar a desarrollar estas capacidades ahora, antes de que la presión competitiva se vuelva abrumadora.

Comprender la modernización: un requisito previo que a menudo se pasa por alto

Además del alto impacto potencial de la innovación, hay otra palanca crítica en el conjunto de herramientas de la transformación: la modernización.

Si bien la modernización en sí es un término más amplio que se utiliza a menudo para describir Infraestructura física. La modernización técnica se refiere a la actualización o sustitución de tecnologías, sistemas o procesos obsoletos por otros más nuevos, eficientes y avanzados para mejorar el rendimiento, la productividad y la competitividad. Los elementos clave de la modernización técnica incluyen los siguientes:

- Digitalización mediante tecnologías como la automatización, la IA, la computación en la nube o el Internet de las cosas (IoT)
- Digitalización de procesos analógicos, por ejemplo, reemplazando registros en papel por sistemas digitales como
- Actualizaciones del la modernización de la infraestructura de TI heredada sistema o software (comúnmente conocidas como refactorización)
- Integración de herramientas modernas en los flujos de trabajo existentes para aumentar la eficiencia y reducir costos
- Mejoras de ciberseguridad que abordan las amenazas en evolución y cumplen con los estándares de la industria

El objetivo de la modernización es mejorar las capacidades, reducir y seguir riesgos operacionales , siendo competitivo en un mundo en constante cambio.

paisaje tecnológico

En el contexto de este libro, la modernización se presenta en dos formas distintas. La primera implica la modernización mediante la adopción de tecnologías avanzadas para abordar lo que posiblemente sea el mayor desafío al que se enfrentan muchas empresas hoy en día: los sistemas heredados.

Aquí, el término "sistema heredado" se utiliza en sentido amplio. Si bien estos sistemas suelen someterse a actualizaciones físicas cada tres a cinco años (un ciclo muy común en el mundo de los mainframes y que sin duda impacta los resultados de IBM), el software que se ejecuta en ellos suele permanecer obsoleto. Esto da lugar a situaciones en las que las empresas utilizan lógica de negocio y software con décadas de antigüedad, a pesar de haberse actualizado a hardware más nuevo. El código y los procesos de negocio subyacentes pueden tener hasta medio siglo de antigüedad, lo que plantea importantes desafíos para los esfuerzos de modernización.

El segundo enfoque, que a menudo es la mejor manera de proceder en situaciones como esta, es un reemplazo completo del sistema construido desde cero.

Pero, como suele suceder en los negocios, el enfoque directo puede no estar disponible ya que las razones para no tocar un sistema como tal son muchas: conocimientos empresariales implícitos, cumplimiento normativo, conectividad a máquinas existentes y más.

Estrategias comunes de modernización

La modernización de las aplicaciones heredadas no es una solución universal. Según estudios del sector y las mejores prácticas [2], existen varias estrategias comunes de modernización que las organizaciones pueden implementar:

- **Refactorización:** Cuando una empresa refactoriza, los desarrolladores actualizan la base de código, mejorando su estructura, rendimiento y mantenibilidad. Esto puede implicar mejorar el código existente sin modificar su funcionalidad, o migrar de lenguajes y frameworks antiguos a alternativas más modernas. Por ejemplo, una aplicación desarrollada en Ruby podría refactorizarse a Rust, o un sistema que utiliza una versión antigua de Java con Spring podría refactorizarse a Java moderno con Quarkus. Esta acción permite un escalado independiente, un mantenimiento más sencillo y el acceso a herramientas y prácticas de desarrollo actuales.
- **Replataforma:** Esto implica actualizar partes de la plataforma de una aplicación, como la base de datos subyacente, y generalmente también requiere modificaciones en el código base. Este método de rehosting o
- **redistribución**, también conocido como "lift and shift", implica migrar aplicaciones a una nube pública, privada, híbrida o multinube. Es una forma sencilla de obtener algunos de los beneficios de la nube sin necesidad de realizar modificaciones exhaustivas, pero no intenta solucionar los problemas de la aplicación tal como está.
- **Reestructuración:** esto puede implicar actualizar la base del código para aprovechar arquitecturas modernas, como contenedores o microservicios.
- **Reconstruir:** comenzar desde cero, preservando el alcance y las especificaciones de la aplicación, también es una opción y resulta útil cuando la aplicación existente está demasiado desactualizada o es ineficiente para la modernización.
- **Reemplazo:** Esto implica comenzar de nuevo con una base de código completamente nueva, comenzando desde los requisitos básicos hacia arriba. En lugar de...

En lugar de replicar la aplicación heredada, este enfoque se basa en la empresa para recopilar los requisitos actuales y modernos y desarrollar a partir de ellos. Muchas aplicaciones no merecen la pena modernizarse porque los procesos de negocio han evolucionado significativamente desde su creación original, por lo que reemplazarlas suele ser la mejor opción. Esto permite a las organizaciones eliminar funciones obsoletas e incorporar nuevas capacidades que se ajusten a las necesidades actuales del negocio.

La elección entre estas estrategias depende de varios factores, como el estado actual de la aplicación, los requisitos del negocio, los recursos disponibles y las limitaciones de tiempo. Las organizaciones suelen encontrar que un enfoque híbrido funciona mejor, combinando múltiples estrategias en diferentes componentes de sus sistemas. Por ejemplo, podrían refactorizar aplicaciones críticas y reubicar las menos críticas, o reconstruir los sistemas principales y reemplazar las aplicaciones periféricas obsoletas.

Cada estrategia implica un equilibrio entre el costo, el riesgo y los beneficios potenciales. La refactorización y la reestructuración ofrecen un menor riesgo, pero mejoras más limitadas, mientras que la reconstrucción y el reemplazo ofrecen un mayor potencial de transformación, pero requieren una inversión mayor y conllevan mayores riesgos de implementación. La clave está en alinear el enfoque de modernización con los objetivos de negocio y las limitaciones técnicas.

Si bien estas estrategias describen cómo se puede abordar la modernización a nivel de aplicación, su ejecución efectiva a menudo depende de la base proporcionada por las plataformas de datos modernas.

Donde la innovación se encuentra

Modernización: la intersección de la IA

Aquí es donde la innovación y la infraestructura impulsadas por la IA

La modernización converge. En los últimos 20 años, muchas empresas...

han ofrecido elaborados enfoques de modernización o prácticas a gran escala,

A menudo implica revisiones de software y procesos existentes.

En última instancia, hacer una reescritura de facto desde cero, esencialmente reconstruyendo sistemas enteros desde cero y lo llaman modernización.

Sin embargo, como analizaremos más adelante [Capítulo 5](#), Modernización en Uso de , Estas reescrituras completas tienen importantes inconvenientes. Carecen IA, la repetibilidad y la transparencia necesarias para impulsar la verdadera modernización de sistemas existentes, que a menudo se convierten en proyectos únicos que consumen muchos recursos y corren el riesgo de perder la lógica empresarial incorporada y el conocimiento institucional.

La IA cambia la ecuación. En lugar de optar por la venta al por mayor,

Sustitución, permite una modernización más inteligente y sostenible,

Preservando lo que funciona y evolucionando lo que no. La IA puede analizar

código heredado, convertirlo a formatos modernos más digeribles (como

diferentes lenguajes de programación o paradigmas), y facilitar

Cambios arquitectónicos integrales desde sistemas monolíticos a

Arquitecturas modernas distribuidas de n niveles, incluyendo diseños basados

en microservicios. Acelera la generación de pruebas y mejora...

mantenibilidad y cierra la brecha entre los sistemas frágiles y

flujos de trabajo modernos. Estas estrategias, exploradas con más detalle en [Capítulo](#)

[5](#), Modernización Usando IA, equie a las organizaciones para evolucionar sistemas de forma iterativa sin tener que empezar de nuevo.

La trampa de la implementación de la IA: cuando la innovación carece de fundamento

La segunda parte, donde se alinean la modernización y la innovación en IA, es más sutil. El fuerte impulso empresarial a las soluciones de IA y su uso para mejorar la funcionalidad empresarial puede conducir a soluciones rápidas que no son sostenibles ni se ajustan a la definición de...

preparación para la producción.

Cuando los proyectos de IA no llegan a producción

Considere este escenario real. Una gran empresa multinacional con un elaborado proceso de innovación recibió el mandato de la dirección empresarial para implementar IA en toda la organización. Entusiasmada por las posibilidades, la empresa inició una evaluación más amplia que finalmente dio lugar a 500 proyectos independientes, todos centrados en la implementación de alguna forma de capacidad de IA. La organización invirtió importantes recursos, formó equipos en múltiples unidades de negocio y generó un entusiasmo considerable por la transformación de la IA. Doce meses después, cuando estos proyectos se sometieron a una evaluación formal para su implementación en producción, ninguno logró avanzar. Ni un solo proyecto entre las 500 iniciativas demostró suficiente valor comercial, técnico...



confiabilidad o disponibilidad operativa para justificar la continuidad inversión.

El análisis mostró una desconexión entre la resolución de problemas empresariales reales y la implementación de soluciones que, si bien eran atractivas desde una perspectiva de TI, no tenían un impacto medible. En segundo lugar, cada proyecto se basaba en investigaciones independientes realizadas por individuos o equipos más pequeños, que ignoraban las discusiones fundamentales sobre la implementación en producción o la integración continua en los flujos de trabajo.

Finalmente, se descuidó la integración de datos, ya que se trabajó con datos de muestra que no reflejaban los requisitos de los casos de uso en tiempo real. Cualquier cambio o actualización de estos conjuntos de datos podría

haber generado resultados inesperados en el LLM, más allá de simples alucinaciones. Por ejemplo, modificar conjuntos de datos con diferentes calibraciones (como una actualización de software en una línea de fabricación) podría haber resultado, en el mejor de los casos, en productos invendibles y, en el peor, en mercancías peligrosas.



En otras palabras, modernizar la infraestructura de datos subyacente es un requisito previo para que estos casos de uso avancen más allá de la experimentación y comiencen la implementación real. Las aplicaciones de IA requieren un enfoque de la infraestructura de datos sustancialmente diferente al de las tradicionales.

aplicaciones que utilizan el mismo esquema durante décadas; deben manejar diversos tipos de datos, soportar el procesamiento en tiempo real y adaptarse a requisitos comerciales y necesidades de integración en rápida evolución.

En este contexto, la modernización no es un efecto secundario opcional ni deseable, sino un requisito indispensable para la implementación de la funcionalidad de IA en producción. Como efecto secundario, la modernización de los entornos de datos simplificará el diálogo con la empresa sobre el valor real de la IA.

Entonces, ¿cómo se ve una base sólida en la práctica? Comienza con plataformas de datos modernas diseñadas para equilibrar la agilidad de la innovación con el rigor de la modernización.

Plataformas de datos modernas: la columna vertebral de la transformación hacia la IA

Las plataformas de datos modernas no son solo una actualización de infraestructura; son fundamentales para la transformación impulsada por la IA, impulsando simultáneamente la innovación y la modernización. En una era marcada por la rapidez de los cambios, los sistemas tradicionales son demasiado rígidos para satisfacer las necesidades cambiantes de las empresas que apuestan por la IA.

Una plataforma moderna cierra esta brecha ofreciendo la flexibilidad, la velocidad y la escalabilidad que exigen tanto la innovación como la modernización.

¿Por qué son necesarias las plataformas de datos modernas? La clave

de la modernización

y la preparación para la IA reside en la capacidad de gestionar y operar con datos diversos y en constante cambio. Muchas empresas dependen de bases de datos relacionales con esquemas fijos y arquitecturas monolíticas que requieren modificaciones significativas para dar soporte a aplicaciones dinámicas de IA. Las plataformas de datos modernas, especialmente aquellas basadas en documentos o arquitecturas no relacionales, ofrecen capacidades mejoradas para las cargas de trabajo actuales, como la flexibilidad de esquemas, el procesamiento en tiempo real y el escalado horizontal, características que suelen requerir las aplicaciones de IA.

Esta flexibilidad es una necesidad estratégica. Los requisitos empresariales modernos suelen incluir decisiones en tiempo real, datos multiformato y desarrollo ágil, aspectos inviables con los sistemas de datos tradicionales.

A medida que las organizaciones buscan la transformación de la IA, su capacidad para innovar, modernizarse y escalar depende directamente de la infraestructura de datos subyacente.

Impulsando la innovación mediante la agilidad y la velocidad. Las bases de

datos tradicionales

obligan a los desarrolladores a dedicar semanas a definir estructuras de datos exactas antes de escribir código. Si desea agregar un nuevo campo o cambiar la conexión de los datos, necesita que los administradores de bases de datos actualicen manualmente los esquemas, lo que a menudo lleva días o semanas.

Las plataformas modernas permiten a los desarrolladores comenzar a codificar inmediatamente con cualquier estructura de datos que tenga sentido. Es necesario agregar clientes.

¿Preferencias para tu app de seguros? Simplemente empieza a almacenar esos datos. ¿Quieres probar un nuevo flujo de trabajo de reclamaciones? Créalo sin esperar cambios en el esquema.

Esto significa que un equipo puede pasar de la idea a un prototipo funcional en días en lugar de meses. Los equipos pueden desarrollar, probar e iterar nuevas soluciones, como la suscripción autónoma o el procesamiento de siniestros en tiempo real, sin depender de cambios manuales en bases de datos rígidas. estructuras.

Además, plataformas como MongoDB admiten formatos de datos naturales como imágenes, documentos y series temporales, lo que permite una mayor variedad de casos de uso. Por ejemplo, al eliminar la necesidad de complejas transformaciones de datos, las organizaciones pueden integrar fuentes de datos previamente aisladas para desarrollar nuevas aplicaciones con mayor rapidez, lo que agiliza la obtención de valor.

Esta flexibilidad y velocidad son esenciales porque la innovación es un proceso continuo que requiere desarrollo e iteración constantes.

A medida que las ideas maduran, las arquitecturas de datos modernas evolucionan con ellas, respaldando el crecimiento del producto, la expansión de funciones y los ciclos de retroalimentación impulsados por el usuario sin requerir migraciones disruptivas.

Simplificar la modernización sin tener que empezar de cero. Los esfuerzos de modernización son notoriamente difíciles, especialmente cuando los sistemas heredados contienen décadas de lógica de negocio integrada y dependencias regulatorias. Las plataformas de datos modernas reducen el riesgo y el costo de la modernización al permitir rutas de migración incrementales.

En lugar de forzar reescrituras drásticas, estas plataformas permiten implementaciones híbridas donde coexisten sistemas heredados y modernos. Las herramientas de integración fluida analizan los esquemas existentes, integran estructuras heredadas en formatos modernos y mantienen la integridad de los datos durante las transiciones. Estas plataformas sincronizan automáticamente los sistemas antiguos y nuevos; cuando un cliente actualiza su dirección en su sistema heredado, el cambio también se refleja instantáneamente en el nuevo sistema. Esto significa que puede migrar clientes y funciones gradualmente en lugar de arriesgarse a un cierre total del sistema. Además, las capacidades de implementación nativas de la nube ofrecen la flexibilidad de escalar la infraestructura según demanda, lo que reduce los costos iniciales y permite la experimentación con nuevas arquitecturas en entornos de pruebas. Esto permite modernizarse sin perder conocimiento institucional ni interrumpir las operaciones principales.

Impulsando la IA a escala. Las aplicaciones de IA dependen de algo más que simples modelos; requieren una infraestructura capaz de almacenar, recuperar y analizar datos complejos. Las bases de datos modernas satisfacen esta necesidad al admitir flujos de trabajo de IA avanzados, como la incrustación de vectores y la búsqueda semántica.

Al almacenar representaciones vectoriales de datos, como las generadas por los LLM, junto con los registros operativos, las organizaciones pueden implementar funciones como la búsqueda por similitud, recomendaciones contextuales y automatización inteligente. La compatibilidad integrada con la búsqueda vectorial elimina la necesidad de canales inconexos y

Permite un acoplamiento más estrecho entre los datos operativos y la toma de decisiones mediante IA.

Además, las capacidades de procesamiento de datos en tiempo real garantizan que los sistemas de IA trabajen con información actual en lugar de instantáneas estáticas.

A medida que los sistemas de IA evolucionan rápidamente y surgen nuevos modelos y arquitecturas cada pocos meses, las plataformas modernas ofrecen la agilidad necesaria para adaptarse sin tener que rediseñar los sistemas fundamentales.

Resumen

Este capítulo exploró la distinción crítica entre innovación y modernización en el contexto de la transformación de la IA. Examinó

La teoría de los puntos de inflexión estratégicos de Andy Grove demostró cómo la revolución de la IA actual representa un punto de inflexión comparable a la revolución informática de la década de 1980.

El debate ilustró por qué la modernización de los sistemas heredados y la infraestructura de datos es esencial para una implementación exitosa de la IA, mediante ejemplos prácticos y casos de éxito. El capítulo estableció que la innovación en IA requiere una base sólida.

La modernización aborda la carga de la infraestructura heredada, en particular en los sistemas de datos.

Al comprender la relación entre la innovación y la modernización, y aprovechar las plataformas de datos modernas que respaldan ambas, las organizaciones pueden navegar con éxito el punto de inflexión de la IA y crear una ventaja competitiva sostenible.

El siguiente capítulo desmitifica el panorama de la IA. Comprenderá cómo las tecnologías centrales, es decir, la búsqueda semántica, los LLM, RAG y

IA agente, se unen para crear valor comercial.

Referencias

1. Superagencia en el lugar de trabajo: empoderar a las personas para liberar todo el potencial de la IA potencial :

<https://www.mckinsey.com/capabilities/mckinsey-digital/our-insights/superagency-in-the-workplace-empowering-people-to-unlock-ais-full-potential-at-work>

2. Por qué la modernización de aplicaciones es vital para el crecimiento empresarial:

<https://www.mongodb.com/resources/solutions/use-casos/modernización-de-aplicaciones#estrategias-comunes-de-modernización>

2

¿Qué diferencia a GenAI, RAG y

Inteligencia artificial agente aparte

Las organizaciones actuales se enfrentan a un reto crucial: separar las capacidades reales de la IA de la publicidad exagerada, a la vez que alinean sus estrategias futuras en un entorno en constante cambio. Con la terminología de IA de reciente creación que inunda cada propuesta, presentación y demostración de producto, incluso los tecnólogos más experimentados se ven envueltos en conversaciones donde las diferencias fundamentales entre las tecnologías siguen siendo confusas. En el mejor de los casos, estas diferencias son confusas; con mayor frecuencia, son incomprensibles. Ya sea que esté evaluando soluciones, diseñando sistemas o asesorando sobre inversiones estratégicas, no se trata solo de comprender las palabras de moda; se trata de tomar decisiones informadas que definan la ventaja competitiva de su organización.

Han surgido tres conceptos como las tecnologías fundamentales que definen las aplicaciones modernas de IA: IA generativa (GenAI), que permite a los sistemas crear contenido nuevo a partir de patrones aprendidos; generación aumentada por recuperación (RAG), que conecta modelos de IA con fuentes de conocimiento externas para mejorar la precisión; e IA agente, que impulsa sistemas autónomos que pueden planificar, razonar y ejecutar flujos de trabajo complejos con una mínima intervención humana.

Comprender cómo estas tecnologías se interconectan y se complementan es esencial para tomar decisiones estratégicas sobre la implementación de la IA. Incluso estos términos ampliamente aceptados tienen una gran cantidad de...

interpretaciones, y si bien no pretendemos presentar la verdad única, nuestro objetivo es brindarle una base fundamental sólida.

Este capítulo te servirá de introducción al mundo de GenAI. Si ya tienes amplia experiencia con arquitecturas de IA y comprendes claramente la diferencia entre estas tecnologías, puedes optar por avanzar a los capítulos siguientes. Sin embargo, para quienes buscan adquirir conocimientos básicos sólidos, este capítulo proporcionará las bases esenciales para todo lo que sigue.

Al final de este capítulo, tendrá una comprensión clara de lo siguiente:

- Una exploración de la evolución histórica de la IA y cómo GenAI surgió a partir de enfoques anteriores
- El papel fundamental de los grandes modelos lingüísticos (LLM) y cómo procesan y generan información
- Cómo la incrustación de modelos transforma los datos en vectores, la base del razonamiento de la IA
- El papel fundamental de las bases de datos vectoriales en el almacenamiento, la gestión y la habilitación de búsquedas de similitud eficientes
- La distinción entre búsqueda semántica, RAG y enfoques de búsqueda híbridos
- ¿Qué hace que la IA agentica sea diferente de los sistemas de IA anteriores y cómo permite la toma de decisiones autónoma?
- Los componentes principales de los agentes de IA, incluidos la memoria, la orquestación, las herramientas, los modelos y los servicios de datos.
- Cómo estos componentes funcionan juntos en aplicaciones prácticas para resolver problemas comerciales reales

Cómo evolucionó la IA: de la teoría a la ChatGPT

Para comprender el panorama actual de la IA, necesitamos rastrear la trayectoria tecnológica que nos ha traído hasta aquí. Esta evolución abarca décadas de avances en la investigación, desde la lógica simbólica y los sistemas expertos hasta las arquitecturas transformadoras que impulsan los LLM actuales. Al examinar esta progresión, podemos comprender mejor cómo surgieron las capacidades actuales y por qué las decisiones arquitectónicas siguen moldeando los sistemas actuales.

Cuando hablamos de modelos en GenAI, nos referimos a un sistema matemático entrenado para reconocer y replicar patrones presentes en los datos. Usamos el término "modelo" porque, al igual que el modelo de un edificio o un sistema climático, es una versión simplificada y estructurada de algo complejo; en este caso, lenguaje, imágenes o comportamiento. Un modelo GenAI se entrena con grandes conjuntos de datos para aprender cómo se relacionan típicamente los elementos (como palabras o píxeles). Una vez entrenado, puede generar nuevo contenido realista basado en esa estructura aprendida. No almacena respuestas exactas; modela cómo funcionan las cosas y luego utiliza esa comprensión para crear nuevos resultados.

Rastreadremos esa evolución a lo largo de tres puntos de inflexión principales: los primeros cimientos de la IA, el surgimiento revolucionario de los LLM y cómo estos desarrollos culminaron en los sistemas GenAI que conocemos hoy.

Un pequeño paseo por la historia

La IA se ha convertido, sin duda, en la tecnología más comentada en la comunidad informática desde la llegada del ratón a través de Xerox PARC. Es fascinante la extendida creencia de que la IA se inventó mágicamente de la noche a la mañana, y que emergió plenamente cuando OpenAI lanzó ChatGPT al público. Sin embargo, las capacidades actuales no surgieron de la noche a la mañana. Para comprenderlas, es necesario rastrear la evolución de la GenAI actual en el contexto temporal.

El término inteligencia artificial fue acuñado en 1955 por John McCarthy y sus colegas, y se utilizó por primera vez en el Taller de Dartmouth en 1956, un evento pionero que reunió a científicos destacados para definir y avanzar en el campo[1]. Según el diccionario Oxford, la IA es:



La teoría y el desarrollo de sistemas informáticos capaces de realizar tareas que normalmente requieren inteligencia humana, como la percepción visual, el reconocimiento de voz, la toma de decisiones y la traducción entre idiomas [2].

A partir de ese punto de partida, surgieron diversos enfoques, cada uno moldeado por las capacidades informáticas y las prioridades de investigación de su época. Entre ellos: los sistemas de lógica simbólica, la lógica difusa (década de 1980), las primeras redes neuronales (década de 1990) y, finalmente, el aprendizaje automático, que se volvió cada vez más práctico y extendido a principios de la década de 2000.

A medida que se aceleró la experimentación, dos avances tecnológicos clave convergieron para posibilitar el desarrollo de la IA a gran escala. En primer lugar, se estableció la potencia de cómputo paralela gracias a la compatibilidad temprana con tarjetas gráficas (GPU) mediante interfaces de software como CUDA (lanzada en 2007), lo que permitió a los programadores aprovechar la enorme capacidad paralela

potencia de procesamiento de las tarjetas gráficas para tareas informáticas generales.

En segundo lugar, marcos como Apache Spark (de código abierto en 2010) ayudaron a superar una limitación fundamental de las plataformas de computación distribuida anteriores, como Hadoop MapReduce.

Hadoop MapReduce fue uno de los primeros sistemas para dividir grandes tareas de computación entre varios ordenadores, pero resultaba lento para el aprendizaje automático debido a la lectura y escritura repetida de datos en el disco. Spark revolucionó este proceso al mantener los datos en la memoria del ordenador entre los pasos de procesamiento, lo que permitió que los algoritmos iterativos, esenciales para el aprendizaje automático, se ejecutaran con una velocidad de órdenes de magnitud mucho mayor. En conjunto, estos avances permitieron a los investigadores procesar y analizar conjuntos de datos masivos de forma eficiente, un avance crucial para el entrenamiento de los modelos de IA a gran escala que vemos hoy.

AlphaGo y el punto de inflexión en la IA

En marzo de 2016, se produjo otro hito. En un tablero de Go en Seúl, Corea del Sur, AlphaGo, un sistema de IA desarrollado por DeepMind, se enfrentó a Lee Sedol, uno de los jugadores de Go más destacados de la historia. El resultado fue una impresionante victoria de 4-1 para la máquina, un punto de inflexión en la historia de la IA moderna.

¿Por qué fue tan importante? El Go, a diferencia del ajedrez, se había resistido durante mucho tiempo al dominio de las computadoras. Su campo de búsqueda es vasto, con más estados posibles en el tablero que átomos en el universo. Exige intuición, reconocimiento de patrones y profundidad estratégica. Durante décadas, los investigadores de IA creyeron que el Go estaba fuera del alcance de la computación de fuerza bruta, requiriendo una forma de razonamiento que antes se consideraba exclusivamente humana.

AlphaGo rompió esa creencia. Al combinar redes neuronales profundas con aprendizaje por refuerzo y búsqueda de árboles de Monte Carlo, marcó un cambio radical de enfoque. En lugar de depender únicamente de reglas predefinidas o búsquedas exhaustivas, AlphaGo aprendió. Primero, de partidas con expertos humanos, y luego, jugando millones de partidas contra sí mismo. Fue una de las primeras demostraciones públicas de aprendizaje por refuerzo profundo a escala, mostrando el poder de los sistemas que podían mejorar con la experiencia, en lugar de programarse línea por línea.

El surgimiento de los LLM

Si AlphaGo marcó un punto de inflexión en la IA para la toma de decisiones, los transformadores redefinieron cómo las máquinas entienden el lenguaje.

A partir de una propuesta de 2006, IBM desarrolló el sistema de [preguntas y respuestas Watson](#), una profunda preguntas y respuestas Watson que ganó Jeopardy! en 2011, un avance significativo para el procesamiento del lenguaje natural (PLN) en datos no estructurados[3]. Watson combinó bases de conocimiento, aprendizaje automático (ML) y sofisticados sistemas de preguntas y respuestas, marcando un hito importante en la capacidad de la IA para comprender y procesar el lenguaje humano.

Pero los LLM actuales siguieron una trayectoria evolutiva distinta. En 2017, investigadores de Google publicaron Attention Is All You Need, donde presentaron la arquitectura de transformadores, crucial para la creación de modelos lingüísticos modernos[4]. La innovación clave de los transformadores fue el mecanismo de autoatención, que permite a los modelos procesar secuencias completas simultáneamente y capturar dependencias de largo alcance en el texto con mayor eficacia que los enfoques secuenciales anteriores.

Los Transformers se convirtieron en la base de los LLM modernos, que realmente ingresaron a la corriente principal con modelos como GPT-3 en 2020 y

ChatGPT en 2022, marcando el comienzo de la era GenAI.



El punto de inflexión

Mientras que Watson presentó sistemas de ingeniería y bases de conocimiento seleccionadas para triunfar, los LLM basados en transformadores tomaron un camino radicalmente diferente. En lugar de ser programados con lo que debían decir, aprendieron a predecirlo, detectando patrones en conjuntos de datos masivos y generando respuestas fluidas, a menudo similares a las humanas. Entre estos hitos, la victoria de AlphaGo reveló algo nuevo: que la IA no solo podía responder, sino también adaptarse, aprender y sorprender. Este cambio sentó las bases para los sistemas generativos y agénticos actuales.

Esta historia reciente subraya que los sistemas GenAI actuales no son el resultado de un único avance, sino el resultado de décadas de innovación incremental, evolución de la infraestructura y un progreso investigador creciente. Si bien la historia más amplia de la IA incluye tanto...

El progreso y los períodos de financiación reducida, conocidos como los "inviernos de la IA", que conducen directamente a la GenAI, se han acelerado drásticamente en los últimos años. Las plataformas de datos modernas han sido cruciales en esta evolución reciente, proporcionando la infraestructura necesaria para almacenar, procesar y analizar los enormes conjuntos de datos necesarios para entrenar los modelos más potentes de la actualidad.

El desarrollo de los LLM continúa evolucionando rápidamente. Si bien líderes pioneros como OpenAI (ChatGPT) y Anthropic dominan el mercado en 2025, están surgiendo nuevos enfoques. Empresas como DeepSeek están explorando metodologías de "divide y vencerás" para reducir...

La complejidad y los costos de LLM, mientras que otros como Zhipu están desarrollando arquitecturas basadas en enrutadores con expertos especializados. A pesar de estos enfoques variados, el concepto central de los LLM que sirven como bases de conocimiento y motores de razonamiento probablemente seguirá siendo central para los sistemas de IA en el futuro previsible.

GenAI: Creación de nuevo contenido a partir de patrones. Los LLM constituyen la base de cualquier solución GenAI. Si bien a menudo se perciben como el único requisito para implementar las capacidades de GenAI, los LLM actuales, a pesar de alcanzar capacidades de razonamiento sustanciales, aún dependen críticamente de un recurso externo para proporcionar un contexto útil: los datos.

Los términos "incitación" e "ingeniería de incitación" se utilizan frecuentemente en el mismo contexto que "LLM" y "GenAI". La incitación se refiere a la creación de consultas para un LLM, mientras que la ingeniería de incitación implica la optimización sistemática de estas consultas para obtener mejores resultados. Las primeras interacciones con LLM priorizaron la ingeniería de incitación independiente y propiciaron el fenómeno de millones de ingenieros de incitación en LinkedIn.

Sin embargo, la aparición de patrones arquitectónicos avanzados como RAG, que combina LLM con sistemas externos de recuperación de conocimiento, ha reorientado el enfoque hacia soluciones más integrales que integran los LLM en sistemas más amplios, en lugar de tratarlos como herramientas aisladas. (Analizaremos RAG en detalle más adelante en este capítulo).

Una sugerencia eficaz ahora implica elaborar preguntas que respondan de manera óptima

aprovechar los ricos datos contextuales proporcionados por estos patrones, haciendo que la calidad del contexto sea tan crucial como el mensaje en sí.

Las técnicas de incitación más avanzadas, como la incitación en cadena de pensamiento (CdP), nos permiten ayudar a la IA a pensar paso a paso, de forma similar a mostrar el trabajo en clase de matemáticas, lo que mejora aún más la calidad de las respuestas. Al pedirle que "piense paso a paso", aumenta la probabilidad de que razone correctamente, especialmente en problemas más complejos de matemáticas, lógica o tareas con varias partes. Este enfoque es particularmente eficaz al abordar escenarios complejos que se benefician de un desglose sistemático; por ejemplo, al procesar documentos extensos, como reclamaciones de seguros, se podría pedir al LLM que primero identifique los componentes clave, luego analice cada sección metódicamente y, finalmente, sintetice los hallazgos.

Como en cualquier sistema de datos, se aplica el viejo dicho: «Entra basura, sale basura». En el caso de los LLM, una mala calidad de entrada puede resultar en respuestas que a menudo generan respuestas alucinaciones que inicialmente parecen ser resultados razonables, pero que, tras una inspección, resultan ser invenciones completas del LLM. Los enfoques para mitigar estos problemas han evolucionado más allá del simple ajuste de las indicaciones, incluyendo un mejor encuadre del contexto, una mejor validación de datos y sofisticados mecanismos de filtrado para evitar la desviación de la información y garantizar la fiabilidad de los resultados.

Cómo funciona GenAI

GenAI se refiere a sistemas de IA que pueden crear nuevo contenido, como texto, imágenes, código u otros medios, basándose en patrones aprendidos de datos existentes. A diferencia de los sistemas de IA tradicionales que siguen reglas explícitas, GenAI...

Aprende patrones y relaciones de grandes conjuntos de datos y luego utiliza este conocimiento para generar contenido nuevo y original que se asemeja a los datos de entrenamiento. Comprender la naturaleza fundamental de los LLM puede ayudar a las organizaciones a evaluar las implicaciones de sus recursos y a aprovechar eficazmente estas tecnologías.

Sin embargo, la realidad es que los LLM son cajas negras y no deterministas, lo que significa que la misma entrada no siempre produce el mismo resultado. Hay algo de cierto en la idea de que aún no comprendemos completamente el funcionamiento interno de los LLM. Si bien se está investigando mucho al respecto, comprender de forma clara y precisa qué sucede realmente dentro de un LLM es tentadoramente inalcanzable.

Anthropic, uno de los líderes en el campo de la seguridad de la IA, escribió un artículo sobre esto y concluyó que:



Comprender las representaciones que utiliza el modelo no nos dice cómo las utiliza; aunque tengamos las características, aún necesitamos encontrar los circuitos en los que participan. Y debemos demostrar que las características relevantes para la seguridad que hemos empezado a encontrar pueden realmente utilizarse para mejorar la seguridad. Queda mucho por hacer.

Reconocer tanto las capacidades como las limitaciones de los LLM, como sus limitadas ventanas de contexto y el potencial de alucinaciones, resulta crucial para establecer expectativas realistas y planificar las medidas de seguridad y las estrategias de aumento necesarias. Además, las decisiones sobre el uso de modelos preentrenados frente al ajuste o la creación de modelos personalizados afectan directamente el presupuesto, los plazos y...

opciones de infraestructura, un conocimiento que resulta invaluable para las negociaciones con proveedores y la selección de plataformas.

El proceso GenAI sigue pasos secuenciales clave, como se ilustra en la Figura 2.1.




Figura 2.1: Flujo del proceso GenAI

El diagrama representa un flujo de proceso que involucra cinco etapas clave.

Primero, se ensambla un conjunto de datos de entrenamiento gigantesco, generalmente de varios petabytes. Este se utiliza para entrenar el LLM. Durante el entrenamiento y con el uso posterior, el modelo comienza a reconocer patrones y a establecer conexiones entre datos dispares. El modelo recibe una solicitud del usuario final y se genera un resultado. A menudo, estas solicitudes y resultados se monitorizan internamente y se retroalimentan al modelo para su refinamiento y mejora de calidad constantes.

Este proceso secuencial demuestra un principio fundamental: la capacidad de GenAI para crear contenido novedoso se deriva directamente de su comprensión integral de los patrones existentes. Cuanto más diversa sea la información...

Cuanto más alta sea la calidad de los datos de entrenamiento, más sofisticados y precisos serán los resultados generados. Esta comprensión es crucial para las organizaciones que planean implementar GenAI, ya que destaca la importancia crucial de la calidad de los datos y la naturaleza iterativa para lograr resultados óptimos.

Limitaciones y desafíos de GenAI

Si bien GenAI ha logrado avances notables, enfrenta varias limitaciones importantes que las organizaciones deben considerar:

- **Limitaciones de los datos de entrenamiento:** Los modelos LLM se ven limitados fundamentalmente por sus datos de entrenamiento. Si estos están desactualizados, sesgados o carecen de diversidad, los resultados del modelo reflejarán estas deficiencias, generando potencialmente información irrelevante o perpetuando estereotipos perjudiciales.
- **Alucinaciones e inexactitud factual:** los modelos pueden generar con seguridad información que parece plausible pero que es incorrecta o sin sentido en los hechos, un fenómeno conocido como alucinación. Esto los hace poco confiables para aplicaciones que requieren altos niveles de precisión fáctica sin las protecciones adecuadas como RAG.
- **Falta de explicabilidad:** la naturaleza compleja y de caja negra de muchos LLM hace que sea difícil comprender su razonamiento interno. Esta falta de transparencia, a menudo llamada el desafío de la explicabilidad o la interpretabilidad, puede ser una barrera importante en industrias reguladas o aplicaciones críticas donde comprender el porqué detrás de una decisión es esencial.
- **Limitaciones del contexto y el razonamiento:** los modelos pueden tener dificultades con la comprensión matizada, el razonamiento de sentido común y

Mantener el contexto durante interacciones largas. Pueden malinterpretar consultas ambiguas o no comprender instrucciones complejas de varios pasos.

- Riesgos éticos y sociales: El uso generalizado de GenAI introduce importantes desafíos éticos, incluido el potencial de generar desinformación y deepfakes, perpetuar sesgos, infringir derechos de autor y crear nuevas vías para uso malicioso.

Las plataformas de datos modernas ayudan a abordar algunos de estos desafíos al proporcionar una infraestructura flexible y escalable para almacenar y procesar los diversos tipos de datos necesarios para el entrenamiento y la operación de la IA. Los modelos de datos basados en documentos son especialmente adecuados para aplicaciones de IA, ya que pueden adaptarse a requisitos cambiantes y almacenar tipos de datos heterogéneos en su forma natural, un paso fundamental para construir sistemas de IA más fiables y sólidos. Además, el acceso a una amplia gama de fuentes de datos, en lugar de limitarse a sistemas aislados heredados, a menudo requiere conceptos como los sistemas dinámicos de acción, que analizaremos en el siguiente capítulo.

De datos a vectores

Sobre la base de las capacidades flexibles de almacenamiento de datos introducidas, el siguiente paso para habilitar el razonamiento de la IA requiere transformar los datos a un formato que las computadoras puedan procesar y manipular matemáticamente. Aquí es donde entra el concepto de vectores; sirven como lenguaje universal que permite a GenAI trabajar con cualquier tipo de datos, estructurados o no estructurados. Piense en los vectores como coordenadas en un... mapa, pero en lugar de solo mostrar la ubicación con latitud y

Longitud: pueden representar el significado de cualquier dato en cientos o miles de dimensiones. Un vector podría capturar qué hace atractiva la descripción de un producto, por qué ciertas reseñas de clientes son similares o cómo se relacionan los distintos documentos.

Si bien la representación de texto en tres dimensiones sigue siendo fácil de comprender, la representación de segmentos de películas en cientos de dimensiones desafía cualquier visualización, y dejamos el concepto como un ejercicio mental. Un caso de uso para los segmentos de películas podría ser la gestión de derechos digitales y la identificación de películas idénticas frente a derivadas, por lo que esto no es inusual.

Aquí está la idea clave: las cosas similares terminan juntas en el vector espacio.



Figura 2.2: Visualización del espacio vectorial: conceptos similares se agrupan

La Figura 2.2 ilustra este concepto en acción. Cada punto de color representa una pieza de datos diferente que se ha convertido en forma vectorial. Observe cómo los conceptos relacionados se agrupan naturalmente. Los términos relacionados con los deportes se agrupan en un área, las bebidas forman su propia región, y actividades específicas como el baloncesto y el fútbol se encuentran cerca a su categoría deportiva más amplia. Esto no es una coincidencia; es la representación matemática del significado que hace que los sistemas de IA sean tan poderoso.

Pero, ¿cómo se ve esto en la práctica en las aplicaciones empresariales?

Un cliente pregunta sobre "problemas de pago" y [redacted], El sistema de IA puede localiza instantáneamente no solo los documentos que contienen esas palabras exactas, sino También contenido relacionado sobre "problemas de facturación" y "cargos de cuenta". [redacted], y "cuotas de suscripción" [redacted], Porque todos existen en el mismo vecindad del espacio vectorial.

Los modelos de incrustación y “incrustadores”

Pero ahora te preguntarás: "¿Cómo transformo mis datos en vectores?"

Los datos se representan como vectores a través de algoritmos especializados.

llamados modelos de incrustación. Estos modelos, que a menudo incorporan

El aprendizaje automático o las funciones matemáticas pueden transformar una amplia variedad de tipos de datos en representaciones numéricas en forma de vectores que permiten a los sistemas de IA comprender las relaciones y encontrar Similitudes en múltiples dimensiones. Texto, imágenes, video y

Las aplicaciones más comunes son las de voz, pero los modelos de incrustación también pueden

representan prácticamente cualquier tipo de datos e incluso combinaciones complejas de datos que capturan estados o contextos específicos.

Las herramientas que realizan esta transformación de datos, comúnmente llamadas *incrustadores*, es donde ocurren las verdaderas matemáticas. No todos

El conjunto de datos es idéntico y, claramente, un vídeo tiene requisitos de incrustación diferentes a los del texto simple. El incrustador es el motor de generación de vectores y, a menudo, se convierte en el componente más solicitado del diseño general del sistema. No es raro que los clientes realicen pruebas A/B (comparando dos enfoques diferentes para ver cuál funciona mejor) con diferentes incrustadores para identificar el que mejor se adapta a sus necesidades específicas (cada incrustador tiene su propia base matemática, y algo que funciona bien con documentos de seguros alemanes puede no ser tan efectivo para documentos de atención médica en Malasia).

Dependiendo de si los equipos provienen del área de desarrollo de aplicaciones o de la ciencia de datos, los integradores se perciben de manera muy diferente. Los desarrolladores de aplicaciones a menudo los ven como herramientas básicas para serializar datos en un formato utilizable, mientras que los científicos de datos y los especialistas en IA los reconocen como componentes críticos que pueden determinar el éxito o el fracaso de toda una solución de IA. La elección de La incorporación de un modelo puede tener un impacto drástico en la relevancia de la búsqueda, la comprensión semántica y el rendimiento general del sistema.

Un buen ejemplo de modelos de incrustación de alto rendimiento es la suite de modelos de incrustación de Voyage AI, optimizada específicamente para tareas de recuperación y que ofrece un rendimiento de vanguardia en diferentes dominios y tipos de datos. Estos modelos demuestran cómo los incrustadores especializados pueden mejorar significativamente la calidad de las representaciones vectoriales y, en consecuencia, la eficacia de las aplicaciones de IA.




Figura 2.3: Cómo los modelos de incrustación convierten diversos tipos de datos no estructurados en representaciones vectoriales

La Figura 2.3 muestra cómo los modelos de incrustación, como Voyage AI, convierten datos no estructurados en representaciones vectoriales para su procesamiento por IA.

La visualización muestra el proceso de transformación a través de varias etapas clave:

1. Datos de entrada: varios tipos de datos no estructurados (documentos de texto, imágenes, audio y vídeo) sirven como punto de partida para el proceso de incorporación.
2. Procesamiento opcional de datos: Dependiendo del tamaño y la complejidad de los datos de entrada, es posible que algunos contenidos requieran preprocesamiento para garantizar que se ajusten a los límites de capacidad del modelo de incrustación. Este paso opcional, denominado ^{es lo máximo} fragmentación, suele ser necesario para documentos de texto grandes que superan las limitaciones del modelo, aunque también puede aplicarse a otros tipos de datos. Más adelante en este capítulo, analizaremos las estrategias de fragmentación y las prácticas recomendadas en detalle.

3. Transformación de incrustación: el modelo de incrustación (como Voyage AI) convierte todos los datos, ya sean procesados o directos, en representaciones vectoriales numéricas que capturan el significado semántico y las relaciones dentro del contenido original.
4. Salida vectorial: el resultado es una colección de vectores numéricos que permiten a los sistemas de IA comprender y comparar matemáticamente el significado de diferentes piezas de contenido.

El diagrama ilustra que, si bien algunos datos siguen una ruta directa al modelo de incrustación, otros contenidos pueden requerir un procesamiento intermedio según las restricciones de tamaño o complejidad. Todas las rutas conducen, en última instancia, al mismo resultado: representaciones vectoriales que permiten una búsqueda, recuperación y razonamiento de IA eficientes en diversos tipos de datos.

Obtenga más información sobre los modelos de integración de

Voyage AI aquí: <https://www.voyageai.com>

Bases de datos vectoriales y su importancia. Una vez que los modelos de incrustación hayan transformado sus datos en vectores, necesita un sistema para almacenar, gestionar y buscar eficientemente en estas representaciones vectoriales, ya sea mediante bases de datos vectoriales dedicadas o bases de datos con funcionalidad de búsqueda vectorial integrada. El enfoque integrado ofrece la ventaja de mantener los datos originales y sus representaciones vectoriales en un solo lugar, eliminando la necesidad de realizar uniones complejas entre varias bases de datos.

El almacenamiento de los vectores se puede lograr en un formato JSON simple, alineado con el conjunto de datos fuente real. Este enfoque tiene ventajas significativas: se pueden almacenar múltiples vectores junto con...

Los datos y los conjuntos de datos pueden tener diferentes vectores adjuntos para diversos propósitos, como el sentimiento del cliente, el comportamiento de compra o las recomendaciones de la siguiente mejor oferta, que cubren una variedad de usos minoristas típicos. casos.

La segunda parte del trabajo implica funciones de búsqueda rápida. Una vez que se tienen millones de vectores almacenados, se necesita una forma de encontrar rápidamente los más similares al ejecutar una consulta. Esta función de búsqueda es la esencia de lo que ofrecen las bases de datos vectoriales. Aquí es donde se pone interesante: las bases de datos tradicionales almacenan y recuperan datos exactos (como nombres de clientes o importes de pedidos). Pero las bases de datos vectoriales se centran principalmente en la búsqueda por similitud, encontrando vectores cercanos al vector de consulta (como se mostró anteriormente). En ese sentido, se parecen más a motores de búsqueda sofisticados que a las bases de datos tradicionales.

Naturalmente, los proveedores de bases de datos vectoriales puras pueden estar totalmente en desacuerdo con esta posición, por lo que mantenemos el término base de datos vectorial en este contexto como un término estándar de la industria.

Las bases de datos vectoriales almacenan información organizacional, que los sistemas de IA pueden consultar y utilizar como contexto adicional. Cuantos más datos pueda almacenar y con mayor precisión pueda representarlos, más amplio será su espacio de información para abordar problemas empresariales específicos.

Es importante reconocer que tanto los modelos como los vectores pueden necesitar actualizaciones frecuentes en función de nuevas investigaciones, requisitos cambiantes o simplemente descubrir que el modelo de integración elegido no es óptimo para la tarea.

Estos sistemas especializados son componentes críticos en las aplicaciones de IA modernas por varias razones clave:

- **Búsqueda eficiente de similitudes:** En esencia, las bases de datos vectoriales se destacan por realizar búsquedas rápidas de similitudes, a menudo mediante algoritmos de vecino más cercano aproximado (RNA), a veces mejorados con técnicas como la agrupación en clústeres de K-medias, para encontrar los vectores más similares entre miles de millones de entradas. Esta capacidad es fundamental para aplicaciones como la búsqueda semántica, los motores de recomendación y la detección de anomalías.
- **Escalabilidad:** están diseñados para manejar los conjuntos de datos masivos que requiere la IA actual, proporcionando la infraestructura para administrar y consultar miles de millones de vectores sin comprometer el rendimiento.
- **Soporte multimodal:** estas bases de datos pueden almacenar representaciones vectoriales de varios tipos de datos, incluidos texto, imágenes, audio y datos de series de tiempo en un sistema unificado.
- **Capacidades de integración:** Las bases de datos vectoriales están diseñadas para conectarse sin problemas con varios marcos y herramientas de IA, lo que facilita su integración en flujos de trabajo de IA y MLOps más amplios.

Para lograr estas capacidades, las bases de datos vectoriales emplean diversas tecnologías avanzadas. Una innovación clave es el uso de algoritmos de indexación avanzados para acelerar las búsquedas de similitud. Una de las implementaciones más destacadas y ampliamente adoptadas es el algoritmo Hierarchical Navigable Small World (HNSW)[5]. HNSW construye una estructura de grafo jerárquica que permite un recorrido y una búsqueda eficientes, acelerando significativamente los tiempos de consulta en comparación con los métodos de fuerza bruta. Este algoritmo no solo ofrece un alto rendimiento, sino también una gran adaptabilidad, lo que lo convierte en una opción popular para bases de datos como MongoDB y Pinecone.

Otra capacidad relativamente nueva en las principales bases de datos vectoriales es la cuantificación vectorial. La cuantificación es el proceso de reducir los vectores de alta fidelidad a menos bits. Reduce la cantidad de memoria principal necesaria para almacenar cada vector en un índice de búsqueda vectorial, indexando en su lugar los vectores de representación reducidos. Esto permite almacenar más vectores o vectores de mayores dimensiones.

Por lo tanto, la cuantificación reduce el consumo de recursos y mejora la velocidad.

Para las implementaciones empresariales, es fundamental considerar aspectos adicionales. En industrias reguladas, es posible que sea necesario conservar los modelos de incrustación y los vectores generados durante períodos considerables. Las organizaciones suelen requerir múltiples incrustaciones vectoriales para un mismo documento con el fin de representar diferentes aspectos o modalidades. Por ejemplo, una base de datos de fauna silvestre podría almacenar tanto una incrustación de descripción (representación vectorial de la descripción textual) como una incrustación de imagen (representación vectorial de la fotografía del animal), o utilizar diferentes modelos de incrustación optimizados para diversas tareas de búsqueda. Además, la implementación de la tecnología de índice de tiempo de vida (TTL), que actúa como un temporizador de caducidad y archiva los datos históricos, resulta crucial para mantener el cumplimiento normativo y, al mismo tiempo, gestionar los costes de almacenamiento. La funcionalidad TTL permite a las organizaciones conservar las incrustaciones vectoriales y los documentos asociados durante los periodos regulatorios requeridos (como 7 años para registros financieros), a la vez que elimina automáticamente los datos obsoletos para evitar que los costes de almacenamiento aumenten indefinidamente.

Las bases de datos basadas en documentos, como MongoDB, con funciones integradas de búsqueda vectorial, ofrecen ventajas adicionales. Al almacenar los datos originales junto con su representación vectorial en un solo documento, a menudo pueden eliminar por completo la necesidad de uniones complejas entre...

Diferentes bases de datos (p. ej., una base de datos relacional para metadatos y un almacén de vectores dedicado). Este enfoque unificado simplifica la arquitectura general, reduce la duplicación de datos y puede generar mejoras significativas en el rendimiento de las aplicaciones de IA.

Estas capacidades técnicas se combinan para convertir las bases de datos vectoriales en una infraestructura esencial para las aplicaciones modernas de IA. Sin embargo, antes de poder aprovechar estos sistemas eficazmente, necesitamos comprender cómo preparar nuestros datos de forma óptima mediante enfoques de fragmentación estratégica.

Estrategias de fragmentación para aplicaciones de IA. Anteriormente, presentamos la fragmentación como un paso opcional de preprocesamiento para datos que exceden los límites de capacidad del modelo de incrustación. Ahora que comprende cómo funcionan los vectores y dónde se almacenan, exploremos cómo implementar la fragmentación estratégicamente para maximizar la eficacia de sus aplicaciones de IA.

La fragmentación es más que simplemente dividir documentos grandes en fragmentos más pequeños; se trata de encontrar el equilibrio óptimo entre preservar el contexto y respetar las limitaciones técnicas. Una fragmentación deficiente puede romper las conexiones lógicas, lo que genera resultados de búsqueda irrelevantes y un rendimiento deficiente de la IA. Sin embargo, una fragmentación eficaz garantiza que cada fragmento contenga información significativa e independiente que los sistemas de IA puedan analizar con precisión.

Toda estrategia de fragmentación implica tres decisiones clave:

- Técnica de división: dónde colocar los límites de los fragmentos en función de los saltos de párrafo, los límites de las oraciones, el contenido semántico o

separadores específicos del lenguaje de programación

- Tamaño del fragmento: el número máximo de caracteres o tokens permitido por fragmento, generalmente restringido por los límites de su modelo de incrustación
- Superposición de fragmentos: superposición de contenido entre fragmentos adyacentes para preservar el contexto a través de los límites, generalmente especificado como un porcentaje del tamaño del fragmento

Exploremos cómo usar la fragmentación estratégicamente para mejorar sus aplicaciones de IA:

- La fragmentación de tamaño fijo divide los documentos en fragmentos con un número predeterminado de tokens. Si bien es fácil de implementar, este enfoque puede fragmentar oraciones o conceptos a mitad de camino, lo que podría provocar la pérdida de contexto importante.
- El tamaño fijo con superposición añade contenido superpuesto entre fragmentos para preservar la continuidad contextual. Por ejemplo, con una superposición del 20 %, cada fragmento comparte contenido con sus vecinos, lo que ayuda a mantener el flujo narrativo y reduce la pérdida de información en los límites.
- La fragmentación recursiva intenta dividir el texto en límites naturales, como párrafos, luego oraciones y luego palabras, manteniendo el contenido relacionado junto tanto como sea posible y respetando los límites de tamaño.
- La fragmentación semántica agrupa el contenido en función del significado en lugar del tamaño, utilizando la similitud de incrustación para identificar dónde cambian los temas y creando fragmentos alrededor de estos límites semánticos.

La estrategia de fragmentación óptima depende del tipo de contenido y del caso de uso, y puede evolucionar durante todo el proceso de implementación.

La documentación técnica con una estructura jerárquica clara se beneficia

de fragmentación recursiva que respeta encabezados y secciones.

El contenido o las narrativas conversacionales suelen funcionar mejor con lenguaje semántico.

Fragmentación que preserva el flujo conceptual. Al igual que con la elección de modelos de incrustación, recomendamos probar diferentes estrategias de fragmentación en una muestra representativa de sus datos y evaluar su impacto en la calidad de la recuperación.

Al diseñar su enfoque de fragmentación, tenga en cuenta los factores prácticos clave que afectan el rendimiento, el coste y la precisión. Comience con los límites de tokens de su modelo de incrustación como una restricción estricta, normalmente alrededor de 8.000 tokens para la mayoría de los modelos. Los tokens son las unidades básicas que los modelos de IA utilizan para procesar texto; considérellos como palabras individuales o partes de palabras que el modelo lee y comprende. Dado que los servicios de IA suelen cobrar en función del uso de tokens, estos se convierten esencialmente en la moneda de las operaciones de IA, comparables a las monedas en muchos juegos en línea, donde se paga por cada acción o función que se desea utilizar. Considere sus patrones de consulta típicos: si los usuarios formulan preguntas conceptuales amplias, los fragmentos más grandes con más contexto pueden tener un mejor rendimiento. Para consultas factuales específicas, los fragmentos más pequeños y centrados suelen proporcionar resultados más precisos.

Recuerde que la fragmentación de las decisiones se integra en todo el flujo de trabajo de IA. Los datos bien fragmentados mejoran la precisión de la búsqueda semántica, optimizan la calidad de la respuesta RAG y permiten un razonamiento más eficaz de los agentes, todo lo cual exploraremos en las siguientes secciones.

Las bases de datos de documentos modernas como MongoDB facilitan la experimentación con diferentes estrategias de fragmentación, lo que le permite probar múltiples enfoques y optimizarlos para su caso de uso específico sin cambios complejos en la infraestructura.

Obtenga más información sobre la

fragmentación en <https://www.mongodb.com/resources/basics/chunking-explained>.

Búsqueda semántica: Poniendo los vectores a trabajar

Tras haber establecido cómo fragmentar los datos eficazmente para obtener el máximo rendimiento de la IA, estamos listos para poner en funcionamiento estos vectores optimizados mediante las capacidades de búsqueda semántica. Para utilizarlos eficazmente, implementamos índices de búsqueda vectorial que permiten la alineación semántica entre las consultas y la información almacenada. Este proceso de coincidencia de un vector de consulta con los vecinos más cercanos en nuestro espacio vectorial se denomina búsqueda semántica.

Al realizar una búsqueda vectorial, el sistema devuelve automáticamente múltiples resultados clasificados por puntuaciones de similitud. Estas puntuaciones indican la proximidad de cada resultado a la consulta original en el espacio vectorial multidimensional. Los resultados más similares (con las puntuaciones más altas) aparecen primero, según cálculos matemáticos de distancia entre vectores. Estas clasificaciones iniciales de similitud pueden refinarse mediante técnicas de reordenación, que exploraremos más adelante, para mejorar la relevancia y la calidad de los resultados obtenidos.

Para ilustrar este concepto, el limón y el plátano se posicionarían cerca en el espacio vectorial, ya que comparten atributos como el color amarillo y la fruta, pero estarían bastante alejados del gato y el perro, que se agrupan debido a sus características comunes de mamíferos y mascotas. El mono podría ubicarse en un punto intermedio entre estos grupos.

compartiendo rasgos de mamíferos y al mismo tiempo teniendo asociaciones con el consumo de fruta.

La búsqueda semántica representa un cambio fundamental respecto a los métodos tradicionales de recuperación de información y abre nuevas y poderosas posibilidades para las aplicaciones de IA. exploremos cómo funciona esta tecnología en la práctica y examinemos sus crecientes capacidades con diferentes tipos de datos.

Más allá de la coincidencia de palabras clave, la búsqueda semántica por sí sola ya es una herramienta potente que permite el uso de datos vectorizados y modelos de incrustación sin necesidad de recurrir a un LLM. A diferencia de la búsqueda tradicional basada en palabras clave, que coincide con términos exactos, la búsqueda semántica comprende el significado y el contexto de una consulta, devolviendo resultados basados en la relevancia en lugar de coincidencias exactas.

Esto funciona porque (al igual que en el ejemplo anterior del mamífero y la fruta) los modelos de incrustación posicionan conceptos semánticamente relacionados cerca en un espacio vectorial multidimensional. Conceptos como "turbinas eólicas", "solares", "energía hidroeléctrica" son todos paneles se agrupan cerca de las energías renovables porque comparten relaciones conceptuales y un significado semántico similar.

Una búsqueda semántica de soluciones de energía renovable podría arrojar resultados sobre paneles solares, turbinas eólicas y energía hidroeléctrica, incluso si no se usaron esos términos exactos en la consulta. Esta capacidad es especialmente valiosa para aplicaciones donde comprender la intención y el contexto es crucial.




Figura 2.4: Comparación entre búsqueda de palabras clave y búsqueda semántica

La figura 2.4 ilustra la diferencia fundamental entre los sistemas tradicionales Enfoques de búsqueda de palabras clave y búsqueda semántica. A la izquierda, una La búsqueda de palabras clave para soluciones de energía renovable realiza el término exacto Coincidencia, devolviendo contenido que incluye toda o parte de la búsqueda frase, como soluciones de energía renovable energía renovable , y soluciones energéticas . A la derecha, una búsqueda semántica comprende el significado subyacente y el contexto de la consulta, recuperando Resultados conceptualmente relacionados, incluida la energía renovable soluciones , turbinas eólicas , y la energía hidroeléctrica , incluso si Esos términos exactos no aparecen en el texto.

Obtenga más información sobre Atlas Vector Search aquí:

<https://www.mongodb.com/products/platform/atlas-vector-search>

Aplicaciones multimodales de la búsqueda semántica

La búsqueda semántica se puede aplicar a diversos tipos de datos, no solo a texto. Por ejemplo, se puede usar para buscar imágenes, patrones de audio o contenido de vídeo similares. Un ejemplo eficaz de búsqueda semántica multimodal sería un sistema de acción capaz de encontrar contenido relevante en diferentes tipos de medios con una sola consulta.

Considere una aplicación de venta minorista donde un cliente sube la imagen de un producto que le gusta. El sistema utiliza un LLM para determinar qué producto es el de la foto y, a continuación, realiza una búsqueda semántica para encontrar productos similares en el catálogo, coincidiendo con las características visuales, el estilo y las características, independientemente de si las descripciones del producto utilizan terminología similar. Esta capacidad permite experiencias de búsqueda más intuitivas y fáciles de usar que reflejan la percepción natural de las personas sobre las similitudes.

Las plataformas de datos modernas con funciones de búsqueda vectorial integradas facilitan la implementación de estas funciones de búsqueda avanzada. Al almacenar las incrustaciones vectoriales junto con los datos originales, permiten una búsqueda semántica eficiente en grandes conjuntos de datos sin aumentar la proliferación tecnológica ni requerir conocimientos especializados.

Comprender la búsqueda semántica es fundamental para aprovechar el potencial de las aplicaciones modernas de IA. Al transformar datos en vectores y permitir la recuperación basada en similitudes, la búsqueda semántica acorta la distancia entre el lenguaje humano y la comprensión de las máquinas. Esta capacidad sienta las bases de patrones de IA más sofisticados, como RAG, donde la calidad de la semántica...

La búsqueda impacta directamente en la precisión y relevancia de las respuestas generadas por IA. Como veremos en la siguiente sección, la combinación de la búsqueda semántica con LLM abre un potencial aún mayor para crear aplicaciones inteligentes y contextuales.

RAG: Mejorar los LLM con datos contextuales

Si bien la búsqueda semántica ofrece potentes capacidades de recuperación, combinarla con LLMs abre un potencial aún mayor. RAG representa la síntesis, un patrón donde los resultados de la búsqueda vectorial mejoran las consultas de los usuarios a LLMs, proporcionando un contexto específico que produce respuestas más precisas y fundamentadas con menos o ninguna alucinación.

Las arquitecturas RAG permiten a las organizaciones crear aplicaciones que fundamentan de forma segura la IA en datos confiables de la empresa, reduciendo así los riesgos asociados a las alucinaciones, garantizando la precisión de los datos y habilitando soluciones específicas para cada dominio. Para ser eficaces con RAG, las organizaciones deben priorizar las estrategias de datos que permitan acceder a información propietaria y actualizada para su recuperación. Desde el punto de vista arquitectónico, la planificación de las implementaciones de RAG influye en las decisiones sobre cómo los LLM se integran con los almacenes de datos existentes y en la necesidad de contar con sólidas capacidades de bases de datos vectoriales.

RAG utiliza los datos corporativos propios de la empresa, específicos del dominio, para agregar contexto a una solicitud, como proporcionar un registro del historial del cliente o una descripción del producto, lo que reduce la solicitud al LLM y ofrece respuestas más precisas y menos alucinatorias.

La capacidad de proporcionar hiperpersonalización a través de implementaciones de RAG representa un diferenciador competitivo significativo que realmente puede agregar valor a las interacciones con los clientes y convertir las tareas mundanas en línea en experiencias agradables y colaborativas.

Si bien este concepto suena complejo, su implementación en realidad es bastante simple, como se puede ver en la siguiente figura.

Cómo funciona RAG

La Figura 2.5 ilustra una implementación integral de RAG que demuestra cómo las organizaciones pueden aprovechar sus datos patentados para mejorar las respuestas de LLM.




Figura 2.5: Flujo básico del proceso RAG

Si bien las arquitecturas RAG pueden variar en complejidad, desde flujos de trabajo básicos de tres pasos (recuperación, aumento, generación) hasta implementaciones de varios pasos más sofisticadas, este diagrama muestra una

proceso detallado de ocho pasos que proporciona una visibilidad completa de la
Flujo de trabajo de RAG:

1. Preparación de documentos: El sistema recopila los datos necesarios para responde preguntas y divide documentos grandes en fragmentos manejables para garantizar que se ajusten a las restricciones del modelo de integración.
2. Generación de vectores: Los modelos de incrustación como Voyage AI convierten cada fragmento de documento en un vector numérico.
representaciones que capturan el significado semántico.
3. Almacenamiento de vectores: Estas incrustaciones de documentos, los vectores, se almacenan en bases de datos como MongoDB, y posteriormente se crea el índice de búsqueda de la base de datos de vectores. Esto crea una base de conocimiento con capacidad de búsqueda de información organizacional.
4. Procesamiento de consultas: cuando un usuario o una aplicación hace una pregunta, el sistema genera incrustaciones para esa consulta utilizando el mismo modelo de incrustación para garantizar la compatibilidad.
5. Búsqueda vectorial: las incrustaciones de preguntas se utilizan en una consulta de búsqueda vectorial para encontrar fragmentos de documentos con un significado semántico similar, recuperando la información más relevante de la base de conocimientos.
6. Aumento del contexto: La información recuperada, ya sea fiable, actualizada o datos organizativos privados, se utiliza para preparar un contexto de aviso mejorado. Esta mejora del contexto es la base de RAG.
7. Generación mejorada: el mensaje contextualizado se envía a un LLM (como GPT-4 de OpenAI, PaLM 2 de GCP, Mistral 7B o Llama 4), que genera respuestas basadas tanto en su conocimiento previamente entrenado como en el contexto recuperado.

8. Resultados optimizados: los usuarios reciben respuestas precisas y contextualmente relevantes que se basan en los datos y conocimientos específicos de la organización.

Este enfoque aborda varias limitaciones de los LLM independientes:

- Reduce las alucinaciones: basando las respuestas en hechos recuperados
- Proporciona información actualizada: recuperando datos actuales que no estaban disponibles durante el entrenamiento del modelo
- Permite la especialización del dominio: al incorporar conocimientos específicos del dominio
- Mejora la transparencia: al citar fuentes de información

Un caso de uso típico es un chatbot que aumenta la información sobre el caso que se está discutiendo con información adicional, como boletos de avión, ubicación real y estado del vuelo, por lo que la respuesta del LLM es relevante para el contexto del individuo y pone la necesidad real en el centro.

Organizaciones de todas las industrias están implementando RAG para mejorar sus aplicaciones de IA:

- Atención al cliente: Ampliar las respuestas con documentación del producto y el historial de soporte.
- Atención médica: proporcionar a los profesionales médicos investigaciones relevantes e historiales de pacientes.
- Servicios financieros: incorporación de información regulatoria y datos de mercado en los servicios de asesoramiento.
- Fabricación: Integración de manuales de equipos y registros de mantenimiento en la guía operativa. Producto y

Los documentos de ingeniería pueden hacerse accesibles.

- Seguros: Evaluación de documentos de reclamación de seguros.
- Sector público: Proporcionar información sobre proyectos de obras públicas.

Las bases de datos documentales modernas son excelentes para implementar RAG, ya que pueden almacenar tanto los datos originales como sus representaciones vectoriales en un modelo unificado. Este enfoque simplifica la arquitectura y mejora el rendimiento al eliminar la necesidad de combinar datos en múltiples sistemas.

Más allá de RAG: Enfoques de búsqueda híbrida. RAG se puede mejorar aún más utilizando la búsqueda de texto regular como una recuperación textual de información junto con la búsqueda vectorial. La combinación de búsqueda de texto y vectorial se denomina búsqueda híbrida y es solo una variante de RAG. No obstante, es potente y permite ampliar y refinar la entrada LLM con puntos de datos adicionales.

La búsqueda de texto tradicional y la búsqueda vectorial tienen ventajas complementarias:

- Búsqueda de texto: se destaca por encontrar coincidencias exactas y palabras clave específicas
- Búsqueda vectorial: mejor comprensión del significado y búsqueda de contenido semánticamente similar

La búsqueda híbrida combina estos enfoques para ofrecer resultados completos y relevantes. Por ejemplo, un sistema de búsqueda híbrido podría usar la búsqueda vectorial para comprender la intención semántica de una consulta, mientras que la búsqueda de texto garantiza la presencia de términos específicos en los resultados.



Figura 2.6: Arquitectura de búsqueda híbrida que combina búsqueda de texto y vectorial

La Figura 2.6 muestra cómo la búsqueda híbrida mejora RAG al combinar las capacidades de búsqueda de texto y búsqueda vectorial. El sistema procesa las consultas mediante dos rutas paralelas: la búsqueda vectorial (izquierda) gestiona la comprensión semántica y encuentra contenido conceptualmente similar, mientras que la búsqueda de texto (derecha) realiza la coincidencia exacta de palabras clave y la identificación precisa de términos. Los resultados de ambos enfoques se combinan mediante un algoritmo de fusión que ofrece una mayor precisión al aprovechar las ventajas complementarias de la comprensión semántica y la coincidencia de términos específicos antes de ampliar la propuesta LLM.

Reordenamiento: Refinando los resultados de búsqueda. La mejora final en el proceso de recuperación es el reordenamiento, un proceso que mejora el contexto recuperado antes de entregarlo al LLM. Como su nombre indica, el reordenamiento reordena los resultados de búsqueda basándose en una comprensión más profunda de su relevancia para la consulta original. Esto suele implicar cuatro pasos:

1. Recuperación inicial: recopilación de un conjunto más amplio de datos potencialmente relevantes documentos
2. Evaluación contextual: evaluar la relevancia de cada documento para la consulta específica en contexto.
3. Priorización: Reordenar los resultados en función de esta información más profunda. evaluación
4. Selección: Elegir los documentos más relevantes para incluir en El mensaje del LLM

Este proceso mejora significativamente la calidad de la información proporcionada al LLM, lo que resulta en respuestas más precisas y útiles. Las plataformas de datos modernas con funciones de búsqueda integradas simplifican la implementación de estos sofisticados patrones de recuperación, permitiendo a los desarrolladores centrarse en la lógica de la aplicación en lugar de en la infraestructura.



Figura 2.7: Proceso de búsqueda híbrido

La figura 2.7 ilustra un ejemplo práctico de búsqueda híbrida en acción, mostrando cómo el sistema procesa un lenguaje natural complejo.

Consulta: "¿Cuál es la canción de rock de los 80 que aparece en una escena de película donde un adolescente va en patineta detrás de coches?" . El proceso demuestra que la búsqueda vectorial captura el significado semántico de la consulta, mientras que la búsqueda de texto completo , "coches" . El identifica palabras clave específicas como "película " y enfoque híbrido conecta estos métodos de búsqueda complementarios para del Amor" de la película Regreso al Futuro identificar con éxito "El Poder" , demostrando cómo la combinación de la comprensión semántica con la coincidencia precisa de palabras clave ofrece resultados precisos que ningún enfoque podría lograr por separado.

Como se ilustra en la figura, la búsqueda híbrida es excelente para gestionar consultas complejas en lenguaje natural, con las que los métodos de búsqueda tradicionales tendrían dificultades. En este ejemplo, se dan los siguientes pasos:

1. La búsqueda vectorial captura el significado semántico de la consulta sobre una canción de rock de los 80 en una escena de skate.
2. La búsqueda de texto completo identifica palabras clave específicas , y autos . patineta . como películas
3. La búsqueda híbrida combina estos enfoques para conectar los puntos conceptuales.
4. El sistema identifica con éxito "El Poder del Amor" de La película Regreso al futuro como respuesta.

Este ejemplo demuestra cómo la búsqueda híbrida puede comprender tanto el contexto (una escena de película memorable) como detalles específicos (andar en patineta detrás de automóviles) para ofrecer resultados precisos que ningún enfoque podría lograr por sí solo.

Inteligencia artificial agente: automatización de la toma de decisiones y el razonamiento

Si bien RAG y la búsqueda híbrida mejoran los LLM con conocimiento externo, aún requieren iniciativa y supervisión humanas. El siguiente paso evolutivo elimina esta limitación, creando sistemas que pueden perseguir objetivos y tomar decisiones de forma autónoma dentro de su dominio designado. Este es el ámbito de la IA agencial.

Esta transición de sistemas de IA guiados por humanos a sistemas de IA autónomos representa más que un simple avance tecnológico; es un cambio fundamental en la forma en que conceptualizamos el rol de la IA en las operaciones comerciales. Mientras que los sistemas RAG destacan por brindar respuestas optimizadas a consultas específicas, los sistemas de IA agéntica pueden identificar problemas de forma independiente, formular estrategias y ejecutar soluciones en flujos de trabajo extensos. Las instancias colaborativas de IA agéntica desarrollan un alcance funcional más amplio que representa el concepto de experto digital, actuando como un experto en la materia dentro de una organización.

Fundamento de la IA de Agentic. La IA de Agentic incorpora una capa de orquestación que gestiona la ejecución de tareas en los flujos de trabajo. Los agentes de IA pueden operar de forma totalmente autónoma o semiautónoma, con intervención humana (HITL). Los agentes de IA están equipados con herramientas avanzadas, modelos, memoria y almacenamiento de datos. La memoria aprovecha los datos contextuales a corto y largo plazo para una toma de decisiones informada y la continuidad de las interacciones. Las herramientas y los modelos permiten a los agentes de IA des

Divida las tareas en pasos y ejecútelas de forma coherente. El almacenamiento y la recuperación de datos son fundamentales para la eficacia de los agentes de IA y pueden mejorarse mediante la integración y las capacidades de búsqueda vectorial.




Figura 2.8: Fundamento de la IA agente

La figura 2.8 ilustra las capas fundamentales de los sistemas de IA agentic y muestra cómo el orquestador gestiona los flujos de trabajo de ejecución de tareas.

La visualización representa la relación entre los agentes de IA, sus herramientas, modelos y sistemas de memoria que permiten el funcionamiento autónomo o semiautónomo con capacidades HITL.

Estas son algunas características clave de un agente de IA:

- **Autonomía:** La capacidad de tomar decisiones en función de la situación de forma dinámica y ejecutar tareas con un mínimo esfuerzo humano.

intervención

- Cadena de pensamiento: La capacidad de realizar razonamientos paso a paso y dividir problemas complejos en pasos lógicos más pequeños para un mejor juicio y toma de decisiones.
- Consciente del contexto: los agentes de IA adaptan continuamente sus acciones en función del entorno y las condiciones cambiantes.
- Aprendizaje: Los agentes de IA mejoran su rendimiento con el tiempo adaptándose y mejorando

La IA con agentes representa un avance significativo hacia la automatización de flujos de trabajo complejos y la toma de decisiones, marcando el siguiente paso evolutivo en nuestra trayectoria hacia la IA. Las organizaciones podrían comenzar a planificar estratégicamente cómo estos sistemas autónomos se integrarán en la arquitectura empresarial, considerando el acceso a los datos, los protocolos de seguridad y los marcos de gobernanza. El desarrollo y la implementación de agentes de IA y expertos digitales requerirán nuevas habilidades y, potencialmente, nuevos roles dentro de las operaciones de TI y de negocio, por lo que es esencial que los líderes con visión de futuro comiencen a evaluar estas necesidades ahora.

Sobre la base de estas capacidades de recuperación y generación, se automatizan los procesos y el razonamiento en un entorno contenido, lo que da origen al concepto de IA agéntica. Si bien los agentes de toma de decisiones basados en motores de reglas existen desde hace mucho tiempo, el concepto de IA agéntica es mucho más refinado. Estos sistemas sofisticados dependen en gran medida de datos robustos, accesibles y bien estructurados, así como de capacidades avanzadas de orquestación. Esto refuerza la importancia crucial de una plataforma de datos moderna y flexible que pueda servir como memoria y capa de acceso a herramientas para estos agentes.

¿Qué es un agente?

Un agente de IA es un sistema autónomo que puede percibir su entorno, tomar decisiones y actuar para alcanzar objetivos específicos. A diferencia de los sistemas de IA más sencillos que realizan tareas específicas de forma aislada, los agentes operan con cierto grado de autonomía y pueden adaptar su comportamiento en función de la retroalimentación y las condiciones cambiantes.




Figura 2.9: Arquitectura del agente de IA y componentes principales

La Figura 2.9 ilustra la estructura fundamental de un sistema de agente de IA, mostrando cómo los usuarios asignan tareas y reciben resultados a través de los componentes principales del agente. La arquitectura demuestra cómo estos componentes trabajan juntos para permitir la toma de decisiones y la ejecución de tareas de forma autónoma, permitiendo al agente percibir su entorno, procesar información y tomar medidas para alcanzar objetivos específicos, adaptándose a la retroalimentación y a las condiciones cambiantes.

Los componentes principales de un agente de IA incluyen lo siguiente:

- Instrucciones y objetivos: El propósito y los objetivos del agente que guían todos los procesos de toma de decisiones.
- Memoria: Tanto a corto plazo (para el contexto de la tarea actual) como a largo plazo (para el conocimiento persistente), lo que permite la continuidad entre interacciones.
- Orquestación: Capacidades de planificación y razonamiento que determinan acciones y coordinan entre diferentes componentes.
- Herramientas: Capacidades específicas que el agente puede utilizar para interactuar con su entorno y ejecutar tareas.
- Modelos: Los modelos de IA subyacentes que potencian las capacidades del agente, desde la comprensión del lenguaje hasta la toma de decisiones.
- Datos: La información a la que el agente puede acceder y utilizar, almacenada en varios formatos y actualizada dinámicamente.

La IA agéntica se aplica en diversos ámbitos para automatizar procesos complejos de toma de decisiones: los servicios financieros implementan agentes de gestión de cartera que analizan las tendencias del mercado, evalúan el riesgo y recomiendan estrategias de inversión. Las organizaciones sanitarias utilizan agentes de diagnóstico que revisan el historial del paciente, los síntomas y la literatura médica para sugerir posibles diagnósticos y tratamientos.

Las empresas de manufactura y logística implementan agentes que optimizan el enrutamiento, el inventario y la programación según las condiciones en tiempo real. Las plataformas de datos modernas con modelos documentales y funciones de búsqueda vectorial son ideales para estas aplicaciones. Proporcionan la infraestructura flexible y escalable necesaria tanto para la memoria del agente (a corto y largo plazo) como para el almacenamiento de datos diversos, a la vez que permiten una recuperación rápida y contextualizada, esencial para una toma de decisiones eficaz.

Expertos digitales o sistemas multiagente: Resolución colaborativa de problemas. Los sistemas multiagente representan un nivel superior de sofisticación, donde múltiples agentes de IA colaboran para resolver tareas complejas. Cada agente se especializa en capacidades específicas, lo que permite una resolución de problemas más sofisticada mediante la colaboración.




Figura 2.10: Evolución de RAG a sistemas multiagente

La Figura 2.10 ilustra la evolución de los chatbots RAG simples a sofisticados sistemas multiagente. A medida que aumenta la madurez de los agentes (eje x), también lo hace la complejidad organizacional (eje y), pasando de asistentes de IA individuales a agentes colaborativos especializados que trabajan en diferentes ámbitos, como la producción y la gestión de calidad.

En un sistema multiagente, diferentes agentes pueden hacer lo siguiente:

1. Especializarse en diferentes dominios: algunos pueden sobresalir en datos otros en el análisis, otros en la comprensión del lenguaje natural y otros en la planificación

2. Colaborar en tareas complejas: dividir los problemas en Componentes manejables 3.

Comunicar y compartir información: Pasar datos y conocimientos relevantes entre agentes 4. Proporcionar

controles y equilibrios: Verificar el trabajo de los demás y detectar errores

A medida que los sistemas de IA maduran, su uso de datos estructurados y no estructurados aumenta exponencialmente. Los sistemas que admiten modelos de datos flexibles (que admiten series temporales, datos relacionales y vectoriales) con capacidades integradas de búsqueda vectorial se vuelven esenciales para implementaciones multiagente eficaces.

Cómo funciona la IA agentic. Desde una perspectiva técnica, la interacción del usuario con los sistemas agentic sigue patrones API familiares, pero con un procesamiento subyacente sofisticado. El agente realiza una planificación multietapa para interpretar con precisión la intención del usuario y contextualizar las consultas.

Este enfoque difiere fundamentalmente del software determinista, que sigue una ruta predefinida. Los agentes determinan dinámicamente su enfoque en función del contexto y los objetivos, lo que marca dónde surge el verdadero valor del enfoque GenAI.

El agente aprovecha varias herramientas, incluida la búsqueda vectorial, la búsqueda de texto y el aumento de datos, para crear un contexto completo. Esto puede incorporar información a largo plazo, como tendencias históricas, datos de transacciones y análisis estadísticos. Al sintetizar este amplio espectro de información y acceder a sus propios almacenes de datos y vectorizaciones, el agente puede proporcionar un contexto completo al LLM para...

Razonamiento y recuperación. Tras reordenar las respuestas, estructura respuestas formales para el cliente solicitante.




Figura 2.11: Flujo de trabajo y arquitectura del sistema de IA de Agentic

La figura 2.11 ilustra el flujo de trabajo completo de un sistema de IA agente.

mostrando cómo se procesan las consultas de los usuarios a través de cuatro etapas principales: Planificación, Percepción, Herramientas , y Memoria .

El sistema procesa cada consulta del usuario moviéndose a través de estos cuatro Etapas interconectadas para ofrecer respuestas inteligentes y contextualizadas:

1. Planificación, donde el agente utiliza la reflexión para analizar lo que el usuario pregunta, emplea una cadena de pensamiento para descomponer Razona en pasos lógicos y utiliza la descomposición para dividir los elementos complejos. tareas en partes más pequeñas y aplica ReAct para planificar el razonamiento y pasos de acción de forma iterativa mientras se determina la estrategia general para respondiendo a la consulta.

Percepción, que implica la recopilación de datos de diversas fuentes, 2.

Incluyendo JSON, CSV y colecciones, mientras que los sistemas de bases de datos como MongoDB Atlas sirven como el centro de datos central. Para datos no estructurados, esta etapa utilizará la búsqueda vectorial para procesar datos y lograr comprensión semántica, recopilar información de múltiples bases de datos y formatos, y contextualizar los datos relevantes para la consulta específica del usuario. Donde las

3. Herramientas , herramientas de búsqueda vectorial encuentran información

semánticamente similar, las herramientas de recuperación de datos acceden a información específica de las bases de datos, las herramientas de procesamiento especializadas manipulan y analizan los datos recopilados, las integraciones externas proporcionan capacidades adicionales según sea necesario, y el sistema ejecuta funciones

a largo plazo específicas requeridas para responder a la consulta. Mantiene memoria para almacenar memoria persistente, conocimiento y experiencias pasadas, memoria a corto plazo para mantener el contexto de la conversación actual, integración de aprendizaje para actualizar la base de conocimiento del agente, preservación del contexto para gestionar preguntas de seguimiento y almacenamiento de datos históricos en colecciones de bases de datos para futuras referencias.

A lo largo de este proceso, el agente central de IA coordina las cuatro etapas para proporcionar respuestas inteligentes contextualizadas, y el sistema adapta dinámicamente su enfoque en función del contexto y los objetivos en lugar de seguir caminos predeterminados.

Este marco propuesto representa la materialización práctica de la evolución de la IA que hemos rastreado desde los sistemas RAG básicos hasta los agentes autónomos. Al aprovechar su infraestructura de datos y capacidades de búsqueda existentes, las organizaciones pueden implementar rápidamente agentes que proporcionen...

valor comercial inmediato al tiempo que establece las bases para sistemas multiagente más avanzados.

La idea clave es que la implementación exitosa de un agente no consiste en reemplazar los sistemas existentes, sino en orquestarlos de manera inteligente para crear capacidades autónomas y orientadas a objetivos que se adapten a las necesidades de su organización.

Resumen

Este capítulo rastreó la evolución de la IA desde sus orígenes en la década de 1950 hasta los sofisticados sistemas GenAI actuales. Exploramos los componentes fundamentales que impulsan las aplicaciones modernas de IA, incluyendo los LLM, los modelos de incrustación que transforman datos en vectores y las capacidades de búsqueda semántica que posibilitan el razonamiento de la IA.

Aclaramos las distinciones entre búsqueda semántica (comprensión del significado de las consultas), RAG (mejora de los LLM con contexto externo), enfoques de búsqueda híbridos (combinando coincidencia semántica y de palabras clave) y sistemas de IA agenticos (toma de decisiones autónoma).

Más importante aún, examinamos cómo estos componentes se complementan entre sí para crear capacidades cada vez más sofisticadas.

A lo largo de estos avances, las plataformas de datos modernas han desempeñado un papel crucial en la innovación en IA. Elegir la plataforma de datos adecuada, flexible, escalable y compatible de forma nativa con estas diversas cargas de trabajo de IA, desde la búsqueda vectorial hasta los modelos de datos complejos para la memoria agéntica, se convierte en un factor clave para la innovación y la ventaja competitiva en la era de la GenAI. Al comprender estos conceptos y sus relaciones, las organizaciones pueden tomar decisiones más informadas sobre cómo aprovechar la IA para generar valor empresarial.

El siguiente capítulo examinará por qué los datos son el factor diferenciador clave para las empresas que invierten en innovación. Analizará por qué la consolidación de los datos operativos en una sola capa es crucial para avanzar en las iniciativas de IA, abarcando los requisitos de datos en tiempo real, la importancia de los datos bien estructurados, el flujo de datos y los enfoques de integración.

Referencias

1. Una historia muy breve de la inteligencia artificial (IA):

<https://www.forbes.com/sites/gilpress/2016/12/30/una-muy-corta-historia-de-la-inteligencia-artificial-ai/>

2. Referencia de Oxford:

<https://www.oxfordreference.com/display/10.1093/acref/9780198609810.001.0001/acref-9780198609810-e-423>

3. ¿Qué pasó con Watson de IBM?

<https://www.nytimes.com/2021/07/16/technology/wh-at-happened-ibm-watson.html>

4. La atención es todo lo que necesitas:

<https://arxiv.org/abs/1706.03762>

5. ¿Qué es un mundo pequeño navegable jerárquico?:

<https://www.mongodb.com/resources/basics/hierarchical-navigable-small-world>

3

El sistema de acción

Los datos son la base para convertir GenAI en resultados empresariales medibles. Las capacidades basadas en IA, como la codificación vectorial de datos no estructurados, la síntesis en tiempo real entre silos y la integración de agentes, están transformando la forma en que realizamos negocios. Las empresas que dominan estas capacidades pueden pasar de decisiones reactivas y aisladas a operaciones proactivas basadas en inteligencia, respondiendo a los cambios del mercado en tiempo real, reduciendo los gastos operativos y generando resultados más sólidos para los clientes.

Aumentar y automatizar los flujos de trabajo empresariales con agentes en el circuito exige mayores exigencias a la capa de datos subyacente. Los agentes pueden acceder y analizar una gran cantidad de fuentes aisladas, generar un contexto completo e informar las decisiones empresariales. Pero ¿dónde se mantiene ese contexto? ¿Cómo pueden los usuarios comerciales ver, interactuar o incluso editar eso? ¿información?

Para impulsar esta evolución, las empresas deben ir más allá de los sistemas estáticos de registro , que almacenan y sirven datos de forma pasiva, hacia y adoptar sistemas dinámicos de acción: sistemas diseñados para la toma de decisiones en tiempo real, la automatización y la colaboración entre humanos, usuarios asistidos por IA y agentes totalmente autónomos para actuar sobre los datos. Si bien los sistemas de registro tradicionales destacan por mantener la integridad y el cumplimiento normativo de los datos, los sistemas de acción pueden tomar decisiones, ejecutar flujos de trabajo y...

Aprender de los resultados. Por ejemplo, en el comercio minorista, un agente de IA podría reordenar el inventario en tiempo real a medida que cambia la demanda del cliente.

Este capítulo explora cómo los sistemas de acción transforman los datos en decisiones: un cambio inevitable. Deben gestionar datos en diversos formatos (desde fuentes originales e índices de búsqueda de texto hasta incrustaciones vectoriales) e incluso entradas LLM que requieren una reclasificación contextual, un proceso para priorizar los resultados más relevantes.

Satisfacer estas demandas requiere una visión unificada y contextualizada de los datos empresariales que supere lo que sus sistemas de registro y de información anteriores podían ofrecer. Este cambio también presenta nuevos desafíos en cuanto a escalabilidad, rendimiento, seguridad y gobernanza.

Al final de este capítulo, comprenderá cómo:

- Las bases de datos del sistema de acción respaldan las aplicaciones de IA y RAG en tiempo real al romper las limitaciones del modelado de datos tradicional y permitir el procesamiento de señales con capas de datos receptivas basadas en documentos.
- El acceso unificado a los datos permite a GenAI procesar diversos formatos, como datos de origen, incrustaciones y señales en tiempo real, dentro de un marco coherente.
- La calidad y la consistencia de los datos reducen las alucinaciones y mejoran la confiabilidad mediante el seguimiento completo del linaje y la procedencia.
conciencia
- Las arquitecturas de datos preparadas para IA rompen con los almacenes y sistemas de información tradicionales y admiten cargas de trabajo dinámicas y multimodelo.
- Las estrategias de gobernanza y seguridad se alinean con las necesidades específicas de la IA, como la privacidad, los controles de acceso y el cifrado.

- Las canalizaciones de entrenamiento y ajuste de modelos preparan y optimizan los datos para las aplicaciones GenAI
- Los patrones de implementación siguen el flujo desde la ingesta de señales a través del enriquecimiento hasta la respuesta inteligente, proporcionando planes de implementación.

Construyendo una base de datos preparada para la IA

Cumplir la promesa de los sistemas de acción requiere un nuevo tipo de base de datos: una diseñada para la velocidad, el contexto y la adaptabilidad.

Los sistemas de IA agéntica difieren fundamentalmente de los sistemas de registro tradicionales en sus exigencias operativas. Mientras que los sistemas tradicionales se centran en la captura y el almacenamiento de transacciones históricas, los sistemas de acción impulsados por IA agéntica requieren toma de decisiones en tiempo real, síntesis dinámica de datos y capacidad de respuesta inmediata. Este cambio exige que nuestras decisiones sobre arquitectura de datos trasciendan las estructuras rígidas y aisladas de los sistemas empresariales tradicionales.

Una visión unificada del núcleo empresarial es esencial. Debe integrar los diversos tipos de datos de los que dependen los agentes autónomos (señales operativas en tiempo real, documentos contextuales, incrustaciones vectoriales) en una plataforma única y coherente. Esta plataforma debe construirse sobre estructuras de datos flexibles que puedan adaptarse a la evolución del comportamiento de los agentes.

La transición del respaldo de sistemas pasivos de registro a la habilitación de sistemas activos de acción introduce seis requisitos arquitectónicos críticos que distinguen la infraestructura de IA agente de los enfoques tradicionales:

- Acceso unificado a datos para eliminar la complejidad de administrar múltiples almacenes de datos dispares
- Mecanismos de calidad y consistencia de datos que reducen las alucinaciones y los errores de sistemas desincronizados
- Capacidades de contexto en tiempo real que permiten el procesamiento inmediato de señales para aplicaciones RAG
- Características de escalabilidad y rendimiento que respaldan la IA operativa en lugar de solo análisis retrospectivos
- Marcos de gobernanza y seguridad que protegen la información confidencial al tiempo que permiten la innovación
- Flujos de trabajo de entrenamiento de modelos eficientes que optimizan la preparación de datos para aplicaciones GenAI

Juntos, estos elementos forman la base de datos para sistemas autónomos e inteligentes.

Al examinar cada uno de ellos en las siguientes secciones, veremos cómo una base de datos de sistemas de acción se aleja de la gestión de datos tradicional y permite aplicaciones de IA más inteligentes, ágiles y escalables.

¿Qué es un sistema de acción?

Los sistemas de acción son una nueva clase de aplicación empresarial, diseñados para ejecutar decisiones e impulsar flujos de trabajo en tiempo real. Facilitan la colaboración entre personas, usuarios asistidos por IA y agentes de IA, facilitando todo, desde la toma de decisiones asistida hasta la ejecución totalmente autónoma.

A diferencia de los sistemas de registro, que almacenan pasivamente transacciones históricas, o los sistemas de conocimiento, que analizan los datos retrospectivamente, los sistemas de acción operan en el momento.

Procesar contexto dinámico, tomar decisiones y ejecutar tareas mediante agentes de IA. Por ejemplo, podrían desviar un vuelo retrasado en tiempo real o ajustar automáticamente la dotación de personal del hospital durante un aumento repentino de pacientes.

Construir sistemas de acción requiere más que capacidades analíticas.

Deben ingerir señales de streaming, analizar fuentes estructuradas y no estructuradas, y responder en tiempo real. Requieren arquitecturas de bases de datos especializadas capaces de gestionar flujos de datos multimodales de alta velocidad y soportar transiciones de estado complejas a lo largo del tiempo. La mayoría de los sistemas heredados, diseñados para flujos de trabajo estáticos y por lotes, simplemente no pueden soportar este tipo de inteligencia continua.




Figura 3.1: Panorama del sistema empresarial: del sistema de registro al sistema de acción

La figura 3.1 ilustra esta evolución en el panorama empresarial.

A diferencia de los sistemas tradicionales que almacenan pasivamente o analizan datos retrospectivamente, los sistemas de acción permiten la interacción en tiempo real entre

usuarios, aplicaciones y agentes; todos impulsados por una capa de datos dinámica y adaptable.

Arquitectura unificada de acceso a datos

La base de cualquier sistema GenAI comienza con el acceso a datos diversos y multimodales, a velocidad y en formatos con los que la IA puede razonar.

Lamentablemente, aquí es también donde la mayoría de las empresas tienen problemas.

Las arquitecturas de datos empresariales tradicionales están fragmentadas en docenas de sistemas incompatibles, cada uno optimizado para casos de uso específicos. El resultado son dificultades de integración, fricción en el acceso y una sobrecarga masiva.

Las aplicaciones modernas de IA exigen un cambio fundamental: el acceso unificado debe considerarse no como una conveniencia sino como un prerequisite.

Los modelos actuales deben gestionar una amplia variedad de entradas: documentos de texto, registros de aplicaciones, catálogos de productos, transcripciones de soporte y transmisión de datos de sensores. Los sistemas relacionales y heredados a menudo almacenan datos semiestructurados (como JSON o XML) como objetos binarios grandes (BLOB) u objetos grandes de caracteres (CLOB), lo que limita su utilidad para los sistemas de IA. En estos casos, los datos reales están ocultos en una única entrada y deben extraerse e interpretarse antes de poder razonar sobre ellos o actuar en consecuencia. Esto era tolerable cuando el objetivo era almacenar y recuperar archivos. Pero para los sistemas GenAI, donde los modelos necesitan acceso inmediato a datos estructurados y semiestructurados, a menudo en la misma consulta, este formato se convierte en un cuello de botella. Incluso un vídeo puede tener su propia estructura de metadatos direccionable, en lugar de existir únicamente como un BLOB opaco, lo que ilustra el cambio necesario para dar soporte al razonamiento nativo de la IA.

Más allá del problema de formato hay un desafío más urgente: la fragmentación.

Una aplicación de IA podría necesitar unir el contexto de un CRM (perfiles de clientes y jerarquías de cuentas), un catálogo de productos (detalles a nivel de SKU, precios, disponibilidad), un almacén de datos (transacciones históricas), una plataforma de transmisión (señales de comportamiento en tiempo real) y un almacén de documentos (contratos, transcripciones de soporte, documentos de políticas).

Cada fuente tiene su propio esquema, patrón de acceso y, a menudo, su propia API. Esta complejidad genera dos desafíos persistentes:

- Fricción de la integración del desarrollador: cada capa presenta sus propios dolores de cabeza, desde la autenticación y la autorización hasta los desajustes de esquemas, conectores frágiles y formatos inconsistentes.
- Fragilidad del sistema/retardo de mantenimiento: con el tiempo, estas integraciones se acumulan, lo que genera fallas silenciosas, problemas de versiones y riesgos de confiabilidad posteriores que hacen que la innovación sea más lenta y más costosa.

El modelo de documentos de MongoDB adopta un enfoque radicalmente diferente. En lugar de forzar la diversidad de datos en esquemas rígidos u ocultarlos en bloques ilegibles, permite estructuras de datos ricas y jerárquicas que reflejan el funcionamiento real de las empresas [1]. Los desarrolladores pueden modelar un cliente, un pedido o un evento completo en un solo documento, incluyendo contexto anidado, historial de versiones y atributos de comportamiento. Esto elimina la necesidad de uniones complejas, a la vez que preserva las relaciones esenciales para un razonamiento agente eficaz.

Aún más crítico, el diseño de esquemas flexibles, es decir, la capacidad de almacenar y consultar datos sin limitarse a un esquema rígido, permite que los campos y las formas de los documentos se adapten a medida que cambian los requisitos. Esto

permite que los datos evolucionen: se pueden agregar nuevos atributos sin tiempo de inactividad y se pueden integrar nuevos tipos de señales sin migraciones costosas.

Para los sistemas de IA (especialmente aquellos que aprenden, se adaptan y se amplían), esta agilidad es esencial.

Esta convergencia arquitectónica permite la integración de transacciones estructuradas, señales en tiempo real y contenido no estructurado en una sola consulta u operación. Las actualizaciones de modelos, las tareas de enriquecimiento o las acciones de los agentes posteriores pueden activarse directamente desde la misma plataforma de datos [2].

Ese modelo unificado sienta las bases para flujos de trabajo sofisticados y nativos de IA.


Quizás aún más importante, el acceso unificado a los datos transforma la productividad de los desarrolladores. En lugar de dedicar ciclos a conciliar formatos o depurar conectores frágiles, los equipos pueden centrarse en desarrollar sistemas inteligentes. Y, como veremos en las siguientes secciones, todo, desde la calidad y la gobernanza de los datos hasta la orquestación en tiempo real, se basa en esta base.

Garantizar la calidad y la consistencia de los datos

La calidad y la consistencia de los datos no son negociables para las soluciones GenAI. A diferencia del análisis tradicional, donde los problemas de calidad de los datos pueden simplemente producir informes incorrectos o información retrasada, la mala calidad de los datos en los sistemas de IA puede causar alucinaciones, introducir resultados sesgados y un comportamiento fundamentalmente poco confiable que socava la confianza del usuario y el valor comercial.

Los enfoques de calidad tradicionales intentaron resolver esto mediante la normalización, la deduplicación y la validación con fuentes externas. Consideremos un modo de fallo

familiar: un sistema valida a Joe Miller, 12 High



Street, mediante API postales y verificaciones de crédito, no distingue entre tres Joe Miller diferentes (abuelo, padre e hijo) en la misma dirección. Para el análisis de entidades, donde el mapeo preciso de relaciones es crucial, esta es una falla crítica.

En este escenario, una tienda en línea podría, sin saberlo, tratar a los tres individuos como el mismo cliente, perdiendo la capacidad de personalizar las interacciones u ofertas. Los esquemas relacionales en estrella agravan este problema al fragmentar la información contextual en múltiples tablas. Cuando los datos de los clientes se dividen entre tablas de hechos, tablas de dimensiones y tablas de búsqueda, el contexto enriquecido que permite una resolución precisa de las entidades se dispersa y dificulta su reconstrucción.

En nuestro ejemplo de Joe Miller, un enfoque basado en documentos mantendría documentos separados para cada individuo, completos con información demográfica detallada, historial de compras, patrones de comportamiento y datos de relaciones que permiten una clara diferenciación.

Dentro de un documento, puede almacenar valores originales junto con enriquecimientos y mejoras dentro del mismo conjunto de datos. Esto
Este enfoque mejora la fiabilidad de los resultados y reduce las alucinaciones o los resultados contradictorios. Cuando un sistema de IA genera un resultado, la cadena completa de fuentes de datos, transformaciones y pasos de razonamiento se puede rastrear a través de la estructura del documento, lo que permite la depuración y la generación de informes de cumplimiento.

Esta capacidad de linaje resulta esencial para mejorar la fiabilidad de los resultados y reducir las alucinaciones o los resultados contradictorios. Cuando los modelos de IA pueden acceder no solo al estado actual de los datos, sino también a su procedencia e historial de transformación, pueden tomar decisiones más informadas sobre la fiabilidad y los niveles de confianza de los datos.

Por ejemplo, la IA de servicio al cliente podría ponderar las interacciones directas recientes con los clientes más que las preferencias inferidas más antiguas, o señalar posibles inconsistencias cuando múltiples fuentes de datos brindan información contradictoria.

Para las organizaciones que implementan estrategias de calidad de datos basadas en documentos, MongoDB ofrece prácticas recomendadas integrales, así como compatibilidad con herramientas líderes en la industria para el modelado y catalogación de datos, lo que facilita una gestión de calidad avanzada a escala [3]. Cuando los datos de alta calidad y con reconocimiento de linaje se convierten en la norma, los sistemas de IA pueden ofrecer resultados precisos, explicables y fiables.

Contexto en tiempo real y RAG

La definición de tiempo real varía significativamente según el caso de uso y el sector, pero los requisitos de tiempo real de los datos utilizados con GenAI son innegables. Los sistemas de negociación de fondos de cobertura, por ejemplo, requieren respuestas en milisegundos, mientras que los procesos de suscripción de seguros de vida miden el tiempo en días. Si bien los tiempos de respuesta de las aplicaciones siguen disminuyendo, muchas arquitecturas utilizan capas de caché que crean la ilusión de un rendimiento en tiempo real a costa de la actualización de los datos.

Un entorno típico en tiempo real sigue un patrón simple donde una interacción genera una señal que permite una interpretación inmediata.

Estas señales pueden provenir de diversas fuentes, como un sitio web de venta minorista que registra las adiciones al carrito de compra, un medidor inteligente que transmite el consumo de electricidad o un laboratorio de patología que completa datos de análisis de cáncer. Todas las señales, al combinarse con conjuntos de datos existentes,

Habilitar la búsqueda de texto, la búsqueda vectorial y el procesamiento LLM para el razonamiento y análisis causal. Esto se aplica igualmente a los sistemas interactivos, como como carritos de compra minoristas y sistemas de agencias autónomas, como procesamiento automatizado de reclamaciones de seguros.

Integración en tiempo real de señales con metadatos, datos de referencia y La información histórica genera nuevos conocimientos instantáneamente.

Considere cómo ha evolucionado esto. Los sistemas tradicionales basados en reglas podrían...

sugiere "Pediste una hamburguesa" , en ¿Quieres papas fritas?

contraste, un sistema impulsado por IA reconoce patrones como "Tú Pida comida para gatos quincenalmente , siempre la misma marca" , y razones

contextualizada con sugerencias como "Según su compra

Historial , podría interesarle nuestra nueva fórmula . ¿Le , más saludable

gustaría que le enviáramos una muestra gratuita ?

El sistema identifica a los clientes habituales y mejora su experiencia.

A través de un razonamiento que conecta los patrones de compra con el producto. recomendaciones, que requieren un conocimiento más profundo sobre el cliente preferencias y características de la mascota.




Figura 3.2: Flujo de datos de IA en tiempo real

El flujo arquitectónico en la Figura 3.2 demuestra cómo la IA moderna

Las aplicaciones procesan señales en tiempo real a través de un sistema de acción

Base de datos que utiliza un escenario de asistencia a pasajeros de aerolíneas. El flujo

Comienza con diversas fuentes de señales a la izquierda: Sistemas de reserva de ,
facturación de pasajeros, Servicios , y actualizaciones del estado del vuelo,

meteorológicos que alimentan los componentes de Procesamiento de Señales y

Conversión de Formato/Captura en Tiempo Real. Estas señales se incorporan posteriormente al...

Almacén de documentos central de MongoDB, , que contiene Vuelo

documentos, vectores de pasajeros y patrones de metadatos de , y histórico

reserva con capacidades de acceso directo a vectores.

El sistema procesa estos datos a través de Atlas Vector Search (búsqueda

interrupciones de vuelo similares) y aumento LLM (generación

respuestas personalizadas con contexto de vuelo) para producir tres tipos de

Salidas inteligentes: Confirmaciones de nuevas reservas , Personalizado

de Datos y Respuestas Automatizadas. La base de la solución son las Opciones, la Capa Operativos (ODL), un patrón arquitectónico que integra y organiza centralmente los datos empresariales aislados, actuando como intermediario entre las fuentes de datos existentes y las aplicaciones que los consumen. En este caso, la ODL enriquece las señales con información contextual procedente de registros de pasajeros, vuelos alternativos, datos meteorológicos e historial de cambios de reserva.

Un ciclo continuo de aprendizaje y enriquecimiento garantiza que cada resultado de la interacción, ya sean nuevas reservas aceptadas o preferencias del usuario, se refleje para mejorar futuras recomendaciones. El modelo documental permite la mejora continua sin necesidad de reestructurar el sistema, creando un sistema que se vuelve más inteligente con cada interacción del pasajero, a la vez que ofrece respuestas contextuales en tiempo real, vitales para las aplicaciones modernas de IA.

Es fundamental que el ciclo de retroalimentación garantice una mejora continua, asegurando que cada resultado de interacción enriquezca la base de datos del sistema de acciones y haciendo que las respuestas futuras sean más precisas y contextualizadas.

Este flujo circular representa la principal ventaja de las arquitecturas basadas en documentos: la capacidad de evolucionar y mejorar sin la rigidez de esquema que limita los sistemas relacionales tradicionales. El resultado es un sistema que se vuelve más inteligente con cada interacción, ofreciendo las respuestas contextuales en tiempo real que requieren las aplicaciones modernas de IA.

Escalabilidad, disponibilidad y rendimiento

Históricamente, los almacenes de datos empresariales representaban las implementaciones de bases de datos más grandes, con estructuras en estrella desnormalizadas y orientadas a columnas.

Esquemas diseñados para consultas analíticas. Estos sistemas funcionan bien con consultas como "Mostrar ventas de yogur por región", donde se filtran grandes conjuntos de datos por criterios específicos (región, tienda, precio) para generar información. La integración de múltiples fuentes condujo al desarrollo de sistemas de , transformar , procesos de carga (ETL) y gestión de datos maestros de extracción. Si bien estas plataformas han incorporado funciones de aprendizaje automático y ahora afirman ser compatibles con las capacidades de GenAI, siguen diseñadas principalmente para herramientas analíticas retrospectivas, inadecuadas para aplicaciones de IA causal, de agente y en tiempo real.

Considere el contraste. Un chatbot que asiste a un pasajero de avión que perdió una conexión requiere capacidades fundamentalmente diferentes a las de responder a la pregunta "¿Cuántos pasajeros sufrieron retrasos de un día en Frankfurt el año pasado?". El chatbot y su sistema de agencia subyacente deben abordar las necesidades inmediatas, encontrar asientos disponibles, ofrecer servicios de mitigación y responder con empatía a los pasajeros frustrados. Los datos requeridos son en tiempo real, sensibles al contexto y simplemente no están disponibles en un almacén histórico.

Para que la solicitud del pasajero sea exitosa, el sistema necesita acceso a la información del asiento en tiempo real (fácil de lograr mediante una API para los sistemas de reserva habituales), así como contexto e información más detallada sobre el pasajero y su situación. ¿Se trata de una familia varada o de un adulto solo? ¿Qué otras dependencias existen con el billete? ¿Se puede redirigir al pasajero por una vía diferente o es mejor pasar la noche?

Este escenario exige que todos los datos de los pasajeros residan en una base de datos del sistema de acción actualizada, ya que las interacciones en tiempo real fallan sin

Información actualizada. A medida que estos sistemas alcanzan una cobertura global, los requisitos no funcionales exigen no solo disponibilidad 24/7/365, sino también la capacidad de gestionar las fluctuaciones del volumen de transacciones desde periodos de baja demanda hasta temporadas altas de viajes, como el Día de Acción de Gracias. Incluso las interrupciones mínimas se vuelven inaceptables, y las soluciones de almacenamiento en caché que simplemente resuelven un problema de disponibilidad de datos comprometen la precisión de los datos al introducir problemas de obsolescencia.

Las arquitecturas basadas en documentos, como las que ofrece MongoDB, ofrecen ventajas en escenarios específicos para este tipo de disponibilidad y escalabilidad de datos. En lugar de requerir uniones complejas entre múltiples tablas para reconstruir el contexto del usuario, los modelos de documentos pueden almacenar información contextual completa en un único registro recuperable de forma eficiente. Este enfoque reduce la sobrecarga computacional de la reconstrucción del contexto, a la vez que permite estrategias de optimización y almacenamiento en caché más sofisticadas.

Las características de rendimiento de las cargas de trabajo de IA también difieren significativamente de los patrones analíticos tradicionales. Mientras que las consultas analíticas suelen procesar grandes volúmenes de datos para generar resultados agregados, las aplicaciones de IA suelen requerir un acceso rápido a información específica y contextualmente relevante. Este patrón favorece las arquitecturas optimizadas para el acceso de alta concurrencia y baja latencia a registros individuales, en lugar del procesamiento masivo de grandes conjuntos de datos.

Gobernanza, seguridad y cumplimiento

Los requisitos de gobernanza y cumplimiento surgen de la necesidad fundamental de proteger a las personas de la toma de decisiones errónea en sistemas que carecen de una autorregulación adecuada. Estas salvaguardas existen para prevenir

daños reales, desde aprobaciones de préstamos sesgadas hasta recomendaciones de productos inseguras.

GenAI se enfrenta a un intenso escrutinio en cuanto a su precisión, y la cobertura mediática de las alucinaciones pone esta preocupación en primer plano.

Por lo tanto, la transparencia en el linaje de datos, los procesos de razonamiento y la interpretación de resultados se vuelve crucial para cualquier solución GenAI. El modelo de documento en una base de datos de sistemas de acción permite el seguimiento de todos los cambios, transformaciones y acciones relacionadas con conjuntos de datos específicos. A diferencia de las bases de datos relacionales tradicionales, los documentos ofrecen flexibilidad para mejorar y enriquecer durante todo el proceso sin necesidad de planificación previa.

Desde una perspectiva de gobernanza, esto permite un seguimiento preciso y exhaustivo de los procesos de comunicación y toma de decisiones. Facilita la auditoría de decisiones y la aplicación de medidas correctivas cuando surgen problemas de cumplimiento, a menudo debido a cambios graduales en los criterios de decisión que requieren ajustes.

La seguridad representa una dimensión crítica adicional. El cifrado consultable de MongoDB mantiene los datos completamente protegidos contra accesos no autorizados. Si bien los datos de los pasajeros pueden tener una sensibilidad moderada, las consultas con profesionales sanitarios sobre posibles enfermedades requieren los más altos niveles de seguridad. La base de datos del sistema de acción permite una implementación de seguridad transparente, lo cual resulta mucho más complejo al coordinar múltiples fuentes de datos con sistemas de seguridad y políticas potencialmente incompatibles [4].

Entrenamiento y ajuste de modelos

El entrenamiento o ajuste de modelos requiere grandes volúmenes de datos limpios, etiquetados y diversos. La base de datos del sistema de acción garantiza una curación, muestreo y preprocesamiento eficientes de datos para los canales de entrenamiento. El enriquecimiento de datos se vuelve clave, ya que funciones como el canal de agregación de MongoDB permiten la anotación de datos y el análisis continuo de criterios como valores mínimos o máximos y medias móviles para validar los procesos de razonamiento.

El tema de la preparación de datos para GenAI suele malinterpretarse, debido a la evolución de las primeras soluciones de IA que respaldan los sistemas de ML (sistemas derivados de arquitecturas de inteligencia empresarial [BI]). Esto a veces conduce a la suposición errónea de que todos los datos para el uso y la interacción con la IA deben prepararse primero en lagos, almacenes o marts, lo que requiere una amplia transformación y procesamiento de canalización de datos. Los objetos de datos resultantes suelen almacenarse como esquemas en estrella con tablas de hechos, cada una con cientos de columnas y tablas de dimensiones correspondientes. Los esquemas en estrella, un formato de modelado de datos diseñado originalmente para resolver el problema de las consultas analíticas de alto rendimiento ejecutadas contra objetos de bases de datos relacionales, introducen la necesidad de consultas complejas y operaciones de unión para extraer información, una arquitectura que aún emplean plataformas como Snowflake.

Las implementaciones de almacenamiento de objetos de Apache Spark, como Databricks, ofrecen capacidades de consulta más complejas mediante marcos de computación distribuida y procesamiento en memoria, lo que representa un avance significativo respecto a los sistemas tradicionales de procesamiento por lotes. Ambos enfoques, los esquemas en estrella y los archivos de almacenamiento de objetos manipulados por Spark, comparten la base del almacenamiento de datos retrospectivo, independientemente de la terminología actual, como lago de datos o lakehouse.

Estos sistemas están optimizados para procesar grandes volúmenes de datos homogéneos alineados a lo largo de ejes dimensionales. El acceso en tiempo real a conjuntos de datos individuales para el procesamiento operativo queda fuera de sus parámetros de diseño. Históricamente, este era el ámbito de los sistemas de procesamiento de transacciones en línea (OLTP). Si bien el registro transaccional no es fundamental para las estructuras de datos de GenAI, los patrones de acceso siguen siendo similares.

A menudo, se utiliza el ejemplo de la creación de modelos para incrustaciones para justificar por qué el almacén de datos debe ser la fuente de datos para GenAI, pero esto es engañoso. En primer lugar, muchas soluciones empresariales implementan con éxito modelos de incrustación estándar para archivos PDF, imágenes y audio, sin necesidad de desarrollo personalizado. En segundo lugar, y más importante, la comparación no es válida, ya que los almacenes que analizan las ventas trimestrales no tienen relevancia para las operaciones en el punto de venta ni para la contabilización de transacciones.

Consideraciones prácticas para el diseño de datos de IA

Si bien los fundamentos teóricos de las bases de datos de sistemas de acción proporcionan el marco conceptual para las arquitecturas de sistemas de acción compatibles con IA, su implementación exitosa requiere prestar atención a los principios prácticos de diseño y a las realidades operativas. Esta sección examina tres aspectos críticos que determinan el éxito de las implementaciones de GenAI en el mundo real: la importancia fundamental de unos datos bien estructurados y organizados, los patrones de movimiento de datos a través de los sistemas de IA y las consideraciones operativas necesarias para la implementación y el mantenimiento de estas arquitecturas a escala.

Una buena estructura de datos es fundamental

Los datos bien organizados, como documentos, índices e incrustaciones, permiten un acceso rápido y relevante a la información, esencial para RAG.

Por el contrario, los patrones tradicionales de almacenamiento de bases de datos relacionales generan desajustes de impedancia fundamentales con las aplicaciones GenAI, que requieren objetos de datos unificados y contextualmente ricos que preserven las relaciones semánticas y el significado empresarial. Cuando las entidades empresariales abarcan datos de referencia, metadatos e información operativa en múltiples tablas normalizadas, a menudo se requieren extensas operaciones de unión y código adicional en la capa de aplicación para reconstruir datos fragmentados en objetos empresariales coherentes, listos para el procesamiento de IA. Esta fragmentación relacional no solo degrada el rendimiento de las consultas y aumenta la complejidad del sistema, sino que también oscurece las relaciones naturales de los datos esenciales para un consumo eficaz de IA, creando límites artificiales que requieren el mantenimiento continuo de las relaciones de esquema interdependientes. En consecuencia, las aplicaciones GenAI exigen arquitecturas de datos que puedan representar de forma nativa entidades empresariales complejas y jerárquicas sin una lógica de reconstrucción extensa, favoreciendo arquitecturas basadas en documentos que se alinean de forma más natural con la forma en que los modelos de IA consumen datos, es decir, objetos contextuales ricos, en lugar de fragmentos descompuestos y normalizados.

Un sistema de base de datos de acciones bien diseñado basado en el modelo de documento es una solución que aborda todos los desafíos anteriores y al mismo tiempo brinda una gran cantidad de beneficios no tangibles, incluida la reducción de la carga cognitiva del desarrollador y la proliferación de tecnología de infraestructura.

La combinación de varias fuentes mejora los metadatos
comprensión y mejora la precisión y relevancia de la

Modelos. Desde la perspectiva del desarrollador, las estructuras de documentos permiten una construcción de indicaciones superior, ya que los documentos desnormalizados son mucho más fáciles de manejar tanto para desarrolladores como para LLM, lo que mejora la calidad de las indicaciones. Además, la estructura más simple con menor normalización reduce la cantidad de datos.

Objetos necesarios para generar el contexto apropiado. Cuanto menor sea el número de objetos de datos, más fácil será garantizar la calidad de los datos para reducir las alucinaciones y mejorar la facticidad.

En el ejemplo anterior de la aerolínea, varios modelos podrían aportar diferentes aspectos del razonamiento: un LLM general para gestionar la comunicación con chatbots y un modelo optimizado para cada dominio para determinar las opciones de enrutamiento. Los LLM secundarios podrían especializarse en la síntesis en lugar de la validación de datos, lo que demuestra por qué depender de un solo LLM probablemente no logre una calidad razonable en sistemas de agencia.

El modelo de documento mejora la calidad de salida a través del enriquecimiento iterativo, evolucionando con los casos de uso en lugar de requerir una nueva arquitectura o refactorización para adaptarse a requisitos nuevos o modificados (un punto problemático inevitable en los sistemas relacionales).

En última instancia, los documentos enriquecidos mejoran la fluidez, la coherencia y la creatividad de los sistemas agentes basados en el razonamiento.

Un diseño deficiente de recuperación de datos, derivado de fuentes poco organizadas, resulta en un rendimiento lento, resultados irrelevantes o información inexacta.

Por el contrario, las arquitecturas bien alineadas garantizan una recuperación rápida y contextualmente relevante que facilita la obtención de resultados significativos del modelo.

En resumen, cuando la estructura de datos y el diseño del modelo están cuidadosamente alineados, el resultado es una solución GenAI más precisa, receptiva y escalable.

Flujo de datos

El flujo de datos de la solución GenAI suele comenzar con datos transaccionales capturados durante interacciones con máquinas, procesos o personas. Posteriormente, estos datos pueden enriquecerse con codificación vectorial de artefactos no estructurados, o incluso con datos de referencia existentes, para que puedan procesarse en flujos de trabajo de sistemas de agencia. Este enriquecimiento de objetos de negocio en tiempo real en MongoDB da como resultado un único documento con toda la información relevante, enriquecida al máximo. En cambio, en una arquitectura tradicional, los datos solo se referenciarían desde sus fuentes, lo que requeriría, en el mejor de los casos, llamadas a API y, en el peor, un posible acceso directo a bases de datos.

El flujo de datos con un enfoque documental permite la transmisión de toda la información contextual en un único objeto y formato, lo que facilita la colaboración entre múltiples sistemas de agencia para un único proceso o flujo de trabajo. En nuestro ejemplo, la interrupción del vuelo se compila en un único documento, que gestiona todos los aspectos del caso, incluyendo las interacciones con los pasajeros, la información del vuelo, los datos contractuales e incluso factores de la situación como las condiciones meteorológicas.

Esto permite que varios sistemas de agencia colaboren en diferentes aspectos del mismo objeto de negocio o interacción transaccional. Por ejemplo, mientras un chatbot se comunica con el pasajero y proporciona actualizaciones de estado en tiempo real, otro componente del sistema...

Trabaja proactivamente en el problema subyacente, tras ser activado por el sistema transaccional al detectar un retraso en el vuelo y calcular la probabilidad de que el pasajero pierda su conexión. Esto significa que el caso comienza a procesarse incluso antes de que el pasajero lo inicie. contacto.

Durante este proceso de creación de casos, el sistema genera múltiples vectores mediante incrustaciones específicas y realiza búsquedas semánticas en casos históricos similares. Esto permite al LLM preparar respuestas en lenguaje natural, como "Identificamos múltiples opciones lo antes posible. El sistema agentic En un escenario con opciones de vuelo óptimas..." . puede generar proactivamente múltiples soluciones y comunicárselas al pasajero con un mensaje como "Lamentamos que haya perdido su vuelo. Tenemos tres opciones disponibles para continuar su viaje..." .

Una vez resuelto el caso, el documento se enriquece con datos completos de los resultados, como "El pasajero aceptó una nueva reserva en el vuelo 345 con salida en una hora, expresó satisfacción con la comunicación proactiva y rechazó la oferta de un cupón de comida" . Las interacciones con el pasajero se pueden interpretar y el resultado general se puede clasificar. Esto permite un control de calidad crucial, ayuda a identificar tendencias emergentes y valida y prueba modelos más nuevos y sus resultados sugeridos.

Puesta en funcionamiento de un sistema de base de datos de acciones

Pasar de los principios arquitectónicos a la implementación en producción requiere abordar las complejidades operativas que distinguen a los sistemas de datos de IA de las bases de datos tradicionales. Las características únicas de las cargas de trabajo de GenAI, como la búsqueda de vectores en tiempo real, la evolución continua de modelos y los requisitos de esquema dinámico, exigen enfoques especializados de implementación, monitorización y mantenimiento que van mucho más allá de las prácticas convencionales de administración de bases de datos.

Patrones de implementación

Implementar una base de datos de sistemas de acción requiere una planificación cuidadosa de la arquitectura de implementación. Las organizaciones suelen seguir uno de tres patrones principales: implementaciones desde cero para nuevas iniciativas de IA, estrategias de migración gradual que abandonan gradualmente los sistemas heredados, o enfoques híbridos que mantienen los sistemas existentes a la vez que desarrollan nuevas capacidades de IA.

Las implementaciones nativas de la nube ofrecen la mayor flexibilidad y escalabilidad, con servicios administrados como MongoDB Atlas, que proporcionan escalado automático, copias de seguridad y funciones de seguridad. Las implementaciones locales pueden ser necesarias para organizaciones con requisitos estrictos de soberanía de datos, mientras que los enfoques de nube híbrida permiten equilibrar las necesidades de seguridad con la eficiencia operativa.

Monitoreo y optimización del rendimiento

Las aplicaciones de IA en tiempo real exigen una monitorización continua del rendimiento en múltiples dimensiones. Las métricas de rendimiento de las consultas deben registrar no solo los tiempos de respuesta, sino también las puntuaciones de relevancia para las búsquedas vectoriales y las métricas de precisión para los resultados generados por IA. Los sistemas basados en documentos requieren la monitorización del tamaño de las colecciones, la eficacia de los índices y el rendimiento del flujo de agregación.

Los indicadores clave de rendimiento deben incluir métricas de rendimiento para la ingesta de datos, mediciones de latencia para operaciones de recuperación y patrones de utilización de recursos durante las cargas máximas de procesamiento de IA.

Los sistemas de alerta automatizados deberían activarse cuando el rendimiento se degrada por debajo de los umbrales aceptables, en particular para aplicaciones en tiempo real donde las demoras afectan directamente la experiencia del usuario.

Gestión de costes y asignación de recursos

La economía de la infraestructura de datos de IA difiere significativamente de la de los sistemas de bases de datos tradicionales. El almacenamiento vectorial y las búsquedas por similitud consumen patrones de recursos distintos a los de las consultas relacionales, lo que requiere nuevos enfoques para la planificación de la capacidad y la optimización de costes.

Los costos de almacenamiento se ajustan tanto al tamaño del documento como a las dimensiones de incrustación, mientras que los costos de cómputo varían según la complejidad del modelo y la frecuencia de las consultas. Las organizaciones deben implementar estrategias de almacenamiento por niveles, trasladando los datos más antiguos o de acceso menos frecuente a niveles de almacenamiento de menor costo y acceso menos frecuente, a la vez que mantienen los datos de acceso frecuente o de alta demanda en sistemas de alto rendimiento para el acceso en tiempo real.

Flujos de trabajo de mantenimiento y gestión del ciclo de vida de los datos

Los sistemas de IA basados en documentos requieren procedimientos de mantenimiento especializados que tengan en cuenta la evolución del esquema, las actualizaciones de los modelos de incrustación y las fluctuaciones en la calidad de los datos a lo largo del tiempo. A diferencia de las bases de datos tradicionales, donde los cambios de esquema requieren una planificación cuidadosa de la migración, los almacenes de documentos permiten una evolución más flexible, pero esta flexibilidad no elimina la necesidad de marcos de gobernanza que garanticen la consistencia de los datos.

El reprocesamiento regular de las incrustaciones se vuelve deseable a medida que se disponga de modelos más nuevos y eficaces. Se deben utilizar canales automatizados para gestionar las actualizaciones de las incrustaciones, manteniendo al mismo tiempo una alta disponibilidad del sistema, utilizando potencialmente estrategias de implementación de alto rendimiento para minimizar las interrupciones del sistema durante las transiciones importantes de los modelos.

Estrategias de migración desde sistemas heredados. Las organizaciones

rara vez parten de cero al implementar sistemas de almacenamiento de datos de acción. La migración necesaria de datos desde sistemas relacionales, almacenes de datos y sistemas operativos dispares existentes requiere enfoques graduales que minimicen las interrupciones del negocio y maximicen los beneficios de los datos unificados. acceso.

La experiencia de una amplia gama de clientes en muchas industrias ha demostrado que las migraciones más exitosas comienzan con un piloto.

Proyectos que demuestran valor rápidamente y luego amplían su alcance gradualmente. Las estrategias de sincronización de datos deben mantener la paridad de datos empresariales entre los sistemas antiguos y los nuevos durante los períodos de transición, con validación automatizada que garantice la integridad de los datos durante todo el proceso de migración.

Consideraciones sobre la capacitación del equipo y la adopción

La implementación exitosa de un sistema de bases de datos de acción requiere inversión en las capacidades del equipo. Los administradores de bases de datos tradicionales pueden necesitar capacitación en los principios de modelado de documentos, mientras que los desarrolladores de aplicaciones pueden necesitar aprender nuevos patrones de consulta y técnicas de optimización específicas para las cargas de trabajo de IA.

Los científicos de datos y los ingenieros de aprendizaje automático (ML) necesitan comprender cómo las estructuras de los documentos impactan el entrenamiento de modelos y el rendimiento de la inferencia, mientras que los equipos de DevOps necesitan familiarizarse con los requisitos de monitorización y escalado específicos de la IA. La colaboración interfuncional se vuelve esencial a medida que se difuminan los límites entre la ingeniería de datos, el desarrollo de IA y las operaciones en las arquitecturas de sistemas de acción.

Resumen

Este capítulo exploró el papel crucial de las bases de datos de sistemas de acción para construir soluciones GenAI eficaces. Examinamos las limitaciones.

de los enfoques tradicionales de gestión de datos y presentó un paradigma alternativo centrado en el modelo documental. Los aspectos clave que se discutieron incluyen el acceso unificado a diversas fuentes de datos, la mejora

calidad y consistencia de los datos, contexto en tiempo real para RAG, escalabilidad, seguridad y gobernanza, y la importancia de alinear las estructuras de datos con el diseño del modelo para lograr un rendimiento y una precisión óptimos.

El principal beneficio de una base de datos de sistemas de acción bien diseñada, basada en el modelo de documento, es su capacidad de proporcionar acceso en tiempo real, sensible al contexto y holístico a diversos datos, esenciales para el razonamiento, el análisis causal y la generación de resultados precisos y relevantes. Este enfoque se diferencia del almacenamiento de datos tradicional al proporcionar una vista unificada de datos enriquecidos, optimizados para RAG, el entrenamiento de modelos y el ajuste fino. Esto da como resultado soluciones GenAI más seguras, precisas, ágiles, escalables y protegidas.

En el siguiente capítulo, exploraremos los fundamentos fundamentales de una IA confiable, examinando cómo las organizaciones pueden desenvolverse en el complejo panorama de marcos éticos, cumplimiento normativo y requisitos de gobernanza de datos. A medida que los sistemas de IA se integran cada vez más en procesos críticos de toma de decisiones, garantizar que operen dentro de los límites de la ética, la ley y la sociedad se vuelve primordial. Analizaremos cómo una gobernanza de datos adecuada, la base que hemos establecido con las bases de datos de sistemas de acción, permite a las organizaciones construir sistemas de IA transparentes, justos, responsables y que cumplan con las regulaciones cambiantes en diferentes industrias y jurisdicciones.

Referencias

1. Enfoque del modelo de documento de

MongoDB: <https://www.mongodb.com/docs/manual/data-modeling/>

2. Una guía completa sobre modelado de datos:

<https://www.mongodb.com/resources/basics/databases/data-modeling>

3. Implementar patrones efectivos de calidad de datos:

<https://www.mongodb.com/developer/products/mongodb/modernizing-rdbms-schemas-mongodb-document/>

4. Funciones de seguridad avanzadas de

MongoDB: <https://www.mongodb.com/docs/manual/core/queryable-encryption/>

4

IA confiable, cumplimiento y Gobernanza de datos

A medida que la IA transforma las industrias, las organizaciones deben equilibrar su poder con las responsabilidades éticas, legales y sociales.

Este capítulo explora cómo la IA confiable, los marcos de cumplimiento normativo y la gobernanza de datos se integran como base de una IA responsable. Aprenderá a sortear la complejidad regulatoria mientras construye sistemas que generan (y mantienen) la confianza mediante la transparencia, la equidad y la rendición de cuentas.

Al final de este capítulo comprenderás lo siguiente:

- Principios básicos de una IA confiable y por qué son importantes
- Cómo los marcos éticos se traducen en estrategias de implementación prácticas
- Cambios regulatorios clave en las industrias y regiones
- Requisitos esenciales de protección de datos y privacidad para los sistemas de IA
- Enfoques prácticos para la evaluación y gestión de riesgos
- Técnicas para lograr la transparencia y explicabilidad de la IA
- Estrategias para implementar una IA confiable en su organización

Por qué es importante la IA ética

Para enfrentar los desafíos crecientes de la adopción de IA y construir sistemas que puedan resistir el escrutinio y al mismo tiempo brindar valor, las organizaciones necesitan una comprensión clara de lo que implica una IA confiable en la práctica. Las buenas intenciones no bastan. Construir una IA confiable requiere principios claros, una ejecución deliberada y marcos de gobernanza estructurados.

Los crecientes riesgos de la implementación de la IA

A medida que la IA se integra cada vez más en sistemas críticos, como el diagnóstico sanitario, la toma de decisiones financieras y el transporte autónomo, las consecuencias de los fallos se agravan. La confianza no es solo una preocupación filosófica. Es un imperativo estratégico. Cuando los sistemas de IA influyen en la vida y los derechos de las personas, deben operar con ética.

El panorama de amenazas en expansión presenta desafíos significativos. En promedio, se tarda casi 200 días en identificar una brecha, y el ciclo de vida completo puede extenderse hasta 300 días, lo que deja a las organizaciones expuestas mucho más tiempo del que imaginan [1]. Al mismo tiempo, las regulaciones se están endureciendo. Leyes como la Ley de Portabilidad y Responsabilidad del Seguro Médico (HIPAA) y las regulaciones de ciberseguridad introducidas por la Comisión de Bolsa y Valores de Estados Unidos (SEC) ahora imponen requisitos de seguridad más estrictos para la protección de datos confidenciales. Es fundamental garantizar que los sistemas de IA se diseñen y gestionen teniendo en cuenta estos riesgos.

Definición de los conceptos básicos

Para sentar una base sólida para comprender la IA confiable, aclaremos tres conceptos interconectados:

- La IA confiable se refiere a sistemas diseñados y operados para ser explicables, justos, seguros y protegidos. Representa un marco para reducir los diversos riesgos asociados con la implementación de la IA, con el objetivo de generar confianza y operar dentro de los límites éticos.
A medida que las organizaciones recurren cada vez más a la IA para la toma de decisiones cruciales, la IA confiable garantiza su alineación con los valores humanos y las expectativas sociales. Esta alineación es crucial tanto por razones éticas como por la sostenibilidad empresarial a largo plazo, ya que los sistemas poco confiables a menudo se enfrentan al rechazo de los usuarios, al escrutinio regulatorio y a riesgos legales.
- El cumplimiento normativo de la IA abarca las decisiones, prácticas, procesos, estándares y marcos que garantizan que los sistemas de IA funcionen de acuerdo con las leyes, regulaciones, directrices éticas, requisitos de privacidad de datos, protocolos de seguridad, principios de equidad y mecanismos de rendición de cuentas aplicables. Las organizaciones también deben mantenerse al día con la evolución de las regulaciones y adaptar continuamente sus sistemas de IA para mantener el cumplimiento normativo y la responsabilidad.
- La gobernanza de datos de IA es la supervisión estructurada de cómo se recopilan, gestionan y utilizan los datos en los sistemas de IA. Garantiza la precisión, la seguridad y la aplicación ética de los datos, a la vez que aborda desafíos como la transparencia algorítmica, la trazabilidad y la amplificación de sesgos. Una gobernanza sólida sienta las bases para el cumplimiento normativo y la fiabilidad de la IA. Sin ella, las organizaciones corren el riesgo de socavar la integridad y la rendición de cuentas de sus sistemas de IA.




Figura 4.1: La gobernanza de datos de IA como base para el cumplimiento y una IA confiable

La Figura 4.1 muestra cómo estos tres conceptos forman un marco interconectado para la implementación responsable de la IA. Una gobernanza robusta de datos de IA constituye la base esencial tanto para una IA fiable como para su cumplimiento normativo, garantizando la calidad, la integridad, la seguridad y el manejo ético de los datos que alimentan los sistemas de IA. Comprender estos conceptos fundamentales sienta las bases para la aplicación de marcos éticos, que traducen los principios en directrices prácticas para la implementación de la IA.

Marcos éticos: De los principios a la práctica

Los marcos éticos ofrecen principios rectores para ayudar a las organizaciones a desarrollar e implementar sistemas de IA de forma responsable. Uno de los más citados son las Directrices Éticas para la Confianza de la Unión Europea (UE).

AI , que describe siete requisitos clave que se han convertido en un estándar global.

punto de referencia:


- **Agencia y supervisión humanas:** Los sistemas de IA deben respaldar la toma de decisiones humanas y estar sujetos a supervisión. En la práctica, esto implica establecer procesos con intervención humana para decisiones críticas, como la aprobación de préstamos o diagnósticos médicos, donde las personas puedan revisar e intervenir según sea necesario.
- **Robustez y seguridad técnicas:** La IA debe ser segura, resiliente y protegida, con mecanismos de respaldo para mitigar vulnerabilidades o ataques adversarios. Esto incluye protocolos de prueba rigurosos, una arquitectura segura y una monitorización continua para prevenir el uso indebido.
- **Privacidad y gobernanza de datos:** Los sistemas de IA deben respetar la privacidad individual y mantener la calidad, integridad y seguridad de los datos durante todo su ciclo de vida. Las técnicas incluyen la minimización de datos, la anonimización y el manejo seguro desde la recopilación hasta la eliminación.
- **Transparencia:** Las capacidades, limitaciones y procesos de toma de decisiones de la IA deben ser comprensibles y rastreables. La documentación debe explicar cómo la IA afecta los resultados y proporcionar explicaciones accesibles de las decisiones.

- Diversidad, no discriminación y equidad: La IA debe diseñarse y probarse para prevenir sesgos injustos y promover un trato equitativo entre los grupos demográficos. Esto incluye el uso de datos de entrenamiento diversos y la realización de auditorías para detectar y abordar patrones discriminatorios en resultados como la contratación, los préstamos o la atención médica.
- Bienestar social y ambiental: la IA debería apoyar el progreso social y reducir los impactos ambientales negativos.
Esto incluye la evaluación de los riesgos de desplazamiento de empleo, el seguimiento de los costos ambientales y la alineación de los sistemas con objetivos de sostenibilidad más amplios.
- Responsabilidad: Se debe establecer una clara responsabilidad por las decisiones y los resultados de la IA. Las organizaciones necesitan mecanismos de auditoría, protocolos de mitigación y formas de responder ante posibles daños.

Obtenga más información sobre estas directrices aquí: <https://digital-strategy.ec.europa.eu/en/library/ethics-guidelines-trustworthy-ai>

Las brechas éticas generan un riesgo operativo y reputacional real. Las sanciones regulatorias están aumentando, y una vez que se rompe la confianza, puede ser difícil restaurarla. Varias grandes empresas tecnológicas ya han retirado productos de IA debido a sesgos o fallos de supervisión. En un entorno competitivo donde la rendición de cuentas es crucial, las organizaciones que descuidan las prácticas responsables de IA corren el riesgo de quedarse atrás.

Purple Fabric de IntellectAI y una IA confiable en finanzas



Un claro ejemplo de IA fiable en un entorno de alto riesgo proviene de IntellectAI, empresa pionera en soluciones de IA para el sector bancario, de servicios financieros y de seguros (BFSI). La empresa creó Purple Fabric.

• Una plataforma de IA de impacto empresarial abierto diseñada para ayudar a las empresas a satisfacer demandas regulatorias y de cumplimiento complejas.

Uno de sus usuarios más destacados es un fondo soberano de riqueza con más de un billón de dólares en activos bajo gestión. El fondo se basa en la orquestación de agentes de IA de Purple Fabric, impulsada por técnicas avanzadas de RAG y MongoDB Atlas Vector Search, para extraer información crítica de millones de documentos no estructurados de las 9000 empresas de su cartera. Esto permite una gestión diferenciada de la cartera y respalda una matriz de sostenibilidad personalizada que va más allá de los marcos estándar, fortaleciendo la generación de informes internos y las iniciativas estratégicas.

Purple Fabric procesa datos empresariales no estructurados a través de su Enterprise Knowledge Garden (EKG), impulsado por MongoDB Atlas Vector Search, y activa esa inteligencia utilizando Enterprise Digital Experts (EDE), un sistema multiagente que orquesta la IA en los flujos de trabajo empresariales.

La tela morada ilustra los principios de la confianza.
IA en acción:



- Privacidad y gobernanza de datos: Basada en MongoDB Atlas, la plataforma gestiona de forma segura datos no estructurados a escala, especialmente en el caso de recuperación descrito. Los controles de acceso precisos limitan la exposición de los datos y los agentes de IA únicamente a los usuarios autorizados. El EKG de la plataforma procesa contenido diverso a la vez que mantiene una gobernanza empresarial sobre la información confidencial.
- Robustez técnica y seguridad: Purple Fabric cumple con los requisitos de cumplimiento de la industria, incluyendo SOC 2, ISO 27001, ISO 27017, ISO 27018 y revisiones de arquitectura de AWS. Su infraestructura...

Monitorea continuamente el comportamiento del agente y las cadenas de datos para respaldar una implementación confiable y segura de IA a escala.
- Transparencia y rendición de cuentas: La suite de gobernanza de Purple Fabric proporciona un linaje completo de fuentes de datos y trazabilidad de los resultados de IA, lo que garantiza que los agentes de IA se basen en datos de fuentes confiables. TRACES garantiza la explicabilidad en operaciones multiagente con un registro de auditoría claro. El Centro de Optimización de Modelos permite a los equipos comparar los LLM en términos de velocidad, costo y precisión, y facilita la selección de modelos de múltiples proveedores o la incorporación de modelos personalizados. Esto proporciona a los usuarios una clara visibilidad y control sobre las decisiones de IA a escala.

Al combinar una base de datos segura con un monitoreo sólido, capacidad de explicación y controles de usuario, IntellectAI ha construido una poderosa plataforma de IA en Purple Fabric que ayuda a las empresas a adoptar la IA de manera responsable y al mismo tiempo ofrece un impacto comercial real [2].



Principios de conexión y aplicación

Organizaciones de todo el mundo están desarrollando métodos prácticos para implementar una IA ética. IBM, por ejemplo, prioriza la empatía y la participación de las partes interesadas en sus prácticas de gobernanza de la IA, garantizando así su alineación con los valores sociales más amplios [3].

En la práctica, las organizaciones están haciendo operativa la ética a través de esfuerzos como:

- Auditorías de sesgo: pruebas periódicas de los sistemas de IA para detectar sesgos injustos en diferentes grupos demográficos
- Juntas de revisión ética: Creación de comités diversos para evaluar Aplicaciones de IA frente a estándares éticos
- Documentación transparente: mantener registros claros de las decisiones de desarrollo, las fuentes de datos y las limitaciones del modelo.
- Participación de las partes interesadas: involucrar a las comunidades afectadas en las decisiones de diseño, implementación y gobernanza de la IA

Cada una de estas prácticas ayuda a traducir principios éticos de alto nivel en acciones repetibles que fomentan la confianza, reducen el riesgo y apoyan la sostenibilidad de la IA a largo plazo.

Auditorías de sesgo

Las auditorías de sesgo evalúan sistemáticamente los sistemas de IA, en particular los LLM, para identificar y mitigar el comportamiento perjudicial. Estas evaluaciones suelen comprobar el rendimiento de los modelos en función de diferentes atributos demográficos o contextos sensibles.

Un estudio dirigido por Stanford aplicó este enfoque a los LLM utilizados en la contratación. Los investigadores recopilaron 801 solicitudes de empleo reales para puestos docentes de primaria y secundaria, y generaron versiones sintéticas que solo diferían en la raza y las características de género (como nombres y pronombres) [4]. Al someterlas a ocho modelos independientes, los resultados revelaron disparidades constantes en la puntuación: las candidatas recibieron una calificación ligeramente superior a la de los candidatos masculinos, y las candidatas negras, hispanas y asiáticas, en general, recibieron una calificación ligeramente superior a la de sus homólogos blancos. Estas brechas persistieron incluso cuando se editaron los currículos, se reformularon las indicaciones o se modificó el contexto geográfico.

Este experimento pone de relieve un desafío crucial: incluso los modelos bien alineados pueden mostrar preferencias demográficas que afectan las decisiones en el mundo real. Por lo tanto, auditorías de sesgo como estas son esenciales en ámbitos de gran importancia, como la contratación, donde la equidad, la transparencia y la rendición de cuentas deben verificarse activamente en lugar de darse por sentado.

Juntas de revisión ética

Los comités de revisión ética desempeñan un papel fundamental en el desarrollo responsable de la IA. Proporcionan una supervisión estructurada, detectan riesgos como sesgos o problemas de privacidad, y garantizan que los sistemas se ajusten a los valores organizacionales y las expectativas sociales. Cuando se integran eficazmente, estos comités ayudan a los equipos a tomar mejores decisiones con mayor rapidez, aumentan la transparencia y se ganan la confianza de los usuarios y las partes interesadas.

IBM ofrece un ejemplo destacado. Su Junta de Ética de IA, integrada por diversos líderes de toda la empresa, tiene autoridad formal para supervisar el desarrollo de la IA. La junta revisa casos de uso, define políticas y responsabiliza a los equipos de producto mediante un proceso repetible. proceso de gobernanza.

El enfoque de IBM opera en cuatro áreas clave:

- Impulsado por principios: El consejo de administración traduce los principios de IA de IBM en requisitos y puntos de control específicos. Por ejemplo, el principio «La IA aumenta la inteligencia humana» impulsó la obligación de una supervisión humana significativa en todos los sistemas, especialmente en aquellos que Los datos pertenecen a su creador era con consecuencias reales. Esto se refleja en estrictos protocolos de gobernanza que protegen los datos de los clientes y exigen el consentimiento. La transparencia se abordó exigiendo estándares de explicabilidad y documentación a lo largo del ciclo de vida del desarrollo.
- Evaluación de casos de uso: La junta directiva revisa los proyectos de IA con especial atención a las consideraciones éticas. Cada proyecto pasa por un proceso de evaluación estructurado que incluye la evaluación de riesgos, el análisis del impacto de las partes interesadas y las comprobaciones de cumplimiento. Dependiendo de los hallazgos, los equipos pueden recibir aprobación, verse obligados a realizar cambios o, en algunos casos, a suspender el trabajo por completo. Por ejemplo, las aplicaciones de IA que afectan las decisiones de contratación se sometieron

pruebas de sesgo mejoradas, mientras que los proyectos de atención médica requirieron garantías de privacidad adicionales, incluida la validación del dominio.

- **Flujos de trabajo y formación:** La junta directiva apoya la formación en ética de la IA en toda la empresa, incluyendo programas de formación y orientación sobre políticas. Estas iniciativas contribuyen a integrar prácticas de diseño responsables en los equipos de ingeniería y desarrollo de productos.
- **Rendición de cuentas:** El consejo directivo contribuye a cumplir los compromisos públicos de IBM con la IA ética, garantizando que las revisiones éticas se tomen en serio y se integren en la toma de decisiones. Actúa como una función de gobernanza, a la vez que moldea la cultura de la empresa a lo largo del tiempo [5].

Para ser eficaces, los comités de revisión ética necesitan más que buenas intenciones.

Requieren una representación diversa, procesos definidos y la capacidad de influir tanto en el desarrollo del producto como en las normas de la empresa.

Sin esta base, incluso principios éticos sólidos corren el riesgo de ser pasados por alto durante su implementación.

Documentación transparente. La documentación transparente

ofrece a las partes interesadas una visión clara de cómo se diseñan, entrenan y gestionan los sistemas de IA. Esta visibilidad fomenta la confianza al desmitificar los modelos complejos de IA y permitir la rendición de cuentas por sus decisiones y resultados. Al registrar cuidadosamente las fuentes de datos, las arquitecturas de modelos, las metodologías de evaluación y los posibles sesgos, las organizaciones pueden identificar y mitigar riesgos, respaldar el cumplimiento normativo y garantizar una implementación responsable de la IA.

A pesar de su importancia, la documentación transparente suele subestimarse.

Los equipos técnicos pueden priorizarla menos en favor de la velocidad, lo que genera lagunas en la información crítica cuando los sistemas pasan a producción. La falta de uniformidad en los estándares entre departamentos dificulta la compilación de registros coherentes para la gobernanza. El rápido ritmo de desarrollo de la IA puede superar las actualizaciones de la documentación, y la preocupación por la propiedad intelectual a veces limita lo que se registra.

Las organizaciones exitosas adoptan un enfoque diferente. La documentación se integra en los flujos de trabajo de desarrollo desde el principio. Las herramientas automatizadas capturan metadatos del modelo, datos de entrenamiento y métricas de rendimiento a medida que avanza el desarrollo. Las plantillas garantizan la consistencia, el control de versiones mantiene los registros actualizados y las revisiones periódicas detectan información faltante o desactualizada. Las auditorías interequipos cierran el ciclo antes de que se produzcan riesgos de incumplimiento. surgir.

Una documentación sólida conecta a los equipos. El departamento legal puede evaluar el riesgo cuando las fuentes de datos y el comportamiento del modelo se registran con claridad. Los líderes empresariales pueden tomar decisiones informadas cuando se documentan las limitaciones del sistema. Los gestores de riesgos pueden actuar con rapidez cuando conocen los datos de formación, los procedimientos de evaluación y los sesgos conocidos.

Con una visión compartida entre las partes interesadas, la colaboración mejora y los sistemas de IA tienen más probabilidades de cumplir con las expectativas técnicas, legales y éticas. El resultado no es solo un mejor cumplimiento normativo, sino también sistemas de IA más fiables y sostenibles.

Participación de las partes interesadas

Involucrar a las partes interesadas en la gobernanza de la IA garantiza que los sistemas se alineen con las necesidades, los valores y las expectativas de las personas a las que afectan. Esto incluye usuarios, comunidades, expertos y reguladores que ayudan a detectar riesgos, brindar retroalimentación y generar confianza antes de la implementación. Si se hace bien, este enfoque colaborativo conduce a soluciones de IA más sólidas y con mayor apoyo [6].

Muchas organizaciones tienen dificultades para lograr esto eficazmente. Identificar a las partes interesadas adecuadas no siempre es sencillo, especialmente cuando los sistemas de IA tienen impactos de gran alcance. Los intereses contrapuestos requieren tiempo, facilitación y decisiones de compromiso. Los plazos de desarrollo y las limitaciones de recursos pueden limitar la participación efectiva. Incluso cuando se recopila retroalimentación, los equipos pueden carecer de las estructuras necesarias para convertirla en cambios viables.

Las consecuencias de la insuficiente participación de las partes interesadas son cada vez más visibles. La herramienta Copilot de Microsoft, por ejemplo, recibió críticas cuando sus primeras versiones presentaron sugerencias de código sesgadas o inseguras. Posteriormente, los expertos vincularon el problema a la falta de interacción con las comunidades de desarrolladores más afectadas. La herramienta de generación de imágenes Gemini de Google se suspendió tras generar imágenes ofensivas e históricamente inexactas, lo que reveló una falta de aportaciones desde diversas perspectivas, especialmente durante la formación y la evaluación.

Estos casos demuestran el riesgo de dejar de lado las voces de las partes interesadas. Esto puede traer como consecuencia daños a la reputación, suspensiones de productos y escrutinio regulatorio, pero lo que es más importante, también pueden hacerlo sistemas que no sirven a las mismas personas para las que fueron diseñados.

Las organizaciones exitosas integran la participación en todo el ciclo de vida de la IA.

Los grupos asesores reúnen a los usuarios. , expertos en el dominio,

defensa de la retroalimentación: y comunidades afectadas. Organizaciones de los ciclos comienzan temprano y continúan durante la implementación. Los programas piloto y las consultas públicas sacan a la luz las preocupaciones antes de que se conviertan en crisis. Una comunicación clara y continua genera confianza y garantiza que las conversaciones sean más profundas que las afirmaciones de marketing.

Es crucial que las aportaciones de las partes interesadas influyan en la construcción de los sistemas, no solo en su presentación. Cuando las organizaciones integran estas aportaciones en el diseño y el desarrollo, los sistemas de IA se vuelven más capaces de satisfacer las necesidades del mundo real. Se ganan la confianza con mayor rapidez, funcionan con mayor eficacia y están mejor preparados para sortear el escrutinio regulatorio y social a lo largo del tiempo.

Navegando por el panorama regulatorio

Las regulaciones de IA varían según la industria y la jurisdicción debido a los distintos riesgos, niveles de madurez e impacto en el usuario final. Sin embargo, están surgiendo temas comunes en todas las regiones. EY identifica seis tendencias globales que configuran el panorama cambiante de la gobernanza de la IA [7]:

- Principios fundamentales: Los marcos suelen partir de compromisos universales como el respeto a los derechos humanos, la sostenibilidad, la transparencia y una gestión rigurosa de riesgos. Estos principios se reflejan en las directrices de la Organización para la Cooperación y el Desarrollo Económicos (OCDE) y el G20.
- Enfoque basado en el riesgo: Las regulaciones se centran cada vez más en la gravedad del daño potencial. Se aplican requisitos más estrictos a los casos de uso de alto riesgo que podrían afectar la seguridad pública, los derechos civiles o la salud. resultados.

- Normas específicas y agnósticas de cada sector: algunas normas se aplican en todas las industrias, mientras que otras se adaptan a sectores como la atención sanitaria y las finanzas.
- Alineación de políticas: las regulaciones de IA se están integrando a dominios de políticas digitales más amplios, incluida la ciberseguridad, la privacidad de los datos y los derechos digitales.
- Colaboración del sector privado: los entornos regulatorios, los centros de innovación y las asociaciones público-privadas permiten una experimentación segura con una supervisión definida.
- Colaboración internacional: a medida que los sistemas de IA cruzan fronteras, los reguladores se coordinan en materia de estándares compartidos y su aplicación, especialmente con modelos fronterizos que presentan riesgos desconocidos.

Si bien estas tendencias ofrecen claridad, no reemplazan la necesidad de cumplimiento normativo local. Cada jurisdicción impone sus propios requisitos, plazos y mecanismos de cumplimiento.

Para mantener su agilidad, las organizaciones deben adoptar estrategias de cumplimiento que combinen un amplio conocimiento normativo con una arquitectura adaptativa.

Las capacidades de gobernanza flexibles permiten que los sistemas cumplan con los requisitos cambiantes sin interrumpir las operaciones.

En las siguientes secciones, analizaremos dos industrias altamente reguladas: la atención médica y los servicios financieros. Examinaremos cómo...

Las tendencias globales se manifiestan en desafíos de cumplimiento concretos.

Cuidado de la salud

La IA en el sector sanitario está sujeta a un mayor escrutinio regulatorio debido a su impacto directo en la seguridad y la privacidad del paciente. Al momento de escribir este artículo,

El panorama regulatorio global está evolucionando rápidamente, pero han surgido varios temas clave que ayudan a enmarcar las estrategias de cumplimiento.

La Organización Mundial de la Salud (OMS) describe cuatro consideraciones fundamentales para la regulación de la IA en la atención médica:

- **Transparencia y documentación:** Mantener registros claros del desarrollo de la IA y la gestión del ciclo de vida para generar confianza y facilitar la evaluación regulatoria. Esto incluye rastrear el proceso de desarrollo y evitar sesgos y manipulación de datos. Los profesionales sanitarios deben poder demostrar cómo se desarrollaron, validaron e implementaron los sistemas de IA para garantizar la seguridad y el cumplimiento normativo.
- **Gestión de riesgos:** Abordar el uso previsto, las capacidades de aprendizaje continuo y los riesgos de ciberseguridad a lo largo del ciclo de vida del producto. El uso previsto se refiere a la especificación previa y la documentación de los fines médicos y los contextos clínicos exactos para los que está diseñado el sistema de IA, garantizando así que no se utilice indebidamente fuera de su ámbito validado. El aprendizaje continuo aborda el reto único de los sistemas de IA, que pueden actualizar sus algoritmos en función de nuevos datos, lo que requiere una monitorización continua para garantizar que no se desvíen de sus estándares originales de seguridad y eficacia. Estos factores, junto con las amenazas de ciberseguridad, deben gestionarse a lo largo de todo el ciclo de vida del producto.
- **Calidad de los datos:** Realizar evaluaciones rigurosas previas a la publicación para evitar la amplificación de sesgos y garantizar la representatividad de la población. La insuficiencia de datos de capacitación, que puede generar errores sistemáticos, especialmente en grupos subrepresentados, debe mitigarse mediante una capacitación más integral.

- Colaboración: Involucrar a pacientes, profesionales sanitarios, organismos reguladores y actores del sector para mejorar la seguridad y la calidad de las tecnologías de IA. La coordinación multilateral fortalece la supervisión, acelera la innovación y promueve la armonización regulatoria durante todo el ciclo de vida del producto.

En EE. UU., la HIPAA regula la protección de los datos de los pacientes, mientras que las nuevas propuestas legislativas se centran en casos de uso específicos, como el uso de la IA en las decisiones de gestión de la utilización [8]. En la UE, la Ley de IA clasifica la mayoría de las aplicaciones de IA en el ámbito sanitario como de alto riesgo, lo que implica obligaciones de cumplimiento más estrictas, que incluyen evaluaciones de conformidad, auditorías de gobernanza de datos y seguimiento posterior a la comercialización [9].

Para satisfacer estas demandas, las organizaciones sanitarias están adoptando tecnologías que promueven la seguridad y la adaptabilidad. Las bases de datos orientadas a documentos con cifrado a nivel de campo y controles de acceso granulares permiten garantizar la privacidad del paciente sin limitar la innovación en IA.

Por ejemplo, MongoDB permite cifrar datos sanitarios confidenciales en reposo y en uso, garantizando así que solo los usuarios autorizados puedan acceder a los atributos designados. En combinación con el acceso basado en roles y una auditoría exhaustiva, esta arquitectura ayuda a cumplir con la HIPAA y otros requisitos regulatorios [10].

A medida que la IA en el ámbito sanitario continúa expandiéndose, estas barreras regulatorias serán cada vez más esenciales. Favorecen no solo el cumplimiento normativo, sino también la confianza pública y la eficacia clínica. Las organizaciones que alineen sus prácticas técnicas con los nuevos estándares de supervisión estarán mejor posicionadas para escalar de forma segura y sostenible.

Servicios financieros

Las instituciones financieras se enfrentan a un panorama regulatorio de IA fragmentado y en constante evolución. Si bien no se ha establecido un estándar global, los gobiernos y los organismos supervisores están desarrollando activamente políticas que buscan un equilibrio entre la innovación y la gestión de riesgos. Esta sección captura los principales avances al momento de redactar este artículo y describe los temas que probablemente definirán la supervisión futura.

Los temas emergentes en los debates regulatorios incluyen la protección del consumidor, la equidad, la explicabilidad, la responsabilidad y la ciberseguridad.

Los avances más importantes incluyen:

- Orden ejecutiva de EE. UU. sobre IA: Las órdenes ejecutivas promueven la innovación a la vez que gestionan los riesgos. Instan a las agencias federales a evaluar el impacto de la IA en todos los sectores, incluidos los servicios financieros, y a desarrollar las mejores prácticas para una IA segura y confiable. Estas órdenes también enfatizan la necesidad de sistemas capaces de gestionar diversas fuentes de datos para el entrenamiento y la validación integrales de modelos, a la vez que abordan la ciberseguridad y la posible inestabilidad financiera sistémica [11].
- Ley de IA de la UE: Este reglamento histórico aplica un marco basado en el riesgo. Los sistemas de IA financiera, como los sistemas de calificación crediticia y de pago y liquidación considerados de alto riesgo, se enfrentan a requisitos estrictos que incluyen evaluaciones de conformidad, una sólida gobernanza de datos y metadatos, transparencia y mandatos de supervisión humana [9].
- Enfoque del Reino Unido: El Reino Unido ha adoptado una estrategia más sectorial. Reguladores como la Autoridad de Conducta Financiera (FCA) y la Autoridad de Regulación Prudencial (PRA) están integrando consideraciones de IA en sus enfoques de supervisión existentes. Estos enfatizan la necesidad de

Las empresas deben mantener fuertes controles sobre los sistemas de IA y aplicar principios de equidad, transparencia y responsabilidad a los servicios financieros específicamente [12].

- Regulación de la IA en APAC: La región Asia-Pacífico sigue enfoques diversos, a menudo sectoriales. La Autoridad Monetaria de Singapur (MAS) ha liderado con sus principios de equidad, , ética, rendición de cuentas y transparencia (FEAT). Si bien no son vinculantes, ofrecen una guía clara a las instituciones financieras. China ha adoptado normas más prescriptivas en áreas como las recomendaciones algorítmicas y los deepfakes. India está configurando su marco regulatorio con énfasis en la privacidad de los datos y el uso ético. Japón y Corea del Sur están impulsando directrices impulsadas por la industria que priorizan el desarrollo ético. Este panorama fragmentado en la región APAC refleja diferentes tasas de adopción de IA y prioridades regulatorias, lo que exige a las empresas fortalecer la gobernanza interna y mantener estrategias de cumplimiento específicas para cada región [13].

Para adaptarse a este panorama cambiante y convertir el cumplimiento normativo en una ventaja competitiva, las instituciones financieras pueden construir sobre una base de datos moderna diseñada para la agilidad y la escalabilidad. Estas plataformas permiten la integración fluida de estructuras de datos complejas y en constante evolución. Facilitan el rápido desarrollo e iteración de modelos de IA y pueden escalar eficientemente para gestionar los enormes volúmenes de datos y las demandas de procesamiento de la IA. Este enfoque integral es crucial para cumplir con los requisitos de cumplimiento normativo y, al mismo tiempo, permitir la innovación responsable en IA.

Construyendo una IA confiable y responsable

Una vez establecidos los principios éticos y los marcos regulatorios, el siguiente paso es ponerlos en práctica. Esto requiere un enfoque integral en cuatro áreas interconectadas: protección de datos, gestión de riesgos, garantía de transparencia e integración de la gobernanza.

Juntos, estos elementos forman la base para una implementación de IA responsable que mantenga la confianza de las partes interesadas y al mismo tiempo genere valor comercial.

Protección de datos La protección de datos es la base de una IA confiable. Abarca tanto el cumplimiento normativo como la disciplina operativa. A medida que los sistemas de IA procesan información personal confidencial a una escala cada vez mayor, las organizaciones deben cumplir con los requisitos de privacidad y, al mismo tiempo, construir estructuras de gobernanza que preserven la calidad, la integridad y la ética de los datos. usar.

Esta sección examina cómo las organizaciones pueden cumplir con las expectativas modernas de privacidad y establecer marcos de gobernanza que respalden la innovación sin sacrificar la supervisión.

Requisitos de protección y privacidad

Los sistemas de IA suelen procesar grandes cantidades de datos personales, lo que convierte la protección de datos en un pilar esencial de una IA fiable. Hay mucho en juego: si bien la eficacia de la IA depende de un amplio acceso a los datos, este mismo apetito conlleva graves riesgos para la privacidad. A diferencia del software tradicional,

Los sistemas de IA, que pueden depender de conjuntos de datos limitados, procesan, analizan y aprenden continuamente de la información personal, lo que genera desafíos complejos en torno al consentimiento, la minimización de datos y los derechos de los usuarios. La opacidad de muchos modelos de IA complica aún más las cosas, especialmente cuando las organizaciones deben explicar cómo los datos personales influyen en los resultados para cumplir con los requisitos de transparencia modernos.

Para conciliar estas tensiones, las organizaciones deben implementar salvaguardas técnicas y organizativas que protejan los derechos individuales y, al mismo tiempo, permitan la innovación.

Técnicas como la privacidad diferencial y el modelado causal (que se analizan más adelante en este libro) pueden ayudar a superar esta situación.

brecha.

Las regulaciones clave incluyen:

- **Reglamento General de Protección de Datos (RGPD):** Exige transparencia, minimización de datos y el derecho a explicación para los sistemas de IA que procesan datos de residentes de la UE [14]. Esto es especialmente relevante para los modelos de aprendizaje automático, a menudo denominados cajas negras. Las organizaciones deben explicar cómo se toman las decisiones automatizadas y garantizar que los usuarios comprendan sus derechos.
- **Ley de Privacidad del Consumidor de California (CCPA):** Otorga a los consumidores el derecho a acceder, eliminar y optar por no participar en la recopilación de datos [15]. Los sistemas de IA que dependen de la recopilación continua de datos para el entrenamiento y la personalización ahora deben proporcionar mecanismos para eliminar los datos del usuario, lo que puede requerir un nuevo entrenamiento o ajustes del modelo.
- **HIPAA:** Protege la información de salud del paciente en aplicaciones de IA de atención médica de EE. UU. [16]. Los sistemas de IA que analizan registros médicos, imágenes de diagnóstico o datos de pacientes deben usar cifrado y una estricta

Controles de acceso. Las infracciones pueden resultar en sanciones significativas y minar la confianza del paciente.

- Ley de Protección de Información Personal de China (PIPL): impone reglas estrictas sobre el manejo de datos y las transferencias transfronterizas [17].

Los proveedores globales de IA deben cumplir con los mandatos de localización de PIPL y obtener el consentimiento explícito antes de utilizar datos de usuarios chinos, lo que puede afectar la forma en que los modelos de IA se entrenan e implementan internacionalmente.

Para cumplir con la normativa, las organizaciones adoptan principios de privacidad desde el diseño, aplican técnicas de anonimización y privacidad diferencial, e implementan sólidos controles de cifrado y acceso. Por ejemplo, un modelo de IA utilizado para el diagnóstico de enfermedades debe cifrar los datos de los pacientes para cumplir con los estándares HIPAA y garantizar que solo los usuarios autorizados puedan acceder a los atributos sensibles.

Desarrollo de una gobernanza robusta de datos de IA. La gobernanza de datos de IA proporciona la infraestructura para una IA confiable y conforme, garantizando la calidad, la integridad, la seguridad y el manejo ético de los datos que impulsan los sistemas de IA. Las prácticas clave incluyen:

- Gestión de la calidad de los datos: garantizar que los datos sean precisos, completos y representativos de la población a la que sirven
- Seguridad de datos: aplicación de cifrado a nivel de campo consultable en reposo, cifrado fuerte en tránsito y auditoría completa del acceso a los datos para proteger la información confidencial
- Privacidad de datos: uso de anonimización (eliminación de identificadores), seudonimización (reemplazo de identificadores por seudónimos),

privacidad diferencial (añadiendo ruido estadístico) y minimización de datos (limitando la recopilación únicamente a la información necesaria)

- Seguimiento del linaje de datos: mantener registros claros de las fuentes de datos, las transformaciones y el uso posterior
- Control de acceso: aplicación de permisos basados en roles y mecanismos de autenticación
- Retención y eliminación de datos: definición de políticas sobre cuánto tiempo se almacenan los datos y cuándo deben eliminarse

Estas prácticas funcionan como un sistema. Una debilidad en un solo aspecto puede comprometer todo el marco de gobernanza y socavar la fiabilidad de los sistemas de IA.




Figura 4.2: Componentes clave del marco de gobernanza de datos de IA

La Figura 4.2 muestra cómo una gobernanza eficaz requiere un enfoque holístico. La calidad de los datos depende de un seguimiento fiable del linaje. La privacidad se ve reforzada por controles de seguridad resilientes. Las políticas de acceso permiten que los protocolos de retención funcionen correctamente. Juntos, estos componentes crean una base que respalda los resultados éticos y el cumplimiento normativo a lo largo del ciclo de vida de la IA, desde la ingesta de datos hasta la implementación del modelo.

La gobernanza se vuelve más difícil cuando la pila de IA está fragmentada.

Cada componente aplica su propio modelo de seguridad, lo que puede generar inconsistencias. Este desafío subraya el valor de una plataforma de datos unificada, como MongoDB Atlas, que simplifica la seguridad y los controles de acceso en toda la pila.

El éxito depende de considerar la gobernanza como un marco integrado, en lugar de un conjunto de tareas desconectadas. Las organizaciones que adoptan esta mentalidad reducen el riesgo de incumplimiento, mejoran la calidad de los datos y fortalecen la confianza de las partes interesadas. A medida que los sistemas de IA escalan y las regulaciones evolucionan, la gobernanza se convierte en un factor estratégico para la innovación. Apoya todas las demás dimensiones de la IA responsable, como la gestión de riesgos, la transparencia y la rendición de cuentas.

Gestión de riesgos: estrategias de evaluación y mitigación. Si bien una sólida gobernanza de datos sienta las bases para una IA confiable, las organizaciones también deben abordar los riesgos únicos que presentan los sistemas de IA. A diferencia del software tradicional, la IA puede amplificar los sesgos, generar nuevas amenazas a la privacidad y generar resultados impredecibles que afectan decisiones cruciales para el negocio y la sociedad.

La gestión proactiva de riesgos implica dos esfuerzos complementarios: evaluar los riesgos de forma temprana e implementar estrategias para mitigarlos.

En conjunto, estos pasos ayudan a las organizaciones a anticipar los desafíos antes de que se conviertan en fracasos.

Evaluación de riesgos

La evaluación de riesgos identifica y evalúa sistemáticamente las amenazas específicas de la IA, como sesgos, vulnerabilidades de seguridad o faltas éticas. Un proceso estructurado suele incluir:

- Identificación de riesgos: catalogación de riesgos en los ámbitos técnico, ético, legal y comercial
- Evaluación de riesgos: Estimación de la probabilidad y el impacto de cada riesgo
- Priorización de riesgos: centrar los recursos en los problemas más críticos
- Implementación de controles: desarrollo de salvaguardas para prevenir o reducir riesgos
- Monitoreo y revisión: Evaluación continua de los controles para comprobar su eficacia

Por ejemplo, una IA sanitaria podría someterse a auditorías demográficas para garantizar la equidad diagnóstica. Un modelo financiero podría someterse a pruebas de robustez ante ataques adversarios.

Enfoques prácticos de gestión de riesgos

Para mitigar los riesgos en la práctica, las organizaciones pueden adoptar una combinación de estrategias técnicas, procedimentales y culturales:

- Monitoreo continuo: Pruebas periódicas de rendimiento y cumplimiento con alertas automatizadas para detectar desviaciones o degradaciones. Planes de
- respuesta a incidentes: Protocolos predefinidos para fallos o infracciones de IA que reducen el tiempo de inactividad y la recuperación. Contar con procedimientos de respuesta predefinidos minimiza los daños.
- Participación de las partes interesadas: Involucrar a diversas comunidades en el diseño y las pruebas de IA para detectar los riesgos que los equipos técnicos podrían enfrentar.

extrañar

- Pruebas adversarias: intentos deliberados de manipular los sistemas de IA para exponer vulnerabilidades antes de que lo hagan los actores maliciosos.
- Redundancia y seguridad: sistemas de respaldo y supervisión humana para la continuidad de las operaciones cuando los sistemas de IA fallan inesperadamente

EY recomienda combinar la alfabetización regulatoria con una gobernanza sólida y una participación activa de los reguladores [18]. IBM ha descubierto que el 80% de los líderes empresariales consideran que la explicabilidad y la ética son barreras para la adopción de IA (un recordatorio de que una gestión de riesgos sólida no se trata solo de preocupaciones de cumplimiento, sino también de un diferenciador estratégico) [19].

Las plataformas de datos modernas respaldan estas estrategias mediante funciones como el registro de auditoría (que rastrea todas las interacciones de datos) y políticas de recursos (que automatizan los controles de acceso y aplican reglas de cumplimiento).

Obtenga más información aquí:

<https://www.mongodb.com/blog/post/simplificar-la-seguridad-a-escala-politicas-de-recursos-mongodb-atlas>

Con una base sólida en principios éticos y cumplimiento normativo, el siguiente aspecto crucial es garantizar la transparencia y la explicabilidad de los sistemas de IA.

Transparencia en acción: Mecanismos de explicabilidad

La explicabilidad y la transparencia generan confianza al hacer que las decisiones de IA sean comprensibles y las operaciones del sistema claras. Si bien la transparencia...

Proporciona una visión general del funcionamiento general de un sistema de IA, y la explicabilidad profundiza en los detalles de por qué tomó una decisión determinada en una situación específica. Ambos son importantes para construir sistemas de IA responsables y fiables.

Transparencia en IA. La transparencia

en IA se refiere a la capacidad de proporcionar información significativa sobre cómo se diseñó un sistema, qué datos utiliza y cómo funciona a nivel de sistema (a diferencia de la explicabilidad, que se centra en los resultados individuales). Incluye la divulgación de los tipos de datos utilizados, la estructura del modelo y los enfoques de toma de decisiones que emplea.

Las organizaciones clasificaron la privacidad y la seguridad de los datos como las principales prioridades para la implementación de IA, seguidas por el rendimiento y la escalabilidad [20]. Desde la perspectiva de un oficial de cumplimiento o un auditor, la transparencia es esencial para demostrar control sobre el riesgo.

Las organizaciones necesitan transparencia para alinear las iniciativas de IA con los objetivos comerciales y garantizar que los sistemas funcionen según lo previsto:

- Uso de datos: La documentación clara de las fuentes de datos, los formatos y los métodos de procesamiento permite la evaluación de riesgos, la auditabilidad y el cumplimiento.
- Patrones generales: la transparencia en cómo los modelos de IA toman decisiones (especialmente en casos de uso de alto riesgo) permite a las organizaciones garantizar que los sistemas cumplan con reglas comerciales definidas, umbrales de equidad y obligaciones regulatorias.
- Estructura del modelo: saber si un sistema utiliza lógica basada en reglas, aprendizaje automático tradicional o redes neuronales profundas

Informa las expectativas sobre mantenibilidad, supervisión y riesgos de fallas.

La transparencia también fortalece la comunicación con las partes interesadas. Los líderes empresariales necesitan claridad cuando los sistemas de IA impulsan las decisiones de los clientes. Los equipos legales y de riesgo necesitan evidencia documentada para responder a consultas o defender resultados. Los desarrolladores internos necesitan una comprensión compartida de cómo se crearon los modelos y dónde residen sus limitaciones.

Cuando se implementa de forma consistente, la transparencia reduce los puntos ciegos institucionales y promueve el escalamiento responsable de los sistemas de IA. Se convierte en un insumo estructural (no un producto de última milla) para la gobernanza, el cumplimiento normativo y la innovación.

Explicabilidad de la IA

La explicabilidad se centra en responder por qué un sistema de IA tomó una decisión específica. Si bien los métodos para lograrla están avanzando, muchos siguen siendo técnicamente complejos debido a la complejidad inherente de los modelos de IA modernos. La compensación entre la precisión y la interpretabilidad del modelo, junto con la necesidad de que los resultados sean comprensibles para los humanos, ha dado lugar a varios enfoques ampliamente utilizados en diversos sectores:

- Explicaciones Locales Interpretables y Agnósticas al Modelo (LIME): Construye modelos sustitutos más simples e interpretables que muestran cómo los cambios en las características de entrada influyen en las salidas. LIME podría usarse para explicar por qué se le denegó un préstamo a un cliente específico, aislando los valores de entrada que más afectaron la decisión.
- Explicaciones aditivas de Shapley (SHAP): utiliza la teoría de juegos cooperativos para asignar a cada característica de entrada un valor de Shapley.

Representando su contribución a una predicción específica. En un modelo de préstamo que predice una probabilidad de aprobación del 70%, SHAP podría mostrar que una puntuación crediticia alta suma un 20%, ingresos estables un 15%, pagos atrasados restan un 5% y una alta relación deuda-ingresos resta un 10%, lo que aclara cómo el modelo llegó a la predicción final.

- **Mecanismos de atención:** Generalmente utilizados en el procesamiento del lenguaje natural y la visión artificial, los mecanismos de atención resaltan en qué partes de la entrada se centró el modelo. En imágenes médicas, las capas de atención pueden mostrar qué regiones de una radiografía influyeron en un diagnóstico, lo que facilita a los profesionales clínicos validar las decisiones de IA.
- **Modelos intrínsecamente interpretables:** Los modelos más simples, como los árboles de decisión o los sistemas basados en reglas, ofrecen total transparencia (aunque probablemente menos precisos que las redes neuronales complejas y los LLM). Un árbol de decisión, por ejemplo, podría decir: «Si la puntuación crediticia es > 700 y los ingresos son > 50.000 \$ y la relación deuda-ingresos es < 30 %, entonces se aprueba el préstamo».

La explicabilidad cumple múltiples funciones críticas para el negocio. Permite la depuración y mejora de modelos al revelar cuándo los sistemas de IA toman decisiones por razones equivocadas, fomenta la confianza de las partes interesadas mediante la transparencia en la toma de decisiones y respalda las auditorías regulatorias al proporcionar documentación clara del razonamiento de la IA. Las organizaciones que implementan IA explicable a menudo descubren que la información obtenida al comprender el comportamiento de los modelos se traduce en un mejor rendimiento de los mismos, una mejor calidad de los datos y una mayor confianza tanto de los equipos internos como de las partes interesadas. Esta combinación de conocimientos técnicos y

Los beneficios comerciales hacen que la explicabilidad sea una capacidad estratégica en lugar de simplemente un requisito de cumplimiento.

El argumento comercial a favor de una IA explicable. La explicabilidad y la transparencia van más allá de la precisión técnica. Definen cómo las organizaciones gestionan el riesgo, se ganan la confianza y cumplen con los estándares de responsabilidad.

- Generar confianza: los usuarios tienen más probabilidades de confiar en los sistemas de IA cuando comprenden cómo y por qué se toman las decisiones.
- Responsabilidad: La explicabilidad aclara la responsabilidad cuando surgen problemas.
- Evaluación de la equidad: los sistemas transparentes facilitan la detección y el abordaje de sesgos o discriminación.
- Cumplimiento normativo: muchas industrias requieren un cumplimiento normativo explicable. IA, especialmente para casos de uso de alto riesgo o de cara al consumidor
- Mejora continua: comprender el comportamiento del modelo ayuda a los equipos a identificar puntos de falla, refinar la lógica y mejorar el rendimiento a lo largo del tiempo.

La explicabilidad debe priorizarse desde la fase de diseño. Los equipos pueden seleccionar las técnicas adecuadas según el uso previsto del sistema, el nivel de riesgo y la normativa aplicable.

Technique	Strengths	Weaknesses	Typical Use Cases
LIME (Local Interpretable Model-agnostic Explanations)	Model-agnostic; fast local explanations; highlights key features per prediction	Valid only locally; unstable for complex models; approximate, not exact	Quick checks, debugging individual predictions, fast instance-level insights
SHAP (Shapley Additive exPlanations)	Grounded in game theory; consistent feature attribution; supports local and global explanations	Computationally intensive; slow on large datasets or complex models	Regulatory reporting, fairness audits, high-stakes decisions needing detailed explanations
Attention Mechanisms	Visualizes model focus; naturally integrated in deep learning models (NLP and vision); intuitive for sequence data	Not a guaranteed explanation (shows focus, not causality); limited scope beyond attention layers	NLP (translation, summarization), vision tasks, any case where knowing model focus aids understanding
Intrinsically Interpretable Models	Transparent by design; decision logic traceable; fast and lightweight	Limited accuracy; misses complex patterns; weak on unstructured data	Finance, healthcare, or domains needing critical interpretability with simple models (e.g., decision trees, linear regression)

Tabla 4.1: Comparación de las técnicas de explicabilidad de la IA: fortalezas, debilidades y casos de uso

La Tabla 4.1 resume cuatro técnicas comunes de explicabilidad y las compara según sus fortalezas, limitaciones y casos de uso típicos.

Estos conocimientos comparados ayudan a los equipos a elegir el método adecuado en función de los requisitos reglamentarios, la complejidad del modelo y las necesidades operativas.

Poner en funcionamiento una IA confiable a través de la gobernanza

Para llevar los principios a la práctica se requieren estructuras de gobernanza eficaces que garanticen el desarrollo, la implementación y la supervisión responsable de los sistemas de IA. Las organizaciones pueden elegir entre varios modelos según su escala, estructura y entorno regulatorio:

- **Gobernanza centralizada:** Un solo equipo o departamento supervisa todas las iniciativas de IA. Esto garantiza estándares consistentes y

rendición de cuentas en toda la organización, pero puede introducir cuellos de botella o ralentizar la toma de decisiones.

- Gobernanza descentralizada: Cada unidad de negocio gestiona su propia gobernanza de IA. Esto ofrece flexibilidad y rapidez, pero aumenta el riesgo de inconsistencias y desalineamiento con los estándares de toda la empresa.
- Gobernanza híbrida: Combina estándares centralizados con una implementación descentralizada. Este enfoque equilibra la consistencia con la agilidad y es ideal para organizaciones grandes o globales con diversos casos de uso.

Independientemente del modelo, la gobernanza de la IA debe estar alineada con las estructuras de gobernanza corporativa más amplias de la organización. Esto incluye la integración de responsabilidades legales, técnicas, operativas y éticas en un sistema coordinado que fomente tanto el cumplimiento normativo como la innovación.

El camino por delante: tendencias emergentes y direcciones futuras

A medida que las organizaciones implementan los marcos de IA confiables descritos en este capítulo, es igualmente importante mantenerse al tanto de la evolución del sector. La gobernanza de la IA está experimentando una rápida transformación, impulsada por las nuevas tecnologías, los cambios regulatorios y la creciente presión de los clientes, los empleados y el público en general para garantizar el desarrollo de sistemas éticos y responsables.

Esta sección prospectiva explora dos dimensiones: las tendencias que darán forma a la gobernanza de la IA en los próximos años y la persistencia

desafíos que las organizaciones deben afrontar para mantener la confianza y el cumplimiento a gran escala.

Evolución de la gobernanza de la IA

Varias tendencias clave están redefiniendo cómo las organizaciones abordan la IA gobernanza:

- Auditoría de IA: evaluaciones independientes de terceros de sistemas de IA para verificar el cumplimiento de los estándares éticos y regulatorios.
- Armonización regulatoria global: esfuerzos internacionales para alinear Leyes y estándares relacionados con la IA en todas las jurisdicciones
- Herramientas de cumplimiento automatizadas: soluciones basadas en IA para rastrear, monitorear y documentar el cumplimiento en tiempo real
- Documentación estandarizada: Herramientas como tarjetas modelo y Hojas de datos que proporcionan informes coherentes y transparentes sobre los modelos de IA
- Gobernanza colaborativa: participación de la industria, los reguladores, el mundo académico y la sociedad civil en la configuración de los marcos de gobernanza

En conjunto, estas tendencias prometen hacer que los sistemas de IA sean más confiables, transparentes y fáciles de auditar. Además, reducen las cargas de cumplimiento normativo mediante la estandarización y la automatización.

Desafíos y oportunidades persistentes

A pesar de los avances, aún persisten varios desafíos:

- Escalar prácticas éticas: aplicar principios de IA responsable de manera consistente en organizaciones grandes y distribuidas

- Equilibrar la innovación y la regulación: garantizar el cumplimiento preservando la flexibilidad y la creatividad
- Complejidad técnica: hacer que los sistemas avanzados sean transparentes, explicables y auditables
- Amenazas en evolución: cómo abordar los nuevos riesgos de seguridad y privacidad que presentan las nuevas capacidades de IA
- Mantener el ritmo de los avances de la IA: adaptar los marcos de gobernanza a tecnologías como GenAI, que evolucionan más rápido que las regulaciones

Estos desafíos también representan una oportunidad para las organizaciones que lideran en IA confiable, permitiéndoles convertir la gobernanza en un diferenciador.

Las plataformas de datos modernas con capacidades de gobernanza flexibles ayudan a sentar las bases para una IA que merece confianza a gran escala.

Obtenga más información aquí:

<https://www.mongodb.com/resources/basics/data-management-strategy>

Resumen

Una IA confiable no se logra únicamente con la intención. Este capítulo examinó cómo implementar activamente los marcos éticos, los cambios regulatorios y las prácticas de gobernanza de datos para garantizar la transparencia, la equidad y la rendición de cuentas en los sistemas de IA.

Exploramos conceptos prácticos de IA confiable, incluyendo auditorías de sesgo, técnicas de explicabilidad, juntas de revisión ética, participación de las partes interesadas y documentación transparente. Estos métodos ayudan

Las organizaciones hacen efectiva la confianza al tiempo que gestionan las expectativas legales y sociales. Estudios de caso de pioneros de la salud, las finanzas y la industria como IntellectAI mostraron cómo se logra el éxito cuando una gobernanza sólida impulsa el impacto en el mundo real.

Con estas bases establecidas, el siguiente capítulo se centra en la ejecución. Exploramos cómo la IA puede impulsar la modernización a gran escala en sistemas complejos, desde la transformación de aplicaciones heredadas hasta el diseño de plataformas de nueva generación.

Referencias

1. Informe de IBM sobre el coste de una filtración de datos:

<https://www.ibm.com/reports/data-breach>

2. IntellectAI libera la IA a gran escala con MongoDB:

<https://www.mongodb.com/company/blog/innovation/intellect-ai-libera-ai-a-escala-con-mongodb>

3. ¿Qué es la gobernanza de la IA? <https://www.ibm.com/topics/ai-gobernanza>

4. Auditorías de sesgo para LLM en procesos de contratación:

<https://arxiv.org/html/2404.03086v1>

5. Ética de la IA:

<https://www.ibm.com/artificial-inteligencia/ética-de-la-ia>

6. Estrategia de gestión de datos:

<https://www.mongodb.com/resources/basics/data-management-strategy>

7. Cómo navegar por las tendencias globales en la regulación de la inteligencia artificial: https://www.ey.com/en_gl/insights/ai/how-to-

[Navegar por las tendencias globales en la regulación de la inteligencia artificial](#)

8. Regulación de la IA en la gestión de la utilización de la atención sanitaria:

[https://www.hklaw.com/en/insights/publications/2](#)

[024/10/regulación-de-la-ia-en-la-gestión-del-uso-de-la-asistencia-sanitaria](#)

9. Ley de IA de la UE: Primer Reglamento sobre Inteligencia Artificial:

[https://www.europarl.europa.eu/topics/es/article](#)

[/20230601STO93804/eu-ai-act-primera-regulación-sobre-inteligencia-artificial](#)

10. Consideraciones de la OMS para la regulación sanitaria de la IA:

[https://pmc.ncbi.nlm.nih.gov/articles/PMC1207608](#)

[3/](#)

11. Eliminando las barreras al liderazgo estadounidense en inteligencia artificial:

[https://www.whitehouse.gov/presidential-actions/2025/01/](#)

[eliminando-barreras-al-liderazgo-estadounidense-en-inteligencia-artificial/](#)

12. Regulación de la IA: un enfoque pro-innovación:

[https://www.gov.uk/government/publications/ai-regulation-a-pro-](#)

[innovation-approach](#)

13. El panorama de la regulación de la IA en la región Asia-Pacífico:

[https://lawtech.asia/el-panorama-de-la-regulación-de-la-ia-en-la-](#)

[region-asia-pacífica/](#)

14. Protección de datos:

[https://commission.europa.eu/law/law-topic/data-protection_es](#)

15. Ley de Privacidad del Consumidor de California (CCPA):

<https://oag.ca.gov/privacy/ccpa>

16. Cumplimiento de HIPAA: MongoDB Atlas:

<https://www.mongodb.com/products/platform/trust/>

17. Navegando la IA en industrias reguladas: una guía para la regulación
Consideraciones:

[Navegando la IA en las industrias reguladas: una guía para las consideraciones regulatorias](#)

18. Cómo navegar por las tendencias globales en la regulación de la inteligencia artificial:

https://www.ey.com/en_pk/insights/ai/how-to-navigate-global-trends-in-artificial-intelligence-regulation

19. Gobernanza de la IA: <https://www.ibm.com/think/topics/ai-gobernancia>

20. Adopción de IA en la auditoría interna:

<https://www.bakertilly.com/insights/abrazando-la-ia-en-la-auditoria-interna>

5

Modernización mediante IA

En el panorama digital actual, en rápida evolución, las empresas se enfrentan a un punto de inflexión crítico, un momento en el que pueden mantener el statu quo o redefinir lo posible. Para las organizaciones de todo el mundo, este punto de inflexión se centra en la modernización de los sistemas heredados, que se han vuelto esenciales para las operaciones y cada vez más difíciles de mantener. Según estudios recientes, entre el 80 % y el 90 % de los proyectos de modernización de aplicaciones fracasan, lo que pone de manifiesto los enormes desafíos que enfrentan las organizaciones al intentar actualizar sus sistemas críticos [1,2].

Este capítulo explora cómo la IA está transformando el panorama de la modernización, ofreciendo nuevos enfoques para superar las barreras tradicionales y acelerar el viaje hacia sistemas modernos, flexibles y escalables.

Al final de este capítulo comprenderás lo siguiente:

- Los desafíos fundamentales que provocan el fracaso de la mayoría de los proyectos de modernización
- Por qué los enfoques tradicionales de modernización son cada vez más insostenibles
- Cómo la IA puede acelerar aspectos específicos de la modernización proceso

- Las limitaciones de la IA y dónde la experiencia humana sigue siendo esencial
- El papel de las plataformas de datos modernas, como MongoDB, en una modernización exitosa
- Enfoques prácticos para implementar un enfoque de modernización repetible con IA
- Cómo se pueden mejorar las estrategias de prueba con IA para reducir el riesgo de modernización
- Resultados reales de la exitosa transformación de un banco privado líder

El desafío de la modernización

Las empresas de todo el mundo se esfuerzan por modernizar su software obsoleto. Se enfrentan a la presión de reducir gastos operativos, acelerar la implementación de nuevas funciones, integrar IA y cumplir con los estándares de seguridad y cumplimiento normativo. La aparición de la IA, en particular la GenAI, ha renovado el entusiasmo por afrontar estos retos de modernización.

Sin embargo, lograrlo no es fácil. Algunos de los principales obstáculos para la modernización de aplicaciones incluyen los siguientes:

- Plazos extendidos y sobrecostos: Las reescrituras de aplicaciones a gran escala son notoriamente difíciles de estimar con precisión. A menudo, extienden los plazos y presupuestos del proyecto a niveles insostenibles, lo que genera presión financiera y erosiona el apoyo organizacional. Lo que comienza como un proyecto de 18 meses con frecuencia se extiende a tres años o más, con costos que superan con creces las expectativas iniciales.

- Rotación de líderes y pérdida de impulso: La naturaleza prolongada de los proyectos de modernización puede estar sujeta a cambios de liderazgo, con la marcha de los promotores iniciales de la reestructuración. Esto deja a la nueva gerencia con la responsabilidad de heredar un esfuerzo costoso, continuo y, a menudo, poco comprendido, lo que puede erosionar la confianza y provocar el abandono del proyecto.
- El fenómeno del objetivo móvil: Mientras se construye el nuevo sistema, el sistema heredado continúa evolucionando. Se añaden nuevas funciones y se corrigen errores en el código antiguo. El equipo de reescritura debe ponerse al día constantemente, intentando alcanzar la paridad de funciones con un objetivo móvil. Este desarrollo paralelo duplica su carga de trabajo, haciendo casi imposible que el nuevo sistema pueda reemplazar realmente al antiguo.
- Complejidades no documentadas y el efecto del segundo sistema: Los sistemas heredados suelen contener años de lógica de negocio acumulada, casos extremos no documentados y características que originalmente eran errores. Una reescritura completa corre el riesgo de perder este conocimiento institucional crucial. Además, los desarrolladores pueden verse afectados por el efecto del segundo sistema, sobrediseñando el nuevo sistema con un exceso de características y una arquitectura demasiado generalizada, lo que añade complejidad innecesaria y retrasa la finalización. Como se reveló en un estudio sobre reescrituras de aplicaciones de mainframe, «9 de cada 10 proyectos de reescritura fracasan en su primer intento», debido a razones como la integración compleja y la falta de herramientas adecuadas [3].

La Figura 5.1 ilustra el círculo vicioso al que se enfrentan muchas organizaciones al intentar modernizar sus sistemas heredados. Muestra cómo los plazos prolongados conllevan cambios de liderazgo, lo que a su vez provoca cambios en los requisitos y una desviación del alcance, lo que finalmente resulta en retrasos en los proyectos.

o fracaso. El ciclo destaca por qué los enfoques tradicionales de modernización suelen ser insuficientes y por qué se necesitan nuevas metodologías asistidas por IA para romper este patrón. En última instancia, la combinación de estos factores genera una alta probabilidad de fracaso en las reescrituras a gran escala, lo que genera pérdidas financieras significativas y reticencia en las organizaciones a emprender iniciativas de modernización similares en el futuro.




Figura 5.1: Círculo vicioso al intentar modernizar un sistema heredado

MongoDB ha desarrollado un enfoque integral para la modernización que incluye ingenieros cualificados, herramientas integrales basadas en IA y procesos desarrollados a partir de la experiencia de trabajar con numerosos clientes en todo el mundo. Muchos de estos clientes hablan de un escenario ideal que implicaría un sistema de IA que gestionaría de forma autónoma todo el ciclo de vida de la modernización, desde el entorno...

Creación y refactorización de código para pruebas y migración a producción.
Sin embargo, este nivel de automatización sigue siendo una aspiración lejana.

Motivaciones para la modernización

A pesar de los desafíos, las organizaciones continúan impulsando iniciativas de modernización porque el costo de la inacción supera el riesgo del cambio. Comprender estas motivaciones proporciona un contexto importante sobre cómo la IA puede ayudar a abordar las necesidades subyacentes. Existen dos motivaciones principales para la modernización en la mayoría de las organizaciones: el miedo a quedarse atrás de la competencia debido a la falta de agilidad causada por sistemas heredados frágiles e inflexibles, y la creciente presión e inversión para mantener los sistemas antiguos, críticos para el negocio, funcionando.

Imperativos empresariales: Presión competitiva e innovación. Las organizaciones no modernizan su infraestructura tecnológica simplemente porque esté obsoleta, sino porque los sistemas heredados limitan cada vez más los objetivos empresariales. La infraestructura digital moderna permite a las empresas adaptarse rápidamente a medida que los mercados cambian y las expectativas de los clientes evolucionan. Cuando los competidores pueden lanzar nuevas funciones en días en lugar de meses, la modernización se convierte en un imperativo estratégico, no en una preferencia técnica.

En un contexto de competencia agresiva, las aplicaciones heredadas representan una amenaza existencial para la mayoría de las organizaciones, creando a menudo barreras invisibles a la innovación. Los equipos de desarrollo dedican la mayor parte de...

Dedican su tiempo al mantenimiento de estos sistemas frágiles en lugar de invertir en las nuevas capacidades que necesitan para competir eficazmente. Al abordar estas limitaciones, la modernización libera recursos humanos y computacionales para centrarse en la innovación y la diferenciación competitiva, incluyendo la integración de IA, servicios en tiempo real y análisis avanzados.

Limitaciones técnicas: La creciente carga de la arquitectura heredada

Detrás de la mayoría de las iniciativas de modernización se encuentran varios problemas técnicos comunes: desafíos que eventualmente se vuelven imposibles de ignorar:

- **Inflexibilidad arquitectónica:** Las aplicaciones heredadas monolíticas se resisten al cambio por su propia naturaleza. Lo que podría ser una simple adición de características en un sistema modular moderno, a menudo requiere modificaciones en cascada entre componentes estrechamente acoplados en arquitecturas más antiguas. Esta inflexibilidad incrementa drásticamente el coste y el riesgo de incluso cambios menores, creando una creciente acumulación de mejoras necesarias que se retrasan constantemente debido al temor a la interrupción del servicio por tiempos de inactividad inevitables.
- **Limitaciones de rendimiento:** Los sistemas heredados no solían estar diseñados para la implementación en la nube ni para gestionar los volúmenes de transacciones y el crecimiento de datos actuales. A medida que aumentan las demandas, estos sistemas alcanzan límites de rendimiento que no pueden superarse sin un rediseño radical. Estas limitaciones se agudizan especialmente cuando las organizaciones intentan implementar capacidades de IA que requieren procesamiento y análisis de datos en tiempo real.

- Exposición a la seguridad: Los marcos obsoletos y los componentes sin parches generan crecientes vulnerabilidades de seguridad. Si bien muchos proveedores ofrecen con gusto soporte extendido para estos sistemas heredados, el costo suele ser abrumador y supera con creces incluso el de los programas de modernización más complejos. Esta imposibilidad de actualizarse aumenta el riesgo de incumplimiento, especialmente a medida que regulaciones como el RGPD, la HIPAA y el PCI-DSS siguen evolucionando con requisitos más estrictos, como se explica en mayor detalle en [Capítulo 4](#) en IA confiable, cumplimiento y datos. Gobernanza .

Las motivaciones para la modernización son claras; no existe ninguna empresa de tamaño significativo que opere hoy en día que no cuente ya con algún tipo de programa de modernización, con distintos grados de éxito. De hecho, muchas empresas ya han comenzado a preguntarse si este nuevo mundo de GenAI, que tanto promete, podría ser justo lo que necesitan para liberarse de las cadenas de suministro tradicionales.

Por qué la IA por sí sola no es la respuesta

Si bien las herramientas de IA ofrecen capacidades impresionantes, cualquier desarrollador con la más mínima experiencia en su uso se dará cuenta rápidamente de que no son soluciones de modernización completas por varias razones:

- Preocupaciones sobre la fiabilidad: Los modelos GenAI generan resultados no deterministas, lo que significa que no se puede garantizar el mismo resultado con las mismas entradas. Esta imprevisibilidad genera un riesgo significativo, ya que el código generado por IA puede contener errores lógicos sutiles, vulnerabilidades de seguridad o problemas de cumplimiento normativo que solo se manifiestan en entornos de producción.

- Limitaciones de contexto: Los LLM tienen dificultades con el alcance y la complejidad de las aplicaciones empresariales. La mayoría de los esfuerzos de modernización implican sistemas interconectados con decenas o cientos de componentes. Los LLM carecen de la capacidad de mantener el contexto en esta amplitud de código, lo que los hace propensos a introducir errores en los límites del sistema, donde las dependencias son más críticas.
- Juicio de ingeniería: Los sistemas de IA no pueden replicar la sabiduría acumulada y la toma de decisiones matizada que los arquitectos e ingenieros experimentados aportan a los proyectos de modernización. Al evaluar el código heredado, los ingenieros sénior toman decisiones críticas sobre qué componentes refactorizar, reemplazar o conservar, en función del impacto en el negocio, la evaluación de riesgos y las futuras necesidades de escalabilidad. Si bien la IA puede analizar el código, no puede equilibrar eficazmente las necesidades inmediatas de migración con los objetivos estratégicos a largo plazo ni priorizar los esfuerzos de modernización basándose en el valor para el negocio frente al esfuerzo técnico.

Los asistentes de programación marcan un período transformador para la productividad de los desarrolladores al automatizar las tareas rutinarias. Sin embargo, estos asistentes enfrentan limitaciones inherentes similares a las de GenAI, dada su dependencia fundamental de dichas tecnologías. Esto no ha impedido que muchos desarrolladores, encargados de modernizar aplicaciones, adopten estas herramientas de programación y se pregunten hasta qué punto pueden impulsarlas hacia sus objetivos de modernización. Rápidamente se hace evidente que cuanto mayor es la complejidad del trabajo que se les asigna a los asistentes de programación, más tiempo se dedica a buscar y corregir errores que el LLM ha introducido. Existe una ley evidente de rendimientos decrecientes, hasta el punto en que, sin experiencia, los procesos,

y herramientas como soporte, es más fácil y seguro simplemente modernizarse utilizando prácticas de desarrollo de software tradicionales.




Figura 5.2: Evolución del desarrollo de software tradicional a la fábrica de software

La Figura 5.2 ilustra tres etapas de la evolución del desarrollo de software: desarrollo de software tradicional (codificación manual con métodos establecidos, más lento para grandes cambios, más costoso y arriesgado), desarrollo de software con IA (desarrollo asistido por LLM que aumenta la productividad individual y mejora los procesos de codificación tradicionales, pero presenta dificultades con la complejidad) y fábrica de software (procesos industrializados y automatizados, diseñados para la velocidad y la escalabilidad, que transforman los sistemas heredados de forma eficiente). Cada etapa muestra niveles crecientes de automatización y capacidad, lo que demuestra cómo la integración de la IA progresa desde la asistencia individual hasta fábricas de desarrollo automatizadas integrales.

Desbloquear la innovación con la modernización impulsada por IA

El enfoque estructurado y probado de MongoDB para la modernización ayuda a las organizaciones a aprovechar la IA para transformar aplicaciones heredadas en soluciones modernas, escalables y de alto rendimiento. Desarrollado en respuesta al hecho de que casi el 80 % de las aplicaciones empresariales aún utilizan tecnología obsoleta, este enfoque combina herramientas basadas en IA, automatización especializada y experiencia humana en desarrollo de software para reducir el riesgo de modernización y acelerar los resultados [2].

En esencia, el enfoque de modernización de MongoDB es un proceso basado en software que acelera cada paso del proceso de modernización. Comienza con el descubrimiento de aplicaciones, donde las herramientas de IA analizan las bases de código y las estructuras de bases de datos existentes, mapean las interdependencias del sistema y generan documentación preliminar. En estrecha colaboración con los clientes, el equipo de MongoDB genera casos de prueba, especialmente valiosos para aplicaciones que carecen de marcos de prueba formales, y convierte iterativamente el código heredado en código moderno, perfeccionándolo según los resultados de las pruebas hasta que el sistema supera todos los controles de calidad. Si bien aún no es un proceso de línea de montaje completamente automatizado, el enfoque evoluciona hacia una mayor eficiencia y automatización con cada iteración.

Lograr la modernización a escala empresarial y en un contexto complejo requiere un conjunto de herramientas robusto que , automatización , y un aproveche la IA como plataforma de datos moderna. Actualmente, ninguna herramienta ofrece una solución integral para la refactorización de código complejo, el análisis de dependencias, la conversión de SQL y la migración de datos a gran escala. Por ello, MongoDB utiliza un enfoque de cadena de herramientas en su modernización.

esfuerzos, integrando más de 25 (y en aumento) herramientas especializadas para distintas tareas.

El resto de esta sección desglosará los componentes esenciales de ese enfoque de fábrica, desde sus bases de datos y patrones de orquestación hasta sus pasos acelerados por GenAI, principios de prueba y puntos de referencia de rendimiento en el mundo real.

Comience con la base de datos adecuada

Las bases de datos relacionales han sido herramientas fundamentales para las empresas durante más de 40 años, pero su diseño impone limitaciones fundamentales al desarrollo de aplicaciones modernas. Los desarrolladores deben fragmentar los datos en múltiples tablas, implementar uniones complejas y mantener esquemas rígidos que resistan los cambios. A medida que las necesidades de las aplicaciones evolucionan, esta incompatibilidad arquitectónica ralentiza la velocidad, aumenta la carga cognitiva y dificulta la innovación.

Las cargas de trabajo actuales, incluidas las funciones de análisis en tiempo real y basadas en IA, exigen una plataforma de datos que pueda manejar diversos tipos de datos, escalar horizontalmente y adaptarse rápidamente a los requisitos cambiantes. Las plataformas avanzadas de bases de datos documentales, como MongoDB, proporcionan esa base. Al alinear el almacenamiento de datos con la forma en que los desarrolladores ya estructuran la información en sus aplicaciones, los modelos documentales eliminan la discordancia de impedancia que ralentiza la entrega y complica el diseño del sistema.

MongoDB ofrece una plataforma de datos unificada que admite de forma nativa una amplia gama de casos de uso: transacciones operativas, datos de series temporales, búsqueda de texto y vectores, telemetría de IoT y más, todo a través de un único modelo de documento e interfaz de consulta. Esto elimina la necesidad de...

bases de datos específicas para cada carga de trabajo, lo que reduce la complejidad, el riesgo de seguridad y los costos operativos, al tiempo que acelera la innovación.




Figura 5.3: Arquitectura de la plataforma de datos unificada de MongoDB

La Figura 5.3 ilustra cómo MongoDB habilita diversas cargas de trabajo mediante un único conjunto de datos central. Todas las cargas de trabajo operan en la misma arquitectura subyacente, optimizada para el rendimiento, la escalabilidad, la resiliencia y la seguridad en entornos globales, multicloud y locales.

Más allá de la eficiencia operativa, el modelo de documentos de MongoDB permite a los desarrolladores crear aplicaciones modernas basadas en IA a un ritmo que los sistemas relacionales tradicionales simplemente no pueden igualar. Dado que la mayoría de las aplicaciones modernas ya utilizan datos con formato JSON para objetos internos, API, eventos e integraciones, almacenar esos datos con el mismo formato ofrece importantes ventajas:

- **Maapeo de datos naturales:** los documentos se asignan directamente a objetos en lenguajes como Java, lo que reduce el código repetitivo y

Simplificando el uso de marcos modernos y bibliotecas de desarrollo

- Agilidad y productividad del desarrollador: los esquemas flexibles se alinean con las prácticas de desarrollo ágil y la iteración rápida comunes en los lenguajes modernos, sin la fricción de las migraciones de esquemas SQL complejos.
- Legibilidad y carga cognitiva reducida: los desarrolladores pueden interactuar con objetos completos y autónomos (como un perfil de usuario o un SKU de producto) sin tener que unir datos en varias tablas.
- Rendimiento y eficiencia de la infraestructura: JSON desnormalizado
Los documentos (BSON) reducen la complejidad de las consultas, aceleran los resultados y mejoran la eficiencia de la infraestructura a escala.

Este contraste se hace especialmente claro cuando se observan lado a lado los modelos relacionales y basados en documentos.




Figura 5.4: Comparación de modelos de datos relacionales y de documentos

La Figura 5.4 compara un esquema relacional normalizado con un modelo basado en documentos. A la izquierda, los datos relacionados se dividen en varias tablas, lo que requiere uniones para reensamblar un registro completo. A la derecha, MongoDB almacena el objeto completo en un único documento JSON, reflejando su uso en la aplicación.

Juntos, el modelo documental y la plataforma de datos unificada forman una base sólida para el desarrollo de software. MongoDB, ya probado en aplicaciones modernas, se está adoptando como la solución ideal también para aplicaciones basadas en IA. Cada vez más, organizaciones de todos los sectores industriales descubren que estos mismos atributos son esenciales para una modernización escalable. Al combinarse con equipos de ingeniería experimentados y un marco repetible, esto

Este enfoque abre la puerta a una transformación de aplicaciones a gran escala a un ritmo que la industria nunca antes había visto.

Automatización del proceso de modernización de fábrica

Cualquier fábrica tradicional depende de procesos repetibles para ofrecer resultados consistentes y fiables. El enfoque de MongoDB para la modernización de aplicaciones empresariales sigue el mismo principio: utilizar la automatización para escalar la transformación de sistemas heredados de forma controlada y eficiente.

Independientemente de las herramientas, el enfoque de modernización sigue un patrón común. Dentro de ese patrón, cada proyecto tiene sus propias particularidades, lo que requiere que las personas adapten las herramientas y los procesos al entorno, la arquitectura y las prioridades únicas del cliente.

Cada iteración de la fábrica incluye lo siguiente:

1. Analizar: comprender la estructura, las dependencias y la lógica empresarial del sistema heredado.
2. Generación de pruebas: cree pruebas integrales para validar el sistema comportamiento.
3. Transformación y prueba de código: convierta código y datos heredados a formatos modernos preservando la equivalencia funcional.
4. Implementar y migrar: mover la aplicación transformada a la nueva plataforma con una interrupción mínima.
5. Repetir: Aplique estos pasos iterativamente para cada modernización. fase.

El tamaño y el alcance de cada iteración dependen de factores como la estrategia de implementación y las herramientas del cliente. En general, las iteraciones más pequeñas y

Las iteraciones más frecuentes reducen el riesgo y brindan una retroalimentación más temprana.

Esta sección explora cómo la IA mejora y acelera estos procesos, manteniendo la supervisión humana necesaria. Primero, examinaremos cómo se organiza la fábrica y cómo la IA optimiza el proceso de modernización.

Orquestación: cómo se automatiza la fábrica

Los flujos de trabajo centrados en IA marcan el comienzo de una nueva era en las herramientas de orquestación. MongoDB utiliza LangFlow como base para la automatización en sus fábricas de modernización gracias a su estrecha integración con los LLM y a su velocidad para crear y actualizar flujos de agentes. Una de las capacidades clave de esta capa de orquestación es la capacidad de los LLM no solo de generar código o scripts, sino también de diagnosticar y corregir los errores que producen. Estos flujos de trabajo autocorrectivos están diseñados con la interfaz visual de LangFlow, como se muestra en la Figura




Figura 5.5: Flujo de trabajo de orquestación de LangFlow para el desarrollo de agentes de IA

La Figura 5.5 muestra la interfaz visual de flujo de trabajo de LangFlow utilizada en el enfoque de modernización de MongoDB para crear y gestionar flujos de trabajo de orquestación de IA. La interfaz muestra un diseño de flujo de trabajo basado en capacidades con diversos componentes conectados, lo que demuestra cómo LangFlow permite una integración estrecha con los LLM y proporciona un enfoque visual para crear y actualizar flujos de trabajo de agentes, simplificando así el desarrollo de procesos de automatización basados en IA mediante su generador de flujos de trabajo de arrastrar y soltar.

Por supuesto, la orquestación solo aporta valor cuando se combina con herramientas de automatización. En la siguiente sección, no nos centraremos en herramientas específicas, sino en las áreas estratégicas donde la IA está teniendo el mayor impacto a lo largo del ciclo de vida de la modernización. Dada la rápida evolución del panorama de herramientas, centrarse en dónde y cómo se utiliza la IA ofrecerá un valor más duradero que analizar herramientas individuales.

Como se mencionó anteriormente, el enfoque de modernización de MongoDB no considera GenAI como una varita mágica. Cualquiera que haya intentado automatizar completamente la modernización mediante LLM conoce las dificultades: resultados frágiles, errores ocultos y una repetición del trabajo que consume mucho tiempo y frustra el objetivo. En cambio, los ingenieros de MongoDB utilizan la IA como parte de un conjunto de herramientas cuidadosamente ensamblado para acelerar las tareas clave, manteniendo el control, la precisión y la responsabilidad.

Esta sección explora dónde la IA está generando mayores mejoras en rendimiento y productividad, comenzando con el análisis.

Análisis. El

primer paso en cualquier proceso de modernización es comprender claramente el sistema heredado: cómo está construido, qué hace y su verdadera complejidad. En un caso, el análisis de MongoDB reveló que la base de código era casi cuatro veces mayor de lo que el cliente creía inicialmente. Esta perspectiva temprana ayudó a dimensionar correctamente el alcance del proyecto y a evitar costosas sorpresas posteriores.

Así es como la IA ayuda a acelerar y mejorar el proceso de análisis:

- **Análisis y documentación de sistemas:** Muchos sistemas grandes carecen de documentación actualizada. Los LLM ayudan a subsanar esta deficiencia analizando el código para generar resúmenes de la funcionalidad y las capacidades principales de la aplicación. Pueden proporcionar una visión general eficaz de una aplicación e identificar los dominios principales, los lenguajes de programación, los marcos de trabajo y los procesos de negocio. Combinados con analizadores de código estático y herramientas específicas para bases de datos, también pueden ampliar su...

acceder a procedimientos almacenados, desencadenadores y esquemas de bases de datos.

Sin embargo, una deficiencia frecuente del análisis del sistema son las implicaciones posteriores. Si bien los LLM pueden ayudar a documentar las integraciones directas, a menudo carecen del contexto de todo el ecosistema. Aquí es donde el repositorio de modelos de arquitectura o integración de una organización cobra valor, ya que los LLM pueden usarlos para destacar áreas clave de enfoque para las integraciones.

- **Mapeo de dependencias:** Un resultado crucial de los gráficos de dependencias asistidos por IA ayuda a los equipos a visualizar interdependencias profundas en el código base. Comenzar con componentes de nodos hoja con pocas o ninguna dependencia permite un progreso más rápido y con menor riesgo. Este enfoque específico ayuda a evitar la ineficiencia de intentar resolver un código base extenso e interconectado en su totalidad. Los esfuerzos de modernización suelen implicar la migración a una arquitectura de microservicios. Los gráficos de dependencias proporcionan información valiosa para identificar posibles contextos delimitados e interdependencias entre servicios. Si bien los LLM ofrecen recomendaciones razonables, se requieren expertos en la materia para garantizar la idoneidad de los servicios.
- **Transformación de esquemas:** Un área importante del análisis implica comprender el esquema de la base de datos y determinar las colecciones y estructuras de documentos adecuadas. En primer lugar, la herramienta Relational Migrator (RM) de MongoDB utiliza IA en segundo plano para lograr precisamente esto. Además de ofrecer recomendaciones, RM permite al usuario ajustar las estructuras de los documentos. En segundo lugar, el uso de LLM para evaluar las entidades de la aplicación, como los objetos Java estándar (POJO) o los Enterprise JavaBeans (EJB), proporciona información adicional sobre la estructura de la ap

Aplicación. A menudo, existen matices o consideraciones contextuales que los LLM no pueden considerar, por lo que es necesario contar con un profesional involucrado. Un punto crucial a recordar es que la flexibilidad de MongoDB facilita enormemente cambiar las estructuras de los documentos a medida que se avanza. Evitar pasar horas interminables debatiendo cada detalle del documento permite a los equipos comenzar a convertir el código, ahorrando tiempo y dinero valiosos. Cuando el equipo descubre algo que debe cambiarse en el documento, el costo del cambio es muy bajo.

- Aumento del conocimiento: al utilizar MongoDB Atlas Vector Search, los equipos pueden crear sistemas RAG para almacenar y buscar semánticamente documentación del proyecto, código y mejores prácticas. Aprovechar RAG es útil para crear chatbots internos o herramientas de búsqueda que permiten a los desarrolladores consultar grandes cantidades de documentación de proyectos, código, informes de análisis y mejores prácticas de modernización. Disponer de una base de conocimientos actualizada y de fácil acceso es otro ahorro de tiempo que la IA hace posible.

Para los líderes, todo esto contribuye a una mayor confianza.

La modernización puede llevarse a cabo de forma segura, a escala y sin interrumpir las operaciones principales. Como veremos en la siguiente sección, esta base de análisis es lo que hace que una estrategia centrada en las pruebas sea no solo posible, sino esencial.

Generación de pruebas

Centrarse en las pruebas en las primeras etapas de la modernización es fundamental para garantizar que las funciones empresariales se mantengan intactas. Muchos esfuerzos se estancan, fracasan o nunca comienzan por temor a romper una solución que ha funcionado.

años. Abordar este riesgo de forma proactiva es esencial para minimizar los problemas y fomentar la confianza durante todo el proceso de modernización. proceso.

Pruebas de extremo a extremo.

Muchas aplicaciones a gran escala carecen de pruebas de extremo a extremo adecuadas, lo que obliga a los expertos en la materia a verificar manualmente cada cambio. Si bien las pruebas unitarias son esenciales (y se tratan en la siguiente sección), las primeras etapas de modernización se benefician más de las pruebas de comportamiento de extremo a extremo. pruebas, particularmente cuando se generan utilizando actividad de aplicación real en lugar de solo indicaciones de código.

La Figura 5.6 visualiza una estrategia más fiable: capturar entradas, salidas y cambios de estado de la base de datos durante el tiempo de ejecución para reflejar con precisión los flujos de trabajo empresariales reales. Con este contexto en la mano, incluyendo el tráfico de API (HTTP, JSON, HTML), los cambios de estado de la base de datos y el esquema subyacente, los LLM pueden generar información precisa y significativa. casos de prueba.




Figura 5.6: Generación de pruebas de extremo a extremo mediante captura del comportamiento de la aplicación

Este método supera la generación de solicitudes solo de código, que a menudo falla debido a la falta de lógica de negocio y estado de la aplicación. Una vez capturado el contexto de comportamiento, los LLM pueden generar pruebas en marcos como Cucumber, Karate u otros, acelerando así la cobertura en un formato que se integra con los procesos de control de calidad existentes. Además, vectorizar estas pruebas generadas y almacenarlas en una base de conocimiento añade valor a largo plazo: los desarrolladores pueden consultar semánticamente la lógica de negocio del sistema y reutilizar patrones clave en diferentes dominios.

Pruebas en papel

Las aplicaciones antiguas suelen depender de planes de prueba estáticos y legibles, almacenados como documentos, pero que nunca se ejecutan automáticamente. Los LLM ofrecen una vía rápida para la automatización. Con acceso a documentos de prueba digitales, pueden analizarlos y transformarlos en escenarios ejecutables. Si los documentos son demasiado largos o tienen una estructura inconsistente, los equipos pueden dividirlos manualmente o vectorizarlos para facilitar la búsqueda semántica y la generación de pruebas mediante RAG.

Para un LLM, analizar el documento y generar un escenario de prueba es sencillo. Sin embargo, las limitaciones de contexto de los LLM pueden ser problemáticas.

Existen varios enfoques para abordar este desafío. Uno consiste en descomponer manualmente las pruebas y otro en vectorizar los documentos. Vectorizar los documentos permite formular preguntas específicas sobre los datos y generar pruebas.

Además de la falta de pruebas automatizadas, muchas aplicaciones carecen de datos o entornos de prueba. Este libro no aborda la creación de entornos de prueba ni la definición de la estrategia de gestión de datos de prueba, ya que estos elementos son específicos de cada organización y su nivel de madurez en pruebas. Tras subsanar las deficiencias más críticas en las pruebas, el siguiente paso es iniciar la transformación del código.

Transformación y prueba de código La modernización de aplicaciones se presenta en muchas formas y tamaños diferentes.

Los esfuerzos de modernización pueden abarcar una o más de las siguientes áreas: migrar la lógica de los procedimientos almacenados y migrar a MongoDB, reemplazar servidores de aplicaciones/tiempos de ejecución (como JBoss y WebLogic), modernizar marcos más antiguos (incluido Oracle Forms

y WCF) y migrar a diferentes lenguajes (como Kotlin, Scala, etc.).

El enfoque general para la modernización no es único y sigue un patrón común:

- Generación de pruebas
- Transformación y prueba de código
- Pruebas comparativas
- Limpieza y optimización de código

Una vez resueltos todos los problemas y el código funcionalmente equivalente, el esfuerzo de optimización se reduce considerablemente. Algunos equipos pueden optar por optimizar durante la fase de transformación, pero esto introduce mayor complejidad y puede dificultar la depuración.

Este capítulo se centra en el proceso de transformación principal y no profundiza en el proceso de optimización posterior a la transformación, ya que estas situaciones son muy específicas de cada iniciativa de modernización. Analicemos el proceso en su conjunto.

Al adoptar un enfoque basado en pruebas, la estrategia de modernización de MongoDB busca implementar modernizaciones complejas de forma segura. Por lo tanto, el primer paso es subsanar cualquier deficiencia en las pruebas de nivel inferior. Independientemente de las tecnologías de prueba utilizadas, los LLM pueden reducir drásticamente el tiempo necesario para generar o mejorar las pruebas.

- Pruebas unitarias: Existen numerosas soluciones preexistentes para generar pruebas unitarias, por lo que este capítulo no profundiza en el tema. Están apareciendo en el mercado herramientas más nuevas y con capacidad de agente, como Qodo Cover [5], que buscan identificar y subsanar las deficiencias en las pruebas unitarias aprovechando los LLM. Uno de los enfoques inteligentes de la solución de modernización de MongoDB aprovecha los informes de dependencias para garantizar...

Se generan pruebas unitarias para todas las clases dependientes. Este enfoque permite una entrega iterativa, garantizando al mismo tiempo que todas las clases dependientes sean testeables. Al automatizar la generación de pruebas y aprovechar los gráficos de dependencia, las organizaciones pueden lograr una estrategia de migración consistente y segura.

- **Pruebas de integración:** En primer lugar, analicemos el término "pruebas de integración", que, en el contexto de este libro, consiste en probar código y otros componentes de infraestructura, como bases de datos. Se requiere un enfoque diferente para las pruebas de integración debido a la mayor complejidad de probar un espectro más amplio de una aplicación. Una estrategia eficaz es seguir un patrón similar al de las pruebas de extremo a extremo. Ejecute el bloque de código (Java, procedimiento almacenado, etc.) y capture las entradas, salidas y cambios de estado. A continuación, introduzca esta información, el código fuente relevante y la estrategia de prueba (pruebas de límite, fuzzing, Monkey, etc.) en el LLM para generar las pruebas automatizadas. Para reducir la cantidad de trabajo necesario...

Para verificar la validez de los resultados generados, utilice un LLM para calificar las pruebas de salida. Esto se logra introduciendo la solicitud original, las entradas y los casos de prueba generados en el LLM y solicitándole que califique las pruebas. Posteriormente, los usuarios pueden inspeccionar los casos de prueba con puntuaciones más bajas para validar su eficacia. Las pruebas de integración deben abordar tanto la solución actual como la nueva.

En cada paso del proceso de modernización, se deben realizar pruebas equivalentes con la solución actual y la nueva para garantizar su equivalencia. Esto se analizará con más detalle en la sección "Pruebas Comparativas".

- **Pruebas de extremo a extremo:** A medida que se identifiquen escenarios de prueba adicionales, se seguirá el enfoque anterior. No es raro que...

Se identificarán casos extremos una vez que los equipos se concentren en las capacidades comerciales específicas de la transformación.

Transformación de código impulsada por IA

La complejidad de la modernización del código varía mucho, pero el siguiente enfoque ha demostrado ser exitoso independientemente de la complejidad para acelerar la entrega:

- **Recomendación:** Los LLM han mejorado drásticamente su capacidad para recomendar un enfoque para la transformación de código. Indique al LLM los informes de dependencias y los objetivos de migración, como la conversión de Java a Kotlin, para que proporcione una estrategia para abordar la transformación del código. Debe incluir en la solicitud detalles básicos sobre cómo desea abordar la transformación, como comenzar con capacidades sin dependencias o centrarse en una capacidad empresarial, como la incorporación de un nuevo cliente. Para obtener los mejores resultados, revise la respuesta del LLM, identifique las deficiencias o inquietudes y solicítele que mejore la solicitud con estos detalles. Después de algunas iteraciones, tendrá una solicitud personalizada, específica para sus objetivos de modernización, que produce un enfoque bien planificado para la modernización. Esto no puede reemplazar a los expertos en la materia que tienen un contexto mucho más allá del que el LLM puede procesar, pero proporciona una base sólida para comenzar.

- **Convertir/compilar/reparar/probar:** el enfoque basado en fábrica de MongoDB utiliza una estrategia de ciclo cerrado y de agencia para automatizar la conversión y eliminar un volumen significativo de trabajo rutinario.

Los humanos están involucrados para dirigir el proceso general y determinar qué aspectos de la aplicación migrar. También están involucrados para intervenir cuando se automatizan la transformación, la compilación,

El bucle de prueba y reparación se bloquea y los LLM no pueden resolver los problemas correctamente. La Figura 5.7 ilustra el flujo de trabajo automatizado de transformación de código de bucle cerrado. Cuando las pruebas superan el proceso, este se completa correctamente. Si fallan, el sistema regresa automáticamente a una fase de reparación de LLM que analiza los fallos e intenta solucionar los problemas antes de reingresar al ciclo de transformación, creando un proceso de modernización automatizado y autocorrectivo con supervisión humana solo cuando el bucle automatizado no puede resolver los problemas.

Además de abordar los problemas durante el proceso, se necesitan personas para revisar el código y refinar las indicaciones de conversión. Al principio del proceso, es necesario experimentar con varias indicaciones para determinar cuál ofrece los mejores resultados. Los LLM se están volviendo muy hábiles en la generación y mejora de indicaciones. Proporcione al LLM la indicación original y las mejoras deseadas. Repita este proceso para cada aspecto de la aplicación. Por ejemplo, las indicaciones para convertir EJB a POJO y los repositorios que apuntan a bases de datos deberán modificarse para comunicaciones asíncronas.




Figura 5.7: Proceso de construcción de circuito cerrado

Desafíos de la traducción

El enfoque de modernización de MongoDB emplea herramientas y flujos de trabajo basados en IA, diseñados para transformaciones de código específicas, como SQL a Java, Java a Kotlin, SQL a lenguaje de consulta MongoDB (MQL), entre otras. Los modelos de lenguaje extensos requieren un contexto específico para realizar estas traducciones eficazmente. Por ejemplo, la conversión de PL/SQL a Java requiere tanto el esquema de base de datos pertinente como el código PL/SQL.

Para superar los desafíos que presentan las traducciones de código extensas o complejas por parte de los LLM, se emplean diversas estrategias adaptadas a la situación. En muchos casos, el código se descompone primero en unidades lógicas o código.



Bloques. Luego, el LLM transforma cada bloque de código y utiliza el código previamente convertido como entrada para la solicitud. De esta manera, el código transformado se construye iterativamente, capa por capa.

Sin embargo, en casos extremos, este enfoque iterativo y compuesto no funciona debido al tamaño del código. Para superar estas situaciones, hemos desarrollado una técnica (pendiente de patente) que adopta un enfoque diferente. Este enfoque alternativo evita los desafíos del código compuesto mediante la compilación y las pruebas en incrementos muy pequeños. Cada incremento se traduce en...

Idioma de destino y luego se prueba. Si bien los incrementos se complementan, cada traducción es independiente, lo que garantiza que el LLM no reciba un archivo de código demasiado grande. Al probar un incremento a la vez, cualquier error se identifica rápidamente.

A medida que se moderniza cada unidad lógica, es fundamental comprobar que las soluciones antiguas y nuevas produzcan los mismos resultados. La siguiente sección analiza dónde la IA ha demostrado una increíble aceleración en pruebas comparativas.

Pruebas comparativas Uno de los


pasos más críticos en la modernización es comparar el sistema heredado y el nuevo para garantizar que la lógica empresarial permanezca intacta, los procesos se comporten como se espera y los datos se conserven.

El enfoque de modernización de MongoDB utiliza una estrategia de conversión de igual a igual al principio del proceso para minimizar los desafíos en la comparación

Los resultados. En esta etapa, el rendimiento y la escalabilidad del nuevo sistema son subóptimos, pero aceptables, ya que el objetivo inicial es la modernización sin afectar la lógica de negocio. Una vez confirmada la corrección del nuevo código, comienza la optimización para los requisitos no funcionales, lo que libera la agilidad y el rendimiento reales del sistema modernizado.

Si bien los LLM no han demostrado ser eficaces para comparar directamente resultados de datos grandes o complejos, se destacan en la generación de utilidades y scripts de prueba necesarios para validar la equivalencia de datos.

La Figura 5.8 ilustra un esquema relacional simplificado (izquierda) junto con una estructura de documento moderna (derecha). En el modelo relacional, los campos usan nombres como `FIRST_NAME`, mientras que el modelo de documento usa `firstName` e integra datos relacionados, como detalles del puesto y del departamento. Los LLM pueden identificar estos patrones estructurales y generar el código necesario para realizar las comparaciones en paralelo.



EMPLOYEES	
_Id	ObjectId
employeeId	Int32
firstName	String
lastName	String
email	String
phoneNumber	String
hireDate	Date
salary	Int32
commissionPct	Int32



department	<i>Object</i>
departmentId	<i>Int32</i>
departmentName	<i>String</i>
location	<i>Object</i>
locationId	<i>Int32</i>
streetAddress	<i>String</i>
city	<i>String</i>
stateProvince	<i>String</i>
postalCode	<i>String</i>
job	<i>Object</i>
jobId	<i>String</i>
jobTitle	<i>String</i>
minSalary	<i>Int32</i>
maxSalary	<i>Int32</i>
manager	<i>Object</i>
employeeId	<i>Int32</i>
firstName	<i>String</i>
lastName	<i>String</i>

Figura 5.8: Estructuras de bases de datos

Con este enfoque iterativo y basado en pruebas, los errores de integración suelen ser fáciles de detectar, especialmente cuando los datos están aislados. Surgen desafíos más interesantes cuando los sistemas posteriores empiezan a interactuar con los datos después de su escritura.

Una vez que el código esté validado y se haya demostrado que es preciso, podemos comenzar a optimizarlo.

Limpieza y optimización de código

Una vez que el código transformado haya superado las pruebas iniciales, existe una valiosa oportunidad para aprovechar los LLM para mejorar el código y optimizar el sistema. Gracias a que se han realizado pruebas adecuadas durante todo el proceso, estos cambios pueden realizarse de forma iterativa, rápida y segura:

- Comentarios de código: Los LLM han demostrado ser muy eficaces para comentar código, incluso infiriendo el significado de nombres de variables o acrónimos poco conocidos. Estos comentarios también pueden servir como fuente para otros recursos, como la documentación de la API de Swagger o las guías de incorporación.
- Legibilidad del código: Otra práctica común de los LLM es mejorar la legibilidad del código. Algunos casos de uso comunes incluyen: Mejorar los nombres de
 - variables y funciones para que sean más legibles.
 - Refactorizar métodos grandes en unidades más pequeñas y
 - comprobables Reescribir lógica condicional compleja para facilitar el
 - mantenimiento Aplicar formato de código para cumplir con los estándares de codificación de una
 - organización Eliminar código duplicado o inalcanzable
- Optimización de código: los LLM pueden ayudar a identificar cuellos de botella, pero este proceso puede ser complicado y puede producir algunos resultados inesperados. Establezca siempre una línea base de rendimiento clara antes de comenzar a optimizar el código. Si se utilizan de forma responsable, los LLM pueden contribuir a lo siguiente: Reducir
 - el uso de memoria Mejorar la
 - velocidad de ejecución Optimizar
 - la gestión de subprocesos o concurrencia

Implementación y migración. Las organizaciones tienen enfoques únicos para implementar código, incluyendo la propagación del entorno, las comprobaciones controladas, el uso de alternancia de funciones, herramientas de canalización de CI/CD, etc. La IA puede ayudar en estas áreas, pero las ganancias de aceleración suelen ser mínimas debido a la naturaleza personalizada de cada canalización. Sin embargo, la mayoría de las organizaciones consolidadas ya han automatizado estos flujos de trabajo, lo que las hace ideales para un modelo de fábrica.

Con las pruebas adicionales generadas durante el proceso, existe la oportunidad de optimizar aún más los pipelines para lograr mayor eficiencia y automatización. La IA puede recomendar cambios continuos para mejorar la velocidad de implementación, reducir la intervención manual y aumentar la confiabilidad.

Cada proyecto de modernización de aplicaciones tendrá sus propios requisitos para migrar a la nueva solución. Algunos equipos pueden optar por ejecutar sistemas heredados y modernos en paralelo y migrar gradualmente, mientras que otros pueden optar por desarrollar capacidades individuales y migrar una a una.

Para una exploración más profunda de las estrategias migratorias, recomendamos el libro de Martin Fowler, *Patterns for Legacy Displacement* [4].

Establecer un proceso de modernización repetible Un resultado clave de la adopción de un enfoque de fábrica de software para la modernización, especialmente uno mejorado por IA, es la capacidad de establecer un proceso repetible. Una vez que se han definido patrones exitosos para las pruebas

La generación, transformación, implementación y migración de código se identifican y perfeccionan para un tipo específico de sistema heredado o componente de aplicación. Estos patrones pueden repetirse para iniciativas de modernización similares. Esta repetibilidad no consiste simplemente en repetir lo mismo una y otra vez, sino en crear un flujo de trabajo bien definido, eficiente y en constante mejora.

El ciclo de mejora continua se nutre de la retroalimentación de cada iteración de modernización. A medida que los equipos completan las transformaciones e implementaciones, recopilan información sobre la eficacia de las herramientas de IA, la precisión de las pruebas generadas, la eficiencia de los flujos de trabajo de transformación y los desafíos encontrados durante la migración. Esta retroalimentación se utiliza para:

- Refinar las indicaciones y los modelos de IA: mejorar las instrucciones dadas a los LLM para tareas como recomendación de código, transformación y generación de pruebas para obtener mejores resultados en iteraciones futuras.
- Optimice los flujos de trabajo: agilice los ciclos automatizados de conversión, compilación, prueba y reparación para reducir la intervención manual y acelerar el proceso.
- Mejorar las estrategias de pruebas: adaptar y mejorar las metodologías de pruebas en función de los tipos de problemas descubiertos en esfuerzos de modernización anteriores.
- Actualizar la documentación y las mejores prácticas: capturar las lecciones aprendidas y las técnicas exitosas en la documentación que se puede utilizar para guiar proyectos de modernización posteriores.

Al incorporar activamente estas mejoras, el proceso de modernización repetible se vuelve más eficiente y eficaz con el tiempo. Esto permite a las organizaciones abordar un mayor volumen de aplicaciones heredadas.

Modernización con mayor velocidad y menor riesgo, acercándonos a un panorama digital completamente modernizado. El objetivo es crear un ciclo autosostenible donde cada proyecto de modernización completado contribuya a que el siguiente sea más fluido y exitoso.

Para ilustrar estos principios y su impacto en el mundo real, considere el siguiente estudio de caso.

La modernización impulsada por IA transforma los sistemas bancarios centrales

Un banco privado con una larga trayectoria se enfrentó al reto de modernizar cientos de aplicaciones heredadas que se habían convertido en un obstáculo para la innovación. Como parte de una iniciativa de transformación plurianual, el banco se asoció con MongoDB para acelerar su modernización utilizando herramientas y metodologías basadas en GenAI.

El esfuerzo comenzó con dos de los sistemas más críticos del banco: su plataforma de gestión de cartera y su interfaz de banca en línea. MongoDB desarrolló herramientas de IA a medida para la arquitectura del banco, combinando scripts, indicaciones y lógica de migración adaptada a su infraestructura tecnológica. GenAI se aplicó en múltiples tareas de modernización, entre ellas:

- Análisis y traducción de código heredado
- Migración de esquemas de modelos relacionales a MongoDB
- Movimiento y transformación de datos



- Migración de middleware (de pilas de Java a entornos de ejecución nativos de la nube)
- Generación y automatización de pruebas funcionales

Trabajando en conjunto con los expertos de MongoDB, el banco adoptó un enfoque iterativo, priorizando las pruebas. Esto preservó la lógica de negocio, redujo el riesgo y permitió generar valor de forma continua durante todo el proyecto.

Los resultados fueron sustanciales:

- La migración de código fue hasta 60 veces más rápida que los esfuerzos manuales anteriores
- La migración de aplicaciones se aceleró por un factor de 20
- Las pruebas de regresión se redujeron de días a horas
- Se automatizaron las tareas repetitivas, liberando capacidad de expertos y comprimiendo los plazos.

Varios principios básicos contribuyeron al banco:
éxito:

- Un modelo de datos basado en documentos alineado naturalmente con el diseño de la aplicación
- El andamiaje de pruebas automatizado preservó la lógica empresarial y redujo el error humano
- La colaboración entre humanos e IA permitió una entrega más rápida sin sacrificar el control
- La entrega incremental favoreció los primeros logros y una adopción más amplia



Este caso destaca el potencial transformador de GenAI cuando se combina con la plataforma de datos, la experiencia técnica y el enfoque de entrega adecuados. Lo que antes se consideraba demasiado arriesgado o complejo ahora es alcanzable a escala empresarial.

Esta historia de éxito demuestra que cuando la IA se combina con el modelo de datos adecuado, la supervisión de expertos y un enfoque iterativo, se puede lograr la modernización a escala.

Si bien los proyectos de transformación de sistemas heredados han fracasado históricamente con tasas de hasta el 80-90%, estos resultados demuestran que esta tendencia puede revertirse mediante una combinación de capacidades de IA, metodologías probadas, bases de datos sólidas y asesoramiento experto. Este ejemplo se ha anonimizado para mayor claridad editorial. Para obtener más información, consulte: <https://mdb.link/private-bank-modernizes-legacy-banking-technology>.

Resumen

La modernización de los sistemas heredados representa una de las iniciativas más desafiantes pero potencialmente gratificantes que una organización puede emprender.

Si bien los riesgos son significativos, entre el 80 y el 90 % de los proyectos de modernización

Al fallar debido a plazos extendidos, rotación de líderes, objetivos cambiantes y complejidades no documentadas, el costo de la inacción continúa creciendo a medida que los sistemas heredados limitan la agilidad y la innovación empresarial.

La IA ofrece nuevas y potentes capacidades para acelerar y minimizar los riesgos del proceso de modernización, pero no es la solución milagrosa. La naturaleza no determinista de la IA, sus limitaciones contextuales y la necesidad constante de criterio humano implican que la IA funciona mejor como parte de un enfoque de modernización integral que combina herramientas automatizadas con la experiencia humana.

El enfoque de modernización de MongoDB encarna esta estrategia híbrida, aprovechando la IA para el análisis de sistemas, la generación de pruebas y la transformación de código, a la vez que mantiene la supervisión humana para las decisiones arquitectónicas y la validación de la lógica de negocio. La metodología se centra en un enfoque iterativo, priorizando las pruebas, que reduce el riesgo mediante pequeños incrementos y una validación continua. Al generar pruebas exhaustivas antes de la transformación y utilizar la automatización de bucle cerrado para los ciclos de compilación, prueba y reparación, las organizaciones pueden modernizarse con mayor confianza y rapidez.

Al partir de una base de datos adecuada y superar las limitaciones de las bases de datos relacionales, aprovechando la flexibilidad y la potencia del modelo documental, las organizaciones no solo pueden modernizar sus sistemas heredados, sino también prepararse para la innovación y el crecimiento futuros. La alineación natural del modelo documental con los patrones de desarrollo de aplicaciones modernas elimina las discordancias de impedancia y posibilita las diversas cargas de trabajo que exigen las aplicaciones basadas en IA.

A lo largo de la Parte 1, IA y conceptos clave, hemos explorado los Conceptos, tecnologías y enfoques fundamentales que permiten la modernización impulsada por la IA. En la Parte 2, se presentan casos prácticos y... Implementaciones, Examinaremos cómo se está aplicando la IA en todo el mundo. varias verticales de la industria, comenzando con un enfoque en la fabricación y movimiento en el próximo capítulo. Estos estudios de caso demostrarán Cómo se traducen los principios y metodologías discutidos hasta ahora resultados comerciales tangibles y ventajas competitivas.

Referencias

1. ¿Por qué fracasan los proyectos y programas de modernización tecnológica?

<https://www.linkedin.com/pulse/por-que-los-proyectos-y-programas-de-modernizacion-tecnologica-fallan-root-phil-harman/>

2. Por qué el 84% de las empresas fracasan en la transformación digital:

<https://www.forbes.com/sites/brucerogers/2016/01/07/por-que-el-84-de-las-empresas-fracasan-en-la-transformacion-digital/>

3. La mayoría de las reescrituras de aplicaciones de mainframe fallan la primera vez:

<https://www.ciodive.com/news/modernizacion-de-aplicaciones-mainframe-nube-hibrida/727958/>

4. Patrones de desplazamiento del legado:

<https://martinfowler.com/articles/patterns-legacy-displacement/>

5. Portada de Qodo: <https://github.com/qodo-ai/qodo-cover>

Parte 2:

Estudios de casos del mundo real y Implementaciones

Este conjunto de capítulos demuestra cómo las organizaciones de todo el mundo
Las industrias están poniendo en práctica la IA generativa y agente,
Convertir la estrategia en arquitectura y la arquitectura en resultados.
Cada estudio de caso explora cómo los desafíos comerciales específicos del dominio
Se resuelven mediante el uso de modelos de datos reales, escalables.
Infraestructura y orquestación inteligente.

Esta parte del libro incluye los siguientes capítulos:

- [Capítulo 6](#), Aplicaciones prácticas de Agentic y GenAI en
Fabricación – Parte 1
- [Capítulo 7](#), Aplicaciones prácticas de Agentic y GenAI en
Fabricación – Parte 2
- [Capítulo 8](#), Estrategias impulsadas por IA para los medios y
Industrias de telecomunicaciones
- [Capítulo 9](#) La voz y los chatbots de Cognigy en la era de la agencia
AI
- [Capítulo 10](#) Aprovechar la IA para transformar la industria minorista
- [Capítulo 11](#), Servicios financieros y la próxima ola de IA
- [Capítulo 12](#) RegData, MongoDB y Voyage AI: datos semánticos
Protección en FSI

- [Capítulo 13](#) Impulsando el éxito del cliente en la banca con GenAI Copilotos
- [Capítulo 14](#), Generando valor comercial con IA en seguros
- [Capítulo 15](#), Automatizando la suscripción de seguros con Fireworks AI y MongoDB
- [Capítulo 16](#), Transformación de la atención médica y la vida impulsada por IA Ciencias

6

Aplicaciones prácticas de Agentic y GenAI en la fabricación – Parte 1

A medida que pasamos de los conceptos fundamentales a las implementaciones prácticas en la segunda parte del libro, comenzamos nuestra exploración sector por sector sobre cómo las organizaciones están implementando la IA. Cada sector presenta desafíos, entornos de datos y métricas de éxito únicos, desde los requisitos de privacidad del paciente en el sector sanitario y las decisiones cruciales para la vida, hasta el cumplimiento normativo y la detección de fraude en tiempo real en los servicios financieros, pasando por los patrones de demanda estacional en el comercio minorista y la optimización de la experiencia del cliente. Estas características distintivas determinan cómo se desarrollan las implementaciones de IA, cómo se ve el éxito y qué tecnologías resultan más efectivas.

Comencemos con la manufactura, ya que ofrece un campo de pruebas ideal: flujos de datos operativos de gran riqueza provenientes de sensores y sistemas, problemas complejos de optimización multivariable, y ahorros de costos y mejoras de eficiencia medibles. Dada la amplitud de las aplicaciones de la IA en este sector, exploraremos la manufactura en dos capítulos. En este capítulo, nos centraremos en dónde la IA se ha convertido en la piedra angular de la transformación de la manufactura moderna, es decir, en la optimización de la cadena de suministro y la gestión de inventarios, campos de batalla críticos donde los sistemas inteligentes ofrecen los resultados más tangibles. Exploraremos cómo la IA generativa (GenAI) y los sistemas agénticos...

revolucionando estas operaciones, transformando la gestión tradicional de inventario desde enfoques reactivos basados en reglas a sistemas inteligentes y predictivos que aprovechan tanto datos estructurados como fuentes de información no estructurada previamente sin explotar.

Al final de este capítulo comprenderás lo siguiente:

- Cómo la IA está impulsando la próxima ola de transformación de la cadena de suministro en la fabricación
- La evolución del análisis ABC tradicional a la clasificación de inventario multicriterio mejorada con IA
- La metodología de cuatro pasos para implementar la clasificación de inventario impulsada por GenAI que incorpora datos no estructurados
- Cómo transformar información empresarial cualitativa en métricas de inventario cuantificables mediante el procesamiento del lenguaje natural (PLN)
- La implementación práctica de la IA agentiva para la gestión autónoma de materias primas y la optimización de las adquisiciones
- Cómo MongoDB Atlas permite una integración perfecta de datos estructurados y no estructurados para tomar decisiones de inventario inteligentes
- Ejemplos del mundo real y demostraciones interactivas de optimización de inventario impulsada por IA que generan resultados comerciales mensurables. resultados
- Técnicas avanzadas de previsión de la demanda que aprovechan la IA para predecir los requisitos de productos existentes y nuevos.

El camino hacia el éxito en la fabricación de IA

Si bien el potencial transformador de la IA en la manufactura es ampliamente reconocido, la realidad es que muchas organizaciones tienen dificultades para avanzar más allá de los proyectos piloto y alcanzar la implementación a escala de producción. Las investigaciones muestran que la mayoría de las empresas se encuentran en las primeras etapas de la adopción de la IA, y la mayoría de los fabricantes aún dependen de métodos tradicionales y equipos obsoletos. La brecha entre las pruebas de concepto exitosas y la implementación en el mundo real representa uno de los desafíos más importantes de la industria, ya que muchas iniciativas prometedoras de IA no logran un uso repetitivo ni una integración en las operaciones del negocio.

La diferencia entre las organizaciones que implementan IA a gran escala con éxito y aquellas que tienen dificultades no radica en el acceso a la tecnología, sino en la eficacia con la que orquestan la compleja interacción entre la infraestructura tecnológica, la preparación organizacional y los factores humanos. Cabe destacar que las investigaciones revelan que el tamaño de la empresa, la intensidad tecnológica y el rol en la cadena de suministro no predicen significativamente el éxito de la adopción de IA. Más bien, son la preparación digital y las capacidades fundamentales de la organización las que... Lo que más importa.

Al comprender estos patrones, las organizaciones exitosas que han pasado de los pilotos a la implementación de IA a gran escala exhiben rasgos comunes en cinco áreas clave:

- Identificación de impulsores de valor de alto impacto y casos de uso de IA: Los esfuerzos deben concentrarse en los ámbitos donde la IA ofrece la máxima utilidad, en lugar de emplearla arbitrariamente. Según un estudio de Capgemini, tres casos de uso destacan para impulsar la transición de un fabricante hacia la IA: la planificación de la demanda, el mantenimiento inteligente y el control de calidad del producto [1]. Estos casos de uso

ofrecen una combinación óptima de valor comercial claro, relativa facilidad de implementación y disponibilidad de datos.

- Alineación de la estrategia de IA con la estrategia de datos: Las organizaciones deben establecer una base de datos sólida con una estrategia de datos que respalde directamente sus objetivos de IA. Esta alineación garantiza que se recopilen, procesen y pongan a disposición los datos correctos para impulsar eficazmente las aplicaciones de IA.
- Enriquecimiento y accesibilidad continuos de los datos: Disponer de datos de alta calidad, fácilmente disponibles y utilizables en toda la organización, es esencial para el éxito de las iniciativas de IA. Los entornos de fabricación generan grandes cantidades de datos procedentes de sensores, equipos y procesos que deben capturarse y estructurarse adecuadamente.
- Potenciando el talento y fomentando el desarrollo: Al capacitar y dotar a su fuerza laboral de recursos, las organizaciones pueden empoderarla para que aproveche la IA eficazmente. Este enfoque centrado en el ser humano garantiza que la IA potencie las capacidades humanas en lugar de reemplazarlas.
- Facilitar la adopción escalable de la IA: Construir una infraestructura sólida y escalable es clave para aprovechar al máximo el potencial de la IA, facilitando su integración fluida y continua en toda la organización. Esta infraestructura debe soportar la implementación de agentes de IA y sistemas multiagente cada vez más sofisticados.

Estos principios fundamentales se hacen particularmente evidentes cuando se aplican a uno de los dominios de la fabricación con mayor cantidad de datos y mayor necesidad de optimización: la gestión de la cadena de suministro. Aquí, la convergencia de vastos conjuntos de datos operativos, métricas claras de ROI y resultados inmediatos...

El impacto empresarial crea un entorno ideal para demostrar el valor práctico de la IA.

Optimización de la cadena de suministro impulsada por GenAI

Las cadenas de suministro de manufactura modernas representan algunos de los sistemas más complejos del mundo empresarial actual, con redes interconectadas que abarcan todo el mundo. En el corazón de estas complejas operaciones reside un desafío fundamental: la optimización y la gestión del inventario. Toda organización enfrenta el mismo dilema crítico: mantener niveles más altos de inventario proporciona un colchón contra fluctuaciones inesperadas en la demanda, pero conlleva mayores costos de mantenimiento que, en última instancia, impactan la rentabilidad y el posicionamiento competitivo.

Este equilibrio se vuelve aún más complejo al considerar el efecto látigo en la cadena de suministro, donde los cambios repentinos en la demanda pueden tener consecuencias en cascada que altera los costos y el rendimiento en las operaciones de compras y abastecimiento, fabricación y producción, distribución, logística y venta minorista. Cada actor de la cadena debe sortear estas complejidades mientras se esfuerza por controlar los costos operativos y garantizar la entrega puntual a los clientes.

Descubra el potencial transformador del avance tecnológico. El IoT y la IA, en particular la GenAI, están revolucionando la forma en que las organizaciones abordan la gestión de la cadena de suministro. Estas tecnologías permiten una transparencia, eficiencia y adaptabilidad sin precedentes mediante la monitorización en tiempo real, el análisis predictivo y una mejor toma de decisiones.

creando capacidades, convirtiendo lo que antes era un acto de equilibrio reactivo en un sistema de optimización proactivo e inteligente.

La industria automotriz ejemplifica esta complejidad, con sus redes de proveedores de múltiples niveles, requisitos de justo a tiempo e interdependencias globales que la convierten en un caso de estudio ideal para comprender los desafíos de la cadena de suministro moderna.




Figura 6.1: Componentes de la gestión de la cadena de suministro y flujo de datos

La Figura 6.1 destaca la estrecha interrelación de la cadena de suministro automotriz. Pone de relieve cómo la toma de decisiones coordinada entre las funciones de upstream, midstream y downstream, como diseño, fabricación y ventas, es esencial para el flujo eficiente de información y piezas. La complejidad de estas interacciones demuestra la necesidad de soluciones de gestión de la cadena de suministro inteligentes, flexibles y resilientes para el sector automotriz.

Este ejemplo automotriz ilustra un desafío más amplio que enfrentan todos los sectores manufactureros: los enfoques manuales tradicionales para la gestión de la cadena de suministro ya no son suficientes para gestionar redes tan complejas. Cada punto de conexión representa un potencial.

cuellos de botella, riesgos y oportunidades de optimización que requieren visibilidad en tiempo real y capacidades de toma de decisiones inteligentes.

La gestión de inventarios se vuelve esencial para lograr cadenas de suministro eficientes, controlar costos y entregar a los clientes con la mínima demora.

Abarca procesos empresariales críticos, como la estimación de las necesidades de material en diferentes puntos de la cadena de suministro y la determinación de las cantidades necesarias, la frecuencia de los pedidos y los niveles de stock de seguridad. Desde la previsión de la demanda y la optimización de los plazos de entrega hasta el mantenimiento de la visibilidad del inventario en tiempo real en redes complejas, estos desafíos interconectados requieren una coordinación sofisticada para garantizar que el inventario correcto esté en el lugar correcto en el momento oportuno, minimizando los costos del sistema y satisfaciendo las necesidades del cliente.

Enfoques de planificación multinivel. La complejidad que se muestra en las cadenas de suministro modernas exige enfoques de planificación igualmente sofisticados que puedan abordar simultáneamente diferentes horizontes temporales y alcances organizacionales. La planificación estratégica y táctica es crucial para una gestión exitosa de la cadena de suministro; el principio de Pareto sugiere que el 20 % de los esfuerzos en planificación estratégica y táctica puede generar el 80 % del efecto total [2]. Sin embargo, estos procesos enfrentan desafíos significativos, particularmente en la predicción de la demanda a largo plazo, las tendencias del mercado y las condiciones económicas debido a los horizontes temporales extendidos que aumentan la incertidumbre a medida que evolucionan las condiciones del mercado, las preferencias de los consumidores y los avances tecnológicos. Para abordar estos desafíos sistemáticamente, las organizaciones deben estructurar sus procesos de planificación en múltiples niveles de toma de decisiones.

Las empresas normalmente realizan la planificación de la cadena de suministro en tres niveles distintos:

1. Nivel estratégico: Decisiones de alto nivel que afectan a toda la organización. organización, incluida la planificación de escenarios que examina datos internos y externos, como noticias mundiales, acontecimientos políticos y literatura científica, para identificar preocupaciones y tendencias estratégicas que informen los escenarios futuros.
2. Nivel táctico: Planificación a medio plazo que se centra en la asignación de recursos y la implementación de decisiones estratégicas dentro de plazos definidos y restricciones operativas.
3. Nivel operativo: planificación a corto plazo que aborda las operaciones diarias, las necesidades inmediatas y los ajustes en tiempo real para mantener un flujo fluido en la cadena de suministro.

Este enfoque de múltiples capas proporciona la base para estrategias de gestión de inventario más sofisticadas, donde cada nivel de planificación aporta insumos esenciales al proceso de optimización que se mejorará mediante técnicas de análisis y clasificación impulsadas por IA.

Enfoques de clasificación y optimización de inventarios Una gestión eficaz del inventario comienza con la clasificación adecuada de los artículos del inventario para determinar políticas de control apropiadas.

Los enfoques tradicionales han progresado desde el análisis ABC clásico, que clasifica los artículos únicamente por su valor en dólares, hasta la clasificación de inventario de criterios múltiples (MCIC), que incorpora múltiples

factores cuantitativos y cualitativos para categorizaciones más precisas. Más recientemente, GenAI ha desbloqueado el potencial de transformar fuentes de datos no estructurados, como reseñas de clientes y comunicaciones con proveedores, en información procesable sobre el inventario, creando posibilidades completamente nuevas para la clasificación inteligente que van mucho más allá de los métodos tradicionales.

El análisis ABC y sus limitaciones

El análisis ABC es un método ampliamente utilizado para clasificar los artículos del inventario en categorías según su importancia relativa.




Figura 6.2: Marco de análisis ABC para la clasificación de inventarios

La figura 6.2 ilustra el método de análisis ABC, que clasifica el inventario en tres grupos según el valor de las ventas: la categoría A incluye el 20% de los artículos que generan el 80% de las ventas totales, la categoría B

La categoría C abarca el 30% de los artículos que contribuyen al 15% de las ventas, y la categoría C se compone del 50% de los artículos que representan solo el 5% de las ventas. Esta clasificación ayuda a optimizar el inventario al priorizar los artículos de alto valor (A), equilibrar la disponibilidad y el costo de los artículos de valor medio (B) y minimizar los costos de los artículos de bajo valor (C). Si bien el análisis ABC se valora por su simplicidad, ha sido criticado por centrarse exclusivamente en el uso de dólares. Esto ha llevado al desarrollo de enfoques más sofisticados.

MCIC y la necesidad de GenAI

El MCIC va más allá del valor en dólares e incorpora criterios adicionales que influyen en las decisiones sobre inventario. Estos criterios incluyen tanto características cuantitativas (datos numéricos medibles) como información cualitativa (evaluaciones descriptivas y subjetivas). Algunos ejemplos de criterios utilizados para el MCIC son factores tanto cuantitativos como cualitativos.

Las características cuantitativas que normalmente se consideran están impulsadas por el objetivo crítico de lograr entregas de inventario justo a tiempo, lo que exige una medición precisa y la optimización de factores como los siguientes:

- Plazo de entrega (días)
- Costos de mantenimiento de inventario (porcentaje del valor del artículo)
- Requisitos de tamaño del pedido (unidades)
- Frecuencia histórica de desabastecimiento (ocurrencias por año)

Los factores cualitativos que pueden influir en las decisiones de clasificación representan lecciones aprendidas a lo largo de décadas de evolución de la cadena de suministro.

Los proveedores de autopartes y los fabricantes de automóviles se encontraron con estos problemas

en los primeros días de la globalización de las cadenas de suministro y tuvieron en cuenta dolorosamente estas preocupaciones en sus sistemas de gestión de pedidos e inventario a través de un extenso ensayo y error:

- Común (qué tan ampliamente se usa un artículo en diferentes productos)
- Riesgo de obsolescencia (probabilidad de quedar obsoleto)
- Durabilidad (vida útil esperada y confiabilidad)
- Confiabilidad del proveedor (consistencia en la entrega y calidad)
- Importancia estratégica (alineación con las prioridades del negocio)

El desafío fundamental en la clasificación de inventarios reside en combinar eficazmente estos diversos tipos de información. Si bien las características cuantitativas pueden incorporarse directamente en los modelos de clasificación, la información cualitativa debe transformarse primero en valores medibles para que sea útil para la categorización sistemática de inventarios.

Tradicionalmente, este proceso de transformación enfrentaba varias limitaciones críticas:

- Carga de evaluación manual: Convertir información cualitativa en características cuantitativas generalmente requería que los expertos del dominio calificaran manualmente cada artículo del inventario en relación con cada criterio, un proceso extremadamente tedioso para inventarios grandes.
- Problemas de coherencia: las evaluaciones humanas de factores cualitativos inevitablemente introducen subjetividad e incoherencia entre los diferentes evaluadores.
- Fuentes de datos sin explotar: a menudo existe información cualitativa valiosa dentro de fuentes de datos no estructuradas (reseñas de clientes, registros de mantenimiento y comunicaciones con proveedores) que permanecen inaccesibles a los métodos de clasificación tradicionales.

- Restricciones de escalabilidad: a medida que crecen los catálogos de inventario, la transformación manual de información cualitativa se vuelve cada vez más insostenible.

Se pueden aplicar implementaciones avanzadas de este enfoque a través de agrupamiento estadístico y otras técnicas de aprendizaje automático no supervisado, creando una comprensión más matizada de la importancia del inventario y estrategias de gestión apropiadas, especialmente cuando se dispone de características cuantitativas e información cualitativa transformada para el análisis.

IA y MongoDB para la optimización del inventario. La convergencia

de la IA y las tecnologías

modernas de bases de datos ha creado oportunidades sin precedentes para abordar estas limitaciones tradicionales en la clasificación del inventario. Los enfoques basados en IA ahora pueden procesar automáticamente grandes cantidades de datos, tanto estructurados como no estructurados, transformando la información cualitativa en características cuantitativas, manteniendo al mismo tiempo la escalabilidad y la consistencia que los procesos manuales nunca podrían lograr. Las plataformas modernas como MongoDB Atlas proporcionan la base de datos unificada necesaria para estas aplicaciones avanzadas de IA, lo que permite a las organizaciones almacenar, procesar y analizar diversos tipos de datos, desde métricas de inventario tradicionales hasta reseñas de clientes y comunicaciones con proveedores, dentro de una arquitectura única y flexible. Esta base tecnológica permite enfoques sofisticados de optimización del inventario que antes eran imposibles de implementar a escala.

Clasificación de inventario impulsada por GenAI

GenAI mejora significativamente el MCIC tradicional al incorporar datos no estructurados que contienen información valiosa sobre la demanda y

Patrones de consumo de inventario. Los datos no estructurados se pueden

transformar en datos estructurados para la entrada de características en los modelos de clasificación de inventario. La adición de datos no estructurados como características...

Puede mejorar los resultados de la clasificación.

Las reseñas de productos permiten extraer métricas cualitativas, como la probabilidad de recomendar el producto, la probabilidad de volver a comprarlo y la comparación entre expectativas y realidad. Además de las puntuaciones, al analizar el texto y las imágenes adjuntas, podemos extraer información detallada sobre la perspectiva subjetiva de nuestros clientes sobre un producto en particular, lo que puede influir en la demanda futura.




Figura 6.3: Transformación GenAI de datos no estructurados para la clasificación de inventario

La Figura 6.3 ilustra el proceso central mediante el cual GenAI transforma datos no estructurados en características valiosas para la clasificación de inventario. A la izquierda, vemos diversas fuentes de datos no estructurados (reseñas de texto de clientes, reseñas de audio/video y menciones en redes sociales) que anteriormente no se habían aprovechado en los sistemas tradicionales de clasificación de inventario. El modelo de lenguaje grande (LLM) en el centro actúa como un potente motor de transformación, procesando

Estas diversas entradas y la extracción de patrones, sentimientos e información significativos se estructuran como características cuantitativas que pueden incorporarse directamente a los modelos de clasificación de inventario junto con las métricas tradicionales.

Metodología para implementar la clasificación de inventario impulsada por GenAI Si bien la transformación conceptual que se muestra en la Figura 6.3 demuestra el potencial de GenAI para la clasificación de inventario, traducir esta visión a la práctica requiere un enfoque sistemático.

Las organizaciones necesitan una hoja de ruta clara que aborde las complejidades técnicas de trabajar con diversos tipos de datos, el desafío de crear criterios de evaluación significativos y los requisitos de integración para los sistemas de inventario existentes.

La metodología para implementar la clasificación de inventario impulsada por GenAI sigue un proceso de cuatro pasos:

1. Cree y almacene incrustaciones vectoriales a partir de datos no estructurados.
2. Criterios de evaluación del diseño y almacenamiento.
3. Cree una aplicación agentic para realizar una transformación basada sobre criterios.
4. Vuelva a ejecutar el modelo de clasificación de inventario con funciones mejoradas.



Figura 6.4: Metodología de cuatro pasos para la clasificación de inventario impulsada por GenAI

Este diagrama de flujo ilustra un proceso secuencial de cuatro pasos para implementar la clasificación de inventario mejorada con IA.

Esta integración de datos no estructurados representa un avance significativo respecto de los enfoques tradicionales de clasificación de inventario, permitiendo a las organizaciones tener en cuenta la voz del cliente, el sentimiento del mercado y otras señales cualitativas que a menudo contienen indicadores tempranos de patrones de demanda cambiantes o problemas de rendimiento del producto.

Cada paso de esta metodología se basa en el anterior, creando un marco integral que transforma la forma en que las organizaciones abordan la clasificación de inventario. Analicemos cada paso en detalle para comprender cómo se desarrolla esta transformación en la práctica.

Paso 1: Creación y almacenamiento de incrustaciones vectoriales a partir de datos no estructurados. En este paso

inicial, las fuentes de datos no estructurados, como reseñas de clientes, menciones en redes sociales y comentarios de audio/video, se procesan mediante modelos de incrustación para crear representaciones vectoriales. Estas incrustaciones vectoriales capturan el significado semántico y la información con matices del contenido no estructurado.




Figura 6.5: Proceso de incrustación de vectores para datos no estructurados

Este diagrama muestra cómo se procesan las reseñas e imágenes de productos mediante un incrustador para crear representaciones vectoriales almacenadas en una colección de reseñas vectorizadas. El proceso de incrustación transforma texto, imágenes u otros datos no estructurados en matrices vectoriales numéricas que se pueden almacenar y consultar de forma eficiente. Por ejemplo, una reseña de producto como "Excelente producto..." se convierte en un vector multidimensional (p. ej., [0.3, 0.6, ..., 11.2]) que conserva su significado semántico.

Estas incrustaciones se almacenan en MongoDB utilizando una estructura similar a la siguiente:

```

{
  "_id": ObjectId('64d39175e65'), "review":
  "Excelente producto...", "score": 5,
  "product": {...},

```

```
"usuario": {...},  
"incrustación": [0.3, 0.6, ..., 11.2]  
}
```

El proceso de vectorización hace que información previamente no cuantificable sea legible y analizable por máquina, creando una base para una clasificación de inventario más sofisticada que considera el sentimiento y la retroalimentación de los clientes.

Paso 2: Diseño y almacenamiento de criterios de evaluación. Un paso crucial en la implementación de GenAI para la clasificación de inventarios es el desarrollo de criterios de evaluación. Estos criterios son las reglas y directrices explícitas que definen cómo se transforma la información cualitativa en puntuaciones cuantitativas. Estos criterios sirven como capa de traducción entre los datos no estructurados y las características numéricas requeridas para los modelos de clasificación de inventarios.

Este proceso involucra múltiples insumos y partes interesadas para garantizar que el sistema de IA evalúe los artículos del inventario en relación con los objetivos comerciales relevantes.




Figura 6.6: Sistema de IA que genera criterios de evaluación empresarial

Este diagrama ilustra cómo un agente de IA sintetiza múltiples entradas, como objetivos comerciales, conocimiento del dominio experto, datos estructurados (rotación de inventario e historial de ventas) y datos no estructurados (opiniones de clientes y políticas de cumplimiento), utilizando LLM, herramientas e integradores para generar automáticamente criterios de evaluación.

Estos criterios de evaluación están diseñados para reflejar tanto las prioridades estratégicas de la organización como su experiencia específica en el dominio.

Las entradas se pueden clasificar, en términos generales, de la siguiente manera:

- **Objetivos de negocio:** Estos incluyen objetivos de reducción de costos, minimización de desabastecimiento y requisitos de experiencia del cliente. Los líderes empresariales definen estos objetivos con base en la estrategia corporativa y las demandas del mercado.
- **Conocimiento experto del dominio:** los expertos en la materia brindan información sobre los factores específicos de la industria que influyen en el inventario.

decisiones, garantizando que el sistema de clasificación tenga en cuenta consideraciones específicas del sector.

- Datos estructurados: se trata de información cuantitativa, como tasas de rotación de inventario, plazos de entrega, historial de ventas y patrones de órdenes de compra.
- Datos no estructurados: se trata de información cualitativa procedente de opiniones de clientes, políticas de calidad y cumplimiento e informes de auditoría de proveedores.

El agente de IA combina estas entradas para generar criterios de evaluación, que se almacenan en un formato estructurado. Si bien el siguiente ejemplo se ha simplificado a modo de ilustración, en la práctica, estos criterios serían significativamente más complejos, ya que suelen incluir múltiples evaluaciones condicionales, esquemas de ponderación y umbrales de confianza:

```
{ _id: ObjectId('64d39175e65'), name:  
  "Durabilidad del producto",  
  definición: "Analizar la durabilidad del producto y asignar un sco  
  dataSources: ["reviews"],  
  embedding: [0.3, 0.6, ... ,      11.2]  
}
```

El agente de IA sugiere proactivamente fuentes de datos relevantes (en este caso, "reseñas") que contienen información pertinente al criterio específico que se evalúa. Al identificar qué colecciones o repositorios de datos contienen información valiosa sobre cada criterio, el sistema de IA crea un puente inteligente entre distintas fuentes de información y datos de inventario útiles.

Estos criterios se vectorizan posteriormente para permitir la correspondencia semántica con la información y las reseñas del producto. Esto permite a la IA evaluar los artículos del inventario no solo con base en métricas tradicionales, sino también en factores cualitativos que podrían afectar la demanda futura o su importancia estratégica.

Las capacidades de búsqueda de modelos de documentos y vectores de MongoDB ofrecen una solución integral para este enfoque, permitiendo a las organizaciones almacenar tanto datos de inventario estructurados como incrustaciones vectoriales de información no estructurada en la misma base de datos. Esta solución unificada... La arquitectura elimina los silos de datos y proporciona una vista integral de los factores relacionados con el inventario.

Paso 3: Creación de una aplicación de agente para realizar una transformación basada en criterios. En este paso, se desarrolla un agente de IA para procesar sistemáticamente cada producto del inventario según los criterios de evaluación establecidos en [Insert]. Este agente actúa como el motor operativo que transforma los datos cualitativos del Paso 2 en métricas cuantificables.




Figura 6.7: Flujo de trabajo del agente de IA para la transformación basada en criterios

Este diagrama muestra cómo un agente de IA procesa sistemáticamente los productos del inventario combinando características cuantitativas tradicionales con información cualitativa extraída por IA. El agente recorre cada producto, aplica criterios de evaluación, realiza una búsqueda vectorial en las reseñas de los clientes y genera datos mejorados del producto que incluyen métricas estándar (SKU, precio y plazo de entrega) y nuevas características derivadas de IA (puntuaciones de durabilidad y calificaciones de criticidad) para una mejor clasificación del inventario.

La aplicación agentic sigue un flujo de trabajo bien definido:

1. Bucle de procesamiento del producto: el sistema itera a través de cada producto en el catálogo de inventario.
2. Coincidencia de criterios: para cada producto, el agente identifica criterios de evaluación relevantes.
3. Integración de búsqueda vectorial: el agente utiliza la búsqueda vectorial. Capacidades para encontrar las reseñas de clientes más relevantes y otras

Datos no estructurados pertenecientes a cada producto en función de los criterios de incrustación.

4. Análisis semántico: Utilizando filtros como product_ID y

Consultas de búsqueda semántica: el agente localiza y analiza reseñas relevantes que contienen información sobre los criterios específicos que se están evaluando (como durabilidad, confiabilidad o satisfacción del usuario).

5. Extracción de características: el agente procesa estos datos no estructurados para extraer puntuaciones cuantificables para cada criterio, transformando las evaluaciones cualitativas en valores numéricos.

El resultado de este proceso es una estructura de datos de producto mejorada que combina métricas cuantitativas tradicionales con nuevas características cualitativas extraídas por IA.

Por ejemplo, un producto representado únicamente con datos cuantitativos podría verse así:

```
{  
  "sku": 1,  
  "costo unitario promedio": 49,92,  
  "consumo anual en dólares": 5840,  
  "plazo de entrega": 2  
}
```

Cuando se mejora con características cualitativas extraídas por GenAI, la misma estructura de datos del producto se expande para incluir atributos como durabilidad y criticidad:

```
{  
  "sku": 1,  
  "costo unitario promedio": 49,92,  
  "uso anual en dólares": 5840,
```

```

    "plazo de entrega":
    2, "durabilidad": 1,
    "criticidad": 0,5
  }

```

Este proceso de transformación crea un perfil completo para cada artículo del inventario que captura tanto los atributos cuantitativos explícitos como las características cualitativas implícitas derivadas de los comentarios de los clientes y otras fuentes no estructuradas.

Paso 4: Volver a ejecutar el modelo de clasificación de inventario con funciones mejoradas

El paso final consiste en utilizar el conjunto de funciones mejoradas para reclasificar los artículos del inventario con mayor precisión y relevancia para el negocio. Este proceso incorpora tanto las métricas cuantitativas tradicionales como las nuevas características cualitativas derivadas de datos no estructurados.




Figura 6.8: Proceso de reclasificación de inventario con funciones mejoradas

Este diagrama muestra el paso final donde las características cualitativas extraídas por IA se combinan con datos cuantitativos tradicionales a través de