

Selección de características, equilibrio de ponderaciones y métodos de clasificación.

El proceso de reclasificación incluye varios componentes clave:

1. Selección de funciones: con la orientación de expertos en el dominio y
Objetivos de negocio: se identifican las características más relevantes para la clasificación. Esto podría incluir métricas tradicionales como el consumo anual en dólares (UAD) y el plazo de entrega, junto con nuevas características derivadas de GenAI, como la durabilidad o la satisfacción del cliente.
2. Equilibrio de peso: se asignan pesos adecuados a cada característica seleccionada en función de las prioridades del negocio y el aporte de expertos, lo que garantiza que la clasificación refleje los objetivos estratégicos de la organización.
3. Implementación del método de clasificación: se selecciona un método para combinar estas características ponderadas, que podrían involucrar modelos basados en reglas, algoritmos de aprendizaje automático o enfoques híbridos, según la complejidad del inventario y los requisitos comerciales.
4. Ejecución del modelo: El modelo de clasificación se ejecuta con el conjunto de funciones mejorado, que genera clasificaciones de inventario actualizadas que reflejan una comprensión más matizada de la importancia de cada artículo.

El resultado de este proceso es un inventario recién clasificado con categorizaciones (por ejemplo, A, B, C) que tienen en cuenta tanto las métricas financieras tradicionales como los aspectos cualitativos más profundos:

```
{  
  "sku": 1,  
  "uso_anual_en_dólares": 5,840,  
  "plazo_de_entrega": 2,
```

```
"durabilidad": 1,  
"clase": "A"  
}
```

Esta reclasificación proporciona una visión más precisa y holística de la importancia del inventario, lo que permite tomar decisiones mejor informadas sobre los niveles de existencias, las frecuencias de pedidos y las estrategias de gestión de proveedores.

Atlas: Infraestructura de IA unificada

MongoDB Atlas sirve como base integral para las soluciones de inventario modernas, ayudando a las empresas a mejorar la calidad del servicio y la eficiencia de su personal, así como a optimizar la gestión de inventario mediante una vista única del inventario, arquitecturas basadas en eventos y análisis en tiempo real. Esta solución sienta las bases para escenarios avanzados como la integración de etiquetas IoT y RFID, profundizando en la previsión de IA/ML para una predicción precisa de la demanda y la logística distribuida.

La flexibilidad de la plataforma permite su aplicación no solo desde el almacén hasta el punto de venta, sino también en toda la cadena de suministro, incluyendo la fabricación, el transporte, el comercio minorista y la logística inversa, lo que la convierte en un recurso valioso para diversos sectores empresariales. El conjunto integrado de productos de MongoDB respalda cada paso del proceso de clasificación de inventario basado en IA:

1. Incrustaciones vectoriales: MongoDB Atlas Vector Search almacena e indexa incrustaciones generadas a partir de datos no estructurados (reseñas de clientes, redes sociales, etc.), lo que permite realizar búsquedas semánticas eficientes.
2. Criterios de evaluación: el modelo de documento flexible de MongoDB almacena criterios de evaluación complejos como documentos JSON, incluidos

definiciones, asignaciones de fuentes de datos y representaciones vectoriales para coincidencia semántica.

3. Aplicación agentic: las capacidades de consulta de MongoDB, combinadas con Atlas Vector Search, permiten al agente de IA filtrar eficientemente los elementos del inventario y encontrar revisiones o documentación semánticamente similares para evaluar criterios cualitativos.
4. Modelo de clasificación: Para métodos de clasificación más simples, El marco de agregación de MongoDB permite procesar el conjunto de funciones mejoradas para recalculas las clasificaciones de inventario y almacenar los resultados en un formato que se integra a la perfección con los sistemas de inventario existentes. Para métodos más avanzados, MongoDB se integra a la perfección con los marcos y plataformas de IA líderes en la industria para ejecutar el modelo de clasificación.

La siguiente figura proporciona una descripción general de alto nivel de cómo MongoDB Atlas respalda cada etapa del flujo de trabajo de clasificación de inventario impulsado por IA, integrando las capacidades de IA con los requisitos de infraestructura de datos.



Figura 6.9: Canal de clasificación de inventario impulsado por IA de MongoDB Atlas

Este diagrama ilustra la integración fluida entre las capacidades de IA y la infraestructura de datos, lo que permite una clasificación sofisticada de inventario a escala. El pipeline demuestra cómo MongoDB Atlas actúa como la base unificadora que conecta las fuentes de datos sin procesar con la información procesable del inventario.

Al admitir incrustaciones de vectores, almacenamiento flexible de documentos e integración de IA nativa dentro de una única plataforma, Atlas elimina la complejidad y la deuda técnica normalmente asociadas con las arquitecturas de múltiples sistemas, lo que permite a las organizaciones centrarse en optimizar sus estrategias de inventario en lugar de administrar tecnologías dispares.

Demostración de clasificación de inventario con GenAI: Un tutorial visual.

Exploremos una demostración real de cómo GenAI transforma la clasificación de inventario en acción. Este tutorial muestra cómo MongoDB Atlas va más allá de las métricas tradicionales para crear un sistema de gestión de inventario verdaderamente inteligente que captura factores cuantitativos y cualitativos.

Paso 1: Comenzando con la clasificación básica

La interfaz de Optimización de Inventario de MongoDB presenta inicialmente una vista sencilla de los artículos del inventario. Esta primera pantalla muestra productos con atributos convencionales como el Código de Producto y `annualDollarUsage`, junto con una Puntuación Ponderada y una asignación de Clase preliminares.

En esta etapa, la clasificación se limita a métricas cuantitativas básicas. Como se muestra en la interfaz, solo `annualDollarUsage` está activo. Se considera con un peso predeterminado, lo que resulta en un sistema de clasificación unidimensional. Observe cómo se ordenan los productos en clases (A, B, y C) basado principalmente en el valor en dólares, faltando muchos factores matizados que podrían afectar las decisiones de inventario.

Este punto de partida representa la clasificación tradicional del inventario:

Funcional pero que carece de la profundidad necesaria para una optimización real.

Gestión de inventarios en cadenas de suministro complejas. El peso

Las puntuaciones visibles en esta pantalla sirven como base para comparar las

Mejoras posibles gracias a GenAI.



Figura 6.10: Interfaz de demostración inicial de optimización de inventario de MongoDB con funciones básicas clasificación

Con esta base establecida, ahora podemos demostrar cómo la IA

Transforma este enfoque básico en algo mucho más sofisticado

y relevante para el negocio.

Paso 2: Generar nuevos criterios basados en IA

La transformación comienza cuando los usuarios hacen clic en el botón "Generar criterios", lo que abre el intuitivo cuadro de diálogo "Generador de criterios con tecnología GenAI", que se muestra en la Figura 6.11. Esta interfaz conecta la experiencia humana con las capacidades de IA, permitiendo a los usuarios empresariales describir factores importantes en lenguaje natural.

En este ejemplo, un usuario introduce: "Considere el nivel de satisfacción del cliente con un producto para considerar su valor futuro potencial" .

El sistema procesa esta descripción en lenguaje natural y completa automáticamente la siguiente información:

- Nombre del criterio: Satisfacción del cliente
- Definición de criterios: Una definición completa que explica cómo se medirá la satisfacción del cliente, incluido el análisis de las reseñas para determinar la probabilidad de repetición de compra, el sentimiento extraído de las calificaciones de estrellas y la percepción general del valor en relación con las expectativas.
- Fuentes de datos: La interfaz permite la selección de datos relevantes repositorios como REVIEWS y PRODUCTS analizarán , que la IA para cuantificar este criterio previamente subjetivo

Este paso representa una innovación clave: traduce el conocimiento empresarial cualitativo en métricas cuantificables mediante PLN. El sistema no requiere conocimientos técnicos del usuario; traduce la intención empresarial en implementación técnica.




Figura 6.11: Cuadro de diálogo de demostración del generador de criterios impulsado por GenAI

La facilidad de esta transformación demuestra cómo la IA democratiza análisis avanzado, lo que hace que la clasificación sofisticada sea accesible para los expertos del dominio, independientemente de su formación técnica.

Paso 3: Integración de nuevos criterios en la clasificación

Tras la generación, el nuevo criterio de satisfacción del cliente, creado por IA, aparece en el panel Seleccionar Criterios, a la izquierda de la interfaz, ahora disponible junto con las métricas tradicionales. Al activarlo (como indica el interruptor), el sistema integra a la perfección esta nueva dimensión en el modelo de optimización del inventario.

Observe cómo la interfaz se actualiza para mostrar esta nueva métrica como una columna adicional en la lista de productos. Cada producto ahora muestra una

Puntuación numérica de la satisfacción del cliente, transformando eficazmente lo que antes era un factor cualitativo no medido en un valor cuantitativo que puede influir en las decisiones de inventario.

Lo especialmente valioso es cómo el sistema mantiene un marco consistente; el nuevo criterio generado por IA se convierte en un componente integral del sistema de clasificación, al que se le da la misma consideración que a las métricas tradicionales. Productos que podrían haber parecido idénticos en el análisis convencional ahora revelan diferencias importantes al considerar la satisfacción del cliente.



Figura 6.12: Interfaz de demostración de gestión de inventario después de la integración de satisfacción del cliente creada por IA

Esta integración muestra el verdadero poder de la clasificación mejorada con IA: la capacidad de incorporar factores comerciales previamente inmensurables en procesos sistemáticos de toma de decisiones.

Paso 4: Ponderación y análisis en ejecución

El paso final demuestra la flexibilidad y el poder de este sistema mejorado.

Sistema de clasificación. Como se muestra en la Figura 6.13, los usuarios pueden asignar

la importancia relativa de cada criterio se basa en una ponderación intuitiva. controles:

- 0,5 para el uso anual de dólares (manteniendo la importancia de métricas financieras)
- 0,3 para el tiempo de entrega (reconociendo las realidades de la cadena de suministro)
- 0,2 para la satisfacción del cliente (incorporando el nuevo perspectiva cuantificada del cliente)

Después de hacer clic en el botón Ejecutar análisis, el sistema vuelve a calcular el Puntuación ponderada para todos los artículos del inventario en función de este informe completo. conjunto de criterios. Las asignaciones de clase resultantes (A, B, y C) ahora reflejan un análisis más sofisticado que equilibra múltiples negocios prioridades.

El verdadero impacto empresarial se hace evidente al comparar el Clasificaciones antes y después. Productos que previamente recibieron una Una clasificación inferior basada únicamente en el valor en dólares podría ser ahora Reconocido como de importancia estratégica debido a la alta demanda de clientes. puntuaciones de satisfacción, que indican potencial de crecimiento futuro.

Por el contrario, los artículos de alto valor con baja satisfacción del cliente pueden ser marcado para una evaluación más detallada.



Figura 6.13: Controles de ponderación y resultados del análisis

El proceso iterativo que se muestra en esta demostración permite el perfeccionamiento continuo de las estrategias de gestión de inventario. Con un enfoque como este, los expertos en la materia del cliente pueden centrarse en la estrategia y el impacto en el negocio, mientras el sistema gestiona la sobrecarga técnica. Las organizaciones pueden mejorar progresivamente su sistema de clasificación generando criterios adicionales para factores como el cumplimiento de la sostenibilidad, el riesgo en la cadena de suministro o la alineación con las tendencias del mercado, todo en un solo lugar. Este enfoque transforma la clasificación de inventario de un análisis estático y retrospectivo a un sistema dinámico y con visión de futuro que aprovecha al máximo el potencial de los datos estructurados y no estructurados mediante GenAI, lo que permite a los equipos dedicar más tiempo a las actividades específicas del cliente que generan valor y resultados comerciales positivos.

Si bien la clasificación impulsada por GenAI mejora la categorización y la comprensión del inventario, el próximo gran avance reside en la automatización de las acciones derivadas de esta información. Más allá del apoyo a la toma de decisiones, los sistemas de IA con agentes pueden gestionar de forma independiente los procesos de compras, las relaciones con los proveedores y la reposición de inventario basándose en las clasificaciones inteligentes que hemos establecido.

Gestión de materias primas mediante agentic AI

Examinemos ahora otra aplicación innovadora de la IA en la gestión de la cadena de suministro: la IA con agentes para la gestión de materias primas. Si bien la sección anterior demostró cómo la IA GenAI puede optimizar la toma de decisiones mediante una mejor clasificación, este enfoque lleva la automatización un paso más allá al implementar agentes de IA autónomos que pueden supervisar, analizar y tomar medidas activamente para optimizar el inventario de materias primas. Esto representa la evolución de la toma de decisiones asistida por IA a operaciones de la cadena de suministro totalmente autónomas.



Figura 6.14: Proceso de orquestación y toma de decisiones del agente de adquisición de IA de materia prima

Este diagrama revela las sofisticadas capacidades de razonamiento que permiten la gestión autónoma de la cadena de suministro. A diferencia de los sistemas tradicionales basados en reglas que siguen rutas lógicas predeterminadas, este agente de IA demuestra una resolución dinámica de problemas mediante su proceso de pensamiento cíclico. La capacidad del agente para evaluar a múltiples proveedores simultáneamente; sopesar factores que compiten, como el coste frente a la fiabilidad; y tomar decisiones matizadas, como la división de pedidos, representa un cambio fundamental de la gestión reactiva de la cadena de suministro a la proactiva. Este enfoque cognitivo permite al sistema gestionar escenarios complejos que normalmente requerirían juicio humano, como equilibrar el ahorro inmediato de costes con los riesgos a largo plazo en la relación con los proveedores.

El agente de gestión de materias primas monitorea continuamente los eventos clave y actúa proactivamente para optimizar los niveles de inventario, las compras, la selección de proveedores y la logística. Garantiza la disponibilidad de material justo a tiempo, a la vez que minimiza los costos y la sobrecarga de almacenamiento. Lo que hace que este enfoque sea particularmente poderoso es la capacidad del agente de aprender de cada ciclo de decisión, mejorando su razonamiento con el tiempo y adaptándose a las condiciones cambiantes de la cadena de suministro sin intervención humana.




Figura 6.15: Arquitectura de orquestación de agentes de IA para la gestión de materias primas

Esta arquitectura demuestra cómo el diseño basado en eventos permite una automatización verdaderamente responsiva de la cadena de suministro. El servicio central de orquestación actúa como coordinador inteligente, procesando diversos desencadenantes de los sistemas de inventario, los programas de producción y las condiciones del mercado, y determinando la secuencia óptima de acciones. La integración con MongoDB Atlas como plataforma central de datos garantiza que todos los componentes, desde las bases de datos de inventario hasta las métricas de rendimiento de los proveedores, mantengan la coherencia de los datos, a la vez que facilitan la toma de decisiones en tiempo real. Este enfoque unificado elimina los silos de datos que tradicionalmente han afectado a los sistemas de la cadena de suministro, donde la información de inventario, compras y proveedores se encuentra en sistemas separados. El diseño modular de la arquitectura permite actualizar o reemplazar componentes individuales sin interrumpir todo el sistema, lo que proporciona la flexibilidad necesaria para adaptarse a las cambiantes necesidades del negocio y a las nuevas capacidades de IA.

Previsión de la demanda y optimización del inventario

Tras establecer cómo la IA mejora la clasificación del inventario y permite la gestión autónoma de materiales, ahora analizaremos con mayor detalle la previsión de la demanda. Esta capacidad se ha destacado a lo largo de nuestro análisis como un elemento fundamental de las operaciones inteligentes de la cadena de suministro.

La previsión de demanda basada en IA representa el motor predictivo que impulsa tanto las decisiones de clasificación como las acciones de aprovisionamiento autónomas.

Los algoritmos de IA analizan conjuntos de datos complejos para predecir las necesidades futuras de productos y piezas. Las mejoras en la precisión de las previsiones se traducen directamente en niveles de inventario más óptimos. Una vez proyectada la demanda, los sistemas de IA pueden determinar los niveles de inventario más eficientes analizando datos históricos de ventas, tendencias del mercado, patrones estacionales, interrupciones en la cadena de suministro y programas de producción.

Los sistemas de IA también pueden automatizar los pedidos según la demanda prevista y los niveles de stock objetivo, lo que reduce los errores humanos y la carga administrativa. Además, la IA puede facilitar la selección de proveedores y la gestión de relaciones mediante el análisis de datos de rendimiento para identificar a los socios que mejor cumplen con los requisitos de calidad, entrega y coste.




Figura 6.16: Arquitectura de previsión de demanda y optimización de inventario impulsada por IA

Este diagrama muestra cómo MongoDB Atlas permite una previsión integral de la demanda mediante la integración de datos de productos nuevos y actuales mediante incrustaciones vectoriales y búsqueda por similitud. El sistema procesa la información del usuario en lenguaje natural, utiliza LLM básicos para el análisis de contexto, combina múltiples fuentes de datos (datos de demanda, precio unitario e índices de consumo) mediante un marco de agregación y alimenta los modelos de previsión de la demanda que impulsan las decisiones de optimización del inventario. Los activadores de Atlas permiten el escalado automático y la compatibilidad multirregional.

Para productos nuevos sin datos históricos de ventas, los modelos GenAI pueden crear datos sintéticos aprendiendo patrones de productos similares existentes. MongoDB Atlas Vector Search mejora esta capacidad al encontrar productos con atributos similares e incorporar ese contexto a los modelos GenAI, garantizando así que los datos sintéticos reflejen condiciones realistas del mercado y el comportamiento de los clientes.

Beneficios de MongoDB para la gestión de inventario. Las sofisticadas aplicaciones de IA que hemos explorado, desde la clasificación impulsada por GenAI hasta los sistemas de agentes autónomos, dependen de una base de datos robusta y flexible que pueda gestionar la complejidad y la escala de las cadenas de suministro de fabricación modernas. MongoDB Atlas proporciona esta base mediante varias capacidades clave que habilitan directamente los enfoques avanzados de gestión de inventario que se describen en este capítulo.

MongoDB Atlas ofrece ventajas significativas para los sistemas de gestión de inventario impulsados por IA:

- Modelo de datos de documentos: maneja estructuras de inventario y jerarquías complejas en múltiples plantas y proveedores
- Búsqueda vectorial: permite funciones de búsqueda semántica para encontrar productos o proveedores similares según múltiples criterios.
- Controles de acceso y seguridad de grano fino: garantiza el acceso adecuado a los datos para las diferentes partes interesadas en la cadena de suministro.
- Recopilaciones de series de tiempo: almacena y analiza de manera eficiente datos temporales para la detección de tendencias y la previsión.

Estas capacidades se combinan para crear una plataforma unificada que abarca desde el seguimiento básico de inventario hasta la optimización sofisticada basada en IA. Al eliminar la necesidad de integraciones complejas entre sistemas separados para datos estructurados, incrustaciones vectoriales y análisis en tiempo real, MongoDB Atlas permite a las organizaciones centrarse en el desarrollo de estrategias de inventario inteligentes en lugar de gestionar la infraestructura técnica. Esta integración...

Este enfoque acelera la implementación de soluciones impulsadas por IA al tiempo que proporciona la escalabilidad y la confiabilidad necesarias para las operaciones de la cadena de suministro de misión crítica.

Reimaginando la gestión de inventario para la Industria 5.0

La gestión y optimización del inventario son componentes cruciales para unas operaciones de fabricación eficientes. Al aprovechar las capacidades avanzadas de IA, en particular GenAI para el análisis de datos no estructurados y la IA agente para la toma de decisiones autónoma, las organizaciones pueden alcanzar nuevos niveles de eficiencia, equilibrando al mismo tiempo los costes, la disponibilidad y la capacidad de respuesta.

La integración de estas tecnologías con plataformas de datos flexibles y escalables como MongoDB Atlas permite a los fabricantes hacer lo siguiente:

- Mejorar la precisión de las previsiones
- Optimizar los niveles de inventario
- Mejorar la selección y gestión de proveedores
- Responder proactivamente a las interrupciones de la cadena de suministro
- Reducir los costos de transporte sin sacrificar los niveles de servicio

A medida que la manufactura continúa evolucionando hacia la Industria 5.0, estos enfoques de optimización de inventario basados en IA serán cada vez más esenciales para mantener una ventaja competitiva en los mercados globales. La transformación de la gestión reactiva de inventario a sistemas predictivos e inteligentes representa solo el comienzo del impacto de la IA en las operaciones de manufactura.

Resumen

Este capítulo ha explorado cómo la IA está revolucionando la gestión de la cadena de suministro y el inventario en las operaciones de fabricación. Hemos examinado la evolución de los enfoques tradicionales de clasificación de inventario, como el análisis ABC, a la sofisticada MCIC mejorada por GenAI, que ahora puede incorporar datos no estructurados de reseñas de clientes, comunicaciones con proveedores y señales del mercado para crear una categorización de inventario más matizada y eficaz.

La metodología de cuatro pasos para implementar la clasificación de inventario impulsada por GenAI (creación de incrustaciones vectoriales, diseño de criterios de evaluación, desarrollo de aplicaciones agénticas y mejora de los modelos de clasificación) demuestra cómo las plataformas de datos modernas pueden reducir la brecha entre la información empresarial cualitativa y la toma de decisiones cuantitativa. Hemos visto aplicaciones prácticas que abarcan desde sistemas de clasificación impulsados por IA que transforman la retroalimentación de los clientes en información sobre el inventario hasta sistemas agénticos autónomos que pueden gestionar de forma independiente la adquisición de materias primas y optimizar las decisiones de la cadena de suministro en tiempo real.

Mediante demostraciones detalladas y ejemplos reales, hemos demostrado cómo MongoDB Atlas sirve como base unificada que habilita estas sofisticadas aplicaciones de IA, brindando la flexibilidad para gestionar tanto datos de inventario estructurados como inteligencia de mercado no estructurada en una única plataforma. Este enfoque integrado permite a las organizaciones pasar del análisis de inventario estático y retrospectivo a sistemas de optimización dinámicos y con visión de futuro que se adaptan continuamente a las condiciones cambiantes del mercado.

El próximo capítulo continúa nuestra exploración de la IA en la fabricación al examinar cómo estos mismos principios se extienden más allá de la gestión de inventario para transformar operaciones de fabricación más amplias, incluido el mantenimiento predictivo, el control de calidad y la optimización de la producción en toda la cadena de valor de la fabricación.

Referencias

1. Europa lidera la adopción de IA en las operaciones de fabricación:

<https://www.capgemini.com/us-en/news/europa-es-lider-en-la-adopcion-de-ia-en-operaciones-de-fabricacion/>

2. Planificación y modelado de la cadena de suministro para tomar decisiones inteligentes:

<https://www.anylogistix.com/resources/blog/cadena-de-suministros-planificación-estratégica-y-modelado-para-apoyo-de-decisiones/>

7

Aplicaciones prácticas de Agentic y GenAI en Fabricación – Parte 2

Partiendo de las bases de la cadena de suministro establecidas en el capítulo anterior, nos adentraremos en la nueva frontera de la IA en la fabricación: sistemas operativos inteligentes que no solo automatizan tareas, sino que también colaboran, aprenden y se adaptan en tiempo real. Si bien la optimización de la cadena de suministro demuestra el poder de la IA para transformar procesos reactivos en predictivos, las aplicaciones que exploraremos en este capítulo representan un cambio fundamental hacia ecosistemas de fabricación verdaderamente autónomos donde múltiples agentes de IA trabajan juntos para optimizar operaciones complejas e interconectadas.

Este capítulo explora cuatro dominios críticos donde la IA colaborativa está redefiniendo la excelencia en la fabricación. Comenzamos con el mantenimiento predictivo, donde los sistemas multiagente se coordinan en la priorización de máquinas, la predicción de fallos, la planificación de reparaciones y la guía de mantenimiento, transformando la gestión de equipos de paradas programadas en intervenciones inteligentes justo a tiempo. A continuación, examinamos cómo la IA preserva y operacionaliza décadas de conocimiento institucional, garantizando que la información de los expertos jubilados siga siendo accesible mediante la búsqueda semántica y sistemas inteligentes de gestión del conocimiento. Más allá de la planta de producción, investigamos cómo GenAI está revolucionando las experiencias en los vehículos mediante sofisticados asistentes de voz que comprenden el contexto, acceden a la documentación técnica y ofrecen orientación personalizada. Finalmente, exploramos la optimización de la gestión de flotas, donde los sistemas de IA con agentes coordinan de forma autónoma decisiones logísticas complejas, equilibrando rutas, horarios, mantenimiento y asignación de recursos en tiempo real.

Cada aplicación demuestra cómo las plataformas de datos modernas permiten a estos sistemas inteligentes integrar sin problemas datos operativos estructurados con fuentes de conocimiento no estructuradas, creando el contexto integral que estos agentes de IA necesitan para tomar decisiones sofisticadas de forma autónoma.

Al final de este capítulo comprenderás lo siguiente:

- Cómo implementar una estrategia de mantenimiento predictivo de cuatro etapas utilizando colaboración multiagente y arquitecturas RAG
- El papel fundamental de la preservación del conocimiento institucional y cómo la IA transforma el conocimiento tribal en información procesable y que se puede buscar
- Cómo GenAI impulsa los asistentes de voz automotrices de próxima generación a través de arquitecturas híbridas de nube y borde
- Estrategias avanzadas de fragmentación para manuales de vehículos y documentación técnica que preservan el contexto y las relaciones críticas
- La implementación de IA agentic para la programación y optimización de flotas autónomas utilizando Marco de trabajo ReaAct
- Cómo los modelos de documentos flexibles, la búsqueda vectorial y las capacidades de series temporales permiten sistemas multiagente sofisticados

- Arquitecturas del mundo real y modelos de datos para sistemas de diagnóstico y gestión de incidentes de flotas conectadas
- Las ventajas estratégicas de los sistemas de fabricación integrados con IA para la excelencia operativa y la diferenciación competitiva

Mantenimiento predictivo y colaboración entre múltiples agentes

Tras establecer cómo la IA transforma la toma de decisiones en la cadena de suministro mediante la integración inteligente de datos, abordaremos ahora otra área crucial donde los sistemas de IA colaborativos están revolucionando la fabricación: el mantenimiento predictivo. Mientras que la optimización de la cadena de suministro se centra en el flujo de materiales y la gestión del inventario, el mantenimiento predictivo aborda la columna vertebral operativa de la fabricación: mantener los equipos de producción funcionando al máximo rendimiento mediante una intervención inteligente y proactiva.

Una estrategia de mantenimiento bien definida puede ser un punto de inflexión para cualquier organización, generando importantes ahorros en ingresos y costos. Así es como funciona:

- Primero, identifique los equipos más cruciales para sus operaciones. El tiempo de inactividad de estos equipos puede generar cuellos de botella y detener la producción.
- En segundo lugar, equipe estos activos críticos con sensores que permitan la monitorización del estado. Esto le permite supervisar el estado del equipo en tiempo real e identificar posibles problemas antes de que se conviertan en fallos catastróficos.
- En tercer lugar, basándose en la predicción, el sistema puede generar órdenes de trabajo, programar actividades de mantenimiento e incluso orientar al personal de mantenimiento. Esto garantiza que el mantenimiento se realice solo cuando sea necesario, optimizando así la asignación de recursos.

Esta serie de actividades ofrece beneficios tangibles. Se reducen los costos gracias al ahorro de horas de trabajo y a la prolongación de la vida útil de las máquinas. Además, los ingresos aumentan a medida que las máquinas funcionan a un rendimiento óptimo.




Figura 7.1: Pasos necesarios para una estrategia de mantenimiento óptima

La Figura 7.1 ilustra un proceso de tres pasos para implementar el mantenimiento predictivo. Comienza con la identificación de equipos críticos y el reconocimiento de las posibles consecuencias de la inactividad, continúa con la sensorización y la monitorización del estado con seguimiento del estado en tiempo real, y culmina con una estrategia de mantenimiento basada en datos que analiza los datos recopilados, genera órdenes de trabajo, programa el mantenimiento y...

Proporciona orientación al personal, lo que en última instancia conduce a una estrategia de mantenimiento óptima que reduce costos y aumenta los ingresos.

Estrategia óptima de mantenimiento. Una estrategia óptima de

mantenimiento no es una solución universal. Se trata de elegir la combinación adecuada de enfoques según sus necesidades operativas y de equipo. Estos enfoques varían desde los más complejos y costosos hasta los más sencillos y asequibles:

- **Mantenimiento reactivo:** Este es el enfoque más básico, en el que se realiza el mantenimiento tras una falla de una máquina. Si bien es simple, puede ocasionar tiempos de inactividad inesperados y mayores costos de reparación.
- **Mantenimiento preventivo:** Este es un enfoque proactivo que implica programar tareas de mantenimiento según intervalos de tiempo predeterminados o métricas de uso. Esto ayuda a prevenir averías, pero puede resultar ineficiente, ya que las condiciones de la máquina pueden variar. Es posible que sea necesario ajustar los límites para estas tareas debido a factores como el envejecimiento de los equipos, cambios en los procesos o el uso de diferentes materiales.
- **Mantenimiento basado en la condición (CBM):** Este enfoque monitoriza continuamente el estado de la máquina mediante sensores y análisis de datos. El mantenimiento se activa según el estado real del equipo, en lugar de un programa preestablecido. Esto es más eficiente que el mantenimiento preventivo, ya que evita mantenimiento innecesario. Los sistemas de alerta basados en umbrales se utilizan a menudo con el CBM.
- **Mantenimiento predictivo:** Este es el enfoque más avanzado, que utiliza el análisis de datos para predecir posibles fallos en los equipos antes de que ocurran, lo que permite un mantenimiento proactivo y minimiza el tiempo de inactividad. El mantenimiento predictivo requiere una inversión inicial considerable en sensores y herramientas de análisis de datos.

El mantenimiento predictivo utiliza el análisis de datos para identificar problemas en las máquinas antes de que fallen. Esto permite a las organizaciones programar el mantenimiento en el momento óptimo, maximizando la fiabilidad y la eficiencia de las máquinas.

Así es como el mantenimiento predictivo puede beneficiar las operaciones de fabricación, según Deloitte [1]:

- Reducción del 3 al 5 % en los costos de equipos nuevos
- Aumento del 5 al 20 % en la productividad laboral
- Reducción del 15 al 20 % en el tiempo de inactividad de las instalaciones
- Reducción del 10 al 30 % en los niveles de inventario
- Reducción del 5 al 20 % en los costos de mantenimiento

El mantenimiento predictivo está en constante evolución. Hemos ido más allá de la monitorización básica basada en umbrales y hemos adoptado técnicas avanzadas como los modelos de aprendizaje automático. Estos modelos no solo predicen fallos, sino que también diagnostican la causa raíz y los factores contribuyentes, lo que permite realizar reparaciones específicas.

La última tendencia en mantenimiento predictivo es la creación automatizada de estrategias. Esto implica el uso de IA para predecir averías de equipos basándose en una combinación de factores cuantitativos y cualitativos, así como para generar planes de reparación, garantizando que se realicen las reparaciones correctas en el momento oportuno. La creación automatizada de estrategias requiere una inversión sustancial en I+D, además de un profundo conocimiento del sector, acceso a datos relevantes y experiencia operativa práctica. La pregunta es: ¿puede ayudar GenAI?

Estado actual y desafíos

La respuesta es sí, GenAI puede ayudar. Sin embargo, existen desafíos en cada etapa de la implementación que las organizaciones deben considerar. Cada etapa presenta una pregunta clave y desafíos únicos, lo que demuestra los obstáculos técnicos y operativos que enfrentan las organizaciones en la implementación del mantenimiento predictivo.




Figura 7.2: Diferentes desafíos observados en cada etapa de la implementación del mantenimiento predictivo

La Figura 7.2 describe el proceso de implementación del mantenimiento predictivo en cuatro etapas, mostrando la pregunta clave y los desafíos asociados a cada fase. Cabe destacar cómo la complejidad y los requisitos de datos evolucionan a lo largo de las etapas, desde el proceso manual y laborioso de priorización de máquinas en la etapa 1, pasando por los desafíos técnicos derivados de la insuficiencia de datos de capacitación y la evolución de los modos de fallo en la etapa 2, hasta las complejidades de la integración y la falta de habilidades en las etapas 3 y 4. Esta progresión revela por qué muchas organizaciones tienen dificultades con la implementación del mantenimiento predictivo: cada etapa presenta distintos obstáculos técnicos y operativos que deben abordarse sistemáticamente. La figura también ilustra por qué un enfoque holístico impulsado por la IA se vuelve esencial; los métodos tradicionales simplemente no pueden manejar de manera efectiva la naturaleza multifacética de estos desafíos interconectados.

Imaginemos ahora una fábrica con máquinas tanto automatizadas como manuales. Llamémosla Gear Transmission Systems Ltd., una empresa de , cuya producción principal son cajas de cambios. En esta fábrica, contamos con una amplia gama de... equipos: máquinas de corte, fresadoras, dispositivos de medición y más. Como gerente general, usted tiene la responsabilidad de gestionar el presupuesto asignado a los procesos de mantenimiento y a las estrategias de mejora. Una pregunta urgente que debe abordar es: "¿Qué máquinas deberían priorizarse en los proyectos de mantenimiento predictivo y por qué?". Esto implica consultar con los gerentes y líderes de mantenimiento y realizar análisis cuantitativos, un proceso bastante manual.

Una vez identificadas las máquinas, el siguiente paso es instalar sensores y entrenar el modelo de aprendizaje automático. Sin embargo, surgen dos desafíos importantes. En primer lugar, no se dispone de suficientes datos de ejecución hasta el fallo para entrenar el modelo eficazmente. En segundo lugar, el estado de la máquina se deteriora con el tiempo, lo que provoca la evolución de los modos de fallo con la edad de la máquina.

Suponiendo que logre superar estos obstáculos, la siguiente fase consiste en la programación y ejecución del mantenimiento. Se enfrenta a una gran cantidad de silos de datos, incluyendo datos de inventario y de disponibilidad de recursos, que deben integrarse para formular un plan de reparación integral. Además, es fundamental garantizar que los operadores sean expertos en la resolución de problemas menores de las máquinas para reducir la dependencia de expertos externos y prevenir fallos más críticos. Si bien los problemas complejos pueden requerir el soporte del OEM o del integrador de sistemas (SI), las capacidades internas de resolución de problemas son invaluable. Por lo tanto, es importante desarrollar documentación fácil de seguir y adaptada a los niveles de capacitación de nuestro personal.

Como demuestra la Figura 7.3, se requieren diferentes datos para resolver los desafíos enumerados:

- Priorización de máquinas/análisis de criticidad: En esta etapa, necesitamos datos estructurados y no estructurados. Necesitamos datos de fallos previos de las máquinas, así como análisis y opiniones de expertos sobre qué máquinas priorizar para el mantenimiento predictivo y por qué.
- Predicción de fallas: esta etapa involucra datos estructurados, como datos de sensores y registros de mantenimiento, para identificar la causa raíz de la falla inminente.
- Generación de planes de mantenimiento y guías: En ambas etapas, trabajamos con datos estructurados y no estructurados. El objetivo es combinarlos para generar un plan de reparación óptimo y una guía para el operador.




Figura 7.3: Diferentes requisitos de datos en cada etapa

Este diagrama muestra las necesidades de datos específicas de cada etapa de la implementación del mantenimiento predictivo.

La etapa 1 requiere datos estructurados (información de la máquina, datos de producción) y no estructurados (entrevistas con expertos, órdenes de trabajo antiguas) para la priorización de las máquinas. La etapa 2 utiliza datos estructurados (datos de sensores, registros de mantenimiento) para la predicción de fallos. Las etapas 3 y 4 combinan datos estructurados (información de fallos, datos de inventario) con datos no estructurados (manuales de la máquina, órdenes de trabajo antiguas, procedimientos operativos estándar, notas de servicio) para generar planes de mantenimiento y orientación para el operador.

Estos variados requisitos de datos a lo largo del ciclo de vida del mantenimiento predictivo revelan un desafío fundamental: los enfoques tradicionales tienen dificultades para integrar la diversa combinación de datos estructurados de sensores, registros históricos y conocimiento experto no estructurado necesario para una toma de decisiones eficaz. Esta complejidad de integración sienta las bases para explorar cómo la IA y las plataformas de datos modernas pueden transformar estos procesos tradicionalmente aislados en sistemas colaborativos e inteligentes.

Cómo ayudan la IA y MongoDB

MongoDB Atlas es una plataforma de datos multicloud para desarrolladores, diseñada para acelerar y simplificar el trabajo con datos. Al usar MongoDB Atlas, los desarrolladores pueden optimizar la cadena de valor de extremo a extremo con IA/ML, análisis avanzado y procesamiento de datos en tiempo real para aplicaciones móviles, edge y de IoT innovadoras.

Para abordar los desafíos de integración de datos que hemos identificado, exploraremos cómo MongoDB Atlas habilita cada etapa del proceso de mantenimiento predictivo: primero, transformando la priorización de las máquinas del análisis manual a información impulsada por IA; segundo, implementando sistemas de predicción de fallas en tiempo real; tercero,

generar planes de reparación integrales que combinen múltiples fuentes de datos y, por último, crear una guía de mantenimiento inteligente que se adapte a las condiciones del mundo real y a las entradas multilingües.

Etapas 1: Priorización de máquinas. La priorización actual de máquinas para el mantenimiento predictivo se basa en gran medida en el análisis manual. El personal de la fábrica recopila datos históricos y actuales de las máquinas sobre pérdidas por averías. Estos datos se revisan junto con la experiencia de los gerentes y líderes de mantenimiento. Con base en este análisis combinado, se recomienda una hoja de ruta para el proyecto de mantenimiento predictivo, que destaca las máquinas que deben priorizarse.

Sin embargo, este enfoque tiene limitaciones. Depender del análisis manual puede consumir mucho tiempo y no siempre captar la visión completa del proyecto de mantenimiento debido al uso limitado de fuentes de datos cuantitativos. Además, las inconsistencias en la interpretación pueden generar una dependencia excesiva del conocimiento institucional, lo que a su vez puede generar análisis potencialmente falsos o inexactos que afecten el retorno de la inversión (ROI) del proyecto.

Con la llegada de GenAI, las cosas han cambiado. Se puede crear una herramienta de priorización de máquinas basada en GenAI para reducir el tiempo que los expertos en fabricación dedican al análisis manual y disminuir el riesgo de malas inversiones. Para aprovechar la IA, los expertos necesitan un almacén de datos capaz de guardar y operacionalizar datos estructurados y no estructurados. Este almacén de datos les permite realizar búsquedas semánticas y proporcionar el contexto adecuado al LLM, garantizando que genere respuestas basadas en datos de fábrica sin alucinar. Un sistema de este tipo puede generar resultados empresariales positivos. La Figura 7.4 muestra cómo se vería el sistema con MongoDB Atlas como almacén de datos de IA.




Figura 7.4: Priorización de máquinas impulsada por GenAI

Este enfoque basado en IA combina datos estructurados (eficacia general del equipo [OEE], frecuencia de averías de las máquinas) con conocimiento experto no estructurado (entrevistas, informes) mediante incrustaciones vectoriales. El sistema utiliza MongoDB Atlas Vector Search para encontrar el contexto relevante y envía esta información a los LLM mediante la metodología de recuperación-generación aumentada (RAG). Cuando los gerentes de mantenimiento preguntan "¿Qué máquina debo priorizar y por qué?", el sistema puede recomendar máquinas específicas, como la M001 o la M002, basándose en un análisis exhaustivo de criticidad, costos de mantenimiento e impacto operativo. Aplicaciones de IA como LangChain, LlamaIndex o interfaces de gestión de mantenimiento personalizadas pueden activar Atlas Vector Search para recuperar información contextual y generar estas recomendaciones basadas en datos.

Etapas 2: Predicción de fallos. Ahora que hemos

analizado la priorización de equipos, pasemos a la predicción de fallos. MongoDB Atlas proporciona todos los componentes y herramientas necesarios para implementar la predicción de fallos. Al ofrecer una vista unificada de los datos operativos, capacidades de procesamiento en tiempo real, monitorización y alertas integradas, y una compatibilidad perfecta con herramientas de aprendizaje automático, MongoDB Atlas permite a las organizaciones optimizar el rendimiento de sus equipos y minimizar el tiempo de inactividad.




Figura 7.5: La fresadora inteligente utiliza datos en tiempo real para predecir fallas

La Figura 7.5 muestra un flujo de trabajo de predicción de fallos de seis pasos con MongoDB Atlas. Comienza con la captura priorizada de datos de la máquina, incluyendo las especificaciones de fresado y las lecturas de los sensores, seguida de la transformación de datos mediante Atlas Stream Processing. Los datos transformados se almacenan en MongoDB Atlas con una vista unificada. Los flujos de cambio activan los procesos de inferencia y el análisis operativo se realiza mediante visualización mediante Atlas Charts. Finalmente, Atlas Triggers permite notificaciones automatizadas para alertar a los usuarios sobre posibles fallos, creando un sistema integral de mantenimiento predictivo en tiempo real.

Como se muestra en la figura anterior, tenemos nuestra máquina priorizada, una fresadora con sensores conectados que recopilan datos como la temperatura del aire, la velocidad de rotación, el par y el desgaste de la herramienta. Estos datos se procesan mediante Atlas Stream Processing, lo que permite procesar flujos de datos complejos utilizando el mismo modelo de datos y la API de consulta que se utilizan en las bases de datos Atlas. Atlas Stream Processing permite a los desarrolladores crear canales de agregación para operar continuamente con datos en streaming sin retrasos.

Inherente al procesamiento por lotes. Los resultados pueden publicarse continuamente en MongoDB Atlas o en un tema de Kafka. Esto permite la transformación y el enriquecimiento de datos incluso antes de que lleguen a la base de datos.

Una vez que los datos están en MongoDB, otra aplicación puede reaccionar a los valores de los sensores y ejecutar un modelo entrenado, diseñado para predecir fallos. Los resultados del modelo se pueden almacenar en Atlas entre las etapas de inferencia y visualización. Estos resultados se pueden visualizar mediante gráficos de Atlas. Finalmente, los activadores y funciones de Atlas se pueden usar para enviar notificaciones a los usuarios in situ. Esto establece un sistema integral para la predicción de fallos.

Mantenimiento predictivo de flotas marítimas en la práctica

Ceto ha revolucionado las operaciones marítimas al asociarse con MongoDB para integrar la IA con datos en tiempo real recopilados de miles de sensores en las flotas de los clientes.

La implementación permite a Ceto predecir y anticiparse a posibles fallas mecánicas, agilizar las operaciones y gestionar los riesgos de forma proactiva.

La tesis principal de Ceto es que los datos de los sensores de los buques pueden revelar la proximidad de un buque a una avería mecánica y, por consiguiente, a una reclamación al seguro. Al aplicar filtros avanzados y análisis en tiempo real a las lecturas de los sensores de los buques, Ceto mantiene a las tripulaciones más seguras en el mar, a la vez que ofrece pólizas de seguro y precios más adecuados.

Ceto procesa actualmente más de tres mil millones de puntos de datos al año. La arquitectura de MongoDB proporcionó a Ceto varias funciones clave cruciales para sus operaciones, como la escalabilidad para gestionar volúmenes de datos cada vez mayores y la recopilación de series temporales para una compresión avanzada de datos. Como señala Ben Harrison, director de tecnología de Ceto: «Esto ha revolucionado la forma en que gestionamos y utilizamos los datos de nuestra flota. La capacidad de procesar y analizar datos en tiempo real ha mejorado significativamente nuestras capacidades de mantenimiento predictivo». Las colecciones de series temporales de MongoDB tienen

Obtenga más información en <https://mdb.link/leading-maritime-technology-company>.



Etapas 3: Generadores de planes de reparación. Una vez identificada la

naturaleza de las fallas del equipo, la implementación de una estrategia integral de reparación se vuelve crucial. Primero, debemos generar una orden de trabajo de mantenimiento. Esta orden debe incluir las instrucciones de reparación, las piezas de repuesto necesarias, un cronograma y la información sobre la disponibilidad de recursos. En este caso, se utilizan datos estructurados y no estructurados. Las instrucciones de reparación se obtendrán del manual de la máquina. Para este proceso, MongoDB Atlas actúa como la capa de datos operativa, integrando a la perfección datos estructurados y no estructurados.




Figura 7.6: MongoDB Atlas como capa de datos operativa para datos estructurados y no estructurados

MongoDB Atlas funciona como la capa central de datos operativos para la generación de planes de reparación, combinando manuales de máquinas y órdenes de trabajo antiguas (procesadas mediante fragmentación e incrustación de PDF) con datos estructurados, incluyendo tipos de fallos, información de inventario e información de recursos. Una aplicación de generador de órdenes de trabajo utiliza LLM y marcos de agregación para generar órdenes de trabajo completas con plantillas correctas, información de programación y planes de reparación, aprovechando las funciones de búsqueda vectorial y la integración de datos estructurados.

La Figura 7.6 muestra el proceso de generación de órdenes de trabajo con GenAI. Primero, extraemos fragmentos de información de un manual de fresadora y órdenes de trabajo antiguas almacenadas en archivos PDF y los convertimos en vectores. Estas incrustaciones se almacenan en MongoDB Atlas. La versatilidad de MongoDB permite almacenar datos estructurados y no estructurados en la misma base de datos. Aprovechando la búsqueda vectorial de Atlas y las canalizaciones de agregación, podemos integrar estos datos para alimentar un LLM que alimenta una aplicación de generador de órdenes de trabajo. El LLM analiza los datos para generar la orden de trabajo y la plantilla adecuadas, basándose en ejemplos anteriores. Completa los detalles del inventario y los recursos mediante técnicas de agregación y datos estructurados. Finalmente, genera un plan de reparación similar a las órdenes de trabajo antiguas. Lo que distingue a este enfoque es la posibilidad de utilizar la misma base de datos MongoDB para almacenar datos estructurados, como tipos de fallos, inventario de repuestos e información de recursos. Al emplear el marco de agregación para extraer información relevante de datos estructurados y la búsqueda vectorial para obtener información de los vectores, el LLM dentro de la aplicación Generador de órdenes de trabajo obtiene comprensión contextual.

Esta aplicación utiliza el LLM de forma fluida para generar órdenes de trabajo con la plantilla correcta, completar los detalles del inventario y los recursos mediante agregaciones y, finalmente, crear planes de reparación basados en los manuales de las máquinas. Esta aplicación puede ejecutarse dentro de un sistema central de gestión de mantenimiento.

Etapas 4: Generación de guías de mantenimiento. Llegamos al último paso: ¿Cómo podemos

usar GenAI para optimizar la guía del operador o técnico en el mantenimiento de la máquina? El reto radica en que los escenarios de mantenimiento suelen implicar documentación multilingüe, notas de servicio en constante evolución y la necesidad de integrar nuevos conocimientos con los procedimientos de reparación existentes en tiempo real.




Figura 7.7: Uso del enfoque RAG para las instrucciones de trabajo del operador

La Figura 7.7 ilustra cómo MongoDB Atlas permite la generación de guías de mantenimiento mediante un enfoque RAG. Las notas de servicio en varios idiomas se procesan mediante modelos de conversión de PDF a texto y traducción, y luego se almacenan en MongoDB Atlas junto con los planes de reparación originales. Una aplicación de generador de instrucciones de reparación que utiliza LLM crea planes de reparación actualizados combinando las notas de servicio traducidas con las instrucciones de reparación existentes. Estos planes se entregan a los técnicos/operadores a través de una aplicación dedicada y se activan mediante disparadores de Atlas para obtener actualizaciones en tiempo real.

Analicemos un ejemplo. El plan de reparación se generó en el paso anterior. Ahora, el sistema de gestión de mantenimiento computarizado (CMMS) ha detectado algunas notas de servicio subidas a la plataforma por otro técnico, pero están escritas en otro idioma (por ejemplo, español). Podemos usar la arquitectura RAG de nuevo para combinar inteligentemente estas notas de servicio con las instrucciones de reparación generadas en el paso anterior.

Primero, necesitamos extraer el texto del PDF, traducirlo al inglés (ya que el resto de nuestros datos están en inglés) y luego proporcionar las notas de servicio y el plan de reparación al LLM como contexto. De esta forma, obtenemos el plan original de los pasos anteriores y lo combinamos integralmente utilizando el LLM con las notas de servicio obtenidas en este paso.

Nota

No realizamos búsquedas vectoriales. Una vez actualizado el plan, podemos enviar notificaciones a la aplicación del técnico mediante los disparadores y funciones de Atlas.

En resumen, integramos aplicaciones de IA y GenAI para implementar una estrategia integral de mantenimiento predictivo. Este enfoque integral demuestra cómo las cuatro etapas se integran (desde la priorización inteligente de máquinas hasta la predicción de fallos, la planificación de reparaciones y, finalmente, la guía de mantenimiento adaptativo), creando un sistema unificado que transforma el mantenimiento reactivo tradicional en una operación proactiva basada en datos.




Figura 7.8: Encadenamiento de modelos con almacén de datos unificado

La Figura 7.8 muestra una estrategia integral de mantenimiento predictivo utilizando MongoDB Atlas como plataforma de datos unificada en cuatro etapas. Cada etapa procesa datos estructurados y no estructurados mediante la plataforma para desarrolladores MongoDB Atlas (que incluye Atlas Vector Search, Stream Processing, Database y Aggregation Framework), en combinación con los marcos LLM y Foundation/IA para generar resultados específicos en cada etapa: prioridad de la máquina, tipos de fallos, planes de reparación y reparación. instrucciones.

Nuestra aportación consistió en una combinación de datos estructurados y no estructurados. Aprovechamos los diversos servicios que ofrece la plataforma de datos para desarrolladores MongoDB Atlas, incluyendo Atlas Vector Search, Atlas Stream Processing y, por supuesto, el marco de base de datos y agregación de MongoDB. Estas funciones nos permitieron proporcionar el contexto adecuado al LLM y los datos apropiados al modelo de IA. Finalmente, obtuvimos el resultado deseado en cada etapa, desde la priorización de máquinas, la identificación del tipo de fallo y la formulación del plan de reparación hasta la generación de instrucciones.

Puede obtener más información sobre cómo se utiliza la IA en las energías renovables aprovechando MongoDB Atlas Vector Search para impulsar la eficiencia a través de diagnósticos de audio en tiempo real aquí: <https://www.mongodb.com/solutions/solutions-library/real-time-audio-based-ai-diagnostics>

Sistema de colaboración multiagente

Además de impulsar las estrategias de mantenimiento predictivo mediante arquitecturas RAG, los sistemas agénticos se perfilan como la próxima frontera en las aplicaciones de GenAI. Estos sistemas constan de uno o más agentes de IA que colaboran para generar valor, a menudo interactuando entre sí en el mismo sistema o en sistemas externos.

Diseñados para interactuar con humanos para recibir retroalimentación y revisión luego de ejecutar los pasos, estos sistemas adaptan su comportamiento en función del contexto proporcionado por los resultados de otros agentes y las aportaciones humanas.

En el mantenimiento predictivo, un sistema multiagente puede asignar un agente para analizar los datos de la máquina para la detección temprana de problemas mecánicos, mientras que otro optimiza la asignación de recursos de materiales y mano de obra.

Además, distintos agentes pueden usar modelos especializados para tareas específicas. Por ejemplo, uno transcribe videos, mientras que otro emplea el procesamiento del lenguaje natural para responder preguntas.

En este contexto, MongoDB actúa como proveedor de memoria para los sistemas de agentes. Los historiales de conversaciones y las incrustaciones vectoriales se almacenan mediante el modelo de documento flexible de MongoDB. La búsqueda vectorial de Atlas permite...

Búsqueda semántica en incrustaciones almacenadas, mientras que las capacidades de fragmentación proporcionan escalabilidad horizontal sin sacrificar el rendimiento. A continuación, exploramos cómo desarrollar un sistema de colaboración de tres agentes para optimizar el rendimiento de la máquina.

Optimización de un entorno de producción

En las operaciones de fabricación, aprovechar la colaboración entre múltiples agentes para el mantenimiento predictivo puede aumentar significativamente la eficiencia operativa. Por ejemplo, considere un entorno de producción donde tres agentes distintos (mantenimiento predictivo, optimización de procesos y control de calidad) colaboran en tiempo real para optimizar las operaciones de las máquinas y mantener la fábrica al máximo rendimiento.




Figura 7.9: Sistema multiagente para la optimización de la producción

La Figura 7.9 muestra un sistema colaborativo de agentes donde tres agentes de IA especializados trabajan juntos para optimizar las operaciones de fabricación. El Agente de Control de Calidad recibe retroalimentación de calidad y la comparte con el Agente de Optimización de Procesos, que gestiona los hallazgos de optimización y mantenimiento. El Agente de Mantenimiento Predictivo supervisa los datos de los sensores de las máquinas e intercambia los hallazgos de mantenimiento con el Agente de Optimización de Procesos, creando un enfoque coordinado para mantener el máximo rendimiento de la fábrica mediante la colaboración en tiempo real entre las funciones de mantenimiento predictivo, optimización de procesos y control de calidad.

En esta configuración, el Agente de Mantenimiento Predictivo se centra en el mantenimiento de la maquinaria. Sus principales funciones son supervisar el estado del equipo mediante el análisis de los datos de los sensores generados por las máquinas. Predice fallos en las máquinas y recomienda acciones de mantenimiento para prolongar su vida útil y minimizar los tiempos de inactividad.

Como complemento a esta función, el Agente de Optimización de Procesos está diseñado para mejorar la eficiencia de la producción mediante el análisis y ajuste de parámetros de producción, como la velocidad y la vibración, para eliminar cuellos de botella y mantener la calidad del producto. Este agente incorpora la retroalimentación de los demás agentes para decidir qué parámetros ajustar. Por ejemplo, si el Agente de Mantenimiento Predictivo detecta un aumento de temperatura en una fresadora, el Agente de Optimización de Procesos puede ajustar la velocidad de corte.

Finalmente, el Agente de Aseguramiento de Calidad evalúa la calidad del producto analizando los parámetros de producción optimizados y evaluando su impacto en el producto. También proporciona retroalimentación a los otros dos agentes.

Los tres agentes comparten continuamente retroalimentación entre sí y almacenan esta información como memoria a corto plazo en la base de datos MongoDB Atlas, mientras que las incrustaciones vectoriales y los datos de los sensores se guardan como memoria a largo plazo.

Con su modelo de documento flexible, seguridad sólida, funciones integrales de gobernanza de datos y escalabilidad horizontal, MongoDB sirve como un proveedor de memoria excepcional para desarrollar sistemas de agentes impulsados por IA.



La empresa de automatización del flujo de trabajo con IA transforma las operaciones comerciales con Atlas de MongoDB

Una empresa líder en automatización de flujos de trabajo se enfrentó al reto de crear agentes de IA personalizados y dinámicos para gestionar tareas repetitivas en roles estratégicos de negocio. Para ello, utilizaron MongoDB Atlas, que unificó sus servicios de datos operativos, analíticos y GenAI, simplificando así el desarrollo de aplicaciones inteligentes.

Con MongoDB Atlas, los agentes de IA de la empresa habilitaron nuevos modos de trabajo con menos recursos, lo que permitió a las empresas automatizar flujos de trabajo complejos manteniendo la supervisión y la colaboración humanas. Su plataforma demuestra cómo los agentes de IA pueden ser más accesibles y capaces de aprender continuamente, lo que permite a múltiples partes interesadas modificar y optimizar colaborativamente el contenido generado por IA para mejorar el negocio.

Este ejemplo se ha anonimizado para mayor claridad editorial. Para más información, consulte: <https://mongodb.link/ai-workflow-company-agents>.



Gestión y preservación del conocimiento

El ejemplo de la automatización del flujo de trabajo demuestra cómo los agentes de IA pueden transformar las operaciones empresariales, pero también revela una dependencia fundamental: la eficacia de estos sistemas inteligentes depende del conocimiento al que pueden acceder y aprovechar. Si bien los sistemas multiagente destacan por coordinar decisiones en tiempo real y optimizar las operaciones, requieren una sólida base de conocimiento institucional para tomar decisiones verdaderamente informadas. Esto nos lleva a otra aplicación transformadora de la IA en la fabricación: la preservación y la puesta en práctica de décadas de experiencia acumulada.

Los enfoques tradicionales de gestión del conocimiento suelen basarse en documentación, programas de capacitación y mentoría. Sin embargo, estos métodos presentan limitaciones significativas:

- La documentación suele estar incompleta, desactualizada o es difícil acceder a ella cuando se necesita.
- Es posible que los programas de capacitación no capturen la experiencia matizada desarrollada a través de años de experiencia.
- La mentoría depende de la disponibilidad de personal experimentado y puede ser inconsistente.

Estas limitaciones se agudizan con el envejecimiento de la fuerza laboral manufacturera y la jubilación del personal experimentado, que se lleva consigo conocimientos invaluable que podrían mejorar la capacidad de toma de decisiones de los sistemas de IA que hemos analizado. La solución reside en transformar este conocimiento ancestral en formatos accesibles para la IA que puedan alimentar directamente los sistemas de mantenimiento predictivo y multiagente que hemos explorado.

El desafío del conocimiento institucional y las soluciones impulsadas por IA

Para entender por qué es tan importante preservar este conocimiento, pensemos en lo que sucede cuando un técnico de mantenimiento veterano que ha trabajado con una máquina determinada durante décadas se jubila repentinamente. Las organizaciones manufactureras suelen depender en gran medida de este conocimiento institucional: la información, las habilidades y las prácticas no escritas que conocen los trabajadores experimentados, pero que no están documentadas formalmente. Este conocimiento suele incluir técnicas de resolución de problemas específicos de los equipos, la configuración óptima de las máquinas para diferentes materiales o condiciones, información sobre la inspección de calidad basada en sutiles señales visuales o auditivas, y ajustes de procesos para adaptarse a las variables ambientales.

Cuando los trabajadores experimentados se jubilan o dejan la organización, este valioso conocimiento puede perderse, lo que conlleva una disminución de la eficiencia, problemas de calidad y un aumento de los costos de capacitación para los nuevos empleados. Más grave aún, esta brecha de conocimiento limita la eficacia de sistemas de IA como los que hemos analizado. Los algoritmos de mantenimiento predictivo pierden precisión si no comprenden los sutiles matices operativos que los trabajadores experimentados conocen instintivamente, y los sistemas multiagente no pueden optimizar procesos que no comprenden por completo.

Los sistemas de gestión del conocimiento basados en IA abordan este desafío capturando e indexando el valioso conocimiento de los trabajadores, incluyendo información textual y no estructurada. Al crear vectores semánticos a partir de documentos, manuales y notas, los fabricantes pueden eliminar la tarea tradicional de localizar y transferir conocimiento desde silos de datos. Este enfoque permite a los usuarios realizar búsquedas entre sistemas mediante consultas en lenguaje natural, lo que facilita un acceso fluido a la información en diferentes plataformas.



Figura 7.10: Fuentes de conocimiento y arquitectura de almacenamiento

La Figura 7.10 ilustra cómo funciona este enfoque integral en la práctica. El sistema integra diversas fuentes de conocimiento organizacional, desde documentación operativa y registros históricos hasta perspectivas de expertos, información regulatoria y materiales de capacitación. En lugar de simplemente catalogar la información, la arquitectura crea conexiones inteligentes entre diferentes tipos de conocimiento. Por ejemplo, cuando un técnico de mantenimiento detecta un comportamiento inusual en un equipo, el sistema puede conectar instantáneamente esa observación con procedimientos de resolución de problemas relevantes, informes históricos de incidentes, perspectivas de expertos de entrevistas grabadas y requisitos regulatorios, todo mediante consultas en lenguaje natural. Todo el contenido fluye hacia MongoDB Atlas como vectores, datos centrales y metadatos, creando un repositorio de conocimiento unificado que transforma información aislada en una red integral de conocimiento, optimizando tanto la toma de decisiones humana como el rendimiento del sistema de IA.

Aplicación del conocimiento en tiempo real. Una vez establecido cómo se puede capturar y estructurar el conocimiento institucional, el siguiente paso crucial es hacer que este conocimiento sea accesible al instante, cuando y donde más se necesite. La arquitectura de gestión del conocimiento procesa las solicitudes de planta a través de un canal inteligente, como se muestra en la Figura 7.11. Esta aplicación en tiempo real representa la culminación de nuestros esfuerzos de preservación del conocimiento, transformando la información estática en una guía dinámica y práctica que puede optimizar los sistemas multiagente y los flujos de trabajo de mantenimiento predictivo que exploramos anteriormente.




Figura 7.11: Arquitectura de gestión del conocimiento

Cuando los operadores ingresan sus observaciones y problemas a través de aplicaciones del taller, el sistema hace lo siguiente:

- Entrada de procesos: Las solicitudes de usuario se envían a través del canal de creación de incrustaciones.
- Búsqueda semántica: MongoDB Atlas Vector Search identifica conocimiento relevante utilizando similitud semántica
- Ensamblaje contextual: El sistema de ingeniería de indicaciones combina los resultados de la búsqueda con la información actual. contexto

- Respuesta inteligente: los LLM generan orientación práctica basada en el conocimiento organizacional
- Aprendizaje continuo: Las nuevas interacciones mejoran la base de conocimientos para futuras consultas.

Esta arquitectura permite el acceso instantáneo al conocimiento institucional, ya sea que los operadores necesiten orientación para la resolución de problemas, consejos para la optimización de procesos o información sobre cumplimiento normativo. Más importante aún, crea un ciclo de retroalimentación donde el repositorio de conocimiento crece y mejora continuamente, garantizando que la información generada hoy se convierta en el conocimiento institucional que guiará los sistemas de IA y a los operadores humanos del futuro.



Una importante empresa energética europea hace que terabytes de datos no estructurados del subsuelo sean procesables con MongoDB Atlas

Con sede en Italia, esta empresa energética global cuenta con más de 30.000 empleados en 69 países. Sus operaciones abarcan desde la exploración y perforación de gas natural y petróleo hasta la cogeneración de electricidad, las energías renovables, la biorrefinación y la producción química.

La empresa se asoció con MongoDB Consulting para la capacitación y el apoyo en la migración de cargas de trabajo a MongoDB Atlas. La organización buscaba migrar a un servicio administrado con una experiencia de usuario fluida y una interfaz intuitiva para desarrolladores.

Con MongoDB Atlas, los usuarios de la empresa pueden encontrar rápidamente datos de varios años y regiones geográficas para identificar tendencias y analizar modelos. MongoDB Atlas Search también ayuda a filtrar documentos irrelevantes. El equipo también integró modelos de IA y aprendizaje automático en la plataforma para facilitar aún más la identificación de patrones.

Este ejemplo se ha anonimizado para mayor claridad editorial. Para más información, consulte: <https://mdb.link/european-energy-company-insights>



Experiencias en cabina hiperpersonalizadas

Si bien la gestión del conocimiento aborda cómo las organizaciones manufactureras preservan y aprovechan la experiencia institucional, otro ámbito donde la IA está transformando las experiencias de usuario se encuentra en la industria automotriz. Las aplicaciones que hemos explorado, desde el mantenimiento predictivo hasta la gestión del conocimiento, demuestran el poder de la IA para mejorar la eficiencia operativa mediante la integración inteligente de datos. Ahora, analizaremos una aplicación orientada al consumidor que muestra cómo estos mismos principios de comprensión contextual y asistencia personalizada están revolucionando la forma en que los conductores interactúan con sus vehículos.

La industria automotriz está experimentando una rápida transformación con vehículos eléctricos, conducción autónoma y funciones de seguridad avanzadas. Estos avances han generado una creciente demanda de sistemas a bordo más sofisticados e inteligentes que puedan brindar experiencias personalizadas tanto a conductores como a pasajeros. Los asistentes de voz se han convertido en una característica estándar en los vehículos modernos, pero hoy en día...

Las implementaciones a menudo se limitan a funciones básicas como la navegación, los controles del vehículo y las llamadas telefónicas.

Según un estudio reciente de SoundHound AI, el 83 % de los conductores que planean comprar un coche en los próximos 12 meses preferirían uno con funciones de IA a uno sin ellas. Además, el 79 % de los conductores europeos indica que utilizaría las funciones de voz GenAI en sus vehículos[2]. Estas estadísticas ponen de manifiesto la gran predisposición del mercado para las experiencias de cabina de nueva generación impulsadas por tecnologías avanzadas de IA.

Los asistentes de voz actuales que se encuentran en los vehículos enfrentan varias limitaciones. Si bien la mayoría de los vehículos vienen... Equipados con estos sistemas, y utilizados con frecuencia por los conductores, suelen ser frustrantes debido a sus capacidades limitadas. Muchos de estos sistemas solo responden a comandos específicos de maneras predeterminadas, lo que crea una experiencia de usuario rígida que no se adapta a las preferencias individuales ni a las circunstancias. contextos.

Desafíos y soluciones basadas en IA para asistentes de voz en el automóvil

El avance de los asistentes de voz en el vehículo se enfrenta a un doble reto: las necesidades del conductor y las limitaciones de los fabricantes. Los conductores tienen expectativas claras respecto a las tecnologías de voz en el vehículo: experiencias personalizadas que comprendan sus preferencias y ofrezcan interacciones adaptadas a sus necesidades específicas, un uso intuitivo que no requiera largos periodos de aprendizaje y funciones avanzadas que mejoren su experiencia de conducción sin sacrificar la simplicidad.

Mientras tanto, los fabricantes de automóviles y los proveedores de tecnología enfrentan su propio conjunto de desafíos. Los costos de desarrollo son considerables, ya que la creación de sistemas inteligentes para el habitáculo requiere experiencia especializada en IA, procesamiento del lenguaje natural e integración automotriz. La presión del tiempo de comercialización obliga a las empresas a lanzar rápidamente soluciones escalables que satisfagan las cambiantes expectativas de los clientes, a la vez que se mantienen al día con la competencia. Además, los fabricantes de automóviles buscan experiencias de marca únicas para destacar en un mercado cada vez más mercantilizado, a la vez que sortean las restricciones regulatorias.




Figura 7.12: Equilibrio entre las necesidades del conductor y los desafíos de los fabricantes de automóviles en el desarrollo del asistente de voz

Este diagrama ilustra la tensión entre las expectativas del conductor y las limitaciones de la industria automotriz en el desarrollo de asistentes de voz avanzados. La clave para resolver esta tensión reside en aprovechar las tecnologías GenAI que pueden satisfacer simultáneamente las demandas del conductor de un sistema sofisticado y personalizado.

experiencias al tiempo que brindamos a los fabricantes de automóviles soluciones escalables y rentables que aceleran el tiempo de comercialización.

GenAI: transformando los asistentes de voz en el coche. GenAI ofrece una solución a estas demandas contrapuestas al transformar fundamentalmente el funcionamiento de los asistentes de voz, pasando de patrones básicos de comando-respuesta a experiencias dinámicas e interactivas que satisfacen tanto las expectativas del conductor como los requisitos de los fabricantes de automóviles. Estos asistentes avanzados pueden:

- 1. Comprender el lenguaje natural y el contexto conversacional.
- 2. Proporcionar respuestas personalizadas según las preferencias y el historial del usuario.
- 3. Acceder a fuentes de información relevantes para brindar respuestas precisas y útiles.
- 4. Adaptarse a diferentes escenarios de conducción y condiciones ambientales.

En lugar de requerir frases de comando específicas o seguir guiones rígidos, los asistentes de voz con GenAI pueden entablar un diálogo más natural con los usuarios. Esto facilita interacciones más intuitivas y reduce la carga cognitiva de los conductores, permitiéndoles concentrarse más en la carretera sin perder acceso a la información y las funciones que necesitan.

Arquitectura de la solución: MongoDB Atlas y Google Integración en la nube

Tras establecer el potencial transformador de GenAI para los asistentes de voz en el coche, la siguiente pregunta crucial es: ¿cómo implementamos realmente estas capacidades? Para abordar estos desafíos y oportunidades, la arquitectura técnica que combina Google Cloud Platform y MongoDB Atlas sienta las bases para los asistentes de voz en el coche de próxima generación.



Nota

Si bien esta solución prioriza los componentes en la nube, los asistentes de coche eficaces requieren arquitecturas híbridas. Las funciones clave deben estar disponibles a bordo para su funcionamiento sin conexión, con versiones ligeras de las capacidades en la nube integradas en el vehículo. A medida que mejoran la capacidad de procesamiento y la conectividad automotriz, este equilibrio entre las capacidades a bordo y en la nube será cada vez más crucial para el rendimiento del asistente.

La figura 7.13 muestra una solución híbrida de nube y a bordo para asistentes de voz automotrices de próxima generación. El lado de Google Cloud gestiona la ingesta de datos (IA de documentos, generación de incrustaciones), el servicio (conversión de voz a texto, texto a voz, IA de Vertex) y la integración con MongoDB Atlas (búsqueda vectorial, flujos de cambios, datos de usuario). El sistema integrado gestiona las funciones del frontend/panel de control, el flujo de trabajo del asistente de backend, las solicitudes de inferencia y las señales del vehículo mediante el SDK PowerSync, lo que permite funciones de asistente de voz tanto conectadas a la nube como sin conexión, con una sincronización de datos fluida.




Figura 7.13: Integración de Google Cloud y MongoDB Atlas para asistentes de voz en el automóvil

Esta solución integra varios componentes clave:

1. API de voz: la tecnología de voz integral de Google Cloud gestiona la conversión de voz a texto.
Transcripción de comandos del conductor y conversión natural de texto a voz para respuestas, funcionando de manera confiable incluso en entornos acústicos desafiantes, como vehículos en movimiento.
2. Búsqueda vectorial para recuperación de contexto: MongoDB Atlas Vector Search recupera secciones relevantes del manual del automóvil y otra información contextual basándose en la comprensión semántica en lugar de una simple coincidencia de palabras clave.
3. Integración de LLM: el contexto recuperado luego se introduce en un LLM a través de Vertex AI de Google.
permitiendo que el asistente genere respuestas precisas y conscientes del contexto que aborden directamente las necesidades del usuario.
consulta.
4. Integración a bordo: El sistema se conecta a la perfección con los sistemas de interfaz existentes del vehículo mediante un backend dedicado que gestiona el flujo de trabajo del asistente. Esta integración proporciona acceso a los datos de las señales del vehículo en tiempo real, lo que permite al asistente comprender el estado actual del vehículo (en marcha/parado), la velocidad, la información de diagnóstico y otros datos telemétricos, lo que facilita respuestas más contextuales y asistencia proactiva según el estado del vehículo.

Esta arquitectura aborda varios desafíos críticos en la implementación de asistentes de voz avanzados en el automóvil.

El sistema logra una comprensión contextual mediante múltiples métodos de acceso a datos: la búsqueda vectorial recupera información específica del modelo y la consulta del vehículo, mientras que la integración directa con los sistemas del vehículo proporciona acceso en tiempo real a las señales operativas y los códigos de diagnóstico de problemas (DTC), lo que permite respuestas basadas tanto en la documentación como en el estado real del vehículo. Además, el sistema aprende de las interacciones del usuario para mejorar la relevancia con el tiempo, creando experiencias cada vez más personalizadas que se adaptan a las preferencias y patrones de uso de cada conductor.

Arquitectura de agencia avanzada: MongoDB Atlas y Google Integración en la nube

Si bien la implementación inicial se centra en mejorar las interacciones de voz con un contexto y una precisión mejorados, la arquitectura que se muestra en la Figura 7.14 está diseñada para soportar una gestión de agentes más sofisticada.

sistemas.




Figura 7.14: Arquitectura de Google Cloud y MongoDB Atlas con integración de agente de IA

Esta arquitectura se basa en la solución anterior agregando capacidades de agente de IA e integración de herramientas.

El enfoque agente organiza el sistema en cuatro componentes principales:

- Agente: El orquestador central que coordina el flujo de interacción general y mantiene la coherencia entre múltiples intercambios.
- Cerebro: El modelo del lenguaje, capacidades y funciones de razonamiento que generan respuestas y hacen decisiones.
- Herramientas: las diversas capacidades que el agente puede aprovechar, incluida la búsqueda de vectores, el acceso a bases de datos y los controles del sistema del vehículo.
- Memoria: Contexto de conversación a corto plazo y preferencias del usuario a largo plazo que mantienen la continuidad a través de interacciones.

Esta base puede ampliarse para incorporar capacidades adicionales en futuras iteraciones. El acceso en tiempo real a datos de tráfico, meteorología y puntos de interés permitirá elaborar rutas y recomendaciones de viaje más informadas. Las recomendaciones personalizadas, basadas en las preferencias y hábitos del conductor, crearán experiencias cada vez más personalizadas, mientras que el razonamiento multipaso para tareas complejas, como la planificación de viajes o el diagnóstico del vehículo, gestionará solicitudes sofisticadas de los usuarios que requieren acciones coordinadas entre múltiples sistemas. La integración con sistemas domésticos inteligentes y otros dispositivos conectados ampliará la función del vehículo como parte de un ecosistema conectado más amplio, permitiendo transiciones fluidas entre el hogar, el vehículo y el entorno laboral.

Desafíos de la implementación del RAG para los manuales de vehículos

Si bien las arquitecturas que hemos explorado proporcionan la base técnica para los asistentes de voz inteligentes, uno de los componentes más críticos implica el acceso y el procesamiento de la documentación específica del vehículo, lo cual presenta desafíos de implementación únicos que pueden determinar la eficacia del sistema. Un aspecto crucial del sistema es la gestión eficaz de la compleja documentación técnica necesaria para obtener respuestas precisas específicas del vehículo. Los manuales de los vehículos presentan desafíos únicos para las implementaciones tradicionales de RAG. Los métodos tradicionales de fragmentación a menudo fragmentan la documentación técnica en elementos aislados.

piezas, perdiendo contexto crítico en el proceso. Esto es particularmente problemático con los manuales automotrices, que contienen información profundamente interconectada, incluyendo procedimientos, advertencias, especificaciones y diagramas.



Figura 7.15: Desafíos de implementación de RAG para manuales de vehículos

Este diagrama ilustra tres desafíos clave en la implementación de sistemas RAG para la documentación técnica automotriz:

- Estructura jerárquica: Los manuales de automóviles tienen una organización jerárquica profunda con títulos, encabezados, subtítulos y secciones de contenido que crean relaciones naturales entre la información.
- Contenido especializado: Estos manuales incluyen advertencias de seguridad, procedimientos paso a paso, especificaciones técnicas, números de piezas y códigos de diagnóstico que deben conservarse intactos.
- Preservación de relaciones: Muchas secciones hacen referencia a otras partes del manual o contienen ilustraciones que se aplican a múltiples procedimientos, creando una red compleja de interdependencias.

Para abordar estos desafíos, se requieren estrategias avanzadas de fragmentación que vayan más allá de la simple segmentación de texto. Los enfoques de fragmentación que tienen en cuenta la estructura respetan los límites de la estructura del documento y mantienen unido el contenido relacionado, evitando la fragmentación de información crítica. Las técnicas de reconocimiento de contenido utilizan el reconocimiento de patrones para identificar y etiquetar contenido especializado, como advertencias o pasos de procedimiento, y garantizar que permanezca intacto durante el proceso de fragmentación. Finalmente, los sistemas de gestión de relaciones mantienen referencias a fragmentos anteriores y siguientes para facilitar la navegación secuencial, mientras que la identificación de fragmentos relacionados conserva las referencias cruzadas de contenido con contexto similar, garantizando así que la información interconectada permanezca accesible incluso cuando se distribuye en múltiples fragmentos.




Figura 7.16: Estrategias de fragmentación: fragmentación tradicional versus fragmentación de migas de pan

Este diagrama compara los métodos de fragmentación tradicionales (lado izquierdo) que fragmentan las advertencias y los procedimientos en partes aisladas, perdiendo información de seguridad crítica, con la fragmentación de migas de pan (lado derecho) que

Mantiene la estructura y el contexto del documento. El método de fragmentación con migas de pan preserva el contexto al mantener rutas jerárquicas (p. ej., Motor > Cambio de aceite > Procedimiento) y mantener unido el contenido semánticamente relacionado. Esto garantiza que, cuando un conductor pregunta sobre un procedimiento de mantenimiento, el asistente pueda acceder no solo a los pasos específicos, sino también a advertencias, especificaciones e información relevante.

Google Cloud y MongoDB: mejores juntos La solución aprovecha las fortalezas complementarias de

Google Cloud y MongoDB Atlas para ofrecer una plataforma sólida y escalable para asistentes de voz en el automóvil.

Google Cloud aporta lo siguiente:

- Liderazgo en IA: herramientas de vanguardia para GenAI y aprendizaje automático optimizadas para aplicaciones de voz
- Plataforma integrada de IA y nube: integración de extremo a extremo para reconocimiento de voz, procesamiento en tiempo real y escalabilidad en la nube
- Infraestructura escalable: Servicios en la nube confiables que garantizan un rendimiento fluido incluso con volúmenes de datos exigentes
- Herramientas para desarrolladores: herramientas robustas para la integración y el escalado de funciones de IA, acelerando el desarrollo

MongoDB complementa estas capacidades con lo siguiente:

- Modelo de datos orientado a documentos: diseño de esquema flexible que puede gestionar requisitos complejos a cualquier escala
- Almacenamiento vectorial a escala: capacidades superiores para almacenar datos operativos, metadatos y vectoriales de manera eficiente.
- Presencia en la industria automotriz: los principales fabricantes de automóviles confían en nosotros con experiencia en escalar y optimizar soluciones de datos
- Desarrollo acelerado: la plataforma MongoDB Atlas totalmente administrada agiliza el desarrollo y reduce la complejidad operativa

Esta asociación permite a los fabricantes de automóviles implementar rápidamente experiencias sofisticadas en la cabina que diferencian sus vehículos manteniendo la confiabilidad y el rendimiento esperados en las aplicaciones automotrices.

Ventajas estratégicas de los sistemas en cabina integrados con IA

Las experiencias hiperpersonalizadas en el habitáculo representan más que una simple actualización tecnológica; ofrecen ventajas estratégicas a los fabricantes de automóviles en un mercado cada vez más competitivo. Al aprovechar las capacidades avanzadas de IA, en particular GenAI para interacciones conversacionales e IA agéntica para asistencia proactiva, los fabricantes pueden crear experiencias de usuario distintivas que fomentan la fidelidad y la diferenciación de la marca.

La integración de estas tecnologías con plataformas de datos flexibles y escalables permite a las empresas automotrices desarrollar interfaces más intuitivas y receptivas que reducen la carga cognitiva durante la conducción, crean experiencias personalizadas que se adaptan a las preferencias y hábitos individuales del conductor, mejoran la seguridad al brindar información contextualmente relevante cuando y como se necesita, y diferencian los vehículos a través de funciones únicas impulsadas por IA en un mercado competitivo.

A medida que la industria automotriz continúa evolucionando hacia vehículos definidos por software, estas plataformas de experiencia en la cabina impulsadas por IA se convertirán en ventajas competitivas cada vez más esenciales, transformando la forma en que los conductores y los pasajeros interactúan con sus vehículos y redefiniendo las expectativas de la experiencia de conducción.

Obtenga más información sobre este caso de uso en los siguientes enlaces:

- Repositorio de GitHub con ejemplos de código y detalles de implementación: <https://github.com/mongodb-industry-solutions/genai-in-car-voice-assistant>
- Entrada de blog técnica detallada: <https://www.mongodb.com/company/blog/innovation/how-mongodb-google-cloud-power-future-of-in-car-assistants>

Gestión y optimización de flotas

Las operaciones de flotas representan un componente crítico para las empresas manufactureras y logísticas, impactando directamente la eficiencia operativa, la satisfacción del cliente y la rentabilidad. A medida que las organizaciones se enfrentan a las complejidades de las cadenas de suministro globales y a las crecientes demandas de velocidad y fiabilidad de los clientes, los enfoques tradicionales de gestión de flotas están dando paso a sistemas basados en IA que pueden optimizar dinámicamente las rutas, los programas de mantenimiento y la asignación de recursos en tiempo real. La optimización de las operaciones de flotas mediante IA ofrece importantes mejoras de eficiencia y reducción de costes. Al aprovechar tecnologías avanzadas, en particular la IA con agentes para la toma de decisiones autónoma, las organizaciones pueden alcanzar niveles sin precedentes de rendimiento de la flota, a la vez que reducen los costes operativos, mejoran la seguridad de los conductores y optimizan el servicio al cliente.

Agente de programación para operaciones de flotas. La integración de la IA

agéntica en la gestión de flotas representa un cambio de paradigma en la organización de las operaciones logísticas. A diferencia de los sistemas tradicionales, que se basan en reglas estáticas e intervención humana, los sistemas de IA agéntica pueden procesar de forma autónoma entradas complejas, analizar múltiples restricciones y tomar decisiones óptimas que equilibran las prioridades contrapuestas.



Figura 7.17: Agente programador de flotas de IA: proceso de orquestación y toma de decisiones

Este diagrama muestra cómo un agente de programación de IA para operaciones de flotas sigue un patrón de orquestación Pensamiento → Acción → Observación → Pensamiento para gestionar decisiones logísticas complejas. El agente de programación se basa en las solicitudes de los usuarios y se guía tanto por el contexto a corto plazo como por los datos a largo plazo almacenados en MongoDB Atlas. Orquesta las interacciones con diversos servicios, como la planificación de rutas, la programación de mantenimiento y la programación de conductores, para generar un cronograma de entregas viable.

Cuando un administrador de flota introduce una solicitud como "Quiero programar las entregas de la próxima semana: 40 ", orquestación para el total de envíos que requieren recogida de lunes a el agente activa un sofisticado proceso de viernes . El sistema primero verifica los recursos disponibles (camiones y conductores), identifica restricciones (programas de mantenimiento, horas de conducción), busca en el historial desafíos de programación similares y aplica las mejores prácticas, como la agrupación regional y la programación escalonada, para evitar infracciones. A continuación, el agente utiliza motores de optimización de rutas con restricciones, genera programas de entrega optimizados y finaliza las rutas mediante API de programación. Todo este proceso demuestra la capacidad del agente para analizar problemas logísticos complejos, tomar medidas informadas basadas en múltiples fuentes de datos, observar los resultados y perfeccionar su enfoque iterativamente hasta alcanzar una solución óptima. Este enfoque de agencia integra múltiples herramientas, fuentes de datos y objetivos en un único marco coherente de toma de decisiones, lo que permite una programación significativamente más sofisticada que los métodos tradicionales.

Arquitectura lógica y física

Tras demostrar cómo el sistema de IA agéntica toma decisiones inteligentes de programación, examinaremos ahora la arquitectura técnica que permite esta sofisticada orquestación. La implementación del agente de programación de flotas sigue una arquitectura modular que separa las preocupaciones y permite una integración fluida entre los componentes.

La Figura 7.18 ilustra el flujo lógico del sistema de programación de flotas, mostrando cómo la solicitud de un usuario "Programar 40 envíos la próxima semana" fluye a través de la lógica de orquestación y razonamiento que interpreta las solicitudes mediante el marco ReaAct y las interacciones LLM. El sistema ejecuta tareas mediante llamadas a la API para la optimización de rutas, la programación de conductores y las API de mantenimiento, a la vez que se conecta a MongoDB Atlas mediante el controlador MongoDB para realizar consultas a la base de datos y funciones de búsqueda vectorial, devolviendo a la interfaz de usuario resultados como "Hemos programado 40 envíos en 18 camiones disponibles la próxima semana" .




Figura 7.18: Arquitectura lógica

A nivel lógico, la arquitectura consta de lo siguiente:

1. Interfaz de usuario: proporciona una interfaz intuitiva para que los administradores de flotas ingresen solicitudes de programación y Ver resultados.
2. Orquestación y lógica de razonamiento: interpreta las solicitudes de los usuarios y planifica tareas utilizando ReAct. El marco ejecuta esas tareas mediante API o llamadas a funciones de herramientas y bases de datos. ReAct permite que la IA circule entre pensar, actuar y observar resultados.
3. LLM: Proporciona indicaciones iterativas a través de API para implementar Pensar → Actuar → Observar → Pensar patrón.
4. Controlador MongoDB: conecta el servicio de orquestación a MongoDB Atlas.
5. Herramientas: Incluye consulta de base de datos, búsqueda vectorial y API especializadas para optimización de rutas. Programación de conductores y programación de mantenimiento.
6. MongoDB Atlas: proporciona capacidades de consulta de bases de datos y búsqueda vectorial.

La implementación física se basa en esta arquitectura lógica. La Figura 7.19 muestra la implementación física del sistema de programación de flotas dentro de una red corporativa en la nube. Los usuarios interactúan a través de una puerta de enlace API que se conecta a microservicios en contenedores, incluyendo el agente de programación de flotas (con orquestación y lógica de razonamiento), el microservicio de optimización de rutas, el microservicio de programación de conductores y el microservicio de programación de mantenimiento. El sistema se conecta mediante enlaces privados a un servidor empresarial LLM y a MongoDB Atlas alojado en una nube pública, que proporciona capacidades de consulta de bases de datos y búsqueda vectorial, garantizando operaciones de gestión de flotas seguras y escalables.




Figura 7.19: Arquitectura física

Esta arquitectura proporciona una base escalable y mantenible para implementar capacidades avanzadas de gestión de flotas y, al mismo tiempo, garantiza que los sofisticados procesos de toma de decisiones que hemos explorado se puedan implementar de manera confiable en entornos empresariales.

MongoDB para el programador de flotas

Tras establecer la arquitectura técnica de nuestro sistema de gestión de flotas agentic, abordaremos un elemento fundamental: cómo el sistema almacena y gestiona las complejas estructuras de datos que permiten una toma de decisiones inteligente. Un aspecto crucial del sistema de gestión de flotas es su modelo de datos, que debe integrar los diversos tipos de información necesarios para una toma de decisiones eficaz.

El modelo de documento de MongoDB proporciona una base ideal para representar las estructuras de datos complejas y jerárquicas involucradas en las operaciones de la flota.




Figura 7.20: MongoDB para el programador de flotas

El sistema de programación de flotas basado en agentes opera mediante una arquitectura modular, donde cada componente cumple una función específica en el proceso de toma de decisiones. La Figura 7.20 ilustra cómo el modelo de documentos de MongoDB respalda esta arquitectura organizando los datos de los agentes en componentes distintos pero interconectados. El perfil del agente establece la identidad principal y los parámetros operativos, mientras que las instrucciones y los objetivos proporcionan el marco para la toma de decisiones. El sistema de memoria distingue entre el contexto operativo a corto plazo y el conocimiento histórico a largo plazo, lo que permite al agente aprender de experiencias pasadas y mantenerse al tanto de las condiciones actuales. El componente de herramientas proporciona acceso a funciones especializadas, como consultas a bases de datos y búsqueda vectorial, mientras que el componente de modelos gestiona las funciones de IA que impulsan los procesos de razonamiento del agente. Este enfoque modular permite que cada componente se gestione de forma independiente, manteniendo una integración fluida en todo el sistema.

Perfil del agente e instrucciones

El documento de perfil del agente define la identidad principal y los parámetros operativos del programador de la flota:

```

{ "_id": "fleet_agent_1",
  "agentProfile": { "role":
    "fleet_scheduler", "permissions":
    ["readFleetDB", "assignDrivers", "optimizeRoutes"] }, "instruction": "Programar próximas
    entregas y recogidas de camiones", "goals": [
      "Minimizar el coste total de tránsito",
      "Cumplir con los plazos de entrega",
      "Optimizar las horas del conductor",
      "Reducir las millas vacías"
    ]
  }
}

```

```
"Reducir millas vacías" ],
```

```
"createdAt": ISODate("2025-02-03T00:00:00.000Z"), "updatedAt":
ISODate("2025-02-03T01:00:00.000Z") }
```

Este documento resume el mandato operativo del agente, estableciendo parámetros claros para sus procesos de toma de decisiones.

Memoria a corto y largo plazo

La arquitectura de memoria del agente distingue entre datos operativos efímeros y conocimiento persistente. La Figura 7.21 ilustra cómo los agentes de IA gestionan la memoria a corto plazo almacenando interacciones discretas o datos de estado efímeros en documentos MongoDB. La arquitectura del agente muestra la memoria como un componente diferenciado, junto con el perfil del agente, las instrucciones y objetivos, las herramientas y los modelos. Cada documento de memoria a corto plazo captura datos operativos específicos, como identificadores de viaje, asignaciones de conductores, estado de ruta y tiempos estimados de llegada, lo que permite al agente mantener el contexto de las operaciones actuales de la flota, a la vez que distingue entre datos operativos temporales y conocimiento persistente.




Figura 7.21: Memoria a corto plazo en agentes

La memoria a corto plazo captura interacciones discretas o fragmentos de estado efímero:

```
{ "_id": ObjectId("123456789abcdefghijklm"), "agentId":
"fleet_agent_1", "timestamp":
ISODate("2025-02-03T09:45:00Z"), "interaction":
"dispatchUpdate", "data": { "tripId":
"TRIP-123",
"driverId": "DRV-01", "status":
"En ruta",
"estimatedArrivalTime":
ISODate("2025-02-03T18:00:00Z")
}}
}}
```

La memoria a largo plazo almacena información de planificación de rutas que puede consultarse mediante parámetros como el rango de fechas. Este diagrama muestra cómo los agentes de IA almacenan información persistente de planificación de rutas en la memoria a largo plazo, que puede consultarse mediante parámetros como el rango de fechas o el ID del plan de ruta. La memoria a largo plazo

El documento contiene datos completos de operación de la flota, incluidos identificadores de planes de ruta, rangos de fechas, envíos totales y problemas históricos encontrados (como demoras climáticas y requisitos de horas del conductor), lo que permite a los agentes aprender de experiencias pasadas y tomar decisiones informadas basadas en patrones y resultados históricos de gestión de flotas.



Figura 7.22: Memoria a largo plazo en agentes

```
{ "_id": ObjectId("123456789abcdefgijklm"), "agentId": "fleet_agent_1",
  "routePlanId": "ROUTEPLAN-1-2025-02-03",
  "dateRange": {
    "inicio": ISODate("2025-02-03T08:00:00Z"), "fin":
    ISODate("2025-02-10T08:00:00Z") }, "totalEnvíos": 40,

  "problemasEncontrados": [

    "Retrasos por mal tiempo en la Ruta A",
    Es necesario reiniciar las horas de conducción a mitad de semana.

  ]
}
```

El agente aprovecha las herramientas de MongoDB, como la API de consulta de la base de datos, la búsqueda vectorial y la búsqueda de texto completo, para acceder a esta información de forma eficiente. La Figura 7.23 ilustra cómo estos agentes aprovechan el completo conjunto de herramientas de MongoDB para el acceso y el razonamiento de los datos. La arquitectura del agente muestra el componente Herramientas como un elemento clave junto con los Modelos de , Instrucciones y objetivos , Memoria, y Perfil del Agente. Las tres herramientas principales de MongoDB disponibles para los agentes son la API de consulta de la base de datos para la recuperación de datos estructurados, la búsqueda vectorial para la coincidencia por similitud semántica y la búsqueda de texto completo para consultas basadas en documentos, lo que proporciona a los agentes múltiples y potentes métodos para acceder y analizar la información de forma eficiente durante la toma de decisiones.




Figura 7.23: Herramientas potentes para el razonamiento del agente

Asesor de incidentes de flotas conectadas

Basándonos en la arquitectura de agente fundamental que hemos explorado, podemos ampliar estos conceptos para crear sistemas especializados que aborden desafíos específicos de la gestión de flotas. El asesor de incidentes de flotas conectado representa una aplicación práctica de los principios de agencia que hemos analizado, demostrando cómo los sistemas basados en IA pueden brindar soporte de diagnóstico en tiempo real y desarrollar conocimiento organizacional con el tiempo.




Figura 7.24: Asesor de incidentes de flota conectada


Este diagrama muestra un sistema integral de asesoría de flotas conectado y basado en IA, desarrollado con MongoDB Atlas, Voyage AI, OpenAI y LangGraph. El sistema procesa quejas de conductores o consultas de administradores de flota, captura datos de telemetría mediante llamadas API y utiliza un motor de flujo de trabajo de agentes (LangGraph) para interpretar solicitudes, planificar tareas, ejecutar funciones y preparar respuestas. La arquitectura se integra con MongoDB Atlas para ofrecer funciones de búsqueda de memoria y vectores, almacenando sesiones de agentes, perfiles, alertas, problemas, puntos de control y datos de telemetría. Además, utiliza LLM y generación de incrustaciones para proporcionar una gestión inteligente de incidentes de flota y recomendaciones de diagnóstico.

Arquitectura del asesor de incidentes

Este sistema está construido utilizando MongoDB Atlas, Voyage AI, OpenAI y LangGraph, creando un flujo de trabajo integrado que procesa quejas de los conductores o consultas del administrador de la flota, analiza datos de telemetría del vehículo, genera un proceso de razonamiento en cadena de pensamiento y ofrece recomendaciones de diagnóstico.

1. Recibe la queja a través de la interfaz de usuario

- La arquitectura física implementa este flujo de trabajo de la siguiente manera:



4. Frontend was interfaced with Next is non-conducting w

1. Frontend: una interfaz basada en Next.js para conductores y administradores de flotas
2. Backend: puntos finales de API REST con FastAPI y un motor de flujo de trabajo de agentes impulsado por LangGraph
3. Servicios de IA: OpenAI LLM para razonamiento en cadena de pensamiento y recomendaciones, y Voyage AI modelo de incrustación para generar representaciones vectoriales
4. Almacén de datos: MongoDB Atlas para almacenar sesiones de agente, perfiles, datos de telemetría, historial de recomendaciones, registros de problemas y funcionalidad de búsqueda de vectores




Figura 7.26: Diagrama de secuencia del asesor de flota

Este diagrama de secuencia muestra el flujo operativo detallado del sistema asesor de incidentes de flota conectado.

La secuencia de operaciones fluye desde que el conductor informa un problema a través de múltiples etapas de procesamiento:

- 1. Envío de informes de problemas a través del frontend.
- 2. Procesamiento de API e invocación de flujo de trabajo.
- 3. Generación de cadenas de pensamiento para el razonamiento diagnóstico.
- 4. Recuperación y análisis de datos del vehículo.
- 5. Generación de incrustaciones y búsqueda de vectores para incidentes pasados similares.
- 6. Persistencia de los datos de la información de la sesión.
- 7. Generación de recomendaciones y entrega al conductor.

Este enfoque no sólo proporciona asistencia inmediata a los conductores, sino que también crea una base de conocimientos de problemas y soluciones que mejora con el tiempo.

Tipos de datos y almacenamiento

El sistema asesor de incidentes administra múltiples tipos de datos, cada uno de los cuales cumple una finalidad específica en el flujo de trabajo de diagnóstico:

Datos tipo	Descripción	Ejemplo en MongoDB
Perfil del agente	Esto contiene el Identidad del agente. Incluye	<pre>{ "_id": "67c20cf886f35bcb8c71e53c", "agent_id": "agente predeterminado",</pre>

	instrucciones, objetivos y restricciones.	<pre>"profile": "Perfil de agente predeterminado", "instructions": "Siga los procedimientos de diagnóstico meticulosamente. "rules": "Garantizar la seguridad; validar los datos del sensor; documentar todo. "goals": "Proporcionar diagnósticos precisos y recomendaciones prácticas. }</pre>
Corto- término memoria	Esto se mantiene temporal, contextual información, como datos recientes entradas o interacciones en curso, que el agente utiliza en tiempo real. Para Por ejemplo, la memoria a corto plazo podría almacenar información sensorial. datos del último pocas horas de actividad del vehículo En cierta agencia Marcos de IA como LangGraph, la memoria a corto plazo se implementa mediante un puntero de control. El puntero de control... víveres intermedio estados de la acciones y/o razonamiento del agente. Esta memoria permite al agente pausar y reanudar operaciones sin problemas.	Datos de telemetría almacenados en colecciones de series de tiempo <pre>{ "_id": "67cb23ee370eb8f40c9bf677", "timestamp": "2025-02-19T13:00:00", "vin": "5TFUW5F13CX228552", "temperatura_del_motor": "90", "presión_de_aceite": "35", "consumo_promedio_de_combustible": "8.5", "thread_id": "thread_20250307_125027" }</pre>
Largo- término	Aquí es donde el tiendas de agentes	Problemas históricos con vehículos conectados vectorizados y almacenados en Mo

La memoria acumula conocimiento a lo largo del tiempo. Esto puede incluir patrones, tendencias, registros e información histórica. recomendaciones y decisiones.	<pre>{ "_id": "67ca173679c7c286f44f4a24", "issue": "Motor golpea al girar", "recommendation": "Inspeccionar las bujías y el aceite del motor.", "embedding": [-0.021414414048194885, -0.0031116530299186707, 0.014275052584707737, -0.030444633215665817, 0.018614845350384712, 0.06425976008176804, 0.0060801152139902115, -0.012883528135716915, -0.007000760640949011, -0.04991862177848816, ...] }</pre>
--	--

Tabla 7.1: Tipos de datos y estructura de almacenamiento para el asesor de incidentes de flota

Esta tabla ilustra cómo el sistema asesor de incidentes administra diferentes tipos de datos en MongoDB, mostrando tres categorías clave: Perfil del agente (que contiene la identidad del agente, instrucciones, objetivos y restricciones para los procedimientos de diagnóstico), Memoria a corto plazo (almacenamiento de información contextual temporal, como datos de telemetría recientes en colecciones de series de tiempo, incluidas métricas del vehículo como la temperatura del motor y el consumo de combustible) y Memoria a largo plazo (acumula conocimiento histórico que incluye patrones, tendencias y problemas históricos vectorizados con recomendaciones, como problemas de detonación del motor con representaciones vectoriales integradas para coincidencia de similitud).

El perfil del agente contiene la identidad del agente, incluidas instrucciones, objetivos y restricciones:

```
{ "_id": "67c20cf886f35bcb8c71e53c",
  "agent_id": "default_agent", "profile":
  "Perfil de agente predeterminado",
  "instructions": "Seguir los procedimientos de diagnóstico meticulosamente.",
  "rules": "Garantizar la seguridad; validar los datos del sensor; documentar todos los
  pasos.", "goals": "Proporcionar diagnósticos precisos y recomendaciones prácticas." }
```

La memoria a corto plazo contiene información contextual temporal, como datos de telemetría:

```
{ "_id": "67cb23ee370eb8f40c9bf677", "timestamp":
  "2025-02-19T13:00:00",
  "vin": "5TFUW5F13CX228552",
  "temperatura del motor": "90", "presión
  del aceite": "35", "consumo
  promedio de combustible": "8.5",
  "thread_id": "thread_20250307_125027" }
```

La memoria a largo plazo almacena el conocimiento acumulado de cuestiones históricas y recomendaciones:

```
json

{ "_id": "67ca173679c7c286f44f4a24", "issue":
  "Golpeteo del motor al girar", "recommendation":
  "Inspeccionar las bujías y el aceite del motor.", "embedding":

  [ -0.021414414048194885,
    -0.0031116530299186707,
    0.014275052584707737,
    //Dimensiones vectoriales adicionales...

  ] }
}
```

Este enfoque de datos unificado permite modelar toda la información de gestión de la flota dentro de una única base de datos, lo que proporciona la base flexible necesaria para operaciones de flota inteligentes y adaptables.

Ventajas de MongoDB para la gestión de flotas. Tras explorar la arquitectura técnica y los detalles de implementación de los sistemas de gestión de flotas con agentes, es importante comprender por qué MongoDB Atlas es la base ideal para estas sofisticadas aplicaciones. La plataforma ofrece varias ventajas clave que habilitan directamente las capacidades avanzadas que hemos demostrado en nuestros ejemplos de gestión de flotas.

El modelo de datos documentales de MongoDB proporciona la flexibilidad esencial para gestionar estructuras de datos complejas y jerárquicas, como telemetría de vehículos, planes de ruta y horarios de conductores. Además, sus funciones de búsqueda vectorial habilitan la función de búsqueda semántica que hemos visto en el diagnóstico de incidentes y la optimización de rutas. Las colecciones de series temporales almacenan y procesan eficientemente los datos temporales que impulsan el análisis predictivo, y los controles de seguridad detallados garantizan el acceso adecuado a los datos entre los diferentes participantes del ecosistema de la flota. Para aplicaciones especializadas como el asesor de incidentes, los modelos de integración de vanguardia con Voyage AI ofrecen representaciones vectoriales de alta calidad para la correspondencia y el análisis semántico.

Estas capacidades técnicas se traducen directamente en ventajas estratégicas para las organizaciones que implementan sistemas de flotas integrados con IA. Al aprovechar las capacidades avanzadas de IA, en particular la IA agéntica para la toma de decisiones autónoma y la GenAI para el análisis de diagnóstico, las organizaciones pueden alcanzar nuevos niveles de excelencia operativa, equilibrando al mismo tiempo los costes, los niveles de servicio y los objetivos de sostenibilidad. La integración permite a las organizaciones optimizar la planificación de rutas y la utilización de los vehículos, reducir el consumo de combustible y las emisiones, mejorar la seguridad de los conductores y el cumplimiento normativo, optimizar la programación del mantenimiento y el tiempo de actividad de los vehículos, ofrecer un servicio al cliente superior mediante un rendimiento de entrega fiable y desarrollar el conocimiento organizacional sobre los patrones operativos y la resolución de incidentes.

A medida que la fabricación y la logística continúan evolucionando hacia la Industria 5.0, estos enfoques de gestión de flotas impulsados por IA serán cada vez más esenciales para mantener una ventaja competitiva en los mercados globales, lo que demuestra cómo las plataformas de datos sofisticadas permiten la transformación de la gestión de flotas tradicional a sistemas inteligentes y adaptativos.

Obtenga más información sobre este caso de uso en los siguientes enlaces:

- Guía de implementación completa para crear sistemas de gestión de flotas con IA de agentes: <https://www.mongodb.com/solutions/solutions-library/fleet-agents> Entrada de blog técnica detallada sobre soluciones de movilidad de próxima

- generación: <https://www.mongodb.com/blog/post/next-generation-mobility-solutions-agentic-ai-mongodb-atlas>

El papel cada vez más importante de la IA en la fabricación

Las aplicaciones que hemos explorado a lo largo de este capítulo representan solo el comienzo del impacto transformador de la IA en las operaciones de fabricación. La IA está revolucionando la fabricación mediante la creación de sistemas inteligentes y adaptativos que optimizan las operaciones en todo el ecosistema de producción. Desde la transformación de las cadenas de suministro con GenAI hasta la habilitación del mantenimiento predictivo mediante la colaboración entre múltiples agentes, estas tecnologías están generando mejoras mensurables en eficiencia, calidad y reducción de costes. Algunos ejemplos han demostrado cómo una base de datos moderna e inteligente como MongoDB Atlas proporciona la plataforma de datos flexible necesaria para implementar estas soluciones de IA a escala, conectando datos de equipos de producción, sistemas de inventario e incluso vehículos conectados para crear un entorno de fabricación digital integral.

La industria manufacturera está presenciando un aumento en las implementaciones de agentes de IA que aprovechan capacidades como el razonamiento profundo, la gestión del contexto y la toma de decisiones similar a la humana para resolver desafíos operativos complejos:

- Orquestación de la cadena de suministro: los agentes de IA permiten la coordinación de proveedores en varios pasos, desde la realización de pedidos hasta el seguimiento de los envíos y la actualización de los plazos de entrega, lo que resulta en una reducción de demoras y una mayor eficiencia en las operaciones diarias.
- Informes de inspección de calidad: Los agentes de IA recopilan, formatean y archivan datos de inspección repetitivos, detectan anomalías e incluso sugieren acciones correctivas, liberando así a los operadores humanos de tareas repetitivas y garantizando el cumplimiento preciso de los estándares del producto mediante tecnología de visión artificial. Con el seguimiento de datos históricos, también ayudan a identificar problemas recurrentes y a guiar la mejora continua.
- Reoptimización de la producción: Cuando se producen interrupciones (fallas en las máquinas, escasez de mano de obra o retrasos en el suministro de piezas), los agentes de IA replanifican dinámicamente los horarios analizando datos de series temporales de sensores instalados en las líneas de producción e información contextual de ERP y MES. Pueden simular múltiples escenarios de redireccionamiento, seleccionar el más eficiente e implementar cambios de forma autónoma. Esto se traduce en una mejor utilización de los activos, una reducción del tiempo de inactividad y una menor tasa de desperdicios, lo que permite una fabricación justo a tiempo incluso en condiciones inestables.
- Gestor de incidentes de flotas conectadas: En entornos donde se transportan productos o materiales mediante flotas autónomas o semiautónomas, los agentes de IA gestionan todo el ciclo de vida de la respuesta a incidentes. Recopilan datos de telemetría y diagnóstico de los vehículos, cruzan registros históricos de mantenimiento y activan flujos de trabajo automatizados para la programación de reparaciones y el pedido de piezas.

Además, notifican a los operadores humanos y a los clientes en tiempo real, ofreciendo transparencia y minimizando las interrupciones del servicio.

- Optimización del mantenimiento: los fabricantes pueden utilizar análisis predictivos impulsados por IA para ofrecer soporte de mantenimiento proactivo y asistencia personalizada a la fuerza laboral, mejorando el tiempo de actividad del equipo y la eficiencia operativa dentro del entorno de producción.

Para obtener más información y recursos, visite la página de MongoDB para fabricación y movilidad en <https://www.mongodb.com/solutions/industries/manufacturing>.

Resumen

Como vimos en el capítulo anterior y en este, la IA está revolucionando la fabricación mediante la creación de sistemas inteligentes y adaptativos que optimizan las operaciones en todo el ecosistema de producción. Desde la transformación de las cadenas de suministro con GenAI hasta la habilitación del mantenimiento predictivo mediante la colaboración multiagente, estas tecnologías están generando mejoras mensurables en eficiencia, calidad y reducción de costes. Los ejemplos que hemos explorado demuestran cómo las plataformas de datos modernas e inteligentes proporcionan la base flexible necesaria para implementar estas soluciones de IA a escala, conectando datos de equipos de producción, sistemas de inventario e incluso vehículos conectados para crear un entorno de fabricación digital integral.

La industria manufacturera está experimentando un auge en la implementación de agentes de IA que aprovechan capacidades como el razonamiento profundo, la gestión del contexto y la toma de decisiones similar a la humana para resolver desafíos operativos complejos. La orquestación de la cadena de suministro mediante agentes de IA permite la coordinación de proveedores en múltiples etapas, mientras que los sistemas de inspección de calidad compilan y formatean automáticamente los datos de inspección, detectan anomalías y sugieren acciones correctivas. Los agentes de reoptimización de la producción replanifican dinámicamente los horarios cuando se producen interrupciones, y los gestores de incidentes de flotas conectados gestionan todo el ciclo de vida de la respuesta a incidentes para flotas autónomas. Además, exploramos cómo los sistemas de gestión del conocimiento preservan la experiencia institucional mediante la asistencia impulsada por IA, y cómo las experiencias hiperpersonalizadas en la cabina están transformando las interacciones automotrices mediante sofisticados asistentes de voz e implementaciones de RAG para manuales de vehículos.

Estas aplicaciones demuestran cómo los fabricantes pueden utilizar el análisis predictivo basado en IA para ofrecer soporte de mantenimiento proactivo y asistencia personalizada a los empleados, mejorando así el tiempo de actividad de los equipos y la eficiencia operativa en el entorno de producción. La integración de la IA con agentes en plataformas de datos flexibles permite a las organizaciones alcanzar niveles sin precedentes de excelencia operativa, a la vez que reducen costes y mejoran la seguridad. En el próximo capítulo, continuaremos explorando cómo la IA está transformando las industrias de las telecomunicaciones y los medios de comunicación.

Referencias

1. Mantenimiento predictivo: el enfoque de Deloitte:

<https://www.deloitte.com/content/dam/assets-zone3/us/en/docs/services/consulting/2024/us-predictive-maintenance.pdf>

2. Una investigación revela que el 79 % de los conductores en toda Europa utilizarían capacidades de IA generativa de voz en sus

Vehículos: <https://www.soundhound.com/newsroom/press-releases/research-finds->

[El 79% de los conductores en toda Europa utilizarían capacidades de IA generativa de voz en sus vehículos.](#)

8

Estrategias impulsadas por IA para medios y telecomunicaciones Industrias

En un mundo inundado de contenido pero ávido de relevancia, las industrias de telecomunicaciones y medios se enfrentan a un desafío paradójico. Mientras el gasto global en telecomunicaciones sigue aumentando hasta alcanzar billones de dólares, los líderes de los medios reportan descensos alarmantes en el tráfico de referencias sociales, con una caída drástica de las visitas generadas por plataformas. Mientras tanto, la adopción de IA se está acelerando a un ritmo vertiginoso y se proyecta que el mercado de IA en telecomunicaciones crecerá a un ritmo asombroso, transformando el modo en que estas industrias operan en esencia.

Este no es solo otro ciclo tecnológico; es una reinención fundamental de cómo nos conectamos, consumimos y nos comunicamos. Para los operadores de telecomunicaciones y las empresas de medios, hay mucho en juego: quienes dominan la personalización impulsada por IA están obteniendo ganancias de miles de millones de dólares (Netflix genera mil millones de dólares anuales solo con recomendaciones de IA) [1], mientras que quienes se aferran a los modelos tradicionales ven cómo sus audiencias e ingresos se evaporan.

En este capítulo aprenderá sobre:

- La arquitectura de los sistemas de personalización de contenido que utilizan análisis de comportamiento y búsqueda vectorial para ofrecer recomendaciones personalizadas y aumentar las tasas de conversión.
- La transformación de la recuperación de información en interacciones conversacionales y conscientes del contexto a través de experiencias generativas de búsqueda (SGE) para reducir las tasas de rebote y aumentar la participación.
- Marcos de operaciones de IA de Agentic que automatizan los flujos de trabajo de telecomunicaciones, permiten el mantenimiento predictivo y potencialmente aumentan los ingresos
- Sistemas de detección de fraude impulsados por IA que procesan millones de eventos en tiempo real, reduciendo las pérdidas mediante el reconocimiento de patrones y la elaboración de perfiles de riesgo.
- Estrategias de automatización que optimizan los flujos de trabajo de contenido a través de procesos impulsados por IA, formato adaptativo e interfaces conversacionales para reducir el trabajo manual y mejorar la participación.

Panorama evolutivo de los medios y las telecomunicaciones

En los últimos años, la industria de los medios de comunicación se ha enfrentado a serios desafíos, desde la adaptación a las plataformas digitales y el consumo bajo demanda hasta la monetización del contenido digital y la competencia con gigantes tecnológicos y nuevas empresas emergentes. A estos desafíos se suma el auge del contenido digital, que ha saturado el mercado de los medios y ha dificultado la captación y retención de la atención de la audiencia.

Como resultado, las organizaciones de medios se ven continuamente presionadas a reevaluar sus estrategias y explorar nuevos caminos hacia el éxito.

Una encuesta industrial global a más de 326 líderes digitales [2] destacó varias tendencias que deben abordar en los próximos años, incluidas las siguientes:

- Disminución del tráfico de referencia: Aproximadamente tres cuartas partes (74 %) de los encuestados están preocupados por una posible disminución del tráfico de referencia procedente de los motores de búsqueda a medida que se implementan las perspectivas de IA. El tráfico total de Facebook a medios de comunicación ha disminuido dos tercios (67 %) en los últimos dos años, mientras que el tráfico procedente de X (anteriormente Twitter) se ha reducido a la mitad (50 %). La intención de los propietarios de la plataforma es clara: retener el tráfico de usuarios dentro de sus propios ecosistemas.
- Priorizar las estrategias de plataforma: los editores se están centrando en plataformas como ChatGPT y Perplexity mientras mantienen el interés en redes de video como YouTube, TikTok e Instagram.
- Centrarse en la innovación: se hace especial hincapié en el desarrollo de nuevos productos para atraer a las audiencias: alrededor de cuatro de cada diez (42%) planean ofertas dirigidas a los jóvenes, y entre una cuarta parte y un tercio exploran productos y servicios de audio (26%) o video (30%).

La IA ayuda a las organizaciones de medios a superar estos cambios mejorando la investigación, la producción y la distribución de contenido. Por ejemplo, la IA puede resumir los puntos clave de varios artículos, lo que aumenta la eficiencia de la investigación. También se pueden aprovechar los LLM para redactar nuevo contenido basado en temas específicos, optimizando así la producción.

Además, la IA permite la personalización del contenido para públicos diversos, como la adaptación de materiales para lectores jóvenes o hablantes de otros idiomas. También mejora la experiencia del usuario al personalizar el contenido.

recomendaciones e interacciones, una capacidad demostrada famosamente por Netflix.

En particular, se espera que las herramientas impulsadas por IA, como SGE y los chatbots impulsados por IA, proporcionen un acceso más rápido e intuitivo a la información, transformando significativamente la forma en que los usuarios interactúan con el contenido. SGE se refiere a la integración de GenAI en los motores de búsqueda, lo que les permite generar respuestas conversacionales y sintetizadas a las consultas de los usuarios, en lugar de simplemente mostrar una lista de enlaces. Este enfoque puede reducir la necesidad de acceder a sitios web externos, lo que podría alterar los patrones de tráfico tradicionales. Como resultado, estas innovaciones no solo están cambiando el comportamiento de la audiencia y la dinámica financiera en todo el sector, sino que también ofrecen a los editores nuevas oportunidades para diversificar sus fuentes de ingresos.

Centrémonos ahora en los retos y oportunidades de la industria de las telecomunicaciones, que opera en un contexto de márgenes de beneficio ajustados y una creciente presión sobre los servicios de conectividad. A medida que se acelera la transformación digital, los operadores de telecomunicaciones deben redefinir continuamente sus modelos de negocio y ofertas de servicios, y la IA emerge como una fuerza transformadora que está transformando toda la industria.

Dado que las ofertas de voz, datos e internet son mayoritariamente homogéneas y tienen bajos márgenes de beneficio, las empresas de telecomunicaciones necesitan diferenciar y diversificar sus fuentes de ingresos para generar valor y destacar en el mercado. La industria continúa experimentando un crecimiento significativo a nivel mundial, con inversiones que alcanzan billones de dólares a medida que los operadores amplían su infraestructura y desarrollan nuevas capacidades de servicio.

A medida que los nativos digitales transforman los modelos de negocio tradicionales con enfoques ágiles e innovadores, las empresas consolidadas compiten no solo entre sí, sino también con las nuevas empresas para ofrecer experiencias de cliente mejoradas y adaptarse a las cambiantes demandas de los consumidores. Por ejemplo, el servicio de internet satelital de Starlink prescinde por completo de la infraestructura de banda ancha tradicional, ofrece precios competitivos que superan a los proveedores de satélite tradicionales, a la vez que ofrece un rendimiento superior, y está creciendo rápidamente al prestar servicio a zonas rurales y remotas que las compañías de telecomunicaciones tradicionales han ignorado en gran medida debido a los altos costos de implementación de la infraestructura [3].

Para prosperar en un entorno donde la conectividad avanzada se espera cada vez más, los operadores de telecomunicaciones deben priorizar la rentabilidad en sus sistemas de soporte a las operaciones (OSS) y sistemas de soporte empresarial (BSS). Los OSS se refieren a los sistemas utilizados para gestionar la infraestructura de red, como el aprovisionamiento de servicios y la gestión de fallos, mientras que los BSS gestionan las actividades de cara al cliente, como la facturación, la gestión de pedidos y la gestión de las relaciones con los clientes. Al optimizar estos sistemas, los operadores pueden elevar los estándares de servicio al cliente y mejorar las experiencias generales del cliente: pasos fundamentales para asegurar participación en el mercado y obtener una ventaja competitiva.

Para implementar estos cambios, la IA ayuda a los operadores de telecomunicaciones a adoptar soluciones innovadoras para navegar por el panorama digital. Según NeuralT, "La IA no es solo una tecnología complementaria, sino una fuerza impulsora que... Redefiniendo la forma en que las empresas de telecomunicaciones operan, prestan servicios y mejoran las experiencias de los clientes" [4]. Por ejemplo, proporciona procesos automatizados para las operaciones de red, mecanismos de optimización para la gestión de la red y la detección rápida de patrones sospechosos de uso de datos para la protección de ingresos y la prevención del fraude.

La investigación de Capgemini destaca que «la IA Agentic se perfila como la próxima frontera en la innovación de las telecomunicaciones, al permitir sistemas que toman decisiones y resuelven problemas complejos con mínima supervisión humana. Este nuevo nivel de autonomía ayuda a las empresas a aumentar drásticamente su eficiencia operativa y a hacer realidad la promesa de redes autooptimizadas» [5].

En conjunto, las empresas líderes en la industria de los medios y las telecomunicaciones están utilizando IA para optimizar sus operaciones, proteger sus negocios e impulsar la innovación.

Descubrimiento y personalización de contenido

Se espera que las organizaciones de medios, desde los servicios de streaming hasta las publicaciones en línea, ofrezcan cierto grado de personalización de contenido. Los espectadores buscan recomendaciones de contenido personalizadas según sus intereses.

Aprovechar la IA puede mejorar significativamente las sugerencias sobre el siguiente artículo más recomendable para leer o ver en streaming. Los sistemas de personalización de contenido más potentes rastrean el comportamiento del usuario en tiempo real, como el contenido buscado, el tiempo transcurrido hasta el siguiente clic y las categorías exploradas. Estos parámetros permiten a los sistemas de personalización aumentar la interacción presentando contenido relacionado o, como alternativa, mostrando contenido nuevo que ayude a los usuarios a descubrir diferentes tipos de medios y a comprobar su interés en consumirlos.

Para llevar el contenido adecuado a las personas adecuadas en el momento adecuado, un sistema de personalización de contenido debe mantener múltiples facetas de información que sientan las bases para sugerencias adecuadas. Con bases de datos de documentos modernas como MongoDB y su modelo de datos flexible, toda esta información se puede gestionar fácilmente.

Además, desarrollar con una capa de contenido basada en JSON es mucho más rápido, intuitivo y menos propenso a errores que manejar tablas relacionales. Además, este enfoque combina contenido vectorizado con datos operativos. Las funciones de búsqueda vectorial permiten crear sistemas avanzados de sugerencias de contenido que potencian las búsquedas semánticas, yendo más allá de la simple coincidencia de palabras clave o atributos.

Plataforma de sugerencias de contenido y personalización. Al aprovechar los datos de los usuarios, el análisis de comportamiento y la vectorización multidimensional del contenido multimedia, las plataformas de datos modernas mejoran la experiencia del usuario final. Las organizaciones de medios ahora pueden sugerir contenido que se ajuste estrechamente a las preferencias individuales y al historial de interacciones.

Las plataformas de datos avanzadas mejoran la estrategia de personalización de contenido al incorporar funciones avanzadas de experiencia de usuario, como se ilustra en la Figura 8.1. Estas funciones incluyen recomendaciones personalizadas, resumen de contenido, extracción de palabras clave y generación automática de insights, lo que hace que el sistema sea más dinámico y centrado en el usuario.




Figura 8.1: Arquitectura de referencia para crear experiencias de usuario personalizadas en MongoDB con Atlas Vector Search

Este diagrama ilustra una plataforma integral de personalización de contenido donde los autores crean contenido mediante un CMS que utiliza Voyage AI para generar incrustaciones vectoriales y almacenar documentos multimedia en MongoDB con funciones de búsqueda vectorial de Atlas. El sistema incluye servicios de contenido impulsados por LLM para análisis, traducción, resumen, extracción de palabras clave, descubrimiento y sugerencias. Todos los componentes se integran mediante colecciones e índices vectoriales de MongoDB para ofrecer recomendaciones de contenido hiperpersonalizadas a los clientes en múltiples canales de salida (móvil, web y tableta), creando experiencias dinámicas gracias a las capacidades avanzadas de la plataforma de datos de M

Sugerencias de contenido y personalización.

Las plataformas multimedia

pueden sugerir contenido adaptado a las preferencias individuales y las interacciones previas mediante el uso de datos de usuario, análisis de comportamiento y la vectorización de elementos multimedia. Este mecanismo mejora la interacción del usuario y aumenta la probabilidad de convertir usuarios gratuitos en suscriptores de pago. Para esta solución, los vectores a veces se incrustan directamente en los documentos.

Además, la escalabilidad y resiliencia integradas resultan ventajosas al gestionar operaciones de búsqueda vectorial. Las organizaciones pueden escalar su base de datos MongoDB vertical u horizontalmente, e incluso optar por escalar los nodos de búsqueda independientemente de los nodos de la base de datos operativa, adaptándose a escenarios de carga específicos de forma rentable.

Resumen y reformato de contenidos

Además de sugerir qué contenido mostrar a los usuarios, las plataformas multimedia también pueden adaptar la presentación de dicho contenido utilizando los mismos datos de usuario e información sobre su comportamiento. Por ejemplo:

- Formato específico del dispositivo: un artículo recomendado podría reformatearse automáticamente como viñetas para usuarios móviles, mientras que los usuarios de computadoras de escritorio ven el texto completo.
- Resúmenes personalizados: los usuarios que normalmente leen rápidamente reciben versiones condensadas, mientras que otros reciben explicaciones detalladas.

- Adaptación de formato: en función de los patrones de consumo, el mismo contenido recomendado podría ofrecerse como texto para algunos usuarios, audio para otros o resúmenes en vídeo.
- Optimización del canal: al compartir contenido en diferentes plataformas, el sistema crea automáticamente versiones abreviadas con aspectos clave para las redes sociales y, al mismo tiempo, brinda una cobertura integral a través de otros canales.

Este enfoque aprovecha los mismos datos de preferencia de usuario y análisis de comportamiento utilizados para las recomendaciones de contenido para determinar el formato y la duración óptimos para cada individuo, mejorando aún más la participación al combinar lo que las personas quieren leer y cómo prefieren consumirlo.

Extracción de palabras clave y entidades

Las plataformas de medios pueden extraer información esencial del contenido a través de la extracción avanzada de palabras clave y entidades, lo que permite a los usuarios encontrar contenido nuevo que les guste rápidamente y con un mínimo de complicaciones. Las palabras clave son fundamentales para la indexación y la localización del contenido en los motores de búsqueda, e influyen significativamente en el rendimiento de la optimización para motores de búsqueda (SEO) del contenido digital. Con la ayuda del LLM subyacente, las plataformas multimedia pueden extraer automáticamente una mayor variedad de palabras clave con gran sofisticación, mejorando aún más la calidad de los metadatos utilizados para las búsquedas.

Creación automática de insights y resúmenes

Las plataformas de medios, como las noticias en línea o los servicios deportivos, pueden generar automáticamente información y resúmenes completos mediante el análisis de múltiples piezas de contenido relacionado, tanto dentro de sus propios archivos como de fuentes externas. Por ejemplo, una plataforma de noticias puede crear resúmenes que sintetizan información de varias noticias relacionadas sobre el mismo evento, mientras que las plataformas deportivas pueden generar panoramas completos combinando informes de partidos, estadísticas de jugadores y comentarios de expertos.

Esta función es especialmente valiosa para usuarios interesados en profundizar en temas o eventos específicos, ya que permite mostrar contenido relacionado que de otro modo sería difícil de encontrar, o generar un resumen diario de noticias, ahorrando tiempo al proporcionar todo el contenido deseado de forma fácil de entender. Esto se logra utilizando uno o más LLM para generar resultados en lenguaje natural, mejorando así la accesibilidad a la información de múltiples fuentes.

En resumen, la personalización impulsada por IA se destaca como una herramienta importante para los editores. Al usar IA para ofrecer contenido a medida y automatizar los procesos administrativos, los editores pueden abordar mejor la disminución de las referencias tradicionales y construir relaciones más sólidas y directas con su público.

Buscar experiencias generativas (SGEs)

Con el auge de la IA captando la atención del público, está claro que un cuadro de búsqueda básico que devuelve una lista de enlaces simples ya no es suficiente para los usuarios. Los SGE representan un cambio transformador en cómo los medios y

Las industrias de contenido abordan las interacciones con las solicitudes de información del usuario (búsqueda). Las empresas de contenido de servicios utilizan IA para generar resultados de búsqueda que no son solo enlaces a contenido existente, sino respuestas completas en lenguaje natural, adaptadas a la intención real del usuario. Estas respuestas inmediatas y concisas ayudan a las plataformas multimedia a mantener la atención de los usuarios durante más tiempo, reducir las tasas de rebote y aumentar la probabilidad de una interacción más profunda con el contenido.

Al utilizar plataformas de datos modernas con capacidades de búsqueda vectorial integradas en el núcleo de una solución SGE (ver Figura 8.2), las organizaciones pueden desarrollar sistemas robustos de generación aumentada por recuperación (RAG). Estos sistemas mejoran los LLM al proporcionar información adicional que sirve como contexto para la solicitud, generando respuestas más precisas, relevantes e interesantes.

La versatilidad de los sistemas SGE abre una amplia gama de casos de uso, incluyendo herramientas de investigación inteligentes, interfaces conversacionales inteligentes y experiencias de aprendizaje gamificadas. Adaptar estas soluciones a las necesidades del sector abre nuevas oportunidades de innovación, monetización y participación.




Figura 8.2: Arquitectura de referencia para la creación de un SGE

Este diagrama ilustra cómo un SGE transforma la búsqueda tradicional mediante IA para generar respuestas completas en lenguaje natural, en lugar de una simple lista de enlaces. La arquitectura muestra cómo una consulta de usuario sobre noticias del mercado de HSBC fluye a través de un modelo de integración, como Voyage AI, hacia Atlas Vector Search de MongoDB, que recupera datos contextuales de los textos de los artículos y vectores.

Incrustaciones. Estos datos patentados mejoran la propuesta LLM, permitiéndole generar respuestas específicas y bien fundamentadas en lugar de respuestas genéricas, y demostrando la transición de la simple recuperación de información a la generación inteligente de contenido contextual.

Interfaces conversacionales inteligentes

Si hablar con tu tostadora o refrigerador sobre tus planes de desayuno todavía te suena a ciencia ficción, bienvenido al futuro. Las interfaces conversacionales inteligentes permiten un acceso fluido a datos en la vida cotidiana a través de dispositivos como relojes inteligentes, wearables y automóviles. Este nuevo...

La oportunidad de interacción crea nuevas formas de involucrar a los usuarios a través de experiencias intuitivas que se sienten naturales y cómodas.

Según Bernard Marr, futurista, influencer y líder de opinión de renombre mundial en negocios y tecnología, «en 2025 se ampliará la adopción de la IA generativa en el sector de las telecomunicaciones y, sin duda, uno de los casos de uso más destacados será la transformación de la experiencia del cliente» [6]. Esto incluye servicios hiperpersonalizados y chatbots de IA que asumen interacciones cada vez más sofisticadas con los clientes.

Experiencias de aprendizaje gamificadas Las plataformas de tecnología educativa están aprovechando la IA para crear experiencias de aprendizaje más atractivas, similares a aplicaciones populares como Duolingo. Estos sistemas utilizan algoritmos de IA para monitorear continuamente el desempeño de los estudiantes y adaptar la dificultad del contenido en tiempo real, creando rutas de aprendizaje personalizadas que ofrecen:

- Entrega de contenido adaptable: ajuste la dificultad y proporcione explicaciones personalizadas cuando los usuarios cometan errores, ayudándolos a comprender mejor los conceptos.
- Sistemas de retroalimentación inteligentes: brindan sugerencias y explicaciones contextuales impulsadas por IA cuando los usuarios tienen dificultades con temas específicos.
- Optimización del progreso: utilice datos de comportamiento para identificar horarios de estudio y tipos de contenido óptimos para cada estudiante.

Para las empresas de medios, esto representa una oportunidad importante para expandirse al creciente mercado de contenidos educativos, en el que la narración digital y el aprendizaje interactivo están experimentando un crecimiento sustancial.

Garantía de servicio

Al pasar de las aplicaciones multimedia a la infraestructura de telecomunicaciones, los proveedores necesitan ofrecer servicios de red de alta calidad con niveles de rendimiento que satisfagan las expectativas de los clientes y los acuerdos de nivel de servicio (SLA). Los aspectos clave de la garantía de servicio incluyen la monitorización del rendimiento, la gestión de la calidad de servicio (QoS) y el análisis predictivo para anticipar posibles degradaciones del servicio o fallos de la red. Con la creciente complejidad de las redes de telecomunicaciones y las crecientes expectativas de los clientes de servicios siempre disponibles, se ha establecido un nuevo estándar para la garantía de servicio, lo que obliga a las empresas a invertir considerablemente en soluciones que puedan automatizar estos procesos para intentar mantener una ventaja competitiva.

La garantía del servicio ha sido revolucionada por la IA a través de varias capacidades clave:

- **Mantenimiento predictivo:** el aprendizaje automático analiza patrones para predecir fallas de la red, lo que permite un mantenimiento preventivo y reduce el tiempo de inactividad.
- **Análisis de causa raíz:** la IA identifica las causas subyacentes de los problemas de red, lo que mejora la eficacia de la resolución de problemas.
- **Optimización de la red:** la IA evalúa los datos de registro para encontrar oportunidades de mejora, reduciendo los costos operativos y optimizando el rendimiento en tiempo real.

En conjunto, estas capacidades demuestran cómo la IA está transformando la confiabilidad de la red y la eficiencia operativa.

Agentic AIOps para la gestión de redes. Basándose en la información generada por IA de los sistemas de garantía de servicio, Agentic AI Ops lleva la automatización un paso más allá al permitir la toma de decisiones y acciones autónomas. Mientras que los sistemas de IA tradicionales ofrecen recomendaciones, la IA de Agentic puede ejecutar soluciones de forma independiente sin esperar la aprobación humana.

Los marcos de operaciones de IA de Agentic ayudan a los proveedores de servicios de comunicación (Los CSP implementan sistemas impulsados por IA que pueden, de forma autónoma:

- Ejecutar acciones correctivas: reconfigurar automáticamente los enrutadores para la gestión de carga durante la congestión de la red
- Tome decisiones en tiempo real: determine e implemente respuestas apropiadas a los problemas de red a medida que ocurren
- Llamar a las API directamente: Interactuar con la infraestructura de red para implementar cambios inmediatamente
- Gestionar flujos de trabajo: coordinar procesos operativos complejos con mínima intervención humana

Por ejemplo, cuando estos sistemas detectan problemas de latencia de la red, no solo alertan a los operadores, sino que pueden redistribuir automáticamente las cargas de tráfico, ajustar los protocolos de enrutamiento o escalar recursos en tiempo real para mantener un rendimiento óptimo.

Estas capacidades autónomas permiten a los CSP gestionar flujos de trabajo complejos con una mínima intervención humana, acelerando la implementación de nuevos servicios y potencialmente aumentando los ingresos anuales hasta en un 5% [7].

Construcción de sistemas de redes impulsados por IA para telecomunicaciones

Con plataformas de datos modernas, los proveedores de telecomunicaciones pueden crear aplicaciones de gestión de red personalizadas que integren la búsqueda semántica con respuestas de texto generativo, como se describe en el siguiente diagrama.




Figura 8.3: Arquitectura de referencia para crear un chatbot de red con MongoDB

Este diagrama muestra cómo los proveedores de telecomunicaciones pueden crear chatbots de red basados en IA utilizando MongoDB como plataforma de datos principal. La arquitectura integra tres componentes principales: ingesta de datos mediante canales de agregación y búsqueda vectorial; y análisis de preguntas, donde las consultas de los usuarios se convierten en incrustaciones para encontrar datos de red relevantes y generar consultas de base de datos adecuadas mediante modelos de incrustación y LLM para el contexto.

Avisos y generación de resultados en lenguaje natural. El sistema procesa las interacciones del chat de red (preguntas, respuestas, historial), mientras que MongoDB gestiona el almacenamiento de datos y el procesamiento de flujos, con resultados que incluyen registros, métricas y auditorías para una gestión integral del sistema de red y la atención al cliente.

En primer lugar, los administradores de red capturan las entradas de registro y los eventos de telemetría, almacenando detalles como direcciones IP, información geográfica, rutas de solicitud, marcas de tiempo, registros de enrutadores y datos de sensores. Con Atlas Stream Processing, los datos se pueden recopilar y enriquecer en tiempo real, lo que proporciona una visión completa de la actividad de la red.

RAG Architecture




Figura 8.4: Ingesta de datos con Atlas Stream Processing

Este diagrama ilustra la arquitectura RAG para chatbots de red y muestra cómo se pueden ingerir y enriquecer los datos de origen mediante Atlas Stream Processing.

RAG Architecture




Figura 8.5: Selección de datos basada en preguntas con la canalización de agregación de MongoDB y Atlas Vector Search

Este diagrama demuestra cómo el sistema RAG procesa las consultas en lenguaje natural de los administradores de red, por ejemplo, "¿Qué está causando el problema de transmisión de video del cliente en Toronto?" .

El LLM primero crea canales de agregación para la recuperación de datos estructurados, mientras que un modelo de integración realiza una búsqueda vectorial semántica para encontrar información contextualmente relevante.

Una vez que el sistema identifica los datos relevantes, un LLM posterior traduce esta información a una explicación en lenguaje natural para el usuario. Durante este proceso, el LLM analiza los datos recuperados para detectar patrones y anomalías, lo que permite identificar con precisión las posibles causas raíz y facilita la toma de decisiones informadas. Por ejemplo, podría descubrir que un nodo CDN local sobrecargado, junto con un alto nivel de solicitudes de enrutadores antiguos, está causando el problema.

RAG Architecture




Figura 8.6: Inferencia y salida en lenguaje natural

Este diagrama muestra la etapa final de la arquitectura RAG. Mediante la inducción del contexto, el LLM realiza inferencia estadística y detección de patrones en los datos seleccionados, traduciendo las métricas de la red en explicaciones en lenguaje natural e información práctica.

La próxima era de las operaciones impulsadas por IA

Este caso de uso destaca cómo las AIOps agentic y las plataformas de datos modernas se complementan entre sí para transformar la gestión de la red a través de lo siguiente:

- **Flexibilidad del esquema:** los modelos basados en documentos almacenan sin esfuerzo registros, métricas de rendimiento y comentarios de los usuarios en un entorno único y consistente.

- Rendimiento en tiempo real: con el escalamiento horizontal, puede ingerir volúmenes masivos de datos generados por los registros de red y las solicitudes de los usuarios a cualquier hora del día.
- Integración de búsqueda vectorial: al incorporar datos textuales (como registros, quejas de usuarios o preguntas frecuentes) y almacenar esos vectores en la base de datos, permite la recuperación instantánea de contenido semánticamente relevante, lo que facilita que un LLM encuentre lo que necesita.
- LLM que crean canales de agregación: los LLM pueden generar canales de agregación para examinar datos numéricos con facilidad, mientras que una segunda pasada al LLM compone un resumen final que fusiona tanto el análisis numérico como el textual.

Adoptar este flujo de trabajo integral ahorra tiempo y esfuerzo, a la vez que permite la escalabilidad en toda la organización. Agiliza tareas como el análisis de picos de tráfico en regiones específicas, el diagnóstico de incidentes de seguridad y la gestión de periodos de máxima demanda. Al combinar plataformas de datos modernas como MongoDB Atlas, LLM y la arquitectura RAG, los proveedores de telecomunicaciones pueden transformar las operaciones de red en sistemas conversacionales, automatizados e inteligentes.

Detección y prevención del fraude. Los proveedores de telecomunicaciones utilizan actualmente diversas técnicas para detectar y prevenir el fraude, adaptándose constantemente a la naturaleza dinámica del fraude en este sector. Las actividades rutinarias para detectar el fraude incluyen el seguimiento de tendencias inusuales de llamadas y uso de datos, además de la protección contra incidentes de intercambio de SIM, un método frecuentemente utilizado para el robo de identidad. Para prevenir el fraude, se aplican estrategias a varios niveles, comenzando con una verificación rigurosa para los nuevos clientes, durante...

Intercambios de SIM, o para transacciones importantes, considerando el perfil de riesgo de cada cliente. Estas medidas son vitales para mitigar los efectos perjudiciales del fraude, como pérdidas financieras, daño a la reputación, multas regulatorias y riesgos de seguridad que amenazan la integridad de la red.

El aprendizaje automático ofrece a las empresas de telecomunicaciones una potente herramienta para mejorar su capacidad de detección de fraude mediante el entrenamiento de modelos con datos como los registros de detalle de llamadas (CDR). Además, estos algoritmos pueden evaluar el perfil de riesgo individual de cada cliente, adaptando las estrategias de detección a sus patrones de uso específicos, como se muestra en la Figura 8.7.




Figura 8.7: Sistema de detección de fraude impulsado por aprendizaje automático

Este diagrama arquitectónico ilustra un sistema integral de detección de fraude que procesa datos de múltiples canales de telecomunicaciones (Canal A y Canal X) a través de un almacén de datos unificado como MongoDB Atlas.

Los modelos de aprendizaje automático pueden adaptarse con el tiempo, aprendiendo de nuevos datos y tácticas de fraude emergentes, lo que permite la detección en tiempo real y la automatización de medidas de prevención del fraude, lo que acelera la respuesta. veces.

Para abordar el fraude con éxito, es necesario considerar diversas dimensiones de los datos. Dado que el tiempo de reacción es un factor crítico para prevenir los peores resultados, la solución debe permitir la toma de decisiones rápidas. Al vectorizar los datos con un modelo de aprendizaje automático adecuado, se puede definir un negocio normal (saludable) e identificar las desviaciones de la norma. Además de la búsqueda vectorial, las API de consulta de MongoDB admiten el procesamiento de flujos, lo que permite el enriquecimiento y el filtrado de datos en tiempo real.

Detección de fraude en tiempo real a gran escala con MongoDB

Uno de los clientes que utiliza MongoDB para su estrategia antifraude es un proveedor líder de telecomunicaciones estadounidense. La empresa eligió MongoDB por su capacidad para procesar y almacenar datos en constante evolución. MongoDB Atlas también supera los requisitos clave del proveedor en cuanto a rendimiento, disponibilidad y seguridad. La plataforma de prevención de fraude ahora opera con más de 50 modelos de IA diferentes, utiliza más de 1200 funciones, almacena 30 TB de datos y procesa hasta 20 millones de eventos al día. Los eventos se procesan en menos de 200 milisegundos, lo que permite la detección y prevención del fraude en tiempo real. Como resultado, el fraude, en particular el relacionado con el iPhone, que anteriormente representaba un problema de mil millones de dólares, se ha reducido en más del 80 %.



Este ejemplo ha sido anonimizado para mayor claridad editorial.

Para obtener más

[información , consulte: https://www.youtube.com/watch?v=gRw5YAsz4U](https://www.youtube.com/watch?v=gRw5YAsz4U) .



El papel cada vez más importante de la IA en los medios y las telecomunicaciones

La IA está transformando las industrias de los medios de comunicación y las telecomunicaciones al permitir un contenido más inteligente, rápido y personalizado, a la vez que facilita la agilidad operativa y la innovación. Desde el descubrimiento de contenido mejorado con IA hasta la automatización de redes, la integración de sistemas inteligentes se ha convertido en un requisito empresarial crucial. Sin embargo, el potencial transformador de la IA en estas industrias se extiende mucho más allá de estos dominios centrales.

La IA también impulsa la innovación mediante estrategias de precios diferenciados, automatización de backend y modernización de sistemas heredados. Estos casos de uso ejemplifican cómo la IA mejora la eficiencia operativa y transforma los procesos de los proveedores de telecomunicaciones y medios. Al aprovechar las tecnologías emergentes que priorizan la toma de decisiones autónoma y la optimización continua, las empresas pueden adaptarse a un mercado en constante evolución.

Precios diferenciales

Para las organizaciones de medios y telecomunicaciones, las aplicaciones impulsadas por IA pueden recopilar información sobre lo que los clientes están dispuestos a gastar en contenido o servicio realizando pruebas A/B y analizando los datos con un algoritmo ML.

Con esta información, las organizaciones pueden adoptar modelos de precios dinámicos en lugar de apegarse a una lista de precios estándar, aumentando así los ingresos generales y ampliando la base de clientes que pagan.

Búsqueda y recorte de videos. Con los nuevos modelos de incrustación de Voyage AI [8], que se incorporaron a MongoDB en 2025, es posible crear incrustaciones multimodales para ofrecer experiencias de búsqueda de videos completamente nuevas. Puedes usar lenguaje natural para describir la secuencia de video que deseas ver (por ejemplo, "Muéstrame a Mario Götze marcando el gol de la victoria en la final del Mundial de la FIFA 2014") y el sistema encontrará el video correcto, incluyendo el desplazamiento dentro del video donde ocurre la acción solicitada, y enviará un clip al usuario.

Cómo un líder mundial en telecomunicaciones aceleró la velocidad de los desarrolladores

Un proveedor líder de telecomunicaciones revolucionó el desarrollo de software al adoptar un modelo de telecomunicaciones como servicio (TaaS) con MongoDB Atlas. Esta estrategia hacia la computación sin servidor aceleró...



Entrega segura de aplicaciones, costos reducidos y desarrolladores capacitados para implementar código más rápido, mejorando tanto la innovación como la experiencia del cliente.

Este ejemplo ha sido anonimizado para mayor claridad editorial.

Para obtener más información, consulte: <https://mdb.link/new-developer-speed-and-dexterity>.



Para obtener más información y recursos, visite la página de MongoDB para medios y entretenimiento en <https://www.mongodb.com/solutions/industries/media-and-entertainment> y la página de MongoDB para telecomunicaciones en <https://www.mongodb.com/solutions/industries/telecommunications>.

Resumen

En este capítulo, exploramos cómo la IA está revolucionando las industrias de los medios y las telecomunicaciones mediante experiencias de contenido personalizadas, SGE, una gestión de red optimizada y la prevención del fraude. Estas estrategias impulsadas por la IA están mejorando la eficiencia operativa y transformando radicalmente la forma en que estas industrias interactúan con los clientes y prestan servicios.

Las plataformas de datos modernas como MongoDB proporcionan la base flexible y escalable necesaria para respaldar estas iniciativas de IA, lo que permite

Las organizaciones pueden almacenar diversos tipos de datos, realizar búsquedas vectoriales e integrarse con LLM para el procesamiento del lenguaje natural. La combinación de las capacidades de IA con la infraestructura de datos está ayudando a las empresas de medios y telecomunicaciones a superar algunos de los mayores desafíos de la industria, desde la disminución del tráfico de referencia hasta la reducción constante de los márgenes de beneficio, a la vez que crea nuevas e increíbles oportunidades de innovación.

El siguiente capítulo explorará cómo la IA está transformando el sector minorista. Profundizaremos en cómo los minoristas aprovechan la IA para lograr experiencias de compra personalizadas, optimizar el inventario, la previsión de la demanda y una integración omnicanal fluida para satisfacer las cambiantes expectativas de los consumidores en un mercado cada vez más competitivo.

Referencias

1. 50 NUEVAS estadísticas de Inteligencia Artificial:
<https://explodingtopics.com/blog/estadisticas-de-ia>
2. Tendencias y predicciones del periodismo, los medios y la tecnología 2025:
<https://reutersinstitute.politics.ox.ac.uk/periodismo-medios-y-tecnologia-tendencias-y-predicciones-2025>
3. Starlink y la disrupción de la industria de las telecomunicaciones, valorada en 2,18 billones de dólares: una apuesta estratégica para el futuro de la conectividad: <https://www.ainvest.com/news/starlink-disruption-2-18-trillion-telecom-industry-strategic-bet-future-connectivity-2508/>
4. El cambio en el consumo de telecomunicaciones: una nueva era de expectativas
<https://www.neuralt.com/news-insights/ai-next->

Frontera en telecomunicaciones: qué esperar en 2025

5. ¿Qué viene a continuación para las telecomunicaciones?: 7 tendencias clave y conclusiones del MWC 2025

: <https://www.capgemini.com/in-en/insights/expert-perspectives/> ¿Qué sigue para las telecomunicaciones? 7 tendencias clave y conclusiones del MWC 2025

6. 9 Tendencias críticas de telecomunicaciones en 2025: Lo que los líderes de la industria necesitan saber

Conozca: <https://bernardmarr.com/9-critical-telecom-trends-in-2025-what-industry-leaders-need-to-know/>

7. Nokia: Logrando una autonomía de red de siguiente nivel (informe de investigación) :

https://onestore.nokia.com/asset/214230?_gl=1*_qmnhb0*_ga*MTU4NTI3MTAxMy4xNzM5ODI4OTY3*_g_a_D6GE5QF247*MTczOTgyODk2Ni4xLjAuMTczOTgyODk2OS4wLjAuMA_

8. Viaje AI: <https://www.voyageai.com>

9

La voz y los chatbots de Cognigy en la era de la IA agencial

Si bien el capítulo anterior exploró cómo las estrategias impulsadas por IA están revolucionando el descubrimiento de contenido y la eficiencia operativa en las industrias de medios y telecomunicaciones, una implementación clave de estas capacidades de IA radica en la comunicación directa con el cliente, donde los agentes inteligentes están transformando cada interacción en una oportunidad para un compromiso contextual personalizado.

El panorama de la comunicación con el cliente ha experimentado una transformación fundamental. Estamos pasando de las interacciones rígidas y basadas en guiones de los centros de llamadas tradicionales a conversaciones dinámicas e inteligentes facilitadas por agentes de IA modernos. Sin embargo, detrás de cada historia de éxito de IA se esconde una verdad crucial: seguimos siendo testigos de errores vergonzosos de chatbots, alucinaciones frustrantes e incidentes infames como el del bot que vendió un camión por un dólar. Estos fracasos revelan una dura realidad: la IA por sí sola no puede generar valor comercial fiable a gran escala sin una base de datos de alta calidad.

La asociación entre Cognigy y MongoDB representa un enfoque desde cero para la comunicación con el cliente de próxima generación, donde la IA agente que planifica, razona y actúa de forma autónoma cumple con la arquitectura de datos necesaria para tener éxito a escala empresarial.

Al final de este capítulo, tendrá una comprensión clara de lo siguiente:

- El cambio fundamental de los chatbots basados en reglas a la IA agente orientada a objetivos y cómo Cognigy posibilita esta transformación
- Por qué los datos de alta calidad y en tiempo real sirven como elemento vital de los sistemas de IA de agentes y cómo el dominio de los datos se traduce directamente en capacidades de personalización
- Los requisitos críticos de rendimiento para los agentes de IA modernos, incluido el acceso en tiempo real a sistemas de inventario, CRM y plataformas operativas
- Cómo las empresas pueden mejorar la excelencia en lugar de los errores desarrollando capacidades de fuerza laboral con inteligencia artificial
- El enfoque integral de la personalización inteligente que combina la memoria del cliente a largo plazo con el contexto en tiempo real

A medida que nos embarcamos en esta exploración de enfoques integrales para la comunicación, descubriremos cómo la convergencia de capacidades avanzadas de IA y una arquitectura de datos sólida crea oportunidades para que las empresas reinventen por completo la interacción con el cliente, yendo más allá de las limitaciones de los centros de contacto tradicionales hacia un futuro donde muchas interacciones puedan ser inteligentes, personalizadas y valiosas.

La evolución de la IA basada en reglas a la IA orientada a objetivos

El panorama de la comunicación con el cliente ha experimentado una transformación fundamental en los últimos años. Los agentes de IA modernos pueden

Ahora comprenden el contexto, analizan escenarios complejos y adaptan sus respuestas en tiempo real, en lugar de seguir rutas predefinidas. Esta evolución representa más que una simple actualización tecnológica; representa un cambio en la forma en que las empresas interactúan con sus clientes, pasando de respuestas reactivas y basadas en reglas a una asistencia proactiva y contextualizada que anticipa las necesidades y ofrece soluciones personalizadas en tiempo real.

Para ver esta evolución en acción, considere el siguiente caso.

Caso práctico: Cómo una aerolínea de primer nivel respondió a la crisis. El 7 de marzo de 2024, Alemania

se enfrentó a un caos total en el transporte. El personal de seguridad del aeropuerto de Fráncfort, uno de los centros internacionales con mayor tráfico del mundo, abandonó sus puestos, mientras que los 25 000 empleados de tierra de una aerolínea de primer nivel iniciaron una huelga coordinada en todos los aeropuertos alemanes [1]. Los centros de atención telefónica tradicionales se habrían derrumbado ante la presión, dejando a cientos de miles de pasajeros varados esperando horas para recibir asistencia.

En cambio, ocurrió algo extraordinario. Durante el punto álgido de la crisis, los agentes de IA de la aerolínea líder, impulsados por la plataforma de Cognigy, gestionaron hasta 10 000 interacciones entrantes por minuto durante 48 horas, un volumen que habría desbordado por completo las operaciones tradicionales. Estos agentes procesaron sin problemas las nuevas reservas y los reembolsos de principio a fin, manteniendo la calidad del servicio incluso bajo presión extrema, mientras que los agentes humanos fueron redirigidos a gestionar los casos más complejos.

Este no fue solo un caso de éxito tecnológico; fue un anticipo de cómo los sistemas de comunicación inteligentes pueden transformar la respuesta ante crisis, pasando del control de daños reactivo a la atención al cliente proactiva. Pero tras esta transformación se esconde una verdad crucial que distingue el verdadero éxito de la IA de los costosos fracasos: la calidad de la base de datos.

Las limitaciones que nos frenaron

Los chatbots tradicionales y los sistemas de respuesta de voz interactiva (IVR) han sido durante mucho tiempo una fuente de frustración en la experiencia del cliente, debido a los numerosos problemas que preocupan a los consumidores sobre las interacciones automatizadas. Estos sistemas eran inherentemente estáticos y basados en reglas, siguiendo árboles de decisión rígidos que no se adaptaban en tiempo real y dejaban constantemente a los clientes frustrados con respuestas impersonales y predefinidas que no satisfacían sus necesidades reales.

El problema principal de estos sistemas heredados no residía solo en su inflexibilidad, sino en su total incapacidad para comprender el contexto, aprender de las interacciones o tomar decisiones inteligentes basadas en las circunstancias únicas de cada encuentro con el cliente. Dado que los sistemas tradicionales se limitaban a flujos preconfigurados y patrones de respuesta predeterminados, carecían de razonamiento en tiempo real y de capacidades de toma de decisiones dinámicas.

El avance de la IA agentic La IA agentic de Cognigy representa un cambio significativo que supera estas limitaciones, incorporando una filosofía sustancialmente diferente sobre cómo la IA debe interactuar con los clientes. A diferencia de los bots más antiguos que simplemente ejecutan scripts predeterminados, los agentes de IA creados con Cognigy poseen...

capacidades sofisticadas que les permiten funcionar más como agentes humanos inteligentes que los sistemas de automatización tradicionales.




Figura 9.1: Arquitectura de IA agéntica de Cognigy con integración de MongoDB

La Figura 9.1 ilustra cómo operan los agentes de IA de Cognigy dentro de un ecosistema empresarial integral. En el centro, el agente de IA, impulsado por Cognigy Nexus Engine, conecta múltiples canales de comunicación (voz del centro de contacto y mensajería digital) con los sistemas empresariales de CRM, ERP y plataformas de automatización.

El agente accede a la memoria unificada y a los repositorios de conocimiento, a la vez que aprovecha las capacidades de la base de datos MongoDB para el procesamiento de datos en tiempo real. Esta arquitectura permite una integración fluida con las herramientas empresariales existentes, como Salesforce, Microsoft Dynamics 365, SAP, Oracle y diversas plataformas de automatización, lo que demuestra cómo la IA agéntica transforma chatbots aislados en miembros inteligentes de la fuerza laboral capaces de actuar en toda la infraestructura tecnológica de una organización.

La transformación comienza con la comprensión contextual mediante datos en tiempo real y capacidades de memoria. Los agentes de IA de Cognigy no solo procesan la interacción actual de forma aislada, sino que mantienen un conocimiento exhaustivo del historial, las preferencias, las interacciones previas y el contexto actual del cliente. Esta memoria va más allá de la simple recuperación de datos e incluye la comprensión del contexto emocional, las preferencias de comunicación y la relación comercial más amplia entre el cliente y la organización.

Además, los agentes de Cognigy pueden tomar decisiones autónomas basadas en razonamiento, en lugar de guiones rígidos. Esta capacidad representa una diferencia significativa con respecto a los sistemas basados en reglas, ya que permite a los agentes evaluar situaciones complejas, sopesar múltiples factores y determinar la acción más adecuada según las circunstancias específicas de cada interacción.

La capacidad de la plataforma para usar herramientas como API, CRM e incluso sensores en el dispositivo para actuar dinámicamente crea oportunidades considerables para la resolución de problemas en tiempo real. En lugar de limitarse a la recuperación de información y respuestas predefinidas, los agentes de Cognigy pueden actuar en nombre de los clientes, procesando reembolsos, reprogramando vuelos, actualizando la información de la cuenta o coordinándose con otros sistemas para resolver problemas complejos.

Por qué los datos son el elemento vital de la agencia AI

La diferencia entre la personalización genuina y el mero tokenismo no reside en la sofisticación de los modelos de IA en sí, sino en la

Calidad, integridad y accesibilidad de los datos que sustentan dichos modelos. Sin un acceso rápido a datos completos y de alta calidad, no hay personalización más allá del simple saludo "Hola [nombre]" , que se ha convertido en sinónimo de automatización superficial.

El alcance de los requisitos de datos modernos Ya sea

que un agente de IA esté

verificando el estado de los vuelos de viajeros varados, resolviendo reclamos de seguros complejos con múltiples partes interesadas o reservando autos de alquiler con preferencias y limitaciones específicas del cliente, estos agentes dependen del acceso inmediato a diversas fuentes de datos que pintan una imagen completa de la situación y las necesidades del cliente.

Las interacciones históricas forman la base del contexto.

Comprensión, que permite a los agentes reconocer patrones en el comportamiento del cliente, comprender las preferencias de comunicación y evitar repetir errores o frustraciones anteriores. El historial de compras y servicio proporciona información importante sobre el valor del cliente, sus preferencias y la etapa del ciclo de vida, lo que permite a los agentes hacer recomendaciones adecuadas y priorizar los niveles de servicio según corresponda.

Las preferencias de los clientes van más allá de los simples datos demográficos e incluyen preferencias de estilo de comunicación, preferencias de canal, preferencias de horario e incluso el contexto emocional que podría afectar la forma en que se deben gestionar las interacciones. La ubicación y el contexto del dispositivo añaden...

Otra capa de oportunidad de personalización, que permite a los agentes proporcionar información específica de la ubicación y comprender la situación del cliente.

situación actual y limitaciones, y optimizar las interacciones para el dispositivo y canal que se utilice.

El rol de MongoDB en la habilitación de inteligencia en tiempo real. Aquí es

donde la colaboración

entre Cognigy y MongoDB se vuelve particularmente efectiva. El modelo de datos orientado a documentos de MongoDB, con capacidades de esquema flexibles (lo que significa que los campos se pueden agregar dinámicamente sin estructuras de tabla predefinidas, a diferencia de las bases de datos relacionales tradicionales que requieren esquemas fijos), y las capacidades de tiempo real permiten a los agentes de Cognigy acceder y procesar diversas fuentes de datos de manera eficiente, manteniendo al mismo tiempo las características de rendimiento necesarias para las interacciones con los clientes en tiempo real.

La combinación crea una base donde la personalización integral no sólo se vuelve posible, sino práctica y escalable en grandes bases de clientes y escenarios de interacción complejos.

Aplicación práctica: transformando la experiencia del cliente minorista.

Considere un escenario práctico de venta minorista que demuestra esta inteligencia en tiempo real en acción. Cuando un cliente contacta con el servicio de atención al cliente de un minorista por WhatsApp para preguntar sobre su fecha de entrega, la interacción desencadena un sofisticado proceso de orquestación de datos que demuestra el potencial de la colaboración Cognigy-MongoDB, como se muestra en la Figura 9.2.




Figura 9.2: Integración de datos en tiempo real en acción

Este diagrama ilustra cómo los agentes de IA de Cognigy se integran a la perfección con MongoDB para ofrecer experiencias personalizadas al cliente. El flujo muestra el recorrido del cliente desde la compra inicial (1), pasando por la consulta conversacional (2), la recuperación y el procesamiento de datos en tiempo real (3), la sincronización automatizada del sistema (4) y la generación de respuestas inteligentes (5), demostrando cómo cada interacción aprovecha los datos empresariales en tiempo real para lograr la máxima relevancia y... exactitud.

La consulta del cliente viaja a través de la plataforma de centro de contacto como servicio (CCaaS) de Cognigy, que consulta inmediatamente a MongoDB para recuperar datos del perfil del usuario e información del pedido en tiempo real.

La estructura de documentos flexible de MongoDB permite que el sistema almacene diversos tipos de datos, desde las preferencias del cliente y el historial de compras hasta el estado actual del pedido y la logística de entrega, todo dentro de colecciones unificadas a las que se puede acceder instantáneamente.

A medida que el agente de IA de Cognigy procesa la consulta en lenguaje natural del cliente, combina estos datos comerciales en tiempo real con la pregunta del cliente para crear una propuesta completa para el modelo de lenguaje amplio (LLM). El LLM genera una respuesta personalizada y contextualizada que no solo responde a la pregunta de entrega, sino que también puede actualizar proactivamente la información del pedido o sugerir servicios relacionados.

Lo que hace que esto sea particularmente potente son los flujos de cambio y la funcionalidad de desencadenadores de MongoDB. Cuando el agente de IA actualiza la información de entrega durante la conversación, por ejemplo, reprogramando una cita de entrega, MongoDB sincroniza automáticamente estos datos con otros sistemas en la experiencia del cliente, incluyendo la gestión de inventario y los proveedores de entrega. Esto garantiza que cada punto de contacto en la experiencia del cliente refleje la información más actualizada sin intervención manual.

La base técnica para una integración fluida: las capacidades en tiempo real de

MongoDB garantizan

que los agentes de IA no trabajen con datos obsoletos, sino que interactúen con los clientes utilizando la información y el contexto más recientes, incluso durante los periodos de máxima demanda, cuando los sistemas tradicionales podrían experimentar problemas de latencia o disponibilidad. Este enfoque arquitectónico transforma el servicio al cliente de la resolución reactiva de problemas a la construcción proactiva de relaciones, donde cada interacción se convierte en una oportunidad para fortalecer la fidelidad del cliente mediante una asistencia personalizada, precisa y oportuna.

La combinación crea una base donde la personalización integral no sólo se vuelve posible sino también práctica y

Escalable a través de grandes bases de clientes y escenarios de interacción complejos.

Rendimiento en tiempo real en momentos críticos

En el exigente mundo de la atención al cliente, la velocidad no solo es una ventaja competitiva; a menudo marca la diferencia entre la retención y la deserción de clientes, entre la resolución exitosa de problemas y la creciente frustración. Los agentes de IA modernos necesitan acceso en tiempo real a sistemas de inventario, CRM, plataformas de gestión de pedidos y herramientas de reserva en el momento exacto de la interacción.

Cuando los sistemas se llevan al límite

La verdadera prueba de un sistema de atención al cliente basado en IA no se da en condiciones normales de funcionamiento, sino en situaciones de crisis que ponen a prueba todos sus componentes. Las huelgas aeroportuarias alemanas de marzo de 2024 crearon precisamente este escenario, colapsando los centros de contacto de toda la industria aeronáutica, ya que miles de pasajeros buscaban simultáneamente nuevas reservas, reembolsos y planes de viaje alternativos.

Durante esta crisis, los agentes de IA de la aerolínea de primer nivel mantuvieron la continuidad del servicio, incluso cuando los centros de llamadas tradicionales tuvieron dificultades para gestionar el repentino aumento de consultas de los clientes. Este desempeño demuestra no solo las capacidades de los agentes de IA de Cognigy, sino también...

La importancia crítica de tener acceso instantáneo a los datos a través de múltiples sistemas a gran velocidad.

La complejidad de las solicitudes sencillas. Sin embargo, la necesidad de velocidad y calidad de datos no se limita a eventos disruptivos poco frecuentes. Considere la pregunta aparentemente simple de un cliente: "¿Cuándo llegará mi paquete?". Esta pregunta cotidiana requiere una secuencia compleja de operaciones de datos en tiempo real que deben completarse en segundos, no minutos, para satisfacer las expectativas del cliente y mantener la calidad del servicio.

El sistema debe primero identificar al usuario mediante procesos de autenticación, acceder a datos de pedidos anteriores, consultar el estado del sistema logístico en tiempo real, procesar información de múltiples proveedores de envío, generar respuestas realistas mediante LLM y registrar la interacción para futuras consultas. Toda esta compleja orquestación debe realizarse en segundos para mantener la ilusión de un servicio sin esfuerzo.

Según un estudio de HubSpot, el 90 % de los clientes esperan una respuesta inmediata al contactar con el servicio de atención al cliente, y las empresas que cumplen este parámetro obtienen índices de retención y satisfacción significativamente más altos [2]. El acceso rápido a los datos no solo acelera la IA, sino que la hace confiable, práctica y centrada en el cliente, lo que permite construir relaciones comerciales duraderas.

Escalando la excelencia, no los errores

La era de los centros de contacto centrados en el teléfono y en el ser humano ha llegado a su inevitable conclusión, marcando el fin de un modelo operativo

que se ha vuelto insostenible en el entorno empresarial moderno.

El enfoque tradicional de escalar manualmente las operaciones de servicio al cliente mediante la contratación de más agentes, a quienes las organizaciones tienen dificultades para retener durante períodos prolongados, representa una estrategia costosa e ineficiente que no puede seguir el ritmo de las crecientes expectativas de los clientes.

Las matemáticas de la transformación

Las matemáticas del escalamiento manual revelan los problemas inherentes a los modelos tradicionales de centros de contacto. A medida que crece la base de clientes y el volumen de interacciones, las organizaciones se enfrentan a aumentos exponenciales en los costos de personal, los requisitos de capacitación y la complejidad operativa. El desafío se vuelve aún más agudo cuando consideramos las altas tasas de rotación que afectan a la industria de servicio al cliente.

En la era de la IA, el objetivo ha cambiado claramente: de simplemente gestionar las consultas de los clientes, a ofrecer la misma o mejor calidad de servicio a un coste significativamente menor, mejorando al mismo tiempo la satisfacción del cliente y los resultados empresariales. Los agentes de IA de Cognigy representan una solución a este desafío, ofreciendo un camino hacia un servicio al cliente sostenible y escalable que mejora en lugar de degradarse con el volumen. aumenta.

Resultados demostrados en todas las industrias

La transformación que Cognigy permite va más allá de la simple automatización para abarcar una reinvención completa de lo que el servicio al cliente puede lograr. En lugar de ver las interacciones con los clientes como centros de costos que deben minimizarse, las organizaciones que priorizan la IA pueden abordar cada...

punto de contacto con el cliente como una oportunidad para construir relaciones, recopilar información y crear valor.

Use Case	Channel	KPI	Impact
Sportswear and Apparel	Chat + Voice	Deflection rate	25%
Insurance	Chat + Voice	ID&V	95%
Insurance	Chat + Voice	AHT reduction	27%
Industrial Technology and Mobility Solutions	Chat + Voice	Deflection rate	76%
Energy Utilities	Chat + Voice	Deflection rate	63%
Airlines	Chat	Deflection rate	70%
Apparel and Luxury Goods	Chat	Deflection rate	43%
Home Healthcare Services	Voice	AHT reduction	50-80%
Home Healthcare Services	Voice	Deflection rate	35%
Airlines	Chat + Voice	Deflection rate	80%
Online Optics and Eyewear	Chat + Voice	ID&V	70%
Online Optics and Eyewear	Chat + Voice	AHT reduction	10%
Online Optics and Eyewear	Chat + Voice	Deflection rate	50%
Telecommunications	Chat	Response time decrease	95%
Robotic Process Automation (RPA)	Chat	Deflection rate	26%
Employee Wellbeing Solutions	Chat + Voice	Deflection rate	43%

Tabla 9.1: Resultados del desempeño del servicio al cliente impulsado por IA en diferentes industrias

Esta tabla demuestra el impacto medible de las soluciones de servicio al cliente impulsadas por IA en diversas industrias y casos de uso.

Los datos muestran mejoras significativas en los indicadores clave de rendimiento (KPI), incluidas tasas de desviación que van del 25% al 95%, reducciones sustanciales en el tiempo promedio de manejo (AHT), identificación y verificación (ID&V) y mejoras operativas.

Métricas como disminuciones en el tiempo de respuesta y ganancias en la eficiencia del agente.

La evidencia de esta transformación se puede ver en la constancia resultados que Cognigy ha entregado en diferentes industrias y casos de uso.

Las organizaciones que implementan el enfoque de IA agentic de Cognigy reportan cambios significativos en su eficiencia operativa, estructura de costos y posicionamiento competitivo. La capacidad de gestionar interacciones complejas con los clientes de forma autónoma, manteniendo altos estándares de calidad y personalización, genera oportunidades para que las empresas amplíen sus capacidades de atención al cliente sin aumentar proporcionalmente sus recursos humanos.

La base para un crecimiento sustentable Con el respaldo de la arquitectura de base de datos de esquema flexible y de alto rendimiento de MongoDB, los agentes de Cognigy operan con velocidad, flexibilidad y confiabilidad de nivel empresarial que pueden escalar para manejar volúmenes masivos de interacción sin degradación en el rendimiento o la calidad del servicio.

Las capacidades en tiempo real de MongoDB garantizan que los agentes de IA no solo extraigan datos de ayer, sino que interactúen con los clientes utilizando la información y el contexto más recientes, incluso durante períodos de máxima demanda, cuando los sistemas tradicionales pueden tener problemas de latencia o disponibilidad.

La personalización no es magia, es dominio de los datos.

La verdadera personalización va mucho más allá del simple reconocimiento de nombre que ha caracterizado la mayoría de las iniciativas de automatización del servicio al cliente hasta la fecha. Si bien los sistemas básicos pueden saludar a los clientes con un "Hola, [nombre]" o indicar su número de cuenta, la verdadera personalización requiere una comprensión profunda del contexto, las preferencias, los patrones de comportamiento y las necesidades actuales del cliente, que va mucho más allá de la simple recuperación de datos.

La arquitectura de personalización inteligente Los agentes de inteligencia artificial de Cognigy

logran este nivel más profundo de personalización al aprovechar datos integrales para acceder al historial de pedidos, las preferencias y los conocimientos de comportamiento del cliente de forma instantánea, lo que les permite adaptar cada respuesta no solo en función de las interacciones pasadas del usuario, sino también del contexto cambiante de la interacción actual.

La verdadera personalización opera simultáneamente en múltiples capas de interacción. Además de brindar información relevante, implica calibrar el estilo de comunicación para satisfacer las expectativas del cliente, seleccionar los canales óptimos según el contexto y ajustar el ritmo de la prestación del servicio para alinearse con los niveles de urgencia y las zonas de confort técnico individuales.

La IA logra esta personalización matizada integrando la memoria a largo plazo, como perfiles de usuario detallados, historial de compras completo y preferencias documentadas, con el contexto a corto plazo, que incluye la consulta o el problema actual, el estado emocional del cliente, el canal que ha elegido para comunicarse y cualquier factor externo que pueda influir en sus necesidades o limitaciones.

La base técnica para la excelencia en la personalización:

el modelo de datos flexible de MongoDB

desempeña un papel crucial para posibilitar esta sofisticada personalización, ya que permite a Cognigy ingerir y unificar diversas fuentes de datos sin las limitaciones de los rígidos requisitos de esquema que caracterizan los enfoques tradicionales de bases de datos. Esta flexibilidad facilita experiencias fluidas en múltiples canales que realmente escuchan al usuario y sus necesidades, en lugar de simplemente repetir respuestas estandarizadas que ignoran el contexto y las preferencias.

La relación entre las capacidades de los datos y los resultados de la IA se puede entender a través de la forma sistemática en que los diferentes tipos de datos habilitan capacidades de IA específicas, que, a su vez, impulsan resultados comerciales mensurables.

Función de la capacidad de IA de datos		Resultado
Cliente perfiles	Segmentación y comprensión del contexto	Interacciones relevantes y personalizadas
Acceso en tiempo real	Participación dinámica e integración de herramientas	Rápido y receptivo servicio
Datos de alta calidad	Respuestas precisas y toma de decisiones	Confianza y satisfacción
Profético	Proactivo	Aumentó

comportamiento modelado	recomendaciones y alertas	conversión y lealtad
Datos centralizados arquitectura	CX unificada en todos los ámbitos canales	Sin costura omnicanal viajes

Tabla 9.2: Cómo los datos impulsan la IA agencial

El conocido dicho «si entra basura, sale basura» nunca ha sido tan relevante ni relevante como en el contexto de los sistemas de atención al cliente basados en IA. En ningún otro contexto se demuestra este principio con mayor claridad que en nuestra experiencia diaria con sistemas de IA que ofrecen respuestas aparentemente seguras, pero completamente incorrectas, basadas en datos de entrenamiento defectuosos o incompletos.

La importancia de la precisión. En contextos de atención al cliente, donde la confianza y la precisión son primordiales, la mala calidad de los datos no solo genera inconvenientes menores, sino que también genera respuestas deficientes, sesgadas o completamente incorrectas que pueden destruir las relaciones con los clientes y perjudicar la reputación de la marca. Las consecuencias de la mala calidad de los datos en la IA de atención al cliente van mucho más allá de simples errores factuales.

Cuando los agentes de IA proporcionan información incorrecta sobre la disponibilidad, los precios o las políticas de los productos, los clientes pueden tomar decisiones basadas en esa información que les provoquen decepción, pérdidas financieras o la pérdida de oportunidades. Cuando los sistemas de IA presentan sesgos basados en datos de entrenamiento incompletos o sesgados, pueden proporcionar diferentes niveles d

de servicio a diferentes segmentos de clientes, creando problemas legales y éticos que pueden tener graves consecuencias comerciales.

Los requisitos integrales para Excelencia en IA

Disponer de datos de alta calidad, precisos, actuales y completos es fundamental para ofrecer respuestas relevantes y humanas en las que los clientes puedan confiar y actuar. Este requisito de calidad de los datos abarca múltiples dimensiones que deben mantenerse simultáneamente para garantizar un rendimiento fiable de la IA:

- La precisión garantiza que la información proporcionada a los clientes refleje la realidad y sea confiable para la toma de decisiones.
- La vigencia garantiza que la información refleje el estado más reciente de los sistemas y procesos
- La integridad garantiza que los agentes de IA tengan acceso a toda la información relevante necesaria para brindar asistencia integral.
- La coherencia garantiza que la información proporcionada a través de los canales de IA se alinee con la información disponible a través de otros canales y sistemas.

En resumen, sin datos de alta calidad en todas las dimensiones, incluso la IA más avanzada se quedará corta. Pero cuando estas bases estén en pie...

La IA agente no solo responde, sino que genera confianza, impulsa la acción y ofrece experiencias que se sienten genuinamente humanas.

Marco de gobernanza y cumplimiento

Con Cognigy, las empresas obtienen no solo agentes inteligentes capaces de razonamiento y toma de decisiones sofisticados, sino también sistemas de IA gobernados y compatibles con funciones integrales diseñadas para proteger información confidencial y garantizar el cumplimiento normativo.

Estas características incluyen capacidades de redacción de información de identificación personal (PII) que identifica y protege automáticamente la PII, controles de acceso basados en roles que garantizan que solo el personal autorizado pueda acceder a datos confidenciales y cifrado de extremo a extremo que protege la información durante todo el ciclo de vida de la interacción.

Estas capacidades de gobernanza y cumplimiento cumplen con estrictos estándares regulatorios en múltiples industrias y jurisdicciones, lo que permite a las organizaciones implementar un servicio al cliente impulsado por IA con la confianza de que están cumpliendo con sus obligaciones legales y éticas.

Resumen

La transición de los chatbots basados en reglas a la IA inteligente con agentes representa un avance tecnológico sustancial que refleja una profunda transformación de las capacidades de comunicación con el cliente cuando las bases de datos estructuradas se integran con sistemas avanzados de IA. A lo largo de este capítulo, hemos examinado cómo la colaboración entre Cognigy y MongoDB establece la infraestructura para este avance, permitiendo a las organizaciones superar las limitaciones tradicionales de los centros de contacto hacia modelos operativos donde cada interacción con el cliente se convierte en una oportunidad para una interacción inteligente y personalizada.

El análisis demuestra que los agentes de IA eficaces requieren arquitecturas de datos robustas, y las organizaciones que dominen esta integración...

Mantener ventajas competitivas en mercados exigentes y centrados en el cliente.

El siguiente capítulo examinará cómo estos principios de utilización inteligente de datos e IA agente están transformando las operaciones minoristas, desde la experiencia del cliente hasta la eficiencia operativa. Analizaremos cómo los minoristas contemporáneos integran la inteligencia en todas sus operaciones, desde la búsqueda optimizada con IA, que procesa la intención del cliente más allá de la coincidencia de palabras clave, hasta sistemas de marketing y contenido individualizados que generan experiencias dinámicas y personalizadas a gran escala.

Referencias

1. Nuevas huelgas del personal de tierra de Lufthansa el jueves y viernes, 7 al 9 de marzo: <https://loyaltylobby.com/2024/03/04/new-lufthansa-ground-staff-strikes-on-thursday-friday-march-7th-9th/> 2. Los 5 estándares de [servicio al cliente más importantes.](#)

según

Consumidores:

<https://blog.hubspot.com/service/customer-service-standards>

10

Aprovechar la IA para transformar la Industria minorista

El comercio minorista ha cambiado. Ya no se trata de reaccionar a las necesidades de los clientes. Los minoristas líderes ahora comprenden que, para triunfar, deben anticipar todas las necesidades de sus clientes y personalizar cada interacción. La IA es la tecnología esencial que lo hace posible. Para crear este futuro predictivo e hiperpersonalizado, los minoristas necesitan integrar la IA en sus soluciones de inmediato.

Hasta ahora, el sector minorista ha prosperado gracias a su capacidad para comprender y responder a las necesidades de los clientes. Pero en el mundo actual, conectado y centrado en la experiencia, esto ya no es suficiente. La experiencia del cliente actual es fragmentada, dinámica y profundamente personal. Los minoristas deben ir más allá de reaccionar; deben predecir, adaptarse e interactuar con inteligencia y precisión en cada punto de contacto.

La IA no es solo una tendencia emergente en este panorama; es el motor que impulsa la próxima era del comercio minorista. Desde el descubrimiento de productos hasta el cumplimiento, desde la creación de contenido hasta la atención al cliente, la IA está transformando la forma en que los minoristas operan, innovan y compiten. Sin embargo, como saben muchos responsables de TI, aprovechar la IA de forma significativa y escalable suele ser más fácil de decir que de hacer. El éxito requiere más que implementar un modelo; exige un enfoque centrado en los datos, plataformas integradas y...

capacidad de respuesta en tiempo y arquitecturas capaces de evolucionar con el negocio.

En este capítulo aprenderá lo siguiente:

- La búsqueda semántica impulsada por la búsqueda vectorial está transformando el descubrimiento de productos y la interacción con el cliente a través de experiencias en tiempo real basadas en la intención.
- El marketing personalizado y la generación de contenido aprovechan GenAI y la generación aumentada por recuperación (RAG) para crear experiencias de cliente dinámicas y escalables en todos los canales.
- La previsión de la demanda y el análisis predictivo utilizan IA para pasar de la planificación reactiva a la proactiva, optimizando la gestión del inventario y la cadena de suministro.
- La digitalización de las interacciones en la tienda reduce la brecha entre el comercio minorista en línea y fuera de línea mediante la captura inteligente de datos y la personalización en tiempo real.
- Los chatbots conversacionales y agentes están revolucionando el servicio al cliente con interacciones autónomas, adaptativas y conscientes del contexto.
- Las empresas de todo el sector minorista están logrando resultados comerciales mensurables a través de implementaciones de IA inteligentes basadas en datos.
- La base de datos unificada de MongoDB proporciona la infraestructura flexible y escalable necesaria para soportar cargas de trabajo minoristas impulsadas por IA
- La IA agente está surgiendo como la próxima frontera, permitiendo sistemas proactivos y autónomos que optimizan continuamente las operaciones minoristas.

- Los minoristas modernos están expandiendo las aplicaciones de IA a la prevención de pérdidas, la ejecución de comercialización, la orquestación de la fuerza laboral y la optimización de la sostenibilidad.

Búsqueda semántica impulsada por búsqueda vectorial

El recorrido del cliente a menudo comienza con la visualización de un artículo en exhibición, que puede pasar rápidamente de una tienda física a una en línea.

En el competitivo panorama actual del comercio minorista en línea, la barra de búsqueda tradicional ha pasado de ser una mera herramienta funcional a un motor sofisticado que capta la intención del cliente y la convierte en ingresos. Los minoristas exitosos ahora aprovechan los datos operativos en tiempo real que poseen sobre las experiencias de los clientes y los enriquecen con IA para crear experiencias inteligentes y generadoras de búsqueda (SGE). Esta evolución, impulsada por innovaciones como la búsqueda vectorial, les permite comprender la intención del cliente, obtener resultados altamente relevantes y ofrecer interacciones proactivas y personalizadas que impulsan las ventas.

A medida que las compras en línea se vuelven más competitivas y aumentan las expectativas de los clientes, las funciones de búsqueda tradicionales ya no son suficientes. Esta sección explora cómo la búsqueda, antes una herramienta funcional, se ha convertido en un potente motor de interacción con el cliente y de ingresos. Analizaremos en profundidad cómo los minoristas modernos están evolucionando su infraestructura de búsqueda mediante la integración de análisis en tiempo real, IA y datos operativos para ofrecer experiencias de búsqueda inteligentes y adaptativas. Estos avances, como la búsqueda vectorial semántica, permiten a los minoristas obtener resultados más relevantes, comprender la intención del cliente y crear interacciones proactivas que la tengan en cuenta.

Transformando la búsqueda en el comercio minorista. A

medida que los clientes navegan por este panorama minorista cada vez más personalizado, su recorrido suele comenzar con la interacción crucial de la búsqueda. Si bien los minoristas se esfuerzan por ofrecer una experiencia de compra diferenciada aprovechando grandes cantidades de datos de los clientes, la eficacia de esta personalización depende de la precisión y rapidez con la que se puedan adaptar los resultados de búsqueda. Tradicionalmente, lograr esto implicaba un almacenamiento de datos complejo y modelos de IA para segmentar a los clientes. Sin embargo, el futuro de la búsqueda en el comercio minorista reside en una personalización aún más dinámica y en tiempo real para guiar al cliente a través de su experiencia de compra única.

Sin embargo, el mundo de las búsquedas no se limita a encontrar el artículo que le interesa al cliente. Los minoristas tienen la oportunidad de clasificar esos resultados de forma que ofrezcan al cliente múltiples opciones atractivas. Tradicionalmente, las decisiones sobre cómo clasificar los resultados de búsqueda de forma personalizada se tomaban segmentando a los clientes mediante la adquisición de datos de diversos sistemas operativos, trasladándolos a un almacén de datos y luego procesándolos con diversos algoritmos de aprendizaje automático.

Normalmente, esto se ejecutaba por lotes (cada 24, 48 o incluso 72 horas o algunos días), y la siguiente vez que un cliente iniciaba sesión, tenía una experiencia personalizada. Sin embargo, esto no captaba el verdadero deseo del cliente en tiempo real.

Los minoristas modernos ahora están mejorando sus resultados de búsqueda con datos en tiempo real y análisis basados en IA. Al incorporar datos de los carritos de compra, el flujo de clics de los clientes y las tendencias de compra, los minoristas pueden ofrecer recomendaciones de productos altamente...

Relevantes y perfectamente alineados con la intención del cliente. Esto se traduce en mayores tasas de conversión, mejores oportunidades de venta cruzada y la capacidad de capitalizar las tendencias emergentes a medida que se desarrollan, en lugar de días después.

Además, en la era de la GenAI, los minoristas están empezando a cambiar de la búsqueda basada en palabras clave a interacciones basadas en indicaciones que imitan conversaciones naturales. Los clientes ahora pueden expresar sus necesidades en un lenguaje sencillo, como "Necesito un regalo para mi papá, que lo adora ", y recibir búsqueda de resultados seleccionados al instante. Este enfoque , que se basa en la palabras clave , permite una mayor personalización al interpretar la intención en lugar de simplemente buscar coincidencias de términos. También permite a los minoristas mostrar productos relevantes de forma más intuitiva, incluso cuando los clientes no están seguros de qué buscar. La búsqueda basada en indicaciones marca un avance significativo en la entrega de experiencias de compra digitales más inteligentes y humanas.

La búsqueda visual representa otra capacidad transformadora, ya que permite a los clientes subir fotos de los artículos que desean encontrar o descubrir productos similares. Un cliente puede tomar una foto de la chaqueta de un amigo o de un mueble que vio en una revista y encontrar al instante artículos iguales o similares en el catálogo del minorista. Esta tecnología utiliza visión artificial e inteligencia artificial para analizar características visuales como el color, el patrón, la textura y el estilo, y luego compararlas con las imágenes del producto. La búsqueda visual elimina la dificultad de describir atributos visuales complejos con palabras y abre oportunidades de descubrimiento que la búsqueda tradicional basada en texto simplemente no puede ofrecer.

Más allá de la personalización, los minoristas influyen estratégicamente en los rankings de búsqueda para alcanzar los objetivos comerciales. Los resultados de búsqueda se ponderan cada vez más por factores como los niveles de inventario, los márgenes de beneficio y...

Campañas promocionales. Un minorista podría promocionar productos con exceso de inventario para liberar espacio en el almacén o priorizar artículos con mayor margen para mejorar la rentabilidad. Las ubicaciones de productos patrocinados permiten a las marcas pagar por un posicionamiento destacado en búsquedas relevantes, lo que genera un flujo de ingresos adicional. Esta clasificación inteligente para los negocios garantiza que la búsqueda satisfaga tanto las necesidades del cliente como las comerciales. objetivos, equilibrando la relevancia con las realidades operativas, como los niveles de existencias y la gestión estacional del inventario.

Construyendo una visión unificada del cliente

El primer paso para comprender verdaderamente al cliente es crear un almacén de datos operativos que consolide la información de toda la organización: soporte, transacciones de comercio electrónico, interacciones en tienda, listas de deseos, reseñas y más. La arquitectura flexible de bases de datos basada en documentos permite reunir datos de diferentes tipos y formatos en un solo documento para obtener una visión clara del cliente en un solo lugar. Un almacén de registros de clientes es precisamente eso: un único documento con todo el historial del cliente, no una multitud de tablas con datos distribuidos en diferentes filas. A medida que el minorista captura más datos sobre el cliente, puede agregar campos fácilmente sin necesidad de tiempo de inactividad debido a cambios en el esquema. Los datos se almacenan exactamente como deben consumirse.

Además, se puede ejecutar análisis en tiempo real, en lugar de hacerlo retroactivamente en otro sistema. Por ejemplo, la arquitectura de MongoDB permite aislar las cargas de trabajo, es decir, las cargas operativas (las acciones del cliente en el sitio de comercio electrónico) y las cargas analíticas o de IA (el cálculo de la siguiente mejor oferta).

ser) pueden ejecutarse simultáneamente sin que uno interrumpa al otro.

Los minoristas pueden crear una clasificación dinámica mediante el uso de MongoDB

Marco de agregación para consultas analíticas avanzadas o activación

Un modelo de IA en tiempo real para dar una respuesta que se pueda integrar en el ranking de búsqueda.

El beneficio de una plataforma todo en uno es enorme, ya que en lugar de tener que

Actualice su indexación de búsqueda para incorporar su aumento de IA,

MongoDB tiene búsqueda incorporada. Todo este flujo se puede completar en

una plataforma de datos automáticamente; a medida que sus datos se enriquecen con

Resultados de IA, la indexación de búsqueda se sincronizará para que coincida.

Como se discutió en [Capítulo 2](#), ¿Qué diferencia a GenAI, RAG y Agentic AI?

Aparte La búsqueda vectorial permite la comprensión semántica al encontrar

del contenido relacionado con la consulta del usuario en el espacio vectorial. En el comercio minorista.

aplicaciones, esto significa que cuando un cliente busca "cómodo"

Puntuaciones de , El sistema devuelve productos clasificados por similitud.

"zapatillas para correr" que indican qué tan cerca coinciden con la intención de la consulta,

potencialmente incluyendo zapatillas deportivas, calzado de alto rendimiento o

calzado deportivo, incluso si esos términos exactos no se usaran en el producto

descripciones.




Figura 10.1: Arquitectura de MongoDB Atlas para una vista unificada del cliente con búsqueda y análisis mejorados por IA

Este diagrama de arquitectura muestra cómo MongoDB Atlas crea una visión unificada del cliente mediante la integración de múltiples fuentes de datos en una única plataforma. El sistema combina operaciones de bases de datos tradicionales con funciones de búsqueda vectorial, lo que permite análisis en tiempo real, búsqueda semántica y recomendaciones personalizadas. Los componentes clave incluyen la ingesta de datos de diversas fuentes, el almacenamiento flexible de documentos de MongoDB, la búsqueda vectorial de Atlas para la correspondencia semántica y el análisis posterior para la inteligencia de productos y el análisis competitivo.

La tecnología de búsqueda de vectores en el comercio minorista proporciona notables beneficios económicos.

Las investigaciones del sector sugieren que los clientes que interactúan con resultados de búsqueda personalizados tienen entre 2 y 3 veces más probabilidades de realizar una conversión [1].

Evolucionando de reactivo a proactivo

Al aplicar los principios de la IA agentic a la [Capítulo 2](#), ¿Qué conjuntos?

GenAI, RAG y Agentic AI Apart monitorean búsqueda minorista, estos sistemas continuamente el comportamiento del cliente, evalúan las tendencias cambiantes y refinan de forma autónoma las estrategias de clasificación o inician flujos de trabajo promocionales sin intervención humana. Esto aborda la reactivación.

La naturaleza de la mayoría de las implementaciones de búsqueda actuales, donde incluso los modelos en tiempo real esperan información explícita en lugar de impulsar iniciativas de forma autónoma, permite a los minoristas ofrecer experiencias adaptativas y contextuales a gran escala.

Para el cliente final, esto se traduce en una experiencia de compra mucho más intuitiva y satisfactoria. En lugar de simplemente mostrar productos relevantes, la IA con agente garantiza que los resultados de búsqueda evolucionen con la experiencia del cliente en tiempo real, no solo sugiriendo productos similares, sino también organizando paquetes, recordatorios de reordenamiento u ofertas basadas en la intención inferida. Esto transforma la experiencia de la recomendación pasiva a la asistencia inteligente, impulsando una mayor satisfacción del cliente, su fidelización y, en última instancia, las tasas de conversión.

Cómo una plataforma global de entrega de alimentos
abordó los desafíos de inventario

Un ejemplo de una empresa que transforma la interacción con el cliente en tiempo real mediante IA es una plataforma líder mundial de entrega de alimentos. Ante el reto de la frecuente escasez de productos perecederos, esta empresa desarrolló una herramienta de reemplazo de artículos que ofrece alternativas personalizadas en tiempo real.

Impulsada por modelos de IA avanzados y datos de inventario en vivo, la solución garantiza que los clientes siempre encuentren una



Una opción ideal que reduce el abandono de carritos y preserva los ingresos. Basada en una infraestructura de datos moderna, la herramienta ya se está probando en Oriente Medio, donde se espera que aumente el valor bruto mensual de la mercancía. Al acelerar la innovación en IA, esta plataforma de reparto de comida no solo mejora la satisfacción del cliente, sino que también prepara sus operaciones para un crecimiento escalable e inteligente.

Este ejemplo ha sido anonimizado para mayor claridad editorial.

Para obtener más información, consulte: <https://mdb.link/food-delivery-platform-ai-innovation> .



Marketing personalizado y generación de contenidos

El entorno minorista actual se define por un panorama digital diverso, donde las redes sociales, el correo electrónico, los sitios web y las aplicaciones móviles son puntos de contacto cruciales para el consumidor. Sin embargo, el verdadero desafío radica en crear contenido personalizado que tenga un impacto único en cada uno de estos canales. Lo que atrae a un consumidor en redes sociales puede diferir significativamente de lo que capta su atención en un correo electrónico o lo que lo impulsa a actuar en una aplicación móvil. A medida que aumentan las expectativas de los clientes de experiencias relevantes y dinámicas, las campañas genéricas dejan de ser efectivas.

Los minoristas necesitan soluciones escalables para crear interacciones profundamente personalizadas que impulsen la interacción, cultiven la fidelidad y conviertan el interés en resultados tangibles. Esta sección explora cómo las tecnologías avanzadas, en particular la IA generativa y la IA con agentes, permiten a los minoristas lograr este sofisticado nivel de personalización específica para cada canal. La IA desempeña un papel fundamental en la creación de estas funciones de personalización, generando diversas variaciones de contenido, desde asuntos personalizados para correos electrónicos hasta diseños dinámicos para aplicaciones móviles. Para las pruebas, las pruebas A/B impulsadas por IA y el análisis multivariante permiten evaluar rápidamente la eficacia de las diferentes estrategias de personalización en los distintos canales, identificando los enfoques óptimos. Finalmente, durante la implementación, los sistemas de IA pueden activar y entregar automáticamente contenido personalizado por correo electrónico, SMS y notificaciones en la aplicación, garantizando una comunicación oportuna y relevante basada en el comportamiento y las preferencias del cliente en tiempo real.

Analizaremos cómo los grandes modelos de lenguaje (LLM), las bases de datos vectoriales y el procesamiento de datos en tiempo real permiten la creación de contenido personalizado a una escala y velocidad sin precedentes. Al aprovechar herramientas como bases de datos modernas (por ejemplo, MongoDB) y RAG, los minoristas pueden integrar las preferencias, el comportamiento y la disponibilidad de productos de los clientes directamente en los flujos de trabajo de marketing. Además, presentamos la IA agentic, que permite a los sistemas de marketing optimizar las campañas en tiempo real, respondiendo a las señales de los clientes y adaptándose continuamente para mejorar los resultados. En conjunto, estas innovaciones están redefiniendo la forma en que se produce, distribuye y perfecciona el contenido de marketing.

Satisfacer las demandas de contenido del comercio minorista moderno con GenAI

GenAI ahora puede crear una amplia gama de contenido, incluyendo textos publicitarios personalizados, descripciones de productos en varios idiomas y diversos recursos visuales, como fotografías y gráficos de estilo de vida. Esta integración en los flujos de trabajo del sector minorista agiliza todo el proceso de generación de contenido, reduciendo drásticamente el esfuerzo manual que tradicionalmente se requería para la redacción, edición y producción visual. Por ejemplo, GenAI puede adaptar automáticamente la documentación de productos para reflejar los tonos de voz específicos de la marca en diferentes lugares y generar imágenes de producto relevantes para diversos públicos. Esto acelera el tiempo de comercialización de nuevos productos y campañas, permitiendo a los minoristas mantenerse al día con los patrones de compra de los consumidores y los catálogos de productos en constante evolución. Al automatizar la creación de contenido, GenAI libera a los equipos humanos para que se centren en iniciativas estratégicas, mejorando la eficiencia y la eficacia general del marketing.

En el comercio minorista, los materiales de publicidad y marketing son vitales para captar el interés del cliente e impulsar la compra. La llegada de las redes sociales ha creado muchos más puntos de contacto para llegar a los clientes: Instagram, Facebook, correo electrónico, boletines informativos y banners promocionales en sitios web. Esto genera oportunidades para los minoristas y, al mismo tiempo, desafíos en cuanto al volumen de generación de contenido necesario, que pueden abordarse eficazmente mediante la adopción de GenAI.

Los patrones de compra de los clientes, la actualización constante del catálogo de productos y la disponibilidad del inventario son componentes críticos de las operaciones minoristas. Junto con esto, también existe la tarea de garantizar que la literatura del producto tenga el tono de voz adecuado para reflejar la marca en múltiples

Idiomas. Las imágenes del producto deben ser relevantes para el público local.

Tradicionalmente, esto requería una gran cantidad de trabajo de redacción y edición, fotografía de diferentes modelos y generación de elementos visuales y gráficos.

El minorista también debe comprender en tiempo real el impacto de las campañas para poder redirigir rápidamente su inversión y estrategia de marketing y reflejar lo que funciona. En un sector donde el marketing y el branding son actividades comerciales cruciales, los minoristas necesitan conocer al máximo a sus clientes para poder llegar a ellos con el mensaje adecuado en el momento oportuno.

Las empresas aprovecharán el fuerte aumento de los puntos de contacto con el consumidor para personalizar y llegar a la creciente población de consumidores que utilizan los canales digitales para descubrir, considerar y comprar productos. El 65 % de los consumidores investiga productos en línea y el 30 % compra en línea. Estas cifras se han duplicado en los últimos tres o cuatro años. Esto crea una enorme necesidad para que las marcas se dirijan a los consumidores en línea con contenido personalizado, una oportunidad que se posibilita gracias a los menores costos de creación de contenido de GenAI [2].

Acelerando el contenido personalizado con GenAI y LLM

GenAI es un catalizador de la innovación en el sector minorista, desde la personalización en la industria de la moda hasta la optimización de las operaciones administrativas. Gracias a RAG con LLM, los minoristas de moda ahora pueden crear materiales de marketing, boletines informativos, publicaciones en redes sociales y campañas de correo electrónico individualizadas, adaptadas a cada cliente, en segundos. Esto se extiende a la generación de elementos visuales, gráficos e incluso fotos únicas.

Imágenes realistas aprovechando los datos existentes de los clientes.

Esta automatización reduce significativamente el esfuerzo manual que antes requería la creación de campañas y acorta drásticamente el tiempo de comercialización de nuevas colecciones y promociones.

En las operaciones de back-office, GenAI puede analizar rápida y fácilmente la efectividad de las campañas, brindando información práctica que impulsa decisiones inteligentes y estratégicas con respecto a la gestión del inventario, la optimización de la cadena de suministro y la gestión de las relaciones con los clientes. Esta capacidad de sintetizar rápidamente datos complejos en recomendaciones claras permite a las marcas de moda tomar decisiones más informadas, mejorando en última instancia la eficiencia y la rentabilidad.

La clave para crear contenido personalizado para el cliente y la marca reside en aprovechar la gran cantidad de datos que los minoristas tienen internamente para contextualizar un LLM. Un ejemplo convincente de esta personalización basada en datos en acción proviene de la industria de la belleza.

Impulsando la innovación en el comercio minorista de belleza con MongoDB Atlas

Una importante empresa global de belleza aceleró su transformación digital mediante un acelerador tecnológico interno, desarrollando aplicaciones de alto rendimiento que permiten análisis complejos en tiempo real para optimizar las decisiones de negocio. Ante las limitaciones de su base de datos NoSQL anterior, especialmente en cuanto a latencia y complejidad del código, el equipo migró a MongoDB Atlas en Google Cloud. Este cambio mejoró drásticamente.



Rendimiento de backend y agilidad para desarrolladores, reduciendo la latencia de segundos a milisegundos y permitiendo una innovación más rápida. La arquitectura simplificada permitió a los equipos de producto iterar con rapidez y escalar eficientemente, en consonancia con su misión de ofrecer experiencias de belleza personalizadas e inclusivas impulsadas por la tecnología.

Este ejemplo ha sido anonimizado para mayor claridad editorial.

Para obtener más información, consulte: <https://mdb.link/lider-en-belleza-transformacion-digital>.



Aprovechar bases de datos modernas para un marketing escalable e

impulsado por IA. Lograr este nivel de creación de contenido

personalizado a gran escala requiere una infraestructura de datos robusta que integre a la perfección los datos de los clientes con los modelos de IA. En MongoDB, el conector Apache Spark permite el entrenamiento de modelos de LLM para que indicaciones como "crear un boletín informativo personalizado para cada cliente, sugiriendo un artículo según la oferta y sus compras anteriores", utilicen datos, imágenes y referencias tonales o lingüísticas para generar difusión. poder

Con enfoques de plataforma integrados como MongoDB, a medida que se agregan nuevos elementos o elementos visuales al catálogo de productos, los flujos de cambio pueden activar la vectorización de nuevos datos, lo que hace que el proceso sea perfecto.

Los modelos de entrenamiento con datos internos brindan a los minoristas un recurso invaluable para llegar de manera efectiva a su audiencia.




Figura 10.2: Arquitectura de personalización impulsada por IA

La figura anterior muestra una arquitectura de referencia que destaca cómo MongoDB puede aprovecharse para lograr una personalización basada en IA. Al aprovechar los datos de usuario y la vectorización multidimensional del contenido multimedia, MongoDB Atlas puede aplicarse a múltiples casos de uso de IA. Esto permite utilizar los canales multimedia para mejorar la experiencia del usuario final de forma más eficaz.

De esta manera, los minoristas pueden sugerir contenido que se ajuste mejor a las preferencias individuales y a las interacciones previas. Esto no solo mejora la interacción del usuario, sino que también aumenta la probabilidad de convertir a los usuarios gratuitos en suscriptores de pago.




Figura 10.3: Generación de boletines informativos personalizados basados en RAG utilizando datos de clientes de MongoDB

Este flujo de trabajo muestra cómo se incorporan los datos de los clientes (lista de deseos, datos de fidelización, historial de compras y comportamiento del cliente) a MongoDB. Estos datos sin procesar se transforman y vectorizan mediante modelos de incrustación. Cada vector representa numéricamente los atributos e interacciones del cliente, capturando sus preferencias, compras anteriores y comportamiento de navegación.

Estos vectores se almacenan en una base de datos de vectores dentro de MongoDB, lo que permite búsquedas de similitud eficientes. Cuando se recibe una solicitud de contenido del boletín informativo (p. ej., "Generar un boletín personalizado"), se activa el boletín informativo para un cliente interesado en equipo para actividades al aire libre del sistema RAG. Primero, se vectoriza la solicitud del usuario. Este vector se utiliza para consultar la base de datos de vectores de MongoDB y recuperar los vectores de datos del cliente más relevantes.

Por ejemplo, si el mensaje es sobre equipos para actividades al aire libre, el sistema recuperaría los perfiles de los clientes y sus datos históricos relacionados con compras de productos para actividades al aire libre, listas de deseos de equipos para acampar o navegación.

comportamiento de las botas de senderismo. Estos datos recuperados del cliente, que son altamente específicos y contextuales para cada individuo, constituyen la base de la contexto .

El contexto del cliente extraído, junto con la solicitud inicial, se incorpora a un LLM. Este aprovecha este contexto rico y personalizado para generar contenido de boletín informativo altamente relevante y personalizado.

Por ejemplo, si los datos del cliente recuperados indican una compra anterior de una marca específica de botas de senderismo, el LLM puede generar un boletín que destaque los recién llegados de esa marca, accesorios que complementan las botas o próximas ventas de equipos para actividades al aire libre similares.

Este proceso permite a los minoristas crear comunicaciones de marketing personalizadas a gran escala, yendo más allá de las campañas genéricas para ofrecer experiencias verdaderamente personalizadas que conecten con cada cliente. La capacidad del LLM para comprender y sintetizar la información del contexto garantiza que el contenido generado no solo sea personalizado, sino también coherente y atractivo, lo que, en última instancia, impulsa una mayor interacción del cliente y tasas de conversión.

Cómo la IA agentic está revolucionando el marketing adaptativo en el

comercio minorista. La IA agentic va un paso más allá al

introducir sistemas autónomos que no solo generan contenido personalizado, sino que también monitorizan, evalúan y ajustan las campañas de marketing en tiempo real según las señales de interacción del cliente. Estos agentes inteligentes pueden evaluar qué mensajes tienen mayor repercusión en los diferentes segmentos de audiencia y ajustar dinámicamente el tono, el formato, el canal y el momento oportuno para maximizar el rendimiento sin intervención humana.

El mayor desafío del marketing de contenidos es el retraso entre la implementación del contenido y la respuesta. Normalmente, los equipos de marketing tienen que esperar los análisis, interpretar los datos y luego ajustar manualmente sus campañas. La IA de Agentic rompe ese ciclo, optimizando continuamente el alcance en tiempo real y eliminando por completo ese retraso.

Para el cliente final, esto se traduce en contenido verdaderamente relevante y oportuno; las ofertas llegan cuando más las necesitan, en un tono que resuena y a través de sus canales de comunicación preferidos. Para los minoristas, significa un mejor retorno de la inversión en marketing, mayores tasas de conversión y una menor dependencia de campañas estáticas que pueden perder impacto con el tiempo. Con la IA agente, el marketing personalizado evoluciona de un proceso estático basado en información histórica a un sistema dinámico que se adapta inteligentemente al comportamiento del consumidor en cada momento.

Previsión de la demanda y análisis predictivo

Una previsión precisa de la demanda es un factor clave entre la eficiencia operativa y los costosos errores. A medida que aumentan las expectativas de los consumidores y las cadenas de suministro se vuelven cada vez más complejas, la capacidad de predecir la demanda con precisión puede tener un impacto significativo en la rentabilidad, la gestión del inventario y la satisfacción del cliente de un minorista. Esta sección explora cómo la previsión de la demanda basada en IA y el análisis predictivo están ayudando a los minoristas a pasar de la planificación reactiva a la proactiva. Con el respaldo de amplios datos históricos e información en tiempo real, las empresas pueden generar previsiones que permitan tomar decisiones más inteligentes de compra, reabastecimiento y promoción.

Abordaremos la evolución de los modelos tradicionales de aprendizaje automático a técnicas de vanguardia como GenAI y la IA agéntica. Esta sección examinará cómo los enfoques modernos de pronóstico integran señales contextuales, como la estacionalidad, los cambios económicos y los patrones de comportamiento, para aumentar la precisión. Aprenderá cómo RAG mejora la relevancia de los datos y cómo la IA agéntica va aún más allá al automatizar ajustes y acciones en tiempo real. En conjunto, estas innovaciones permiten a los minoristas satisfacer la demanda de forma eficiente, minimizando el desperdicio y maximizando la satisfacción del cliente.

Pronóstico de la demanda basado en IA para una gestión más inteligente del inventario y la cadena de suministro. Los minoristas suelen predecir la demanda desarrollando sus propias aplicaciones con aprendizaje automático tradicional o adquiriendo productos de pronóstico especializados. Si bien los sistemas locales pueden ser eficaces, presentan varios desafíos:

- **Requisitos de infraestructura significativos:** Los sistemas locales requieren una infraestructura sustancial tanto para el almacenamiento y procesamiento de datos como para las operaciones de aprendizaje automático (MLOps). Esto implica la necesidad de considerables recursos de hardware, software y redes.
- **Experiencia técnica especializada:** El desarrollo, la gestión y el mantenimiento de estos sistemas requieren conocimientos técnicos especializados. Esto puede suponer un reto a la hora de encontrar y retener profesionales cualificados.

- Cuidado y mantenimiento constantes: Estos sistemas requieren un cuidado constante para garantizar un rendimiento óptimo y aportar valor a las empresas. Esto implica una demanda constante de supervisión, resolución de problemas, actualizaciones y mantenimiento general, lo que puede consumir muchos recursos y tiempo.

Posteriormente, la ingeniería de características permite extraer información sobre estacionalidad, promociones, impacto e indicadores económicos generales. Se puede incorporar un modelo RAG para mejorar las predicciones de la demanda y reducir la posibilidad de alucinaciones. Los mismos conjuntos de datos históricos podrían utilizarse para entrenar y ajustar el modelo.

Precisión mejorada.

Estos esfuerzos conducen a los siguientes beneficios comerciales:

- Precisión en la previsión de la demanda
- Planificación optimizada de productos y suministros
- Precisión en la gestión de inventarios
- Mayor satisfacción del cliente

Cómo GenAI está transformando el análisis predictivo en el comercio minorista

La IA tradicional se utiliza en la previsión de la demanda y el análisis predictivo en el comercio minorista mediante la integración de datos de diversas fuentes, como transacciones de ventas, redes sociales y patrones climáticos, lo que genera previsiones muy precisas y oportunas.

GenAI, a diferencia del aprendizaje automático tradicional, puede crear datos novedosos, como imágenes, texto y audio realistas, en lugar de simplemente analizar datos existentes para realizar predicciones. Esta capacidad permite que las aplicaciones...

como la creación de contenido, la generación de datos sintéticos para capacitación y experiencias personalizadas, que se extienden más allá de las limitaciones analíticas y predictivas del aprendizaje automático tradicional.

GenAI puede optimizar significativamente el diseño y desarrollo de productos al generar rápidamente nuevas iteraciones de diseño, simular el rendimiento en diversas condiciones y optimizar según criterios específicos. Esto acelera la fase de prototipado, reduce la necesidad de costosas maquetas físicas y permite explorar una gama más amplia de soluciones creativas, lo que en última instancia resulta en productos más innovadores y listos para el mercado.




Figura 10.4: Una ilustración de un escenario de cambio de precios donde los costos del combustible han aumentado, lo que lleva a un aumento en los costos de envío y, a su vez, en los precios.

Desglosemos los pasos mencionados en la imagen:

- [1] Esto genera eventos sobre el aumento de costo y los coloca en el flujo de mensajes, donde la cola de eventos los pone a disposición. Todos los microservicios están atentos a estos mensajes.
- [2–4] El microservicio de precios consume el evento, lo analiza comparándolo con los datos existentes y transmite además el nuevo precio en el flujo de mensajes.
- [5–6] La base de datos envía esos mensajes a la cola de eventos, lo que los pone a disposición de todos los consumidores que los reciben. Los microservicios directamente afectados por los cambios de precios, como los que gestionan el inventario, el marketing, las promociones, los cupones, el punto de venta (TPV) y el sistema de gestión de pedidos (OMS) del proveedor de comercio electrónico, consumen los eventos de cambio de precio y actualizan sus bases de datos individuales en consecuencia.
- [7] La base de datos centralizada agrega y persiste eventos, enriquece los flujos de eventos con datos de otras fuentes, incluidos datos históricos, y proporciona un repositorio central para múltiples flujos de eventos

Transformando el análisis predictivo con IA agentic en el comercio minorista. Un siguiente paso importante en esta evolución es el uso de IA agentic, que va más allá de la predicción estática para supervisar, adaptar y actuar activamente sobre los resultados de las previsiones en tiempo real. La IA agentic introduce agentes autónomos que evalúan constantemente la precisión de las previsiones, los cambios del mercado y las interrupciones de la cadena de suministro, y ajustan los precios, los pedidos de reposición y las estrategias promocionales sin necesidad de intervención humana. El reto que esto aborda es el desfase entre la comprensión y la ejecución en...

sistemas tradicionales, donde se generan pronósticos pero a menudo se actúa manualmente, lo que crea retrasos que reducen su efectividad.

Al automatizar el ciclo de respuesta, la IA de Agentic reduce drásticamente esa brecha. Para el cliente final, esto se traduce en una mejor experiencia de compra, mayor disponibilidad de productos, precios más dinámicos y adaptables a la demanda real, y promociones más oportunas y específicas. Para los minoristas, se traduce en menos ventas perdidas, menos desperdicio y una cadena de suministro verdaderamente adaptable a las dinámicas del mundo real.

Agentic AI transforma la previsión de la demanda de una herramienta de apoyo a la toma de decisiones en un motor operativo inteligente.

La IA agente, a diferencia de los sistemas tradicionales de análisis predictivo que suelen operar con modelos estáticos y reglas predefinidas, destaca por adaptarse dinámicamente y aprender de las interacciones en curso y de una gama más amplia de señales en tiempo real. Esto permite realizar predicciones mucho más matizadas y precisas.

Consideremos un escenario de venta minorista: un cliente explora una nueva línea de ropa en línea. Un sistema tradicional podría recomendar artículos similares basándose en compras anteriores o popularidad general. Sin embargo, un sistema de IA agéntica no solo consideraría datos históricos, sino que también observaría activamente el comportamiento actual del cliente en el sitio web: cuánto tiempo permanece en ciertas imágenes de productos, los artículos que añade al carrito y luego retira, sus movimientos del ratón e incluso su velocidad de desplazamiento. Si el cliente ve repetidamente artículos de un color o tipo de tela en particular, la IA agéntica podría ajustar instantáneamente sus recomendaciones, priorizando las novedades o los accesorios que se ajusten perfectamente a esa preferencia. Incluso podría detectar dudas y ofrecer un descuento específico en un artículo específico que esté considerando.

En tiempo real. Este enfoque dinámico y receptivo va mucho más allá de lo que un modelo estático puede lograr.

Los sistemas de IA agentic en el comercio minorista pueden escuchar una amplia gama de señales, incluidas las siguientes:

- Señales de comportamiento: datos de flujo de clics, tiempo invertido en las páginas, profundidad de desplazamiento, consultas de búsqueda, artículos agregados o eliminados del carrito, visualizaciones de productos e interacciones con promociones.
- Señales contextuales: hora del día, día de la semana, ubicación (si está permitido), tipo de dispositivo e interacciones previas con la marca.
- Señales externas: patrones climáticos, eventos locales, tendencias de redes sociales, titulares de noticias y promociones de la competencia (donde los datos son accesibles y éticos)
- Señales implícitas: vacilación al navegar, visualización repetida de atributos específicos del producto y cambios en los patrones de navegación.

Al analizar continuamente estas señales multifacéticas, la IA agente puede desarrollar una comprensión más integral y en tiempo real de la intención del cliente, lo que conduce a análisis predictivos más efectivos y experiencias personalizadas.

Digitalización de las interacciones en la tienda con inteligencia

A medida que la transformación digital se acelera en el comercio minorista, un área con gran potencial es la experiencia en tienda física. Si bien los canales en línea han captado desde hace tiempo las señales de los clientes para una interacción personalizada, el comercio físico sigue fragmentado, y el comportamiento del cliente a menudo...

No registrados o aislados. Esto crea una brecha crítica en la experiencia omnicanal del cliente, especialmente cuando los consumidores esperan cada vez más las mismas experiencias personalizadas y en tiempo real en la tienda física que en línea.

GenAI está transformando la forma en que los minoristas interpretan la intención del cliente en entornos digitales, transformando la búsqueda y la segmentación básicas en recomendaciones conversacionales y personalización en tiempo real. Estas mismas tecnologías, combinadas con interacciones digitalizadas en tienda, como los recibos digitales, pueden llevar esta inteligencia al comercio minorista físico.

Al convertir eventos tradicionalmente analógicos, como las transacciones en el punto de venta, en datos estructurados y analizables, los minoristas pueden obtener una comprensión integral del cliente, personalizar recomendaciones e impulsar la lealtad a través de una interacción significativa basada en datos.

Como ejemplo del potencial que tiene esta transformación, un estudio realizado por Bain & Company encontró que “las empresas de productos de consumo líderes superan a los rezagados en intención digital y asignación de recursos y tienen inversiones tecnológicas superiores que representan un presupuesto tecnológico de crecimiento alrededor de 2 veces más rápido en los últimos cinco años, lo que representa alrededor de un 30% más de presupuesto para el cambio y la transformación digital (como porcentaje de los ingresos)” [2].

Del papel a la información: Los recibos digitales como catalizador de datos. El recibo tradicional, antes un artefacto estático y desechable, se está convirtiendo en uno de los activos más valiosos del comercio minorista moderno. Al digitalizarse, los recibos proporcionan un registro estructurado y de alta fidelidad de las transacciones en tienda, capturando detalles como los artículos comprados, los precios, etc.

Descuentos aplicados, método de pago, ubicación e identificadores de clientes. A diferencia de los sistemas tradicionales de fidelización por lotes, que requieren mucho tiempo para recopilar información de las transacciones, los recibos digitales ofrecen información inmediata y granular sobre las preferencias e intenciones de los clientes.

Por ejemplo, cuando un cliente compra zapatillas deportivas y una mochila de hidratación en una tienda, un recibo digital alimenta instantáneamente esta información a una plataforma unificada de datos de clientes. GenAI puede usar esta información para recomendar artículos complementarios, como calcetines deportivos o una suscripción a una app para correr, por correo electrónico, una app o incluso señalización digital en su próxima visita.



Figura 10.5: Recorrido del cliente con recibo digital: desde la compra hasta las recomendaciones personalizadas.

Este diagrama de flujo de trabajo muestra cómo los recibos digitales transforman la experiencia del cliente a través de cinco pasos clave:

1. El cliente realiza una compra en la tienda.
2. Reciben un recibo digital vía correo electrónico o SMS.
3. Verifican la compra a través de una aplicación móvil.
4. El cliente accede a su historial de compras y recibe recomendaciones de productos personalizadas generadas por IA.
5. Pueden recomprar artículos directamente a través de la aplicación.

El proceso demuestra cómo los recibos digitales sirven como catalizador de datos para crear experiencias minoristas omnicanal fluidas.

Las bases de datos documentales flexibles, como MongoDB, son ideales para almacenar este tipo de registros de datos dinámicos y multiformato. Gracias a la flexibilidad de esquemas y la compatibilidad nativa con documentos complejos y anidados, los minoristas pueden desarrollar estructuras de recibos con el tiempo, incorporar nuevos campos de metadatos y consultar información al instante, sin tiempos de inactividad ni refactorizar tablas antiguas.

Cómo un supermercado digitalizó los recibos de compra para impulsar la personalización y reducir costes

Un ejemplo de una empresa que está evolucionando hacia la digitalización de sus tiendas es una importante cadena de supermercados europea. El minorista utilizó MongoDB Atlas para digitalizar los recibos de compra en su aplicación móvil, ofreciendo a los clientes visibilidad de sus compras en tiempo real e históricas. Estos datos ahora impulsan recomendaciones y promociones personalizadas. El enfoque de datos unificados mejoró la experiencia del cliente, impulsó la eficiencia de los desarrolladores y aceleró la innovación. Como resultado, este minorista logró un ahorro anual de costos del 25%. Esto sienta las bases.



para una interacción más avanzada impulsada por IA, como gestión predictiva de inventario, campañas de marketing personalizadas basadas en el comportamiento en tiempo real y chatbots inteligentes de servicio al cliente.

Este ejemplo ha sido anonimizado para mayor claridad editorial. Para obtener más

información, consulte: <https://mdb.link/innovation-largest-netherlands-supermarket>.



Creación de un perfil omnicanal del cliente en tiempo real. Los recibos digitales no solo digitalizan las compras; conectan el comportamiento offline con la identidad online. Al vincular cada transacción en tienda física con un ID de cliente unificado, los minoristas pueden crear un perfil completo del comportamiento en todos los puntos de contacto: qué visitó un cliente online, qué probó en tienda física, qué devolvió, qué descuentos influyeron en sus decisiones, etc.

Los minoristas que utilizan MongoDB pueden fusionar datos en tiempo real de los sistemas de la tienda, aplicaciones móviles, portales web, programas de fidelización y canales de atención al cliente en una única capa de datos operativos. Esto permite una lógica de personalización inmediata: si un cliente compró recientemente ropa para el frío en la tienda, se le pueden presentar recomendaciones.

para accesorios o promociones basadas en el clima local la próxima vez que abran la aplicación o reciban un correo electrónico de seguimiento.

Este enfoque cambia la personalización de campañas reactivas y específicas del canal a una estrategia de interacción proactiva y en tiempo real, que responde al contexto y las preferencias cambiantes del cliente, independientemente de dónde se originó la interacción.

Personalización en el punto de venta

Las interacciones digitalizadas en tienda también abren la puerta a la personalización en tiempo real. Por ejemplo, un cliente que regresa entra en la tienda y el vendedor, mediante un punto de venta móvil o una aplicación de análisis de clientes, puede ver sus compras recientes, su nivel de fidelidad y sugerencias de productos relevantes según su última visita. Si el cliente compró granos de café expreso y un molinillo, por ejemplo, el vendedor podría recomendar un kit de limpieza o una mezcla premium de la misma marca.

Estas recomendaciones se basan cada vez más en sistemas GenAI entrenados con datos del recorrido del cliente. El factor clave es la infraestructura: la capacidad de MongoDB para soportar cargas de trabajo operativas y analíticas en paralelo permite que los modelos de IA accedan a los datos transaccionales más actualizados sin demoras ni duplicaciones. Ya sea creando incrustaciones vectoriales personalizadas para recomendaciones de productos o generando recibos inteligentes con ofertas seleccionadas, MongoDB proporciona la agilidad y el rendimiento de datos necesarios para ofrecer un comercio minorista personalizado a gran escala.

Inteligencia artificial agente: del conocimiento a la acción inteligente

Si bien GenAI permite una personalización adaptativa y contextual, el siguiente paso es la IA agencial, sistemas que no solo interpretan el comportamiento del cliente, sino que actúan en consecuencia de forma autónoma. En lugar de esperar la información, los sistemas agenciales observan patrones, anticipan las necesidades del cliente y orquestan experiencias en todos los canales para alcanzar objetivos de negocio como la retención, las ventas adicionales o la conversión.

En el contexto de las interacciones digitalizadas en tienda, la IA de agencia podría identificar automáticamente que un cliente compra regularmente productos de cuidado para bebés e iniciar una oferta de suscripción inteligente. Podría detectar una disminución en las visitas a la tienda de un cliente previamente fiel e implementar una campaña de reactivación personalizada. Estas acciones requieren más que reglas estáticas; requieren la orquestación en tiempo real de flujos de trabajo, datos y razonamiento basado en IA.

Al consolidar datos en una plataforma como MongoDB, que admite activadores inteligentes, arquitecturas basadas en eventos y análisis en tiempo real, los minoristas pueden sentar las bases para sistemas de IA agentes que evolucionan con el cliente, tanto en canales físicos como digitales.

Chatbots conversacionales y agentes

En el entorno minorista conectado digitalmente de la actualidad, los clientes esperan interacciones inmediatas, personalizadas y fluidas con las marcas.

Los chatbots conversacionales, especialmente aquellos impulsados por IA generativa y agente, están cumpliendo estas expectativas y transformando la forma en que los minoristas brindan atención al cliente, impulsan el descubrimiento de productos y fomentan la fidelidad a la marca. Esta sección profundiza en el auge de la IA conversacional en

Comercio minorista: se examina cómo se utilizan los chatbots no solo para mejorar la atención al cliente, sino también para optimizar la eficacia del marketing, impulsar la eficiencia operativa y obtener información más detallada mediante el procesamiento inteligente de datos. Esta sección también presenta arquitecturas y tecnologías avanzadas, como RAG y la búsqueda vectorial, para mostrar cómo los chatbots se vuelven más inteligentes, rápidos y relevantes con cada interacción.

Con el creciente uso de la IA conversacional, es fundamental comprender las necesidades cambiantes de los clientes minoristas actuales. Los compradores exigen no solo respuestas rápidas, sino también experiencias profundamente personalizadas que reflejen sus preferencias, historial y contexto. Los chatbots agénticos, con su capacidad de memorizar, analizar consultas complejas y tomar medidas proactivas, permiten a las empresas ofrecer estas experiencias de cliente excepcionales. Por ejemplo, un chatbot con RAG integrado puede recuperar al instante las compras anteriores de un cliente y recomendar artículos complementarios según el inventario en tiempo real. De igual forma, un bot de soporte agéntico puede detectar señales de frustración en una conversación y escalar la respuesta de forma autónoma a un agente humano u ofrecer un descuento personalizado, convirtiendo la posible pérdida de clientes en fidelización.

Al seleccionar contenido de forma inteligente y ajustar dinámicamente sus respuestas, estos chatbots avanzados ayudan a los minoristas a pasar del servicio transaccional a una interacción empática y centrada en el valor. Pueden recordar las interacciones y actuar con lógica, lo que facilita este proceso. Estos chatbots avanzados, al seleccionar información de forma inteligente y adaptarse en tiempo real, ayudan a los minoristas a construir relaciones empáticas y valiosas con los clientes en lugar de simplemente procesar transacciones.

A medida que exploramos estas innovaciones, veremos cómo los agentes conversacionales están evolucionando desde respondedores con guiones a respondedores dinámicos,

Entidades autónomas que se adaptan en tiempo real. Esta sección aborda el potencial transformador de la IA agencial, un enfoque emergente que permite a los chatbots optimizar su comportamiento basándose en la retroalimentación en vivo de los clientes sin intervención humana. Este cambio aborda...

Las limitaciones de los sistemas reactivos y sienta las bases para una nueva era de interacción digital proactiva y contextualizada. A través de ejemplos de arquitectura, casos de uso e historias de impacto empresarial, comprenderá a fondo cómo la IA conversacional se está convirtiendo en un factor diferenciador estratégico en el comercio minorista.

Cómo los chatbots GenAI están revolucionando la

interacción en el comercio minorista Los chatbots conversacionales impulsados por GenAI están revolucionando la industria minorista al mejorar el servicio al cliente. Estos chatbots pueden manejar una amplia gama de consultas de clientes, desde recomendaciones de productos hasta seguimiento de pedidos, brindando respuestas instantáneas y precisas. Esto reduce los tiempos de espera y mejora la experiencia general del cliente, lo que genera una mayor satisfacción y lealtad.

Además, los chatbots pueden operar con datos en tiempo real las 24 horas del día, los 7 días de la semana, lo que garantiza que los clientes reciban soporte en cualquier momento, lo cual es especialmente beneficioso para los minoristas globales. Estudios recientes en Estados Unidos revelan que los chatbots impulsados por IA pueden aumentar las ventas en línea en casi un 4% año tras año [3], lo que refuerza la noción de que la IA no es solo una tendencia, sino un impulsor duradero del crecimiento en el comercio minorista.

Más allá de la atención al cliente, los chatbots de IA también están transformando las estrategias de marketing y ventas en el comercio minorista. Pueden analizar los datos de los clientes para personalizar las experiencias de compra, ofreciendo...

Recomendaciones y promociones basadas en preferencias y comportamientos individuales. Esta personalización ayuda a los minoristas a impulsar las tasas de conversión y aumentar las ventas. Además, los chatbots pueden interactuar con los clientes a través de diversos canales digitales, como redes sociales, sitios web y aplicaciones de mensajería, ampliando el alcance y la eficacia de las campañas de marketing.

La eficiencia operativa es otro ámbito donde los chatbots de IA están teniendo un impacto significativo. Al automatizar tareas rutinarias como responder preguntas frecuentes, gestionar consultas de inventario y procesar devoluciones, los chatbots permiten a los empleados concentrarse en actividades más complejas y de mayor valor añadido. Esto no solo reduce los costes operativos, sino que también mejora la precisión y la consistencia en la prestación del servicio. Además, los datos recopilados por los chatbots pueden proporcionar información valiosa sobre las preferencias y el comportamiento de los clientes, lo que ayuda a los minoristas a perfeccionar sus estrategias y mejorar sus ofertas.

Entre los usuarios expertos y no expertos en lo digital, entre el 50 % y el 60 % han mostrado una alta preferencia por migrar a recorridos conversacionales para casos de uso cotidianos en todos los sectores verticales [4].

Impulsando conversaciones inteligentes con búsqueda e IA

A continuación, se muestra un ejemplo de la arquitectura RAG de un chatbot. Este chatbot se creó utilizando la arquitectura RAG. RAG amplía el conocimiento de los LLM al recuperar información relevante para las consultas de los usuarios y usarla en la respuesta generada por el LLM. La documentación pública de MongoDB se utiliza como fuente de información para el chatbot.

respuestas generadas.

Para recuperar información relevante según las consultas de los usuarios, se utiliza MongoDB Atlas Vector Search. En este ejemplo, se utiliza OpenAI en conjunto con Vector Search para generar respuestas a las preguntas de los clientes. Utilizando datos de fuentes privadas y mejorados por los LLM, los datos se amplían, se contextualizan y se devuelven al usuario. La API de incrustaciones de Azure OpenAI se utiliza para convertir la documentación de MongoDB y las consultas de los usuarios en incrustaciones vectoriales, lo que ayuda a encontrar el contenido más relevante para las consultas mediante Atlas Vector Search.




Figura 10.6: Ejemplo de flujo de datos para una arquitectura RAG de chatbot

La IA está revolucionando la forma en que los minoristas mejoran su ventaja competitiva al proporcionar información más profunda sobre el comportamiento del cliente y optimizar

Márgenes de beneficio mediante procesos de toma de decisiones inteligentes. Al incorporar IA tradicional y GenAI, los minoristas pueden aprovechar las ventajas de la búsqueda semántica mejorada basada en la búsqueda vectorial, crear contenido de marketing específico basado en las tendencias actuales del mercado, utilizar eficazmente el análisis predictivo para la previsión de la demanda, emplear chatbots conversacionales y mejorar significativamente la experiencia general del cliente.

De guionados a inteligentes: Transformando los chatbots minoristas con IA de Agentic. La IA de Agentic lleva las capacidades de los chatbots un paso más allá al introducir agentes autónomos que pueden aprender continuamente de las interacciones con los clientes y optimizar su comportamiento en tiempo real. A diferencia de los chatbots tradicionales que siguen rutas predefinidas o se basan únicamente en modelos preentrenados, la IA de Agentic puede monitorear de forma independiente las señales de interacción, ajustar el tono y los mensajes, escalar problemas cuando sea necesario e incluso decidir el mejor momento y canal para interactuar con un cliente, todo ello sin necesidad de intervención humana. El principal desafío que esto aborda es la naturaleza reactiva de los flujos de trabajo de los chatbots convencionales, donde las mejoras a menudo dependen del análisis posterior y la reprogramación manual. Los sistemas de Agentic eliminan ese retraso, permitiendo que los chatbots evolucionen con cada interacción.

Para los clientes finales, esto se traduce en un servicio verdaderamente intuitivo y adaptable. En lugar de recibir respuestas predefinidas, los usuarios interactúan con bots que comprenden el contexto, personalizan la conversación dinámicamente y actúan con inteligencia proactiva, ofreciendo ofertas, respuestas o soporte justo cuando más se necesita.

Los minoristas se benefician de este ciclo de optimización continua mediante una mayor interacción, mayores tasas de conversión y una mayor confianza en la marca, a la vez que reducen los gastos operativos. A medida que la IA agente madura, las experiencias conversacionales en el comercio minorista serán cada vez más humanas, lo que hará que las experiencias digitales del cliente sean más relevantes, receptivas y efectivas que nunca.

El papel cada vez más importante de la IA en el comercio minorista

El poder de la IA en el comercio minorista va mucho más allá de la búsqueda, la personalización y la previsión. Ahora está transformando la esencia de las operaciones de las tiendas, desde la seguridad y la gestión del personal hasta la sostenibilidad.

El papel en expansión de la IA en el comercio minorista se ejemplifica con las tecnologías de agencia emergentes que van más allá de la generación de conocimiento hacia la acción autónoma y la optimización continua.

Un estudio de McKinsey afirma: «Durante los próximos tres años, el 92 % de las empresas planean aumentar sus inversiones en IA. Sin embargo, si bien casi todas las empresas están invirtiendo en IA, solo el 1 % de los líderes considera que sus empresas están «maduras» en cuanto a su implementación» [5].

La prevención proactiva de pérdidas, la comercialización basada en IA, la autorreparación de las operaciones de tienda, la orquestación dinámica de la fuerza laboral y la optimización de la sostenibilidad en tiempo real ilustran cómo la IA está evolucionando, pasando de ser una herramienta de apoyo a un socio activo en la gestión minorista. Al pasar de un enfoque reactivo a uno proactivo y de la automatización aislada a una inteligencia integrada y contextualizada, los minoristas están logrando nuevas eficiencias, reduciendo el riesgo y mejorando las experiencias de los empleados y los clientes. Esta sección final profundiza en estas aplicaciones de vanguardia, mostrando cómo el papel de la IA continúa creciendo.

empoderar a los minoristas para que lideren con confianza en un mercado en constante cambio.

Prevención proactiva de pérdidas

La IA está transformando la seguridad en el comercio minorista, pasando de la supervisión reactiva dirigida por personas a la intervención proactiva. Los sistemas modernos de visión artificial, combinados con IA agente, analizan las transmisiones de vídeo en tiempo real para detectar patrones de comportamiento sospechosos, como la ocultación de productos, el intercambio de artículos o la reincidencia. Estos modelos no solo detectan anomalías, sino que también inician flujos de trabajo como la notificación al personal o el ajuste de los protocolos de salida. Los minoristas están observando un impacto medible en la reducción de mermas y la mejora de la protección de los activos sin aumentar la supervisión humana.

Ejecución de comercialización impulsada por IA

La IA de Agentic optimiza el cumplimiento de los planogramas y la ejecución de las promociones mediante la comparación continua de los datos de los estantes con la distribución prevista. Aprovechando las imágenes de las cámaras de la tienda o de los dispositivos móviles de los empleados, estos sistemas identifican automáticamente extravíos, situaciones de falta de stock o señalización incorrecta. En lugar de mostrar únicamente alertas, la IA sugiere acciones específicas, como reordenar, reabastecer o señalar problemas con los proveedores, lo que permite tomar medidas correctivas más rápidas y ofrecer una experiencia de compra más consistente en todas las ubicaciones.

Operaciones de tienda con autorreparación

Con una infraestructura inteligente de borde impulsada por IA, las tiendas están adquiriendo la capacidad de autorrepararse. Desde quioscos bloqueados hasta sistemas POS defectuosos, la IA agente supervisa la telemetría del rendimiento e inicia diagnósticos y soluciones en tiempo real. En muchos casos, puede resolver problemas automáticamente, reiniciando servicios, ajustando configuraciones o aislando fallos, sin esperar la intervención del departamento de TI. Esta capa de operaciones autónomas mejora el tiempo de actividad y garantiza una experiencia del cliente más fluida en la tienda.

Orquestación dinámica de la fuerza laboral

La programación laboral en el sector minorista ha tenido dificultades durante mucho tiempo para equilibrar la dotación de personal con los aumentos repentinos de la demanda y las preferencias de los empleados. La IA de Agentic ahora permite una orquestación adaptativa de la fuerza laboral al aprender continuamente del tráfico en tienda, los patrones climáticos, los eventos locales y las tendencias individuales de productividad. Estos sistemas no solo pronostican las necesidades de mano de obra, sino que también proponen e incluso implementan planes de turnos óptimos, notifican a los empleados y realizan concesiones alineadas con los objetivos comerciales. Esto se traduce en una mejor cobertura, una mayor satisfacción de los empleados y operaciones más ágiles.

Optimización de la sostenibilidad en tiempo real

Los minoristas se ven presionados para reducir las emisiones de carbono y los residuos sin sacrificar el rendimiento. La IA de Agentic respalda estos esfuerzos mediante el seguimiento del consumo de energía, la eficiencia de la refrigeración y el desperdicio de envases en tiempo real. Esta tecnología puede ajustar de forma autónoma sistemas como la iluminación, la climatización o la configuración de la cadena de frío, e identifica inefficiencias antes de que resulten costosas. Algunos sistemas incluso pueden...

Optimizar las rutas de entrega para cumplir con los objetivos de sostenibilidad. Estas optimizaciones continuas e incrementales generan importantes beneficios ambientales y económicos.

Para obtener más información y recursos, visite la página de MongoDB para Retail en <https://>

www.mongodb.com/solutions/industries/retail

Resumen

Este capítulo ha explorado la transformación integral del comercio minorista a través de la IA, demostrando cómo los minoristas modernos están aprovechando la IA para crear experiencias de cliente más inteligentes, rápidas y personalizadas, a la vez que impulsan la excelencia operativa. Desde la búsqueda aumentada por IA, que va más allá de la coincidencia de palabras clave, hasta el descubrimiento de productos conversacional basado en la intención, hasta el marketing personalizado que genera contenido dinámico a escala utilizando GenAI y RAG, hemos visto cómo los minoristas están reinventando fundamentalmente la interacción con el cliente. La integración de la previsión de la demanda con el análisis predictivo permite la gestión proactiva del inventario y la optimización de la cadena de suministro, mientras que la digitalización de las interacciones en tienda mediante tecnologías como los recibos digitales cierra la brecha crítica entre las experiencias en línea y fuera de línea. Los chatbots conversacionales avanzados impulsados por IA agente están revolucionando la atención al cliente al proporcionar asistencia autónoma y sensible al contexto que aprende continuamente y se adapta a las necesidades del cliente.

El surgimiento de la IA agente representa la próxima frontera en la transformación del comercio minorista, yendo más allá de los sistemas reactivos hacia sistemas proactivos y con objetivos.

Inteligencia artificial que opera de forma autónoma en múltiples dominios. Hemos presenciado cómo empresas del sector minorista logran resultados comerciales medibles mediante implementaciones inteligentes basadas en datos. El rol creciente de la IA ahora abarca la prevención proactiva de pérdidas, la ejecución de la comercialización impulsada por IA, la autorreparación de las operaciones de tienda, la orquestación dinámica de la fuerza laboral y la optimización de la sostenibilidad en tiempo real. Estos avances demuestran que la IA en el comercio minorista ha evolucionado de una herramienta de apoyo a un socio activo en la gestión empresarial, impulsando la eficiencia, reduciendo costos y mejorando la experiencia del cliente, a la vez que permite a los minoristas liderar con confianza en un mercado cada vez más competitivo.

En el próximo capítulo, dedicado a los servicios financieros, exploraremos cómo las instituciones financieras están evolucionando más allá del análisis predictivo para implementar sistemas de IA autónomos y con agentes capaces de percibir, razonar y actuar de forma independiente dentro de parámetros definidos. Esta transformación abarca desde la GenAI, que revoluciona el cumplimiento normativo y el análisis documental, hasta la creación de gestores de relaciones digitales y responsables de cumplimiento virtuales que monitorizan proactivamente los mercados e interactúan con los clientes en tiempo real, cumpliendo a la vez con los rigurosos requisitos de seguridad y explicabilidad del sector.

Referencias

1. 5 tendencias de búsqueda en comercio electrónico que debes conocer en 2025:

<https://searchanise.io/blog/tendencias-de-busqueda-en-sitios/>

2. Capturando el futuro de lo digital en los productos de consumo:

<https://www.bain.com/insights/capturando-el-futuro-de-lo-digital-en-los-productos-de-consumo/>

3. Las compras impulsadas por IA impulsan las ventas navideñas online, según datos de Salesforce

Muestra: <https://www.reuters.com/business/retail-consumer/ai-influenced-shopping-boosts-online-holiday-sales-salesforce-data-shows-2025-01-06/>

4. Ganar con conversaciones:

<https://www.bain.com/insights/ganar-con-conversaciones/>

5. Superagencia en el lugar de trabajo: empoderar a las personas para liberar todo el potencial de la IA
potencial :

<https://www.mckinsey.com/capabilities/mckinsey-digital/our-insights/superagency-in-the-workplace-empowering-people-to-unlock-ais-full-potential-at-work>

11

Servicios financieros y la próxima ola de IA

En el cambiante panorama financiero actual, la IA se ha convertido en la piedra angular de la transformación de la banca moderna. A medida que las instituciones financieras de todo el mundo se apresuran a adoptar las tecnologías de IA, se perfila un nuevo paradigma: los sistemas inteligentes evolucionan desde la simple predicción hasta la acción autónoma, revolucionando todo, desde la experiencia del cliente hasta la gestión de riesgos en toda la cadena de valor de los servicios financieros.

Este capítulo explora cómo la IA está transformando los servicios financieros y creando oportunidades sin precedentes de eficiencia, personalización e innovación.

Al final de este capítulo comprenderás lo siguiente:

- Cómo la IA generativa (GenAI) está transformando los casos de uso clave en la banca
- Las formas en que la IA está mejorando las experiencias de los clientes a través de interacciones conversacionales inteligentes
- Enfoques avanzados para la prevención de delitos financieros y el cumplimiento normativo mediante IA
- Ejemplos del mundo real de almacenes de datos operativos que también pueden servir como almacenes de funciones de IA, impulsando tanto la predicción como la generación
- Cómo las integraciones específicas de dominio están revolucionando la búsqueda, el cumplimiento y el análisis contextual en las finanzas
- Principios de diseño y arquitecturas de referencia para construir e implementar una IA agente, equilibrando la innovación, la seguridad y la confianza regulatoria.

La evolución de la IA en las finanzas

El viaje de la IA en las finanzas comenzó con el análisis predictivo: aprovechando datos históricos y datos en tiempo real para evaluar el riesgo crediticio, detectar fraudes, pronosticar cambios en el mercado y predecir abandono de clientes. Estos casos de uso siguen siendo fundamentales y ofrecen beneficios comerciales cruciales. Valor e impulsar la eficiencia operativa. Las instituciones financieras necesitan almacenes de características robustos y en tiempo real que permitan un acceso escalable a los datos enriquecidos y gobernados que Los modelos predictivos requieren optimizar las decisiones y los resultados.

La llegada de GenAI amplió el campo. Con grandes modelos lingüísticos (LLM) y la generación aumentada por recuperación (RAG), las instituciones financieras ahora están Automatizar y mejorar tareas que antes se consideraban demasiado complejas: generar políticas documentos, responder a consultas regulatorias, resumir grandes casos de cumplimiento presentaciones y potenciar la banca conversacional tanto para clientes como para empleados. GenAI eleva la inteligencia de “lo que podría suceder”, la sintetiza y la a “déjame generar, explica, liberando aún más valor tanto de la inteligencia estructurada como de la inteligencia artificial. datos no estructurados.

Hoy, nos encontramos en el umbral del próximo gran avance: la IA agencial. A diferencia de Enfoques predictivos y generativos que apoyan la toma de decisiones o el contenido La creación de IA agencial proporciona agentes autónomos y orientados a objetivos que pueden percibir, razonar y actuar dentro de parámetros definidos. Piense en la IA agencial como la inteligencia artificial digital. gerente de relaciones o oficial de cumplimiento virtual que monitorea proactivamente los mercados, Adaptarse a los cambios regulatorios, gestionar los flujos de trabajo e interactuar con los clientes en tiempo real, todo ello mientras aprendemos y mejoramos continuamente.

Esta evolución de la IA predictiva a la GenAI y a la IA agente exige una plataforma de datos que sea a la vez flexible y potente:

- Para IA predictiva , Las instituciones financieras necesitan almacenes de características robustos y en tiempo real, donde se almacenan, versionan y acceden las funciones de aprendizaje automático sin problemas
- Para GenAI , requieren la integración de datos estructurados y no estructurados datos, que abarcan registros de transacciones, documentos, correos electrónicos, imágenes y voz grabaciones, contenido de video y bases de conocimiento específicas del dominio para acelerar modelos de lenguaje, búsqueda vectorial y recuperación de contexto
- Para que los , Un sustrato unificado y agilidad operativa son esenciales para agentes de IA perciban el mundo, recuerden el contexto y tomen decisiones informadas,

y actuar con confianza

En los servicios financieros, estas olas de IA no son aisladas; se complementan entre sí.

Los líderes siguen confiando en modelos predictivos sólidos, amplificados por la automatización generativa y orquestados por sistemas agentes que se adaptan y gobiernan en tiempo real.

Las bases de datos modernas e inteligentes como MongoDB, con su arquitectura flexible y profundas capacidades de integración, como la integración de MongoDB con Voyage AI, ofrecen modelos de integración y rerankers de primera clase y están en una posición única para respaldar este panorama híbrido.

El poder de las integraciones específicas de finanzas

En los servicios financieros, la precisión, el contexto y la explicabilidad son esenciales. Ya sea analizando la información regulatoria, automatizando los flujos de trabajo de cumplimiento o interactuando con los clientes mediante asistentes inteligentes, los sistemas de IA deben interpretar lenguaje complejo y conceptos específicos de su dominio con un alto grado de precisión. Los LLM de propósito general, con una amplia formación en contenido de internet, a menudo tienen dificultades con la terminología especializada, las abreviaturas y los formatos estructurados que definen el mundo financiero.

Las incrustaciones específicas de cada dominio, en particular las optimizadas para el sector financiero, son una solución fundamental para este desafío. Estas incrustaciones están diseñadas para capturar la semántica, los patrones y el contexto regulatorio propios del sector, lo que permite a los modelos de IA:

- Interpretar con precisión documentos financieros, Desde llamadas y presentaciones de ganancias hasta contratos e informes de riesgos
- Descubra información relevante mediante RAG o búsqueda semántica, lo que mejora la precisión y reduce las alucinaciones.
- Apoyar la explicabilidad, haciendo que los resultados sean más auditables y cumplan con las expectativas regulatorias
- Proporcionar inteligencia justo a tiempo, aprovechando el conocimiento del dominio al instante para guiar la toma de decisiones

Los avances recientes en este ámbito, como las integraciones de voyage-finance-2 de Voyage AI , demuestran cómo los modelos optimizados para cada dominio superan a las alternativas de propósito general en tareas específicas de finanzas. Los resultados de las pruebas comparativas han demostrado...

Se mejoró significativamente la relevancia en la recuperación de información y la respuesta a preguntas sobre textos financieros.

Estas integraciones específicas para finanzas permiten a los desarrolladores crear aplicaciones de IA que no solo sean más conscientes del contexto, sino que también estén más alineadas con los rigurosos estándares de la industria financiera.

A medida que las instituciones financieras adoptan GenAI y la IA agente, la incorporación del conocimiento del dominio directamente en las representaciones de modelos será fundamental para construir sistemas que sean inteligentes, confiables y operativamente resilientes.

Obtenga más información sobre las integraciones financieras de Voyages AI en esta publicación de blog: <https://blog.voyageai.com/2024/06/03/domain-specific-embeddings-finance-edition-voyage-finance-2/>.

La transformación de las solicitudes de crédito con IA La misma progresión de la IA predictiva a la GenAI y a la IA agente está transformando profundamente el modo en que se evalúan, procesan y califican las solicitudes de crédito.

Tradicionalmente, la calificación crediticia se basaba en reglas rígidas y datos históricos limitados, excluyendo a menudo a personas con historiales crediticios limitados o nulos. La IA predictiva comenzó a abordar estas limitaciones mediante el aprendizaje automático para predecir los impagos de préstamos basándose en patrones históricos de comportamiento crediticio.

A medida que la industria avanzaba hacia la calificación crediticia alternativa, los modelos de IA comenzaron a incorporar fuentes de datos no tradicionales, como el historial de alquiler, el pago de servicios públicos y la huella digital, ofreciendo una visión más amplia e inclusiva de la solvencia.

Este cambio permitió a las entidades crediticias evaluar el riesgo con mayor precisión y atender a segmentos que antes se pasaban por alto.

Hoy, GenAI y la IA agente están impulsando el siguiente paso adelante, creando un ecosistema crediticio más adaptativo, inteligente e inclusivo:

- GenAI mejora la comprensión y síntesis de datos, lo que permite extraer y estructurar información de fuentes no estructuradas como los bancos.

Extractos, comprobantes de ingresos o correspondencia por correo electrónico. También puede generar explicaciones legibles para decisiones complejas y crear datos sintéticos.

que llena vacíos en conjuntos de datos limitados, ofreciendo una visión más holística del comportamiento financiero.

- Agentic AI aporta capacidades autónomas y orientadas a objetivos que permiten a los sistemas gestionar flujos de trabajo de crédito completos, automatizar la recopilación de documentos, verificar la identidad, adaptar la lógica de puntuación en respuesta a cambios regulatorios e incluso guiar a los solicitantes a través del proceso de forma interactiva e inteligente.

Esta progresión ofrece beneficios en varias dimensiones:

- Adaptabilidad: Los modelos de IA aprenden y evolucionan continuamente en respuesta a las condiciones económicas cambiantes y al comportamiento del consumidor. Esto garantiza que los sistemas de calificación crediticia se mantengan precisos, ágiles y relevantes en entornos financieros dinámicos.
- Detección de fraude: la IA detecta anomalías y actividades sospechosas en tiempo real mediante el análisis de patrones en aplicaciones e historiales de transacciones.
- Análisis predictivo: las técnicas de aprendizaje automático descubren correlaciones e indicadores de riesgo crediticio a partir de conjuntos de datos vastos y complejos, que van más allá de lo que los sistemas basados en reglas pueden detectar.
- Puntuación conductual: para las personas que carecen de historial crediticio, la IA puede generar evaluaciones de riesgo dinámicas basadas en el comportamiento financiero y los hábitos de gasto en tiempo real.
- Transparencia en las declinaciones: la IA puede ayudar a explicar por qué se rechazó una solicitud de crédito, yendo más allá de las decisiones binarias para ofrecer soluciones prácticas y humanas. retroalimentación legible

A pesar de los claros beneficios, la transparencia y la explicabilidad siguen siendo preocupaciones comunes, en particular entre las instituciones financieras sujetas al escrutinio regulatorio.

La complejidad de los modelos de aprendizaje profundo ha dificultado históricamente la explicación de decisiones a consumidores y reguladores. Afortunadamente, los avances en IA explicable (XAI), incluyendo técnicas como los valores de explicaciones aditivas de SHapley (SHAP) y los gráficos de explicaciones locales interpretables independientes del modelo (LIME), ahora brindan visibilidad sobre cómo los modelos llegan a sus conclusiones, lo que ayuda a desmitificar la caja negra y a restaurar la confianza en la IA. decisiones.

Además, GenAI puede complementar estas técnicas generando explicaciones en lenguaje natural para los resultados crediticios, reduciendo aún más la brecha entre la lógica de modelos complejos y la comprensión humana.

Desarrollar un sistema de crédito más inteligente con MongoDB. Para impulsar esta evolución se requiere

una plataforma de datos moderna y flexible. MongoDB, con su modelo de datos basado en documentos y su arquitectura intuitiva para desarrolladores, es ideal para impulsar flujos de trabajo de crédito basados en IA.

Las principales ventajas incluyen las siguientes:

- Captura y procesamiento de datos simplificados: Al utilizar JSON para los formularios de solicitud en línea, las instituciones pueden optimizar la ingesta de datos, reducir la redundancia y optimizar la velocidad de procesamiento. El modelo de documento es excelente para gestionar diversos tipos de datos, como datos personales, financieros y laborales, sin sacrificar la estructura.
- Puntuación crediticia mejorada con IA: con la plataforma de datos para desarrolladores de MongoDB, un conjunto unificado de servicios de datos creados alrededor de una base de datos nativa de la nube, las instituciones financieras pueden crear una vista de 360 grados de cada cliente combinando fuentes de datos estructuradas, semiestructuradas y no estructuradas.
- Declinaciones transparentes con LLM: los LLM integrados con MongoDB pueden interpretar los resultados de modelos de aprendizaje automático complejos como XGBoost. En lugar de emitir rechazos vagos o estereotipados, los LLM pueden generar explicaciones personalizadas y comprensibles que mejoran la experiencia del cliente y ayudan al cumplimiento.

Por ejemplo, el proceso de toma de decisiones crediticias ilustrado en la Figura 11.1 se utiliza para predecir la probabilidad de morosidad y la calificación crediticia. Este proceso consta de varias etapas clave: recopilación de datos, procesamiento, generación de perfiles de riesgo, desarrollo de modelos, transformación de datos y toma de decisiones.

El resultado de la calificación crediticia podría significar la aprobación o el rechazo de la solicitud de crédito. Comprender los motivos de un rechazo es especialmente vital tanto para el cumplimiento normativo como para la experiencia del cliente. Los LLM, integrados con

Plataformas como MongoDB pueden mejorar la explicabilidad. Por ejemplo, los LLM pueden interpretar los resultados de modelos complejos como XGBoost para generar explicaciones claras y legibles sobre el rechazo de una solicitud, yendo más allá de los simples mensajes predefinidos que solo transmiten el estado final.




Figura 11.1: Arquitectura del flujo de procesamiento de datos para predecir la probabilidad de morosidad y la calificación crediticia

Este diagrama ilustra el flujo de procesamiento de datos integral para la evaluación del riesgo crediticio, mostrando cómo los datos de los clientes fluyen a través de las etapas de recopilación, procesamiento, elaboración de perfiles de riesgo, desarrollo de modelos y toma de decisiones para generar predicciones precisas de morosidad. En la Figura 11.2, se puede ver la arquitectura que explica la calificación crediticia mediante un LLM.




Figura 11.2: Arquitectura de la declinación de solicitudes de crédito

Esta visualización demuestra cómo los LLM pueden integrarse en los sistemas de decisión crediticia para proporcionar explicaciones claras y comprensibles sobre el rechazo de solicitudes, mejorando así la transparencia y la experiencia del cliente. En caso de rechazo de una solicitud de crédito, la interacción no debería terminar en un rechazo.

En cambio, presenta una valiosa oportunidad para que las instituciones mantengan el compromiso ofreciendo productos de crédito alternativos y personalizados que se alineen mejor con el perfil financiero del solicitante.

Los motores de recomendación tradicionales suelen basarse en sistemas estáticos basados en reglas o modelos de filtrado colaborativo, que pueden carecer de la flexibilidad necesaria para responder a las necesidades específicas de los clientes o a la evolución de la oferta de productos. Estos sistemas suelen tener dificultades para contextualizar el motivo del rechazo de un solicitante y las alternativas viables existentes. GenAI cambia esta dinámica por completo.

Al aprovechar los datos de los clientes, los resultados de las calificaciones crediticias y la disponibilidad de productos en tiempo real, los modelos GenAI pueden funcionar como motores de recomendación inteligentes, sugiriendo proactivamente alternativas adecuadas según el perfil de riesgo, los ingresos, el comportamiento crediticio y las preferencias del solicitante. Por ejemplo, si se rechaza una solicitud de préstamo personal debido a un historial crediticio insuficiente, un modelo GenAI podría recomendar una tarjeta de crédito más básica con comisiones más bajas y sin características premium, un préstamo a plazos pequeños con condiciones flexibles o un producto de educación financiera para aumentar la solvencia.

Además de generar coincidencias de productos, los LLM pueden explicar por qué se ofrece una alternativa específica, mejorando la transparencia y generando confianza. Este nivel de personalización y claridad era difícil de lograr con los sistemas de recomendación convencionales.

La siguiente arquitectura demuestra cómo se puede integrar GenAI en un proceso de toma de decisiones crediticias, no solo para evaluar el riesgo, sino también para brindar recomendaciones de las mejores acciones siguientes que mantengan a los clientes comprometidos, informados y respaldados durante su recorrido financiero:




Figura 11.3: Arquitectura de las recomendaciones de productos crediticios alternativos

La Figura 11.3 ilustra la arquitectura integral de un sistema alternativo de recomendación de productos crediticios. Muestra cómo las interacciones del usuario a través de la interfaz web activan llamadas a la API, aprovechando MultiQueryRetriever de LangChain y MongoDB Vector Search para procesar documentos fragmentados sin procesar desde una base de conocimiento privada en MongoDB. Recupera sugerencias relevantes de tarjetas de crédito y documentos resumidos, que luego se introducen en un motor de razonamiento basado en LLM para el refinamiento de consultas y el procesamiento de información. Finalmente, las sugerencias refinadas de productos de tarjetas de crédito se entregan a través de un sistema inteligente que combina la recuperación de documentos basada en vectores, el procesamiento de múltiples consultas y el razonamiento LLM para proporcionar recomendaciones personalizadas de productos financieros.

Descubra cómo la convergencia de datos alternativos, IA y GenAI está transformando las bases de la calificación crediticia en

<https://www.mongodb.com/docs/atlas/architecture/current/solutions-library/credit-card-application-with-generative-ai/>.

Análisis de crédito impulsado por IA de Base39

Además del uso de datos alternativos, IA predictiva y GenAI, la IA agentiva también se está aplicando ahora en el ámbito de las decisiones crediticias.

Una de estas empresas es Base39, proveedor de tecnología financiera con sede en São Paulo, Brasil. Su oferta principal se centra en servicios avanzados de análisis crediticio y de riesgos. Base39 se fundó para revolucionar el análisis crediticio aprovechando el poder de la IA con MongoDB Atlas Vector Search y Amazon Bedrock.

Base39 se dio cuenta de que los análisis de crédito existentes generan decisiones financieras insuficientemente exhaustivas, principalmente debido a la escasez de datos. Datos esenciales, como la verificación de ingresos, el historial laboral y la calificación crediticia, representan solo una fracción de la información requerida. Además, la recopilación y selección de estos datos depende en gran medida de procesos subjetivos. Este proceso complejo y altamente manual puede durar varios días y generar resultados inexactos e incompletos.

Si bien los algoritmos de aprendizaje automático predictivo están diseñados para gestionar la puntuación básica, la combinación de esfuerzos con GenAI mejora la introducción de datos, la interpretación de resultados y los análisis hipotéticos. GenAI agiliza la actualización de los parámetros del modelo mediante el análisis de patrones de datos históricos. Esto elimina la necesidad de actualizaciones manuales en hojas de cálculo o configuraciones. El LLM funciona como un asistente inteligente para los analistas de riesgos, ofreciendo recomendaciones y guiándolos para seleccionar las fuentes de datos y los campos más pertinentes para cada escenario de préstamo.

“MongoDB sustenta la capa de datos, brindando compatibilidad flexible con esquemas, búsqueda vectorial para el contexto LLM y un modelo de implementación administrado que se alinea con la filosofía de Base39 de priorizar al desarrollador”.

— Bruno Nunes, director ejecutivo de Base39



MongoDB Atlas es el componente principal del almacén de características de Base39. Un almacén de características es una herramienta o sistema utilizado en aprendizaje automático para almacenar, gestionar y servir datos conocidos como características. Las características son propiedades o características individuales medibles que se utilizan en los modelos de aprendizaje automático para realizar predicciones. Las capacidades de búsqueda nativa de MongoDB, tanto en datos estructurados (financieros enriquecidos) como no estructurados (de comportamiento), a través de Atlas Vector Search, lo hacen crucial para el proceso de evaluación.



Con Atlas Vector Search, Base39 pudo acelerar la recuperación de características y actualizar dinámicamente sus modelos de aprendizaje automático. Esta flexibilidad es crucial para realizar ajustes en tiempo real a las políticas crediticias. Al utilizar los datos recuperados por Vector Search, Base39 puede complementar las recomendaciones del LLM con contexto específico del dominio, aumentando así su fiabilidad y precisión para los evaluadores de riesgos. Esto evita la revisión manual de numerosos documentos o archivos de configuración. Por último, pero no menos importante, una de las innovaciones de vanguardia y un diferenciador clave de la solución de Base39 reside en la autonomía lograda mediante su enfoque de IA agente. El modelo de Base39 puede percibir, razonar y actuar basándose en datos. Emplea una metodología de cadena de pensamiento (CoT), un método de razonamiento donde la IA descompone problemas complejos en pasos secuenciales. Esto permite la autonomía necesaria para analizar la información y tomar decisiones adaptadas al contenido de cada préstamo individual. Esto permite que la recopilación de información crediticia sea...



Dinámico e hiperpersonalizado, sin necesidad de prescribir muchas reglas como en los sistemas tradicionales de automatización de IA basados en reglas (que, de todos modos, no pueden decidir exhaustivamente qué información debe recopilarse de los solicitantes de crédito). Este enfoque de IA agente abre un potencial infinito para una gestión más precisa y completa.

perfiles crediticios y eventuales decisiones crediticias. Obtenga más información sobre la historia de

Base39 en <https://www.mongodb.com/solutions/customer-case-studies/base39>.

Si bien la IA transforma las decisiones crediticias de los clientes, es igualmente revolucionaria en el modo en que los bancos gestionan el conocimiento y las operaciones internas.

Revolucionando la gestión del conocimiento empresarial en la banca con GenAI

El acceso y la utilización eficiente del conocimiento empresarial son fundamentales. Los empleados internos de diversos departamentos dependen de grandes cantidades de información, desde políticas y procedimientos hasta normativas y detalles de productos. Los sistemas tradicionales de gestión del conocimiento empresarial (EKM) suelen ser insuficientes para proporcionar un acceso fluido e intuitivo a esta información. GenAI presenta una oportunidad transformadora para revolucionar la EKM en los bancos, dotando a los empleados de herramientas inteligentes que mejoran significativamente la productividad y la toma de decisiones.

Desafíos de los sistemas EKM tradicionales en la banca. Los sistemas EKM tradicionales

han desempeñado

un papel fundamental en la organización de la información dentro de los bancos, pero se enfrentan a desafíos cada vez mayores debido a las cambiantes exigencias comerciales y regulatorias. Estos sistemas suelen tener dificultades para proporcionar información precisa, oportuna y contextualmente relevante, y presentan diversas limitaciones:

- Silos de información: el conocimiento puede fragmentarse en distintos sistemas y departamentos, lo que dificulta que los empleados encuentren una visión integral de un tema en particular.
- Interfaces de búsqueda complejas: la búsqueda basada en palabras clave a menudo produce resultados irrelevantes, lo que requiere que los empleados dediquen mucho tiempo a revisar documentos para encontrar la información que necesitan.

- Contenido obsoleto o difícil de entender: las políticas y los procedimientos pueden ser largos, complejos y difíciles de digerir, lo que dificulta su rápida comprensión y aplicación.
- Falta de conocimiento del contexto: los sistemas tradicionales a menudo no comprenden el contexto específico de la consulta de un empleado, lo que genera respuestas genéricas e inútiles.
- Altos costos de mantenimiento: mantener las bases de conocimiento actualizadas y relevantes requiere un esfuerzo manual significativo.

Estas limitaciones dificultan la eficiencia operativa y el cumplimiento normativo. Superar estos desafíos requiere la adopción de soluciones EKM más avanzadas y adaptadas al contexto.

Cómo GenAI está transformando los sistemas EKM en la banca. GenAI ofrece potentes capacidades

para superar estas limitaciones y crear sistemas EKM más eficaces e intuitivos para los empleados internos del banco. Muchos bancos han comenzado a implementar chatbots GenAI, a menudo consolidando primero los datos en un repositorio central de conocimiento empresarial para impulsar su nueva generación de aplicaciones inteligentes de gestión del conocimiento.

A continuación se presentan algunas de las características clave que suelen implementarse en dichos servicios:

- Consultas en lenguaje natural y búsqueda conversacional: GenAI permite a los empleados formular preguntas en lenguaje natural, tal como lo harían con un compañero. La IA puede comprender la intención de la consulta y proporcionar respuestas precisas y relevantes, lo que reduce significativamente el tiempo de búsqueda y la frustración.
- Resumen inteligente de documentos: GenAI puede resumir automáticamente políticas, procedimientos y documentos regulatorios extensos, proporcionando a los empleados resúmenes concisos y conclusiones clave. Esto permite una comprensión y aplicación más rápida de la información crítica.
- Recuperación de información contextualizada: al comprender el rol del usuario, su departamento y el contexto de su consulta, GenAI puede proporcionar más

Información personalizada y relevante, evitando respuestas genéricas.

- Generación dinámica de conocimiento: GenAI puede sintetizar información de múltiples fuentes para responder preguntas complejas que podrían no estar explícitamente abordadas en un solo documento. Esto permite a los empleados obtener respuestas completas a consultas con matices.
- Recomendaciones de conocimiento personalizadas: según las consultas anteriores de un empleado y su función, los sistemas GenAI pueden recomendar de forma proactiva conocimientos y actualizaciones relevantes, lo que garantiza que se mantengan informados sobre información crítica.
- Actualizaciones automatizadas de la base de conocimientos: GenAI puede ayudar a mantener las bases de conocimientos actualizadas identificando información obsoleta y sugiriendo revisiones basadas en nuevas regulaciones o cambios en políticas internas, lo que reduce el mantenimiento manual.
- Intercambio de conocimiento y colaboración mejorados: GenAI facilita el intercambio de conocimiento interno al identificar expertos en la materia según las consultas de los empleados y conectarlos para una colaboración directa. También puede resumir los puntos clave de debate de foros y reuniones internas, facilitando el acceso al conocimiento.

Estas capacidades no solo mejoran la eficiencia operativa, sino que también fortalecen el cumplimiento normativo y la toma de decisiones en toda la organización. A medida que los bancos siguen adoptando sistemas EKM basados en GenAI, sientan las bases para ecosistemas de conocimiento más ágiles, informados y colaborativos que evolucionan junto con las exigencias regulatorias y empresariales.

Casos de uso de GenAI para sistemas EKM internos en bancos

Varios casos prácticos resaltan cómo los bancos están aprovechando o pueden aprovechar GenAI para EKM interno:

- Consultas regulatorias y de cumplimiento: los empleados pueden obtener rápidamente respuestas a preguntas regulatorias complejas al preguntar en lenguaje natural, con el sistema GenAI sintetizando información de varios documentos de cumplimiento.

- Soporte de conocimiento del producto: el personal de recepción puede acceder rápidamente a información detallada sobre productos y servicios bancarios para responder las consultas de los clientes de manera precisa y eficiente.
- Orientación sobre políticas y procedimientos internos: los empleados pueden comprender y navegar fácilmente por las políticas y los procedimientos internos a través de consultas y resúmenes en lenguaje natural.
- Soporte y resolución de problemas de TI: los equipos de TI internos pueden aprovechar GenAI para encontrar rápidamente soluciones a problemas técnicos consultando bases de conocimiento y documentación utilizando lenguaje natural.
- Incorporación y capacitación: los nuevos empleados pueden ponerse al día rápidamente haciendo preguntas sobre los procesos internos y accediendo a materiales de capacitación relevantes a través de un sistema EKM impulsado por GenAI.
- Información sobre gestión de riesgos: los analistas de riesgos pueden aprovechar GenAI para sintetizar información de varios informes de riesgos e identificar tendencias emergentes y problemas potenciales.

Estos casos de uso demuestran cómo EKM impulsado por GenAI puede agilizar el acceso a información crítica, reducir cuellos de botella operativos y mejorar la productividad de los empleados, lo que en última instancia permite a los bancos responder de manera más rápida y eficaz tanto a las necesidades internas como a las demandas externas.

Consideraciones arquitectónicas para sistemas EKM impulsados por GenAI

Implementar GenAI para EKM en un entorno bancario requiere un diseño arquitectónico meticuloso, con énfasis en la integración, la seguridad y la escalabilidad. Un aspecto crucial de este diseño es la consideración de la plataforma de datos, ya que la eficacia de GenAI depende en gran medida de la capacidad de almacenar, gestionar y recuperar eficientemente diversos tipos de conocimiento empresarial. Las consideraciones clave incluyen las siguientes:

- Integración con la infraestructura de conocimiento existente: El sistema GenAI debe integrarse fluidamente con los sistemas existentes del banco. Esto suele implicar la creación de conectores y API para acceder a la información de sistemas dispares. Un almacén central de datos operativos puede consolidar datos de diversas fuentes, proporcionando una visión unificada del sistema GenAI.

- Selección de la plataforma de datos: elegir la plataforma de datos adecuada es fundamental. Las bases de datos modernas capaces de gestionar datos estructurados, semiestructurados y no estructurados, además de ofrecer funciones avanzadas de indexación y búsqueda, son esenciales. El almacenamiento orientado a documentos destaca en la gestión de diversos recursos de conocimiento empresarial. Este enfoque multimodal resulta crucial para la eficacia de las aplicaciones GenAI.
- Acceso y gobernanza seguros de los datos: Dada la alta sensibilidad de los datos bancarios, es fundamental contar con medidas de seguridad robustas. Funciones como los controles de acceso y el cifrado garantizan la protección y el cumplimiento normativo de los datos.
- Elección de modelos y plataformas GenAI: Los bancos deben elegir los LLM adecuados y la infraestructura subyacente (en la nube o local). La arquitectura debe facilitar la integración con estos modelos.
- RAG: Para garantizar que las respuestas de GenAI sean precisas y se basen en el conocimiento específico del banco, la implementación de RAG es crucial. Las funciones integradas de búsqueda y búsqueda vectorial son especialmente adecuadas para respaldar las implementaciones de RAG, ya que almacenan, indexan y recuperan eficientemente diversos tipos de datos, incluyendo contenido textual y sus correspondientes incrustaciones vectoriales para búsquedas de similitud semántica, lo que garantiza que GenAI tenga contexto para sus... respuestas.
- Escalabilidad y rendimiento: El sistema EKM debe gestionar un gran volumen de consultas. Las funciones de escalado automático garantizan la escalabilidad y respuestas de baja latencia, satisfaciendo así los picos de demanda.
- Monitoreo y explicabilidad: Implementar un monitoreo sólido del rendimiento y la precisión del sistema GenAI es esencial. El almacenamiento de registros y metadatos sobre consultas y respuestas facilita el análisis y la explicabilidad.
- Integración de la interfaz de usuario y el flujo de trabajo: El sistema EKM con GenAI debe tener una interfaz de usuario intuitiva y estar integrado en los flujos de trabajo existentes. Un modelo de datos flexible permite una fácil adaptación a los requisitos cambiantes y una integración fluida.

Al abordar estas consideraciones de manera integral, los bancos pueden crear una arquitectura EKM impulsada por GenAI que no solo cumpla con estrictos requisitos de seguridad y cumplimiento, sino que también ofrezca ganancias mensurables en eficiencia, accesibilidad al conocimiento y calidad en la toma de decisiones.

Implementación del chatbot GenAI de un banco asiático

Uno de los bancos más innovadores de Asia implementó un chatbot GenAI en una aplicación interna para mejorar la eficiencia operativa del personal. El chatbot ofrece funciones como generación de contenido, resumen de textos y traducción, lo que ayuda a los empleados a mejorar su eficiencia laboral. También facilita la recuperación de normativas, procedimientos, contactos comerciales, formularios de solicitud y documentos, ahorrando así tiempo considerable en la búsqueda de información.

El liderazgo tecnológico del banco reconoce abiertamente que el desarrollo de aplicaciones GenAI eficaces presenta obstáculos únicos, entre los que destaca el arte y la ciencia de la ingeniería de indicaciones: la elaboración de las instrucciones dadas al modelo de IA. La calidad del resultado de la IA depende en gran medida de la claridad y especificidad de estas indicaciones. Consciente de ello, el banco está desarrollando activamente su cultura de desarrollo de aplicaciones. Ajustan estratégicamente la responsabilidad, animando a los usuarios empresariales, aquellos con un profundo conocimiento del dominio, a liderar el ciclo de vida del desarrollo de GenAI, especialmente en el perfeccionamiento y ajuste de las indicaciones. Esto marca una diferencia con el desarrollo de software convencional, donde el departamento de TI suele encargarse de la mayor parte de la implementación técnica.



Para facilitar este cambio cultural, el banco ha implementado programas internos de capacitación en GenAI, destinados a dotar al personal de la empresa de habilidades esenciales de ingeniería rápida. Esta adaptación organizacional busca reducir la brecha entre la capacidad técnica y las necesidades del negocio, garantizando que las herramientas y aplicaciones de GenAI sean lo más relevantes y eficaces posible, incorporando directamente la experiencia del usuario en el proceso de ajuste. El banco también está

técnicas de mejora automatizada de las indicaciones para agilizar aún más este proceso.

Además, el banco entiende que el chatbot interno no existe de forma aislada, sino que es parte de un ecosistema más amplio e interconectado de aplicaciones de IA dentro del grupo bancario y sus subsidiarias.

Si bien cumple un propósito interno específico, comparte el impulso tecnológico subyacente de GenAI y potencialmente aprovecha la infraestructura de datos común con iniciativas en otras áreas.

La siguiente figura muestra el flujo de trabajo del conocimiento:




Figura 11.4: Flujo de trabajo del sistema de conocimiento RAG

Este diagrama ilustra el flujo continuo de información entre varios componentes en un sistema de soporte al cliente impulsado por IA, mostrando cómo se procesan las consultas de los usuarios a través de Vector Search, se enriquecen con contexto y se transforman en lenguaje natural. respuestas.

El impacto de GenAI en los sistemas EKM

La integración de GenAI en los sistemas EKM promete importantes beneficios para los bancos:

- Mayor productividad de los empleados: un acceso más rápido y sencillo al conocimiento permite a los empleados realizar sus tareas de manera más eficiente.

- Toma de decisiones mejorada: el acceso a información completa y contextualizada permite a los empleados tomar decisiones más informadas y oportunas.
- Experiencia mejorada de los empleados: los sistemas EKM fáciles de usar impulsados por GenAI pueden reducir la frustración y mejorar la satisfacción laboral al facilitar que los empleados encuentren la información que necesitan.
- Reducción de errores y mejora del cumplimiento: un conocimiento preciso y fácilmente disponible de las políticas y regulaciones puede ayudar a reducir los errores y garantizar un mejor cumplimiento.
- Incorporación y capacitación más rápidas: los nuevos empleados pueden volverse productivos más rápidamente con acceso inteligente a materiales de capacitación y conocimiento interno.
- Mejor retención de conocimientos: los sistemas GenAI pueden ayudar a preservar el conocimiento institucional al hacerlo fácilmente accesible y buscable, incluso cuando los empleados se van o cambian los roles.

Si bien estas aplicaciones internas de GenAI están transformando el modo en que los bancos operan detrás de escena, la tecnología es igualmente revolucionaria en las aplicaciones de cara al cliente, transformando el modo en que las instituciones financieras interactúan con sus clientes y los sirven.

Mejores experiencias de banca digital a través de interacciones impulsadas por IA

Esta transición hacia una IA centrada en el cliente está creando experiencias bancarias más intuitivas, personalizadas e inteligentes. Para satisfacer las crecientes expectativas, los bancos están adoptando plataformas basadas en IA, basadas en LLM y automatización inteligente. Esta transformación requiere una base de datos flexible y escalable, esencial para la banca moderna impulsada por IA.

Mejorando la experiencia del cliente con GenAI

GenAI introduce capacidades avanzadas como chatbots inteligentes y asistentes virtuales, lo que permite a los bancos brindar soporte en tiempo real y adaptado al contexto. Estas herramientas basadas en IA pueden interpretar consultas complejas de los clientes, acceder a información relevante y brindar respuestas concisas y personalizadas al instante. Esto no solo...

Mejora la satisfacción del cliente pero también agiliza las operaciones al reducir la dependencia de los canales tradicionales de servicio al cliente.

Además de la asistencia, GenAI también facilita la banca proactiva. Los sistemas de IA pueden extraer información de datos de transacciones, tendencias de uso y análisis de comportamiento para recomendar productos financieros personalizados, notificar a los usuarios sobre actividades inusuales o guiarlos en momentos clave de la vida, como la compra de una vivienda o el ahorro para la educación.

En lugar de simplemente reaccionar a las consultas, los bancos ahora pueden anticipar las necesidades de los clientes, ofreciendo una experiencia fluida y rica en valor.

La incorporación de GenAI en los flujos de trabajo bancarios transforma radicalmente la prestación de los servicios financieros. Los clientes interactúan con su banco mediante una conversación natural, en lugar de formularios rígidos o menús desplegables. En lugar de leer extensos documentos de políticas, reciben resúmenes y explicaciones generados por IA, adaptados a sus preguntas. El banco se convierte en un verdadero socio financiero, disponible 24/7, escalable e inteligente.

Fundamentos de datos bancarios digitales impulsados por IA

Implementar la IA en la banca moderna requiere más que modelos potentes; exige una base de datos flexible y en tiempo real. Una arquitectura basada en documentos es ideal para gestionar datos bancarios complejos, como perfiles de clientes, historiales de transacciones, comportamiento de cuentas y contenido no estructurado, como preguntas frecuentes o documentos de políticas, todo en un mismo lugar. Este modelo unificado permite a los sistemas de IA acceder a información rica y contextual al instante, lo que genera experiencias del cliente más precisas, personalizadas y ágiles.

Las plataformas de datos modernas como MongoDB también admiten patrones de IA avanzados como RAG, lo que permite a los asistentes bancarios recuperar instantáneamente documentos relevantes y generar respuestas precisas adaptadas a las consultas de los clientes, ya sea para explicar los términos de la hipoteca o marcar un cargo sospechoso.

Además, los robustos marcos de agregación permiten a los agentes inteligentes analizar la actividad de las cuentas, las tendencias de gasto o los saldos de los préstamos en tiempo real, en combinación con datos históricos, lo que facilita la obtención de información proactiva y el apoyo a la toma de decisiones. La seguridad y el cumplimiento normativo son esenciales, y funciones como el cifrado, los controles de acceso detallados y la auditoría son cruciales para cualquier IA que gestione datos financieros personales confidenciales.

Con una integración perfecta en los ecosistemas de IA modernos y soporte para arquitecturas basadas en eventos, la plataforma de datos adecuada permite a los bancos automatizar flujos de trabajo, personalizar la interacción a escala y llevar servicios inteligentes al mercado más rápido, lo que la convierte en un facilitador central de la banca digital impulsada por IA.

Arquitectura de solución de referencia para la atención al cliente basada en IA. Para

habilitar estas capacidades, es esencial una arquitectura de referencia diseñada para mejorar las interacciones con los clientes mediante GenAI. En el núcleo de esta arquitectura se encuentra MongoDB, que sirve como plataforma centralizada para almacenar y acceder a información estructurada y... datos no estructurados.

El proceso comienza con la ingesta y transformación de datos, donde se procesan documentos de políticas, preguntas frecuentes, información de productos y otros recursos con mucho texto utilizando técnicas de procesamiento del lenguaje natural (PLN).

El PLN utiliza métodos computacionales para analizar y comprender el lenguaje humano, extrayendo significado, estructura y contexto de texto no estructurado. Estos documentos se dividen en segmentos más pequeños y se convierten en incrustaciones vectoriales. Tanto el texto original como las incrustaciones se almacenan en MongoDB, aprovechando sus capacidades de búsqueda vectorial para una recuperación eficiente.

Cuando se produce una nueva interacción, ya sea por voz, chatbot o formulario, la consulta del usuario se vectoriza de la misma manera. La aplicación realiza una búsqueda de similitud semántica en los vectores almacenados, recuperando el contenido más relevante y alineado con la intención del usuario. Este enfoque permite respuestas precisas y contextuales que mejoran la eficiencia y la satisfacción del cliente.

La figura 11.5 ilustra el flujo de extremo a extremo de un sistema de atención al cliente impulsado por IA.




Figura 11.5: Interacciones de procesos y componentes de la atención al cliente impulsada por IA

El diagrama muestra cómo se procesan las consultas de los usuarios, se enriquecen con datos contextuales y se transforman en respuestas personalizadas mediante la integración de Vector Search, modelos de lenguaje y datos operativos. Estos documentos recuperados, enriquecidos con contexto adicional de datos operativos (como el historial de la cuenta o los criterios de elegibilidad), se transfieren a un modelo de lenguaje que genera una respuesta en lenguaje natural.

Esta arquitectura se basa en gran medida en el acceso en tiempo real a múltiples tipos de datos. Por ejemplo, los metadatos de transacciones, los perfiles de usuario y las señales de comportamiento se almacenan en MongoDB y pueden agregarse según sea necesario. Mediante el uso de disparadores Atlas, el sistema también puede reaccionar dinámicamente. Por ejemplo, si un cliente pregunta sobre un descubierto, el sistema podría activar una consulta de los saldos actuales y los calendarios de pagos antes de responder.

Esta arquitectura modular está diseñada para integrarse con la pila de IA más amplia, incluyendo marcos de orquestación LLM (como LangChain o LlamaIndex) y entornos de implementación que gestionan modelos y flujos de trabajo de IA. MongoDB se encuentra en la intersección de todas estas capas, lo que permite tanto el almacenamiento como la recuperación dinámica de los datos de alto valor de los que dependen los agentes de IA.

A medida que los bancos mejoran las interacciones con los clientes a través de la IA, deben fortalecer simultáneamente sus defensas contra delitos financieros cada vez más sofisticados.

Mitigación y cumplimiento de delitos financieros mejorados mediante IA

La IA está transformando el riesgo y el cumplimiento normativo en los servicios financieros mediante la detección de fraude en tiempo real, la interpretación regulatoria automatizada y una toma de decisiones más inteligente. MongoDB proporciona la base de datos flexible y escalable en la que se basan estos sistemas de IA, especialmente para gestionar diversos datos en los procesos de conocimiento del cliente (KYC) y prevención del blanqueo de capitales (AML), desde documentos hasta voz e imágenes. A medida que los delitos financieros se vuelven más sofisticados y las regulaciones se vuelven cada vez más complejas, la IA y las plataformas de datos de vanguardia permiten a las instituciones mantenerse a la vanguardia, convirtiendo el riesgo en resiliencia y el cumplimiento normativo en una ventaja competitiva.

Los delitos financieros han evolucionado drásticamente en los últimos años y los delincuentes aprovechan tecnologías avanzadas y explotan vulnerabilidades en los sistemas digitales. Los métodos tradicionales de detección, basados en reglas estáticas y umbrales predefinidos, tienen dificultades para adaptarse a estos sofisticados esquemas. Al mismo tiempo, los requisitos regulatorios siguen expandiéndose, lo que genera importantes cargas de cumplimiento para las instituciones financieras. Los costos de una prevención inadecuada de delitos financieros son considerables e incluyen pérdidas económicas, sanciones regulatorias, daño a la reputación y pérdida de confianza de los clientes. Para abordar estos desafíos, las instituciones necesitan soluciones adaptables capaces de responder a las amenazas emergentes, manteniendo al mismo tiempo la eficiencia operativa.

Fortalecimiento de la mitigación de los delitos financieros con AI

En términos generales, los delitos financieros representan un conjunto integral de políticas, controles, análisis e investigaciones para prevenir, detectar, denunciar y recuperarse de cualquier actividad delictiva que pueda perjudicar no solo a los clientes, sino, aún más grave, la reputación de las instituciones financieras. Por lo tanto, se considera un riesgo operativo importante que debe abordarse adecuadamente.

Entre las diferentes amenazas potenciales, las más comunes son la gestión del fraude (pérdida de activos), la lucha contra el blanqueo de capitales (origen de los activos), el cumplimiento de sanciones (legalidad de los activos) y todos los riesgos operativos, principalmente debidos a una gobernanza deficiente, un análisis anticuado, la falta de controles de procesos o la baja calidad y validación de los datos. Todas estas amenazas podrían verse sustancialmente incrementadas y volverse indetectables mediante técnicas sofisticadas en el ciberespacio, lo que haría inútiles las comprobaciones manuales. Por lo tanto, las ciberamenazas deben ser abordadas por tecnologías modernas equivalentes, lo que convierte a la IA en la solución ideal para optimizar las capacidades técnicas de mitigación de delitos financieros.

Tendencias emergentes que redefinen el futuro de la IA en el cumplimiento normativo. La IA, especialmente

GenAI, se perfila como

una herramienta vital para ayudar a las organizaciones a pasar de la mitigación reactiva de riesgos a una gobernanza proactiva. En el centro de esta transformación se encuentran las plataformas de datos flexibles diseñadas para facilitar la toma de decisiones en tiempo real, impulsada por IA y a gran escala. Por ejemplo, los sistemas tradicionales de detección de fraude se basan en reglas estáticas y umbrales predefinidos. Estos son cada vez más ineficaces contra las técnicas de fraude modernas, que son rápidas, adaptables y, a menudo, ocultas en actividades legítimas. La IA mejora la gestión de riesgos al aprender de datos históricos y en tiempo real, detectar anomalías e identificar patrones de comportamiento sospechoso.

GenAI va más allá al permitir el modelado de escenarios y las simulaciones sintéticas de fraude, lo que ayuda a las organizaciones a probar hipótesis y descubrir vectores de amenaza previamente desconocidos. Los sistemas basados en IA pueden detectar no solo acciones fraudulentas individuales, sino también redes de fraude coordinadas y multicanal. Al integrarse con plataformas de datos modernas como MongoDB, estos sistemas obtienen acceso a una visión unificada y contextualizada de los datos de diversas fuentes, lo que mejora la detección y la precisión en la toma de decisiones.

Para habilitar todas estas capacidades de IA se requiere una plataforma de datos que no solo pueda almacenar vastos datos históricos de transacciones en tiempo real, sino que también los gestione eficientemente para diversos modelos de IA, desde detectores predictivos de anomalías hasta modelos generativos para simulación, a menudo en tiempo real o casi real. Con una plataforma de datos moderna, las instituciones financieras pueden desarrollar capacidades inteligentes como las siguientes:

- XAI: A medida que aumenta el escrutinio regulatorio, las instituciones financieras necesitan sistemas de IA que expliquen sus decisiones. Los enfoques XAI brindan transparencia sobre cómo los modelos de IA llegan a conclusiones, cumpliendo con los requisitos regulatorios de rendición de cuentas y manteniendo la precisión de la detección. Las principales plataformas de datos facilitan esta explicabilidad al preservar las relaciones entre los datos y las decisiones.
- Detección proactiva de riesgos: En lugar de limitarse a responder a patrones conocidos, los sistemas avanzados de IA pueden anticipar riesgos emergentes mediante el análisis de cambios sutiles en el comportamiento y las condiciones del mercado. Este enfoque prospectivo requiere una base de datos flexible que pueda integrar diversas señales y respaldar el análisis en tiempo real.
- Aprendizaje federado para la defensa colaborativa: Las instituciones financieras están explorando técnicas de aprendizaje federado que les permiten entrenar colectivamente modelos de detección de fraude sin compartir datos confidenciales de los clientes. Este enfoque colaborativo fortalece todo el ecosistema financiero, preservando al mismo tiempo la privacidad y la confidencialidad. Las plataformas de datos modernas con funciones de seguridad sofisticadas son esenciales para implementar estos enfoques sofisticados.

En conjunto, estas capacidades posicionan a las instituciones financieras para mantenerse a la vanguardia de las amenazas cambiantes, satisfacer las demandas regulatorias con confianza y transformar el cumplimiento de una necesidad defensiva a una ventaja estratégica.

IA para inteligencia regulatoria y automatización de políticas

El objetivo principal de la prevención de delitos financieros es frenar la actividad delictiva y garantizar el cumplimiento normativo. GenAI está transformando este ámbito mediante la creación de nuevas y potentes capacidades para detectar y prevenir delitos financieros:

- Conjuntos de datos de fraude sintético: GenAI puede crear conjuntos de datos sintéticos de transacciones fraudulentas que imitan patrones de ataque novedosos que aún no se han observado en la práctica. Esto permite a las instituciones financieras entrenar sus sistemas de detección de forma proactiva, preparándose para las amenazas emergentes antes de que se materialicen en ataques reales.

- Pruebas adversarias: Al simular intentos de fraude sofisticados, GenAI ayuda a las instituciones a identificar vulnerabilidades en sus controles existentes. Estas simulaciones pueden modelar ataques complejos y multicanal que los métodos de prueba tradicionales podrían pasar por alto.
- Generación de anomalías: en lugar de esperar a que ocurran naturalmente eventos de fraude raros, GenAI puede producir anomalías realistas que ayudan a mejorar los modelos de detección, particularmente para escenarios de fraude de baja frecuencia pero de alto impacto.

La IA también ayuda a las instituciones a interpretar las regulaciones, traducirlas en políticas internas y supervisar su cumplimiento continuo. GenAI puede leer y resumir textos legales, extraer obligaciones y sugerir políticas de cumplimiento. Los agentes autónomos inteligentes, es decir, sistemas impulsados por IA que perciben su entorno, toman decisiones y actúan para alcanzar objetivos específicos, validan continuamente las actividades operativas según los requisitos regulatorios, detectando el incumplimiento en tiempo real.

Con plataformas de datos modernas como base, los sistemas de cumplimiento se benefician del acceso en tiempo real a datos críticos: perfiles de clientes, transacciones, comunicaciones y registros de auditoría. El modelo documental de plataformas como MongoDB permite a las organizaciones almacenar interpretaciones regulatorias, normas de cumplimiento y metadatos contextuales en un formato fácil de buscar y rastrear, lo que facilita comprobaciones de cumplimiento automatizadas y eficientes, así como informes auditables.

El papel de MongoDB en KYC y AML

La IA está transformando el riesgo y el cumplimiento normativo en los servicios financieros mediante la detección de fraude en tiempo real, la interpretación regulatoria automatizada y una toma de decisiones más inteligente. Las plataformas de datos modernas como MongoDB proporcionan la base de datos flexible y escalable en la que se basan estos sistemas de IA, especialmente para gestionar diversos datos en KYC y AML, desde documentos hasta voz e imágenes.

MongoDB permite a las instituciones financieras ingerir y almacenar datos no estructurados, como identificaciones escaneadas, información biométrica y registros de voz de atención al cliente, junto con datos estructurados, como transacciones e historiales de cuentas. Esto permite que los modelos de IA... para realizar un análisis multimodal más profundo. Por ejemplo, GenAI puede transcribir y

Analizar interacciones de voz en busca de intenciones sospechosas o detectar falsificaciones de documentos utilizando datos de imágenes.

MongoDB Atlas mejora aún más esta función al ofrecer funciones integradas como búsqueda de texto completo, búsqueda vectorial (para coincidencias por similitud) e integración con procesos de aprendizaje automático. Con estas funciones, las instituciones pueden comparar los documentos enviados por los clientes con patrones de fraude conocidos, ejecutar reconocimiento facial o validación de huella de voz, y realizar búsquedas semánticas en las interacciones de los clientes, lo que permite un proceso de evaluación de riesgos KYC/AML mucho más completo.

Un enfoque centrado en la IA para el riesgo y el cumplimiento normativo comienza con una vista dinámica de un solo cliente, como se muestra en la Figura 11.6. MongoDB Atlas procesa datos estructurados y no estructurados de sistemas internos, puntos de contacto con clientes y fuentes externas, que posteriormente son procesados por modelos de IA para detectar posibles fraudes o infracciones de cumplimiento normativo basándose en comportamientos aprendidos y lógica regulatoria. Diversas fuentes de datos, como datos transaccionales estructurados, documentos no estructurados y conjuntos de datos externos, se integran en un perfil unificado, lo que permite una evaluación integral de riesgos y una prestación de servicios personalizada.




Figura 11.6: Almacén de datos convergente para crear un perfil de cliente dinámico

Una vez creada esta vista única, se puede combinar con datos no estructurados adicionales, como listas de vigilancia de sanciones y políticas AML, junto con datos transaccionales, para un análisis exhaustivo. La flexibilidad del modelo de documentos de MongoDB permite este enfoque de base de datos multimodal. Tras la convergencia de los datos en un conjunto completo, la Búsqueda Vectorial de MongoDB puede identificar representaciones vectoriales similares de actividades sospechosas conocidas, como se muestra en la Figura 11.7. Esto garantiza que solo se marquen para su revisión las transacciones fraudulentas con alta probabilidad de fraude, lo que reduce los falsos positivos y mantiene la precisión de la detección.




Figura 11.7: Filtrado de transacciones en tiempo real mediante búsqueda vectorial

La Búsqueda Vectorial desempeña un papel fundamental en el análisis de transacciones en tiempo real, ya que permite comparar las transacciones entrantes con patrones establecidos de actividad sospechosa. Al aprovechar este enfoque, las instituciones financieras pueden reducir significativamente los falsos positivos, mejorar la precisión de la detección y responder con mayor rapidez a posibles amenazas.

Beneficios empresariales estratégicos

La implementación de la detección de transacciones en tiempo real impulsada por IA y Vector

Las capacidades de búsqueda pueden brindar las siguientes capacidades estratégicas mensurables para instituciones financieras:

- Mejor detección de fraudes: los modelos de IA impulsados por el acceso a datos en tiempo real de MongoDB pueden detectar señales de fraude sutiles en grandes conjuntos de datos, lo que reduce los fraudes.

aspectos positivos y acelerar los tiempos de respuesta.

- Cumplimiento mejorado: la interpretación y aplicación automatizadas de las regulaciones reducen los gastos generales manuales y los riesgos de auditoría.
- KYC/AML mejorado: la capacidad de almacenar y analizar datos no estructurados de clientes enriquece la verificación de identidad y la puntuación de riesgo.
- Mayor agilidad: los departamentos de TI pueden adaptarse rápidamente a nuevos mandatos regulatorios o tipologías de fraude emergentes, ya que el esquema flexible de MongoDB admite el desarrollo iterativo y la implementación rápida de nuevos modelos de datos y reglas impulsadas por IA sin largos ciclos de rediseño de bases de datos.
- Eficiencia operativa: la automatización de la IA y los flujos de trabajo de datos integrados liberan a los equipos humanos para que se concentren en tareas de alto valor.
- Confianza regulatoria: al proporcionar una plataforma de datos unificada con registros de auditoría completos para decisiones impulsadas por IA, los tomadores de decisiones de TI pueden ayudar a sus instituciones a demostrar de manera más efectiva controles sólidos y responsabilidad ante los reguladores, fomentando una mayor confianza y reduciendo potencialmente el escrutinio.

A medida que los delitos financieros siguen evolucionando, los sistemas de prevención basados en IA se volverán cada vez más sofisticados. Técnicas integrales como el aprendizaje federado, que permite entrenar modelos en múltiples instituciones sin compartir datos confidenciales, prometen mejorar las capacidades de detección, preservando al mismo tiempo la privacidad y la confidencialidad.

Los agentes inteligentes autónomos representan la próxima frontera, con sistemas capaces de detectar patrones sospechosos de forma proactiva, adaptar defensas en tiempo real e incluso predecir amenazas emergentes antes de que se materialicen. Estos sistemas requerirán plataformas de datos robustas capaces de gestionar datos complejos e interconectados y facilitar la toma de decisiones en tiempo real a gran escala.

Al invertir en prevención de delitos financieros basada en inteligencia artificial y construida sobre plataformas de datos flexibles y escalables como MongoDB, las instituciones financieras pueden mantenerse a la vanguardia de las amenazas en evolución, al mismo tiempo que reducen los costos operativos y mantienen el cumplimiento normativo.

Más allá de la gestión de riesgos tradicional, la IA también está transformando el modo en que las instituciones abordan la responsabilidad ambiental y social.

Análisis ESG multimodal e impulsado por IA

El profundo impacto de los principios ambientales, sociales y de gobernanza (ESG) es evidente, impulsado por los cambios regulatorios, especialmente en Europa, que obligan a las instituciones financieras a integrar ESG en las decisiones de inversión y préstamos.

Regulaciones como el Reglamento de la UE sobre la Divulgación de Finanzas Sostenibles (SFDR) y el Reglamento de Taxonomía de la UE son ejemplos de directivas que exigen a las instituciones financieras considerar la sostenibilidad ambiental en sus operaciones y productos de inversión. La demanda de opciones sostenibles por parte de los inversores ha aumentado, lo que ha dado lugar a un aumento de los fondos con enfoque ESG. Los requisitos regulatorios y comerciales, a su vez, impulsan a los bancos a mejorar también sus prácticas de préstamos verdes.

Este cambio es estratégico para las instituciones financieras, ya que permite atraer clientes, gestionar riesgos y crear valor a largo plazo.

Sin embargo, las instituciones financieras se enfrentan a numerosos desafíos a la hora de gestionar diferentes aspectos para mejorar su análisis ESG. Los principales retos incluyen la definición y la armonización de estándares y procesos, así como la gestión de la avalancha de datos, que cambian rápidamente y son variados, y que deben incluirse en el análisis ESG.

La IA puede ayudar a abordar estos desafíos clave no solo de forma automática, sino también adaptativa mediante técnicas como el aprendizaje automático. Las instituciones financieras y los proveedores de soluciones ESG ya han utilizado la IA para extraer información de informes corporativos, redes sociales y datos ambientales, mejorando así la precisión y la profundidad del análisis ESG. A medida que el mercado exige una sociedad más sostenible y equitativa, la IA predictiva, combinada con GenAI, también puede ayudar a reducir el sesgo en los préstamos para crear una financiación más justa e inclusiva, a la vez que mejora la capacidad predictiva. El poder de la IA puede facilitar el desarrollo de modelos y estrategias de sostenibilidad sofisticados, lo que supone un gran avance en la integración de ESG en las prácticas financieras y corporativas más amplias.

Bajo el paraguas más amplio de ESG, el riesgo ambiental y climático constituye un desafío clave tanto para las instituciones financieras como para las no financieras. Con el cambio climático acelerándose a un ritmo sin precedentes, millones de activos están en riesgo. Las instituciones necesitarán análisis inteligentes de datos climáticos para gestionar el riesgo climático y encontrar mejores oportunidades ajustadas al riesgo.

Plataforma de datos climáticos de Ambee

Ambee, una startup de tecnología climática de rápido crecimiento con sede en India, está revolucionando el mundo de los datos ambientales con su misión de crear un futuro sostenible. Con más de un millón de usuarios activos diarios, Ambee ofrece datos climáticos y ambientales patentados como servicio para empoderar a gobiernos, organizaciones sanitarias y empresas privadas a tomar decisiones informadas sobre sus políticas y estrategias comerciales.

MongoDB Atlas ha sido fundamental en la arquitectura de bases de datos de Ambee, respaldando sus modelos de IA y aprendizaje automático. La empresa utilizó MongoDB Atlas para gestionar sus extensos y diversos conjuntos de datos ambientales. Al procesar aproximadamente 4 terabytes de datos diarios provenientes de más de 800.000 sensores y 11 satélites de observación de la Tierra, Ambee se enfrentó a desafíos para escalar y garantizar respuestas rápidas de API. Al adoptar MongoDB Atlas, la empresa centralizó su almacenamiento de datos, lo que agilizó el acceso a los mismos y redujo la necesidad de uniones complejas entre múltiples tablas. Esta transición permitió a Ambee escalar de gestionar 60.000 llamadas a la API al mes en 2020 a aproximadamente 790 millones en 2023, a la vez que mejoró los tiempos de respuesta de la API de 2 segundos a menos de 300 milisegundos.

Los datos de Ambee proporcionan a los usuarios información ambiental precisa en un radio inferior a 1 km². Para lograr este alto nivel de precisión y granularidad, Ambee necesitaba una plataforma capaz no solo de gestionar un gran volumen de datos, sino también de satisfacer amplias necesidades geoespaciales. MongoDB Atlas se adapta perfectamente a sus necesidades gracias a su rápida capacidad de consulta geoespacial. Por ejemplo, con MongoDB, pueden consultar la ubicación más cercana a una coordenada dada en 20 milisegundos, incluso con millones de puntos de datos geoespaciales.





El rendimiento, la escalabilidad y las capacidades multimodales de MongoDB Atlas respaldan los servicios basados en IA de Ambee, como la predicción de incendios forestales y el suministro de datos sobre la calidad del aire y el polen en tiempo real. Además, MongoDB Atlas Search facilita la búsqueda de texto, incluyendo búsquedas parciales, con comodines y con autocompletado, lo que mejora la capacidad de la plataforma para proporcionar información precisa con rapidez.

El papel de MongoDB en la gestión de datos ESG

La arquitectura dinámica de MongoDB revoluciona la gestión de datos ESG, gestionando datos semiestructurados y no estructurados. Su esquema flexible permite...

Adaptación de los modelos de datos a medida que evolucionan las estrategias ESG. Las funciones avanzadas de búsqueda de texto analizan eficientemente grandes cantidades de datos semiestructurados para generar informes ESG fundamentados. La compatibilidad con la búsqueda vectorial enriquece el análisis ESG con información multimedia.

La incorporación de LLMs mejora la capacidad de MongoDB para procesar contenido textual ESG, automatizando la extracción de opiniones, la síntesis y la identificación de tendencias. Al combinar LLMs con la gestión de datos vectoriales, se pueden crear aplicaciones GenAI para interpretar la compleja y cambiante taxonomía de sostenibilidad y guiar los procesos de inversión y financiación de forma conforme a las normativas. Este enfoque basado en IA, respaldado por la robusta gestión de datos de MongoDB, ofrece un método sofisticado para analizar datos narrativos extensos en informes ESG.

Además, MongoDB admite análisis geoespaciales y de grafos de red, lo que proporciona una potente combinación de análisis para identificar los riesgos físicos asociados al cambio climático (p. ej., inundaciones o incendios forestales) para los activos financiados por bancos o empresas de inversión, y para evaluar el impacto de los riesgos climáticos en la cadena de suministro. El análisis de riesgos puede, a su vez, facilitar estrategias específicas para la mitigación de riesgos y la resiliencia de la cadena de suministro.

Con la evolución de la IA agentic, están surgiendo nuevos casos de uso de sostenibilidad. Por ejemplo, las aplicaciones de IA agentic pueden servir como copilotos inteligentes para las relaciones.

Los gestores durante la originación de préstamos verdes garantizan el cumplimiento y la elegibilidad de las normas ESG en tiempo real. La IA de Agentic puede supervisar continuamente la información ESG y los medios externos para detectar el lavado de imagen, activar alertas de riesgo de forma autónoma y recomendar medidas de mitigación a los equipos de cumplimiento. En la gestión de la cadena de suministro, los agentes de IA de Agentic pueden mapear proactivamente las vulnerabilidades climáticas de los proveedores, simular escenarios de disrupción y orquestar medidas de resiliencia automatizadas, impulsando compras y operaciones más sostenibles.

Aprovechando las capacidades multimodales, completas y listas para usar, y las herramientas de IA integradas, la plataforma de datos de MongoDB constituye la base ideal para impulsar el uso de la IA en aplicaciones de IA de agentes, ya que puede servir como almacén de datos operativos y analíticos en tiempo real para ingerir, almacenar y organizar todos los datos ESG, regulatorios y contextuales relevantes que los agentes de IA de agentes necesitan para tomar decisiones informadas y autónomas. Al integrarse perfectamente con los modelos de IA y soportar el procesamiento de eventos en tiempo real, MongoDB permite que la IA de agentes monitoree los riesgos ESG, active alertas y organice flujos de trabajo en los módulos de préstamos, cumplimiento normativo o cadena de suministro, todo ello utilizando datos ESG operativos.

Política ESG impulsada por IA y cumplimiento normativo

La IA puede desempeñar un papel transformador en el análisis de políticas ESG y la interpretación regulatoria al automatizar la asimilación, comprensión y síntesis de regulaciones complejas y en constante evolución en diferentes jurisdicciones. Mediante modelos avanzados de PLN y aprendizaje automático, la IA puede analizar rápidamente textos regulatorios extensos, extraer con precisión los requisitos clave y compararlos con las políticas y prácticas actuales de una organización. Esto permite a los equipos de cumplimiento identificar rápidamente brechas, solapamientos o posibles infracciones, y recibir recomendaciones prácticas para la actualización de políticas. Las herramientas basadas en IA también pueden realizar un seguimiento de los cambios regulatorios en tiempo real, generando resúmenes concisos y alertando a las partes interesadas relevantes sobre nuevas obligaciones u oportunidades, reduciendo significativamente el esfuerzo manual y el riesgo de descuido.

Los sistemas de IA de Agentic pueden monitorear de forma autónoma múltiples jurisdicciones regulatorias e iniciar de forma proactiva revisiones o actualizaciones de políticas cuando se implementan nuevos requisitos ESG.

detectados, orquestar flujos de trabajo internos para el cumplimiento interdepartamental e incluso ayudar a redactar respuestas o divulgaciones iniciales a los reguladores.

Por ejemplo, en un caso de uso en tiempo real, la IA con agentes puede analizar continuamente las publicaciones oficiales de los reguladores internacionales y, al detectar una nueva norma ESG, actualizar automáticamente los documentos de políticas internas, crear acciones personalizadas para los equipos de cumplimiento y enviar notificaciones a las unidades de negocio afectadas, todo ello en cuestión de minutos tras la publicación de la normativa. Sin embargo, al reconocer la importancia del control institucional y la rendición de cuentas, muchas organizaciones pueden implementar un enfoque de intervención manual, donde las recomendaciones, actualizaciones y acciones impulsadas por la IA se envían a expertos humanos para su revisión y aprobación antes de que se tomen decisiones finales o se divulguen públicamente. Esto garantiza que, si bien la IA aporta velocidad y coherencia a los procesos de políticas ESG, los juicios críticos y los controles finales permanecen en manos de profesionales experimentados. Para las instituciones financieras globales que se desenvuelven en un panorama regulatorio ESG en constante evolución, tanto el análisis de políticas tradicional como el de IA con agentes, combinado con la supervisión humana, ofrecen una forma escalable y coherente de mantener el cumplimiento, optimizar la elaboración de informes y perseguir con seguridad los objetivos de sostenibilidad.

El valor de MongoDB va más allá de la gestión de datos ESG, acelerando la productividad de desarrolladores y equipos de ciencia de datos. Su modelo de datos intuitivo, herramientas analíticas e integraciones de IA optimizan el desarrollo y la implementación de aplicaciones basadas en datos, lo que convierte a MongoDB en un elemento clave para que las organizaciones impulsen sus agendas ESG de forma eficiente.

La Figura 11.8 representa una arquitectura de solución ESG empresarial con los cuadros etiquetados con una hoja donde se puede implementar MongoDB para respaldar los servicios de análisis de datos ESG.




Figura 11.8: Plan para la arquitectura de la solución ESG empresarial utilizando MongoDB

Esto ilustra una arquitectura de solución ESG completa y resalta los puntos de integración donde se puede implementar MongoDB para respaldar la recopilación, el análisis y los informes de datos en todos los dominios ESG.

Procesamiento de pagos directos impulsado por IA

El sector de pagos está experimentando una rápida transformación. A medida que los clientes corporativos exigen servicios más rápidos, inteligentes y eficientes, las instituciones financieras están...

recurriendo a la IA para permitir la toma de decisiones y la automatización basadas en datos en tiempo real. Para liberar estos beneficios no solo es fundamental la IA en sí, sino también la tecnología fundamental que la sustenta, en particular una infraestructura de datos flexible, escalable y de alto rendimiento como MongoDB.

Esta sección explora cómo el procesamiento de pagos directo (STP), la ejecución perfecta de extremo a extremo de transacciones de pago sin intervención manual, está siendo revolucionado por la IA, y cómo MongoDB proporciona una columna vertebral fundamental para esta transformación.

Perspectivas de negocio

La industria de pagos se encuentra en la cúspide de una profunda transformación, impulsada por la IA. Con el auge de las transacciones en tiempo real, las expectativas de la banca digital y

Ante la complejidad de los requisitos de cumplimiento, los bancos y las instituciones financieras se ven sometidos a una creciente presión para ofrecer servicios más inteligentes, automatizados y personalizados. La IA ya no es solo una iniciativa de innovación; se está convirtiendo en un imperativo empresarial.

Varias fuerzas están convergiendo para hacer de la IA una piedra angular del procesamiento de pagos modernos:

- Expectativas del cliente: tanto los clientes minoristas como corporativos ahora exigen información en tiempo real, experiencias de pago fluidas y servicios predictivos como pronósticos de flujo de caja o alertas de anomalías.
- Complejidad operativa: los flujos de trabajo manuales tradicionales de conciliación de pagos, control de fraude y enrutamiento son cada vez más insostenibles debido al crecimiento de los volúmenes de transacciones.
- Presiones competitivas: Las empresas disruptivas de tecnología financiera y los bancos nativos digitales están aprovechando la IA para diferenciarse. Los bancos tradicionales corren el riesgo de quedarse atrás si no evolucionan con rapidez.
- Exigencias regulatorias: regulaciones como PSD2, ISO 20022 y esquemas de pago en tiempo real (por ejemplo, RTP, FedNow) requieren que las instituciones financieras modernicen la infraestructura y los flujos de trabajo de datos, lo que se alinea bien con la naturaleza hambrienta de datos de la IA.

En la banca corporativa, la adopción de la IA es particularmente estratégica. Según un estudio de Celent, el 73 % de los bancos corporativos reportaron claras oportunidades de ingresos derivadas de las inversiones en analítica avanzada. Por otro lado, el 30 % de los bancos que están incrementando su inversión en tecnología de pagos han considerado la IA como una alta prioridad [1].

Este énfasis no se pone sólo en eficiencias incrementales, sino también en nuevos modelos de negocios y servicios de valor agregado monetizables, como paneles financieros en tiempo real, pronósticos automatizados y herramientas de liquidez inteligentes.

El papel de GenAI

La aparición de GenAI y LLM ha añadido nuevas dimensiones al papel de la IA en los pagos:

- Interfaces de lenguaje natural: los clientes ahora pueden consultar datos de pago de manera conversacional ("¿Cuáles son mis cuentas por cobrar pendientes de más de \$10,000 este trimestre?"), lo que transforma la experiencia del usuario
- Generación y prueba de código: las herramientas GenAI mejoran la productividad del desarrollador, lo que permite una creación más rápida de lógica de procesamiento de pagos, validaciones y
- verificaciones de cumplimiento Resumen e informes de datos: los LLM pueden sintetizar grandes volúmenes de datos de transacciones en información, resúmenes o informes regulatorios, lo que reduce la dependencia del manejo manual de datos

Sin embargo, la aplicación de GenAI introduce desafíos en materia de seguridad de datos, explicabilidad y cumplimiento normativo, especialmente cuando se maneja información financiera confidencial, lo que hace que la arquitectura y la gobernanza de datos sean facilitadores críticos.




Figura 11.9: Factores clave de los pagos

Este diagrama ilustra la arquitectura fundamental de los sistemas de pago en tiempo real modernos y muestra cómo el núcleo de procesamiento central gestiona flujos de trabajo de pago integrales al integrar capacidades de entrada como personalización en tiempo real, categorización automatizada, prevención de fraude y monitoreo de cumplimiento con servicios de salida que incluyen ajustes de datos, integración de procesos, liquidación de pagos y ejecución 24 horas al día, 7 días a la semana para permitir un procesamiento de pagos seguro, continuo y sin inconvenientes con capacidades operativas en tiempo real.

El éxito de la IA en los pagos depende fundamentalmente de una infraestructura de datos robusta.

Los modelos de IA son tan buenos como los datos con los que se entrenan, y la información que generan es tan fiable como los sistemas que gestionan esos datos. Aquí es donde MongoDB desempeña un papel fundamental:

- Capa de datos unificada: MongoDB permite a las organizaciones unificar fuentes de datos dispares (mensajes de pago, datos de cuentas, perfiles de clientes y registros) en una única vista, estructurada y lista para análisis o procesos de aprendizaje automático.
- Análisis en tiempo real y preparación para IA: su capacidad para soportar streaming, series de tiempo y cargas de trabajo transaccionales de gran volumen garantiza que las aplicaciones de IA sean receptivas y escalables.
- Experiencia de desarrollador moderna: el rico ecosistema de desarrolladores de MongoDB, que se integra con Python, Spark, TensorFlow y bases de datos vectoriales, lo hace ideal para crear e iterar funciones impulsadas por IA.

Con una base de datos unificada, escalable y preparada para IA, MongoDB permite a los proveedores de pagos aprovechar la IA con velocidad, precisión y confianza, impulsando la innovación y garantizando al mismo tiempo la confianza en cada transacción.

A pesar de la promesa, la integración de IA en STP presenta importantes desafíos en materia de datos:

- Volumen y variedad: Los sistemas de pago procesan millones de transacciones en diversos formatos y de fuentes dispares.
- Procesamiento en tiempo real: muchas aplicaciones de IA dependen de la transmisión o del procesamiento de datos casi en tiempo real.
- Calidad y normalización de los datos: los formatos heredados y las estructuras de datos inconsistentes obstaculizan el rendimiento del modelo
- Auditabilidad y gobernanza: la IA, especialmente GenAI, requiere un manejo transparente de los datos para el cumplimiento normativo.

Estos desafíos exigen una plataforma de base de datos ágil y escalable que gestione datos estructurados, semiestructurados y no estructurados. MongoDB ofrece capacidades únicas adaptadas a sistemas STP basados en IA:

- Modelado de datos flexible: El modelo orientado a documentos de MongoDB permite la integración fluida de diversas fuentes de datos financieros, como historiales de transacciones, facturas y datos de mercado, en un formato unificado. Esta flexibilidad es...

crucial para la previsión precisa del flujo de caja o para soportar varios esquemas de pago, incluido ISO 20022, facilitando decisiones de enrutamiento inteligentes.

- Consultas de alto rendimiento: las capacidades de indexación y agregación de la base de datos permiten un análisis rápido de patrones de transacciones, lo que ayuda a detectar actividades fraudulentas.
- Manejo seguro de datos: características como el cifrado en reposo y en tránsito, junto con el control de acceso basado en roles, garantizan que los datos financieros confidenciales estén protegidos durante el análisis.
- Validación de datos: la validación de esquema incorporada ayuda a identificar y corregir anomalías en los datos de pago, lo que reduce la necesidad de intervención manual.
- Procesamiento de datos en tiempo real: con funciones como flujos de cambio y recopilaciones de series de tiempo, MongoDB permite el seguimiento y análisis en tiempo real de las transacciones financieras, lo que facilita obtener información oportuna sobre las posiciones de efectivo.
- Integración con herramientas de análisis: la compatibilidad de MongoDB con herramientas como Apache Spark y su propio marco de agregación admite consultas analíticas complejas necesarias para los modelos de pronóstico.
- Resiliencia operativa: las capacidades de replicación y fragmentación de MongoDB garantizan alta disponibilidad y escalabilidad, que son esenciales para procesar y redirigir los pagos de manera eficiente.
- Preparación para múltiples nubes e híbridas: MongoDB Atlas, la plataforma en la nube completamente administrada, permite a los bancos ejecutar cargas de trabajo de IA en entornos locales, de nube pública o híbridos, lo que es fundamental para las necesidades de cumplimiento y residencia de datos en la banca global.

El objetivo final es acelerar el desarrollo y la adopción de IA y, al mismo tiempo, permitir el análisis en tiempo real como un facilitador tecnológico clave para el procesamiento de pagos modernos.

El camino por delante

A medida que la industria de pagos entra en una nueva fase de digitalización, la fusión de la IA y una infraestructura de datos escalable definirá a los líderes del futuro. STP ya no es una aspiración técnica; es un imperativo estratégico. MongoDB permite a los bancos lograrlo.

Visión: simplificar la gestión, el análisis y la gestión de datos de pagos en tiempo real. Al invertir hoy en arquitecturas de datos flexibles y tecnologías que facilitan la IA, los bancos no solo mejorarán su oferta actual, sino que también sentarán las bases para la innovación continua del futuro.

Mercados de capitales

El sector de los mercados de capitales se enfrenta a retos únicos en la gestión de grandes cantidades de datos diversos en un entorno dinámico y de alto riesgo. Las instituciones financieras modernas requieren plataformas de datos flexibles y escalables que puedan satisfacer las demandas de las operaciones comerciales con un uso intensivo de datos. Una arquitectura de datos eficaz permite la integración de las tendencias del mercado en tiempo real, fuentes de datos alternativas, información regulatoria y perfiles de clientes, a la vez que facilita la conexión fluida entre las diversas funciones del sector de los mercados de capitales.

La IA puede abordar varios desafíos de la industria de servicios financieros, incluidos los siguientes:

- Gestión de riesgos: mejora la resiliencia a la volatilidad del mercado a través del monitoreo en tiempo real, la toma de decisiones adaptativa y la mitigación automatizada de riesgos, reduciendo así el error humano.
- Análisis de datos: mejora el procesamiento de datos al ingerir sin problemas entradas no estructuradas, como opiniones de noticias y datos de redes sociales, aprovechando las soluciones GenAI y RAG para obtener análisis más profundos y conocimientos más precisos.
- Cumplimiento normativo: agiliza las operaciones al automatizar los informes, detectar anomalías, prevenir el fraude y mejorar la auditabilidad.
- Servicio al cliente: mejora la colaboración entre humanos e IA para optimizar el servicio al cliente con asistentes de IA, al tiempo que automatiza los flujos de trabajo para que las instituciones financieras sean más ágiles, receptivas y rentables.

Las plataformas de datos modernas con una robusta ingesta de datos de alto rendimiento, análisis en tiempo real, seguridad avanzada y compatibilidad con datos de series temporales fortalecen la capacidad de las organizaciones de servicios financieros para obtener información útil e impulsar una toma de decisiones más inteligente. Las capacidades de IA y las tecnologías de búsqueda vectorial permiten que los mercados de capitales se adapten a las condiciones cambiantes del mercado y a los cambios regulatorios.

Requisitos y necesidades del cliente. Ya sea transformando la gestión de datos de mercado, optimizando las estrategias comerciales, optimizando la gestión de riesgos o agilizando los informes de cumplimiento, la arquitectura de datos adecuada proporciona la agilidad necesaria para innovar y destacar en un panorama de servicios financieros en constante evolución.

Reimaginando la gestión de carteras de inversión con IA de agencia

La gestión de riesgos en los mercados de capitales es cada vez más compleja y está basada en datos, lo que plantea importantes desafíos para los gestores de carteras de inversión. La necesidad de procesar grandes cantidades de datos diversos, desde datos de mercado en tiempo real hasta datos no estructurados de redes sociales, exige un nivel de flexibilidad y escalabilidad que los sistemas tradicionales tienen dificultades para mantener.

Los agentes de IA, un tipo de IA que puede operar de forma autónoma y tomar medidas basadas en objetivos e interacciones del mundo real, están llamados a transformar la gestión de las carteras de inversión [2]. Según Gartner, el 33 % de las aplicaciones de software empresarial incluirán IA con agentes para 2028, frente a menos del 1 % en 2024. Al menos el 15 % de las decisiones laborales diarias se toman de forma autónoma a través de agentes de IA [3]. La arquitectura de datos adecuada puede ayudar a estos agentes de IA a transformar eficazmente el panorama de la gestión de carteras de inversión. Al aprovechar la combinación de LLM, RAG y las capacidades avanzadas de Vector Search, los agentes de IA pueden analizar vastos conjuntos de datos financieros, detectar patrones y adaptarse dinámicamente en tiempo real a las condiciones cambiantes. Esta inteligencia avanzada optimiza la toma de decisiones y permite a los gestores de carteras optimizar el rendimiento de las carteras, gestionar los riesgos del mercado de forma más eficaz y realizar análisis precisos del impacto de los activos.

Gestión inteligente de carteras de inversión. La gestión de carteras de inversión consiste en seleccionar, equilibrar y supervisar una combinación de activos financieros, como acciones, bonos, materias primas y derivados, para lograr un mayor retorno de la inversión (ROI), gestionando el riesgo de forma eficaz y proactiva. Implica una asignación de activos inteligente, la diversificación para mitigar la volatilidad del mercado, la monitorización continua de las condiciones del mercado y el rendimiento de los activos subyacentes para mantener la coherencia con los objetivos de inversión.

Para mantener su relevancia hoy en día, la gestión de carteras de inversión requiere la integración de datos alternativos diversos y no estructurados, como noticias financieras, la opinión en redes sociales e indicadores macroeconómicos, junto con datos de mercado estructurados, como movimientos de precios, volúmenes de negociación, índices, diferenciales y registros históricos de ejecución. Esta compleja integración de datos presenta un nuevo nivel de sofisticación en el análisis de carteras, como se describe en la Figura 11.10. Requiere una plataforma de datos flexible, escalable y unificada que pueda almacenar, recuperar y gestionar eficientemente estos diversos conjuntos de datos y allanar el camino para el desarrollo de soluciones de gestión de carteras de última generación.




Figura 11.10: Análisis de la cartera de inversiones

Este diagrama ilustra la arquitectura integral de los sistemas modernos de análisis de carteras de inversión, mostrando cómo el motor de análisis central integra diversas entradas de datos, incluidos datos comerciales (transacciones históricas, órdenes y mejores métricas de ejecución), datos de mercado (precios, volúmenes, índices, rendimientos, calificaciones, datos de la cartera de órdenes, volatilidad y diferenciales) y datos macroeconómicos no estructurados de múltiples formatos (imagen, texto, video y audio) para brindar funciones básicas de gestión de cartera, incluida la gestión de riesgos, la generación de recomendaciones, la optimización, la reasignación y las capacidades de backtesting que permiten la toma de decisiones inteligente y la mitigación proactiva del riesgo de mercado a través del esquema flexible de MongoDB para la ingesta acelerada de datos en varias fuentes.

La incorporación del esquema flexible de MongoDB acelera la ingesta de datos de diversas fuentes, como feeds de mercado en tiempo real, registros históricos de rendimiento y métricas de riesgo. Las nuevas soluciones de gestión de carteras, habilitadas con datos alternativos, facilitan una toma de decisiones más inteligente y la mitigación proactiva del riesgo de mercado. Este cambio de paradigma permite obtener información más profunda, mejora la generación de alfa y perfecciona la reasignación de activos con mayor precisión, lo que subraya el papel crucial de los datos en la gestión inteligente de carteras.

Cómo MongoDB facilita la gestión de carteras con IA. La asignación de activos de carteras con IA se ha convertido en una característica deseable de las estrategias de inversión modernas. Al aprovechar el análisis de carteras basado en IA, los gestores de carteras acceden a herramientas avanzadas que ofrecen información adaptada a objetivos financieros y tolerancias al riesgo específicos. Este enfoque optimiza la construcción de la cartera al recomendar una combinación alternativa de activos, desde acciones y bonos hasta fondos cotizados (ETF) y oportunidades emergentes, a la vez que evalúa continuamente la evolución del mercado.

La siguiente figura ilustra un flujo de trabajo propuesto para la gestión de cartera de inversiones impulsada por IA que incorpora diversos datos del mercado, incluidos el precio de las acciones, el índice de volatilidad (VIX) e inductores macroeconómicos como el PIB, la tasa de interés y la tasa de desempleo, en una capa de análisis de IA para generar información procesable y más inteligente:




Figura 11.11: Flujo de trabajo de gestión de cartera impulsado por IA

Este diagrama ilustra la arquitectura integral de los sistemas de gestión de carteras de inversión basados en IA. Muestra un flujo de trabajo de tres etapas que comienza con el procesamiento de la ingesta de datos de eventos de mercado (como PIB, tasas de interés, desempleo, noticias y redes sociales mediante API, conectores y activadores) y datos de mercado, como precios de acciones, VIX, ETF, bonos y datos de materias primas, mediante el procesamiento de flujos y la recopilación de series temporales. Posteriormente, se incorpora a las capacidades centralizadas de IA y análisis (como análisis de riesgo de cartera, análisis de impacto en el mercado, análisis de sentimiento, macroeconomía y análisis de volatilidad mediante agregación, búsqueda vectorial, incrustación y análisis). Finalmente, proporciona información práctica mediante asistentes de IA (como responder a las preguntas de los gestores de cartera mediante indicaciones y consultas) e informes completos (explicaciones y recomendaciones mediante gráficos Atlas e informes) para facilitar la toma de decisiones de inversión inteligentes y basadas en datos para los gestores de cartera.

El versátil modelo de documentos de MongoDB ofrece una forma más intuitiva de almacenar y recuperar datos estructurados, semiestructurados y no estructurados. Esto se alinea con la forma en que los desarrolladores estructuran los objetos dentro de las aplicaciones.

En los mercados de capitales, las series temporales se utilizan a menudo para almacenar datos comerciales y de mercado basados en el tiempo. Las colecciones de series temporales de MongoDB son óptimas para analizar datos a lo largo del tiempo. Están diseñadas para procesar eficientemente grandes volúmenes de datos de mercado con alto rendimiento y escalabilidad dinámica. Descubrimiento de información y patrones de...

Las recopilaciones de series de tiempo de MongoDB son más fáciles y eficientes debido a mecanismos de ingesta y recuperación subyacentes más rápidos.

Al aprovechar el panel de inteligencia empresarial de MongoDB Atlas Charts y evaluar información de inversión avanzada generada por IA, los administradores de cartera obtienen acceso a capacidades sofisticadas que integran información de alta dimensión derivada de diversos conjuntos de datos, revelando nuevos patrones que pueden conducir a una mejor toma de decisiones para la generación de alfa y un mayor rendimiento de la cartera.

MongoDB Atlas Vector Search desempeña un papel fundamental en el análisis del sentimiento de las noticias del mercado al permitir la recuperación consciente del contexto de artículos de noticias relacionados.

Las búsquedas tradicionales basadas en palabras clave a menudo no logran captar las relaciones semánticas entre las noticias, mientras que la Búsqueda Vectorial, impulsada por incrustaciones, permite una comprensión más contextual de cómo se relacionan los diferentes artículos con el sentimiento bursátil. Las siguientes funciones facilitan un enfoque más contextual y preciso para el análisis del sentimiento bursátil:

- Almacenamiento de noticias como vectores: Al ingerir noticias sobre acciones, cada artículo se vectoriza como una representación numérica de alta dimensión mediante un modelo de incrustación. Estas incrustaciones encapsulan el significado y el contexto del texto, en lugar de solo palabras individuales. Los artículos de noticias sin procesar se incrustan y almacenan en MongoDB como vectores.
- Búsqueda de noticias relacionadas: La búsqueda vectorial se utiliza para encontrar noticias basadas en algoritmos de similitud, incluso si no contienen exactamente la misma información bursátil. Esto ayuda a identificar patrones y tendencias en múltiples noticias según la similitud contextual.
- Mejora del cálculo del sentimiento: En lugar de basarse en un solo sentimiento de noticias, se agrega una puntuación final de sentimiento a partir de múltiples artículos relacionados con contenido similar y relevante. Esto evita que un artículo atípico influya en el resultado y proporciona una visión más integral.

Sentimiento de las noticias del mercado.

MongoDB Atlas Vector Search transforma el análisis del sentimiento de las noticias del mercado yendo más allá de las simples palabras clave para capturar un contexto y conexiones más profundas, lo que permite obtener información más inteligente y confiable para tomar mejores decisiones de inversión.

Gestión inteligente de carteras de inversión con agentes de IA. Los agentes de IA están posicionados para revolucionar la gestión de carteras al pasar de una toma de decisiones basada en reglas a una adaptativa, contextual e impulsada por IA. Las aplicaciones de gestión de carteras basadas en IA aprenden, se adaptan y optimizan continuamente las estrategias de inversión de forma más proactiva y eficaz. El futuro no consiste en que la IA sustituya a los gestores de carteras, sino en que los humanos y la IA colaboren para crear carteras más inteligentes, adaptables y con mayor conciencia de riesgo. Los gestores de cartera que aprovechan la IA obtienen una ventaja competitiva y un conocimiento más profundo para mejorar significativamente el rendimiento de sus carteras.

La solución ilustrada en la Figura 11.12 incluye una aplicación de ingesta de datos, tres agentes de IA y una aplicación de conocimiento del mercado que trabajan en armonía para crear un enfoque más inteligente y basado en conocimientos para la gestión de cartera.

La aplicación de ingesta de datos recopila continuamente datos de mercado y los almacena en MongoDB como series temporales o colecciones estándar. Los conjuntos de datos que se ingieren incluyen los siguientes:

- Datos de mercado: Recopila y procesa datos de mercado en tiempo real, incluyendo precios, volúmenes, actividad comercial y VIX. Noticias de
- mercado: Captura y extrae noticias relacionadas con el mercado y las acciones. Los datos de noticias se vectorizan y almacenan en MongoDB. Indicadores de
- mercado: Recupera indicadores financieros macroeconómicos clave, como el PIB, la tasa de interés y la tasa de desempleo.

El agente de análisis de mercado y el agente de noticias del mercado tienen flujos de trabajo analíticos de IA. Se ejecutan según una programación diaria de forma totalmente automatizada, generando el resultado esperado y almacenándolo en MongoDB. El agente asistente de mercado cuenta con un flujo de trabajo más dinámico y está diseñado para asistir al gestor de cartera. Funciona con ingeniería rápida y toma de decisiones estratégica. El agente asistente de mercado puede responder preguntas sobre la reasignación de activos y los riesgos del mercado según las condiciones actuales del mercado y proporciona la nueva información basada en IA a los gestores de cartera.

Cada agente desempeña un papel distinto en el flujo de trabajo general para producir información inteligente:

- Agente de análisis de mercado: Analiza las tendencias, la volatilidad y los patrones del mercado para generar información sobre el riesgo de los activos de la cartera.
- Agente de noticias del mercado: Evalúa la percepción de las noticias sobre cada activo mediante el análisis de noticias que pueden afectar directa e indirectamente el rendimiento de la cartera. Este agente está potenciado por MongoDB Vector Search. Agente asistente
- de mercado: Responde, a petición y mediante una solicitud, las preguntas del gestor de cartera sobre las tendencias del mercado, la exposición al riesgo y la asignación de la cartera utilizando fuentes de datos e información generada por otros agentes.

La aplicación de análisis de mercado es una capa de visualización que proporciona gráficos, paneles e informes a los gestores de cartera, con información práctica sobre inversiones a partir de los resultados generados por agentes de IA. Esta información se genera automáticamente según un programa diario predeterminado y se presenta a los gestores de cartera.




Figura 11.12: Gestión de cartera de inversiones impulsada por agentes de IA de MongoDB

Como se ilustra aquí, la gestión de la cartera de inversiones está impulsada por Agentes de IA de MongoDB, que muestran cómo los agentes de IA especializados (agente de análisis de mercado, agente asistente de mercado y agente de noticias de mercado) aprovechan las capacidades de orquestación de gráficos y LLM para procesar datos de la aplicación de ingesta de datos (datos de mercado, noticias e indicadores) a través de la búsqueda vectorial de MongoDB.

funcionalidad, lo que permite una integración perfecta con la aplicación de información del mercado (gráficos, paneles e informes) para brindar respuestas inteligentes y rápidas a los gestores de carteras de inversión a través de un ecosistema unificado impulsado por IA que Combina procesamiento de datos en tiempo real, análisis avanzados y conversación. Interfaces para una mejor toma de decisiones de inversión.




Figura 11.13: Arquitectura del agente ReAct del asistente de mercado

Los agentes de IA permiten a los gestores de cartera adoptar un enfoque inteligente y basado en el riesgo. Analizando el impacto de las condiciones del mercado en la cartera y su inversión objetivos. Los agentes de IA aprovechan las potentes capacidades de MongoDB, incluida la Marco de agregación y búsqueda vectorial, combinado con incrustación y GenAI modelos para realizar análisis inteligentes y ofrecer carteras reveladoras recomendaciones.

Para obtener más detalles sobre los agentes de IA, [Capítulo 2](#), ¿Qué distingue a GenAI?, TRAPO, y consulte Agentic AI Apart.

El papel cada vez más importante de la IA en los servicios financieros

Al cerrar esta sección, queda claro que la IA es una fuerza poderosa que está transformando el futuro. de servicios financieros, y MongoDB está facilitando el viaje de transformación de la IA. El éxito es una función de la arquitectura de datos adecuada, la escalabilidad, la calidad y la accesibilidad.

y agilidad. El modelo de documento flexible de MongoDB, la búsqueda vectorial y la plataforma integral de datos para desarrolladores proporcionan la columna vertebral de las aplicaciones de IA. El paso de la IA de la experimentación a la adopción empresarial requiere un replanteamiento estratégico de cómo fluyen los datos, los modelos y las decisiones a través de la organización. Ya sea que estén impulsando la innovación, gestionando el riesgo o creando experiencias de cliente de última generación, las instituciones financieras que lideren la próxima década no solo adoptarán IA, sino que la integrarán en cada decisión, cada producto y cada interacción con el cliente.

Con el auge de la IA agencial, las instituciones de servicios financieros tienen un gran potencial para redefinir la gestión inteligente del riesgo, optimizar flujos de trabajo complejos y ofrecer experiencias de cliente hiperpersonalizadas. A medida que los agentes autónomos de IA avanzan, ofrecen la posibilidad de transformar la toma de decisiones de reactiva a proactiva, combinando razonamiento y acción, yendo más allá de la simple respuesta a datos hacia una comprensión más profunda de la causa y el efecto, dotando a las instituciones financieras de mayor precisión y soluciones más inteligentes. De cara al futuro, quienes aprovechen eficazmente el potencial de la IA estarán mejor posicionados para liderar este panorama de servicios financieros en rápida evolución, estableciendo un nuevo estándar de agilidad, innovación y confianza del cliente.

Los siguientes son ejemplos adicionales de cómo la IA está transformando las finanzas. servicios:

- **Análisis avanzado de comportamiento del cliente y KYC:** Vector Search permite la creación de perfiles sofisticados de clientes mediante la correlación de patrones de comportamiento con fuentes de datos no estructurados, como correos electrónicos, actividad en redes sociales y narrativas de transacciones. Esto proporciona una visión más profunda de los perfiles de riesgo del cliente y permite procesos de verificación de identidad más precisos.
- **Investigación de mercado inteligente:** Los sistemas de IA pueden sintetizar rápidamente información de mercado mediante la búsqueda en amplios repositorios de informes de investigación, presentaciones de resultados, informes regulatorios y fuentes de noticias. La similitud semántica permite a los analistas descubrir conexiones no obvias y tendencias emergentes en diferentes segmentos de mercado y geografías.
- **Inteligencia documental de gran tamaño para presentaciones regulatorias:** El procesamiento de documentos con IA transforma la forma en que las instituciones financieras gestionan presentaciones regulatorias complejas. Los sistemas pueden extraer, validar y contrastar automáticamente.

datos en cientos de páginas de documentos regulatorios, lo que garantiza el cumplimiento y reduce el tiempo de revisión manual de semanas a horas.

- Generación de código de aplicaciones financieras impulsada por IA: los equipos de desarrollo aprovechan la IA para acelerar la creación de aplicaciones financieras mediante la generación de fragmentos de código compatibles, integraciones de API y lógica de validación regulatoria. Esto permite una implementación más rápida de nuevos productos financieros manteniendo estrictos estándares de seguridad y cumplimiento.
- Precios dinámicos de productos de banca minorista: La fijación de precios en tiempo real basada en IA permite a los bancos ajustar instantáneamente las comisiones y los descuentos según las condiciones del mercado, los costes del servicio y el comportamiento del cliente. Mediante el análisis de datos en tiempo real, la IA puede optimizar los precios para mejorar la competitividad, la rentabilidad y la capacidad de respuesta, garantizando así agilidad en entornos de pago dinámicos.
- Previsión de liquidez y flujo de caja de la tesorería: El posicionamiento dinámico de efectivo mediante paneles de control con IA proporciona visibilidad y predicción del flujo de caja en tiempo real. Al aprovechar la IA en el análisis de escenarios y la modelización de diversas condiciones económicas, los bancos pueden ajustar proactivamente sus estrategias de financiación.
- Enrutamiento inteligente de pagos: El enrutamiento inteligente de pagos basado en IA aprovecha la toma de decisiones dinámica y el aprendizaje continuo para optimizar cada transacción en tiempo real. La IA analiza diversas condiciones, comisiones, tipos de cambio y patrones históricos para seleccionar proactivamente las rutas más eficientes y rentables. A medida que los ecosistemas de pagos se vuelven más complejos y globales, un enrutamiento inteligente basado en IA es esencial para adaptarse a las regulaciones cambiantes, el aumento del volumen de transacciones y la creciente demanda de velocidad, rentabilidad y fiabilidad.

Estas aplicaciones emergentes demuestran cómo la IA continúa ampliando los límites de lo posible en los servicios financieros, permitiendo a las instituciones operar con mayor inteligencia, eficiencia y enfoque en el cliente que nunca.

Para obtener más información y recursos, visite la página de MongoDB para servicios financieros en: <https://www.mongodb.com/solutions/industries/financial-services>.

Resumen

En este capítulo, hemos explorado el impacto transformador de la IA en el sector de servicios financieros, rastreando su evolución desde el análisis predictivo hasta la GenAI y, ahora, la IA agente. Hemos visto cómo estas tecnologías están revolucionando la gestión del conocimiento empresarial (EKM), la experiencia del cliente, la prevención de delitos financieros, el análisis ESG, las solicitudes de crédito y el procesamiento de pagos.

El sector de servicios financieros se encuentra en un momento crucial donde la IA no solo está mejorando los procesos existentes, sino que está reimaginando fundamentalmente cómo operan las instituciones financieras y cómo generan valor. Desde chatbots inteligentes que brindan atención al cliente personalizada hasta sofisticados sistemas de detección de fraude que anticipan nuevos vectores de ataque, la IA está permitiendo niveles sin precedentes de eficiencia, personalización y seguridad.

De cara al futuro, la continua evolución de la IA agencial promete cambios aún más profundos, con sistemas autónomos capaces de percibir, razonar y actuar dentro de parámetros definidos. Estos agentes inteligentes actuarán cada vez más como gestores de relaciones digitales, responsables de cumplimiento virtual y analistas de riesgos automatizados, trabajando junto a expertos humanos para lograr mejores resultados para las instituciones financieras y sus clientes.

La clave de esta transformación es la infraestructura de datos subyacente. Plataformas de datos modernas y flexibles como MongoDB proporcionan la base que los sistemas de IA necesitan para acceder, analizar y actuar sobre diversos datos en tiempo real. La integración de inteligencia específica para cada dominio, como los modelos de integración especializados en finanzas, mejora aún más la precisión y la relevancia de las aplicaciones de IA en este sector altamente regulado.

Como hemos visto en diversos casos prácticos, desde el chatbot GenAI de Asia Bank hasta la plataforma de datos climáticos de Ambee y la solución de análisis crediticio de Base39, las instituciones financieras que adoptan la IA y se basan en bases de datos sólidas obtienen importantes ventajas competitivas. Pueden tomar mejores decisiones con mayor rapidez, ofrecer experiencias de cliente más personalizadas y desenvolverse con mayor confianza en entornos regulatorios complejos.

A medida que avanzamos hacia el siguiente capítulo, sobre seguros, veremos cuántos de estos mismos... Se están aplicando tecnologías y enfoques de IA para transformar otro aspecto crítico

sector de la industria de servicios financieros, con sus propios desafíos únicos y oportunidades.

Referencias

1. Informe Celent: Aprovechar los beneficios de la IA en los pagos:

<https://www.mongodb.com/resources/solutions/use-cases/celent-report-harnessing-the-benefits-of-ai-in-payments>

2. Desmitificando a los agentes de IA: una guía para principiantes:

<https://www.mongodb.com/resources/basics/artificial-intelligence/ai-agents>

3. Los agentes inteligentes en IA realmente pueden trabajar solos. Aquí te explicamos cómo.

<https://www.gartner.com/en/articles/agente-inteligente-en-ai>

12

RegData, MongoDB y Voyage IA: Protección de datos semánticos en FSI

La IA se ha convertido en un componente cada vez más importante de la transformación de la banca moderna. Sin embargo, a medida que la industria de servicios financieros (SFI) a nivel mundial adopta las tecnologías de IA, se enfrenta a un desafío crucial: cómo aprovechar la IA sin comprometer los requisitos de privacidad, cumplimiento normativo y control que definen al sector financiero.

Este capítulo explora cómo MongoDB, RegData y Voyage AI han formado una sólida alianza para abordar este desafío mediante la protección semántica de datos, una metodología sofisticada que permite a las instituciones financieras preservar la calidad y la utilidad de los resultados de IA, a la vez que aplican rigurosos estándares de seguridad de datos. También facilita la implementación segura de agentes de IA, que actúan cada vez más de forma autónoma sobre información regulada en flujos de trabajo financieros complejos. Juntas, estas tecnologías ofrecen una solución integrada adaptada a las exigentes exigencias de alta seguridad y alto riesgo de la IA en los servicios financieros.

Al final de este capítulo comprenderás lo siguiente:

- Por qué los métodos de protección tradicionales, como el cifrado y el enmascaramiento, resultan insuficientes en los servicios financieros impulsados por IA
- Cómo la protección de datos semánticos preserva el significado, el contexto y el formato sin exponer datos confidenciales
- Los componentes centrales de una arquitectura de IA segura para instituciones financieras, desde la tokenización hasta la decoración inmediata
- Cómo las integraciones específicas de dominio mejoran tanto la protección como el rendimiento en aplicaciones de IA financiera
- Patrones de implementación seguros para agentes de IA, incluido el modelo Protocolo de contexto (MCP) y estrategias de nube híbrida
- Estrategias de cumplimiento alineadas con marcos como GDPR, FINMA y la Ley de IA de la UE

El dilema de la protección de datos en la IA financiera

Las instituciones financieras se encuentran en la intersección de dos fuerzas poderosas, pero aparentemente contradictorias: el impulso por innovar con IA y el mandato de proteger los datos sensibles. Los bancos y las empresas de servicios financieros poseen vastos repositorios de información altamente regulada, desde información de identificación personal (PII), que incluye datos como nombres, direcciones y números de la seguridad social que pueden identificar a una persona, hasta datos de identificación del cliente (CID), que se refieren a cualquier información que pueda usarse para identificar a un cliente o consumidor específico, e historiales de transacciones. Estos datos representan tanto su mayor activo para la innovación en IA como su mayor vulnerabilidad. Si se manejan incorrectamente, pueden propiciar fraudes, violaciones de la privacidad o costosas...

Sanciones regulatorias. Si se limita demasiado, se vuelve inutilizable para la innovación.

Los enfoques tradicionales de seguridad de datos, como el cifrado completo, el enmascaramiento de datos y el acceso restringido, suelen inutilizar los datos para las aplicaciones de IA o reducir significativamente la calidad de sus resultados. Cuando las instituciones financieras intentan aprovechar los servicios de IA en la nube, se enfrentan a desafíos adicionales, ya que los datos confidenciales pueden salir de sus entornos controlados, lo que las expone a infracciones regulatorias y riesgos de seguridad.

Este dilema ha creado una barrera significativa para la adopción de la IA en los servicios financieros. Según estudios del sector, muchas instituciones financieras citan la seguridad de los datos y las preocupaciones sobre el cumplimiento normativo como obstáculos importantes para la implementación de soluciones avanzadas de IA. Las consecuencias son considerables: innovación limitada, desventaja competitiva e incapacidad para ofrecer los servicios personalizados e inteligentes que los clientes esperan cada vez más.

Los métodos tradicionales de protección de datos resultan insuficientes en contextos de IA por varias razones clave:

- Pérdida de contexto: El enmascaramiento o el cifrado eliminan las relaciones semánticas y el contexto que los modelos de IA necesitan para generar resultados significativos. Un sistema de detección de fraude, por ejemplo, ya no puede detectar patrones de gasto que señalen comportamientos sospechosos.
- Enfoque binario: Los métodos tradicionales suelen adoptar un enfoque de todo o nada: los datos son totalmente accesibles o están completamente restringidos, sin un punto medio para el procesamiento de IA. Por ejemplo, o todos los analistas ven el número de seguro social completo de un cliente, o ninguno lo ve, y ninguna de las dos opciones es adecuada para el procesamiento de IA.

- Protección estática: las reglas fijas para la protección de datos no pueden adaptarse a la naturaleza dinámica y contextual de las interacciones y los casos de uso de la IA. Considere una regla que funciona durante el entrenamiento pero falla cuando el modelo encuentra entradas nuevas en la producción.
- Disminución de la utilidad: Las técnicas de protección excesivamente agresivas reducen significativamente la calidad y la relevancia de los resultados de IA. En estos casos, la información se vuelve tan genérica que ya no resulta útil para los gerentes de relaciones ni para los equipos de producto.

Estas deficiencias explican por qué los enfoques tradicionales son incompatibles con las necesidades de la IA financiera y apuntan a la necesidad de un nuevo paradigma: la protección de datos semánticos.

Entendiendo MongoDB, El enfoque de RegData y Voyage AI para la protección de datos semánticos

La integración de MongoDB, RegData y Voyage AI representa un cambio de paradigma en la forma en que las instituciones financieras pueden proteger la información confidencial, preservando al mismo tiempo la funcionalidad de la IA. A diferencia de los enfoques tradicionales que se centran únicamente en ocultar o restringir los datos, esta solución combinada preserva el significado, el contexto y el formato de la información, a la vez que reemplaza los propios valores confidenciales.

MongoDB proporciona una base de datos flexible y escalable con su modelo de documentos y las funciones de búsqueda vectorial Atlas. RegData aporta su metodología de protección avanzada y su experiencia en cumplimiento normativo.

Voyage AI (adquirida por MongoDB) proporciona integraciones específicas del dominio que comprenden la terminología financiera y...

conceptos. Juntos, crean un enfoque integral para abordar los desafíos únicos de la seguridad de la IA en los servicios financieros.

Esta alianza hace que la adopción de IA sea práctica, no teórica, para los bancos bajo escrutinio regulatorio.

¿Qué es la protección de datos semánticos?

La protección de datos semánticos protege el significado y el contexto de la información, más allá de sus valores brutos o su formato superficial. Mientras que los métodos tradicionales de protección de datos (como el cifrado, el enmascaramiento y el control de acceso) suelen centrarse en proteger los valores o formatos de los datos, la protección de datos semánticos tiene un enfoque más profundo. Sustituye los valores sensibles de forma que se preserve el formato, las relaciones y el contexto normativo, de modo que los sistemas de IA sigan siendo útiles sin exponer identidades reales.

Los principios básicos de la protección de datos semánticos incluyen los siguientes:

- **Protección semántica:** La protección conserva la semántica o los datos originales. Un número de teléfono se reemplaza por otro número de teléfono; el nombre de una ciudad se reemplaza por otro nombre de ciudad.
- **Protección semántica contextual:** La protección depende del significado y el uso de los datos, no solo de su tipo o etiqueta. Por ejemplo, un número de teléfono puede tratarse de forma diferente según sea personal, comercial o público. El nombre de una ciudad puede sustituirse por el de una ciudad de la misma jurisdicción, donde se aplicarán las mismas leyes.

Más allá de estos enfoques fundamentales, la protección semántica de datos incorpora varias capacidades sofisticadas adicionales. La clasificación y los controles de los datos se determinan por la sensibilidad semántica, en lugar de por los tipos de datos simples, lo que garantiza que los niveles de protección coincidan.

El riesgo real y la importancia de la información. El sistema aprovecha modelos semánticos como ontologías, taxonomías o grafos de conocimiento para definir las relaciones y significados de los datos, lo que permite la aplicación coherente de políticas en ecosistemas de datos complejos. Además, la gobernanza de datos se vuelve verdaderamente contextual, con reglas de uso que se adaptan dinámicamente en función del significado contextual de los datos, los roles de los usuarios, los casos de uso previstos y los marcos regulatorios aplicables, como el RGPD, la FINMA o la HIPAA.




Figura 12.1: Arquitectura del marco de protección de datos semánticos y flujo de datos

Este diagrama ilustra los componentes clave de un marco de protección de datos semánticos, mostrando cómo los datos fluyen a través de las etapas de descubrimiento, clasificación, protección y procesamiento seguro, manteniendo la integridad semántica. Demuestra cómo se transforma la información sensible preservando el contexto y el formato, lo que permite a los sistemas de IA procesar datos protegidos sin comprometer la seguridad ni la calidad de los resultados.

El módulo de Descubrimiento y Clasificación analiza los datos de entrada para identificar cualquier información sensible, la clasifica adecuadamente y comprende el contexto y el alcance de la consulta. Con base en estos hallazgos, el módulo de protección de datos aplica la técnica de protección más adecuada para salvaguardar los datos sensibles, garantizando que el método seleccionado se ajuste a la clasificación y la comprensión contextual proporcionadas por el módulo de descubrimiento y clasificación.

El módulo de protección de datos se encarga de proteger los datos sensibles contenidos en la entrada. Con base en la clasificación y el contexto identificados por el módulo de Descubrimiento y Clasificación, se selecciona la técnica más adecuada para proteger los datos sensibles.

RegData admite técnicas que preservan el formato o el tipo de información (p. ej., tokens que coinciden con el formato y la suma de comprobación del Número Internacional de Cuenta Bancaria (IBAN), o la sustitución del nombre de una ciudad por otro del mismo país). Gracias a la lógica semántica adicional, ahora puede elegir la técnica basándose en la comprensión de la información. El resultado son datos tokenizados que pueden ser procesados por LLM públicos sin revelar información de identificación personal (PII).

Técnicas clave en la protección de datos semánticos

La protección de datos semánticos en los servicios financieros se basa en técnicas avanzadas diseñadas para salvaguardar la información confidencial y preservar su utilidad. Analicemos estas técnicas con más detalle.

Tokenización con preservación de formato. Un método de este tipo consiste en tokenizar datos sensibles con , que reemplaza preservación de formato mediante tokens sustitutos que mantienen el mismo formato (longitud, clases de caracteres, patrones) que el original. Por ejemplo, un número IBAN como CH93 0076 2011 6238 5295 7 podría reemplazarse por CH93 [BANK_TOKEN_001], donde el token conserva el formato y oculta los detalles reales de la cuenta. Esta técnica es especialmente útil para datos financieros como números de cuenta, números de tarjetas de crédito, IBAN, códigos de ruta e identificadores de transacciones.

Protección semántica contextual. Otro enfoque eficaz es la Protección Semántica Contextual, que asigna , cual entidades reales a seudónimos consistentes que comparten el mismo tipo y función en los datos. Por ejemplo, analicemos una aplicación de reubicación. Esta aplicación contiene información de ubicación de las personas: de dónde se mudan y adónde se mudan. Si solo nos interesa ocultar las ubicaciones, la protección semántica es suficiente. Reemplazaríamos los nombres de las ciudades con otros nombres aleatorios o con nombres de ciudades del mismo país que el de destino.

Pero si nos interesa asesorar o estimar el coste de la reubicación, incluyendo el coste de la vida y los impuestos locales aplicables en la ubicación de destino, un seudónimo aleatorio no servirá. Aquí es donde entra en juego la protección semántica contextual. El nombre de la ciudad de destino se seudonimizará con el nombre de otra ciudad donde se apliquen las mismas normas o impuestos.

Por ejemplo, la pregunta: "¿Cuál sería el aumento de impuestos si John Smith se mudara a Zúrich?" podría seudonimizarse como "¿Cuál sería el aumento de impuestos si Marcus Reed se mudara a Elsau?". En esta transformación, se conserva la semántica. Marcus Reed sigue siendo claramente identificable como persona (cliente individual). Elsau es un nombre de ciudad legítimo, y las normas fiscales de Elsau son coherentes con las de Zúrich.

También podríamos considerar las transferencias bancarias, donde podríamos seudonimizar los valores IBAN con un esquema que preserve el formato. En cuanto a la protección semántica contextual, elegiríamos IBAN seudonimizados que cumplan con las normas de la empresa.

Por ejemplo, un IBAN de un país europeo determinado sería reemplazado por el IBAN de otro país europeo, mientras que un IBAN estadounidense sería reemplazado por otro IBAN estadounidense.

Por ejemplo, todos los nombres de los clientes podrían ser reemplazados por seudónimos consistentes que preserven su identidad como personas mientras ocultan sus identidades reales.

Al mantener una relación consistente entre los datos a proteger, permitimos que los modelos de IA generen información significativa sin exponer identidades reales.

Partición semántica con clases de token

Esta técnica clasifica los tokens en categorías semánticas (PII, identificadores de cliente, información financiera, ubicación, etc.) y tokeniza cada categoría con su propio espacio de nombres. A continuación, se muestran algunos ejemplos:

- [PII_001] para información personal identificable
- [CID_017] para CID
- [FIN_042] para información financiera

La partición semántica con clases de token permite políticas de protección granulares basadas en el tipo de datos y el contexto, al tiempo que permite que los modelos de IA comprendan la función semántica de cada token.

Tokens deterministas

La tokenización determinista garantiza que la misma entrada siempre genere el mismo token (p. ej., Alice siempre se asigna al mismo token). Esta consistencia es crucial para el razonamiento o diálogo de varios pasos, donde el modelo debe reconocer referencias en las interacciones. Por ejemplo, si un cliente pregunta por "mi cuenta de UBS" en un mensaje y luego se refiere a ella como esa cuenta en un mensaje de seguimiento, los tokens deterministas garantizan que la IA comprenda ambas referencias.

resolverse en la misma entidad, preservando la continuidad.

Construcción de una arquitectura integral de protección semántica

La protección eficaz de datos semánticos va más allá de las técnicas individuales; requiere una arquitectura holística que se integre con todos los componentes del ecosistema de IA de una institución financiera. La alianza MongoDB, RegData y Voyage AI ha sido pionera en este enfoque integral, desarrollando una arquitectura integral que aborda todos los desafíos de seguridad y cumplimiento normativo. Esta sección describe los componentes clave de este marco integrado de protección semántica.




Figura 12.2: Arquitectura de protección semántica de extremo a extremo

Este diagrama muestra el flujo completo de datos a través de un sistema de IA semánticamente protegido, desde la ingesta inicial de datos, pasando por el procesamiento mediante servicios de IA en la nube, hasta la generación segura de resultados. La visualización destaca los puntos de integración entre los sistemas bancarios, las capas de protección, las puertas de enlace API y los servicios en la nube, demostrando cómo los datos sensibles se mantienen protegidos durante todo su ciclo de vida.

Los datos de entrada pueden ser de varios tipos y provenir de diferentes fuentes, como archivos, bases de datos, aplicaciones y archivos de audio. Las llamadas a los LLM públicos se realizan generalmente mediante llamadas a la API a través de una puerta de enlace API. La puerta de enlace API garantiza la protección de la información de identificación personal (PII) antes de enviarla a los LLM públicos. Por lo tanto, la puerta de enlace utiliza servicios de protección para clasificar y proteger los datos sensibles. El módulo de protección de datos reemplaza los campos sensibles con datos tokenizados antes de enviarlos a los LLM.

MongoDB como base con la plataforma de seguridad de datos de RegData.

MongoDB es la plataforma de datos fundamental para esta solución integrada, donde la Plataforma de Seguridad de Datos (DSP) de RegData proporciona la capa de protección especializada. Esta combinación ofrece lo siguiente:

- Almacenamiento de datos unificado: el modelo de documento flexible de MongoDB almacena datos estructurados, semiestructurados y no estructurados en una única plataforma, lo que elimina los silos y simplifica la arquitectura.
- Descubrimiento y clasificación: la identificación automatizada de datos confidenciales dentro de contenido no estructurado por parte de RegData utiliza Técnicas avanzadas como PNL y Entidad Nombrada Reconocimiento (NER), una tecnología que identifica y categoriza entidades específicas en el texto
- Rendimiento escalable: la arquitectura distribuida de MongoDB garantiza que la solución pueda manejar datos financieros a cualquier escala, desde miles hasta miles de millones de registros.

- Selección de la técnica de protección: aplicación inteligente del método de protección más adecuado según el tipo de datos y contexto
- Gestión de bóvedas de tokens: almacenamiento seguro de la correspondencia entre los valores originales y sus representaciones tokenizadas
- Aplicación de políticas: aplicación consistente de políticas de protección en todas las interacciones de IA

Juntos, MongoDB y RegData proporcionan una columna vertebral resistente e inteligente para los servicios financieros, permitiendo a las instituciones unificar sus datos, aplicar políticas de protección sólidas y acelerar la adopción de IA sin sacrificar la seguridad.

Puerta de enlace API con MongoDB y la función de personalización de RegData. La solución integrada incluye una puerta de enlace API que actúa como un middleware seguro, inteligente y compatible con IA (software intermediario que conecta diferentes aplicaciones) entre las aplicaciones financieras y los modelos de IA. MongoDB proporciona la infraestructura de datos, mientras que RegData aporta funciones de personalización:

- MongoDB Atlas como centro de datos: sirve como repositorio central para todos los datos que fluyen a través de la puerta de enlace API, lo que garantiza la coherencia y la persistencia.
- Decoración de indicaciones: la capa envolvente de RegData modifica, anota o mejora las indicaciones (instrucciones dadas a los modelos de IA) antes de que se envíen a los modelos de IA.

- Normalización: estandariza el formato de los tokens semánticos y Envoltorios para garantizar un procesamiento consistente
- Aplicación de protección: aplica todas las técnicas de protección necesarias antes de enviar solicitudes a modelos de IA basados en la nube
- MCP: Un marco estandarizado que define cómo el contexto (información relevante sobre la conversación o tarea) se transmite entre sesiones de usuario, modelos de IA y sistemas backend

Al combinar la infraestructura de datos centralizada de MongoDB con el manejo inteligente y rápido de RegData, la solución crea un puente seguro y listo para IA entre los sistemas y modelos financieros, agilizando las interacciones y protegiendo el contenido confidencial en cada paso.

Búsqueda de vectores protegidos con MongoDB Atlas y Voyage AI

MongoDB Atlas Vector Search, combinado con las técnicas de protección de RegData y las integraciones específicas de dominio de Voyage AI, crea una poderosa capacidad de búsqueda protegida esencial para RAG en aplicaciones de IA financiera:

- MongoDB Atlas Vector Search: proporciona la infraestructura para almacenar y consultar miles de millones de vectores con un rendimiento inferior a un segundo.
- Integraciones financieras de Voyage AI: genere representaciones vectoriales específicas del dominio que comprendan la terminología y los conceptos financieros
- Incrustaciones tokenizadas de RegData: almacene incrustaciones vectoriales (representaciones numéricas de texto que capturan el significado semántico) de documentos y datos en formato tokenizado

- Preservación semántica: garantiza que la similitud vectorial siga siendo válida incluso cuando el texto de la superficie esté enmascarado
- Recuperación contextual: permite que la IA recuerde que [ADDR_42] es semánticamente similar a otras direcciones sin exponer la dirección real

Este enfoque integrado ofrece una búsqueda vectorial de alto rendimiento que preserva la privacidad y está adaptada a contextos financieros, lo que permite que los sistemas de IA recuperen información matizada y consciente del dominio mientras mantienen todos los detalles confidenciales en secreto.

Representación de salida segura

El componente final garantiza que los datos protegidos solo se revelen en contextos apropiados:

- Reasignación de tokens: en dispositivos autorizados o dentro de entornos seguros, los tokens se asignan nuevamente a sus valores originales.
- Autorización contextual: el acceso a los valores originales se otorga en función del rol del usuario, la ubicación y el propósito.
- Registro de auditoría: todo acceso a los valores originales se registra para fines de cumplimiento y supervisión de seguridad.

Esta última medida de protección garantiza que la información confidencial solo se revele cuando se cumplan las condiciones, manteniendo el cumplimiento y la confianza al tiempo que brinda a los usuarios autorizados acceso a los datos que necesitan; nada más, nada menos.

Inteligencia específica del dominio para mejorar la seguridad y el rendimiento

Si bien la protección semántica proporciona la base para una IA segura en Servicios financieros, la inteligencia específica del dominio toma en cuenta tanto la seguridad y el rendimiento al siguiente nivel. Como se explora en detalle en [Capítulo 11](#), Servicios Financieros y la Próxima Ola de IA, servicios financieros implican lenguaje especializado, regulaciones complejas y matices. conceptos que los modelos de IA de propósito general a menudo tienen dificultades para interpretar exactamente.

Aprovechar las características financieras específicas incrustaciones para una mayor protección

La integración de MongoDB, RegData y Voyage AI se basa en capacidades de incrustación específicas del dominio detalladas en [Capítulo 11](#). Al incorporar la integración especializada en finanzas de Voyage AI modelos, el marco de protección semántica gana varias claves ventajas:

- Precisión de detección mejorada: integraciones financieras mejoradas identificar información sensible que requiere protección, Mejorando la precisión de los sistemas de clasificación de RegData
- Protección contextual: La comprensión específica del dominio permite Decisiones de protección más matizadas basadas en el contexto financiero en lugar de una simple coincidencia de patrones
- Calidad de recuperación mejorada: cuando se combina con MongoDB Atlas Vector Search, las incrustaciones financieras garantizan que la información protegida Las búsquedas mantienen la relevancia y la precisión

Este enfoque ofrece mejoras de rendimiento significativas con respecto a modelos de propósito general, particularmente para tareas relacionadas con el cumplimiento e identificación de datos sensibles. Garantiza la protección semántica.

No solo protege, sino que también mantiene los resultados de alta calidad y contextualmente relevantes que las instituciones financieras requieren para aplicaciones de IA eficaces. La combinación de las técnicas de protección de RegData con inteligencia financiera específica crea una solución integral que aborda los requisitos de seguridad y rendimiento en el exigente entorno de los servicios financieros.

Innovación en el mundo real: banca interactiva. Para ilustrar cómo funciona en la práctica la


solución integrada de MongoDB, RegData y Voyage AI, examinemos el caso práctico de un banco privado que ofrece un asistente de chat digital con tecnología GenAI para sus clientes de alto patrimonio (UHNW). Esta implementación demuestra el potencial de combinar la plataforma de datos de MongoDB, la Suite de Protección (RPS) de RegData y las integraciones específicas de dominio de Voyage AI para permitir interacciones de IA seguras y eficaces en un entorno altamente regulado.

Los clientes UHNW del banco utilizan el asistente bancario de inteligencia artificial para diversas tareas:

- Consultar saldos de cuentas e historial de transacciones Solicitar
- transferencias (por ejemplo, Transferir 300 000 CHF a mi abogado)
- Recibir alertas de mercado e información sobre inversiones.
- Revisar el rendimiento de la cartera y las asignaciones de activos.
- Programar reuniones con gerentes de relaciones.

Estas interacciones involucran datos altamente sensibles: números de cuenta, historial de transacciones, identificadores personales y patrones de comportamiento.

Procesar estos datos mediante modelos GenAI en la nube conlleva el riesgo de exponerlos a plataformas de terceros, lo que podría infringir las normativas y comprometer la confidencialidad del cliente. ¿Cómo podemos aprovechar los servicios públicos de GenAI o los modelos LLM a la vez que protegemos los datos altamente sensibles?






Figura 12.3: Flujo de trabajo del sistema bancario interactivo y componentes de la interfaz de usuario

Este diagrama ilustra la arquitectura integral de un asistente bancario con protección semántica, mostrando cómo las consultas de los clientes se procesan a través de múltiples capas de protección antes de llegar a los modelos de IA. El sistema integra la plataforma de datos de MongoDB con las incrustaciones específicas de dominio y RPS de Voyage AI para ofrecer protección semántica y contextual.

La arquitectura demuestra cómo la protección semántica conserva el significado y el formato de los datos (reemplazando valores sensibles con tokens semánticamente equivalentes), mientras que la protección contextual adapta las medidas de seguridad en función del uso de los datos, los roles de usuario y los requisitos normativos. Las consultas de los clientes fluyen a través de la puerta de enlace API hacia la capa de Descubrimiento y Clasificación (utilizando tecnologías SLM, NLP y NER), y posteriormente a través del módulo de Protección Semántica y Contextual con sus políticas integradas, mecanismos de protección y funciones de generación de informes.

Los datos protegidos son procesados por LLM en la nube pública, y las respuestas se procesan de forma segura, mostrando los valores originales solo en los dispositivos autorizados. La visualización destaca la protección integral de la información financiera confidencial en todo el proceso.

flujo de conversación, garantizando el cumplimiento normativo y manteniendo la calidad y la utilidad de las interacciones bancarias impulsadas por IA.

Así es como la integración de MongoDB, RegData y Voyage AI permite interacciones de IA seguras pero efectivas:

- Descubrimiento y clasificación de datos: cuando un cliente dice Transferir, el sistema utiliza 200.000 CHF a Pierre , información de identificación personal (PII) impulsada por RegData AI. Identificación y modelos financieros específicos de Voyage AI para identificar a Pierre como PII y 200K CHF como información financiera que requiere protección.
- Protección de datos semánticos con RegData: Antes de enviar los detalles al modelo GenAI, RegData Protection Suite (RPS) aplica lo siguiente: Protección que preserva la semántica:
 - ¿Cuáles son las tarifas y condiciones si quiero transferir 200 000 CHF a este IBAN CH93 0076 2011 6238 5295 7? se convierte en ¿Cuáles son las tarifas y condiciones si quiero transferir 200 000 CHF a CH2008770435380216999?
 - Protección semántica contextual: Proporcionarme la lista de todas las transacciones en mi cuenta UBS se convierte en Proporcionarme la lista de todas las transacciones en mi cuenta Bank_CH Tokens
 - deterministas: Pierre siempre se asigna a Jacques y el IBAN CH2008770435380216999 siempre se asigna a CH93 0076 2011 6238 5295 7, en todas las interacciones Decoración
- rápida con MCP: el decorador rápido garantiza que el modelo GenAI reciba solo tokens protegidos y los trate como corresponde, al mismo tiempo que preserva su significado semántico a través de MCP.

- Búsqueda de vectores protegidos con MongoDB Atlas: Cuando el cliente pregunta "¿Cuánto gasté en actividades filantrópicas el mes pasado?", el sistema utiliza Voyage AI para convertir la consulta protegida en un vector (una representación matemática de texto). La búsqueda de vectores de MongoDB Atlas encuentra contenido similar en datos de transacciones tokenizadas, y RegData garantiza que solo se recuperen los datos protegidos sin revelar los detalles reales de la transacción.
- Representación segura de la salida: En el dispositivo autorizado del cliente, la aplicación reasigna los tokens a valores reales (p. ej., Jacques → Pierre). El cliente ve respuestas naturales y fluidas con sus datos reales, mientras que el modelo de IA solo procesa tokens protegidos.

Esta implementación integrada de MongoDB, RegData y Voyage AI ofrece beneficios significativos:

- Cumplimiento normativo: Cumple con los requisitos de la FINMA (la Autoridad de Supervisión del Mercado Financiero Suizo), RGPD y otras regulaciones al no exponer nunca datos confidenciales a terceros proveedores de IA
- Experiencia de usuario mejorada: los clientes reciben respuestas personalizadas y adaptadas al contexto a pesar de la protección subyacente.
- Eficiencia operativa: los administradores de relaciones se centran en actividades de alto valor mientras la IA maneja las consultas rutinarias
- Seguridad escalable: la arquitectura distribuida de MongoDB, combinada con la protección de RegData, garantiza que la solución pueda escalar para manejar casos de uso de IA en crecimiento sin comprometer la protección de datos.
- Relevancia superior: las integraciones específicas del dominio de Voyage AI garantizan que las respuestas sean altamente relevantes para los contextos financieros.

Estas capacidades básicas forman la base, mientras que las avanzadas
Las técnicas pueden aprovecharse de ellas para desbloquear posibilidades aún mayores.

Construyendo el futuro con tecnología avanzada técnicas y estándares emergentes

A medida que las instituciones financieras continúan mejorando sus capacidades de inteligencia artificial,
Varias técnicas y estándares emergentes están dando forma al futuro de
protección de datos semánticos.

MCP

MCP representa un avance significativo en la estandarización de cómo
El contexto se gestiona a través de las interacciones de IA. Como se detallará
Ampliamente en [Capítulo 19](#) Mas allá de la IA actual, que transforma la , MCP es
forma en que se crean e integran las aplicaciones de IA, avanzando
Más allá del enfoque anterior de crear herramientas únicas para cada uno
integración.

MCP ofrece varias ventajas clave para la protección de datos semánticos
sistemas:

- Gestión del contexto estandarizado: un marco consistente para
pasar contexto entre sesiones de usuario, modelos de IA, agentes de IA y
sistemas backend
- Interoperabilidad mejorada: eliminación de silos de datos mediante
Estandarización de las interacciones del modelo de IA con las aplicaciones comerciales
- Tiempo de procesamiento en la nube reducido: manejo de contexto más eficiente
Reduce el tiempo que los datos sensibles pasan en entornos de nube.

En el contexto de la alianza entre MongoDB, RegData y Voyage AI, MCP permite una integración más fluida de los flujos de trabajo de protección con agentes de IA y sistemas externos. Esta estandarización es especialmente valiosa para las instituciones financieras que necesitan mantener el contexto en...

interacciones de IA complejas de múltiples pasos, garantizando al mismo tiempo que la protección de datos se mantenga constante en todo momento.

Como descubrirá, el servidor MCP de MongoDB ejemplifica este potencial de integración, permitiendo que los agentes de IA interactúen directamente con las bases de datos de MongoDB respetando los controles de acceso existentes, una capacidad fundamental para mantener la protección semántica en entornos de IA de agentes.

Estrategias de protección híbrida. Establecer enfoques de nube

híbrida puede mejorar tanto la seguridad como el rendimiento al permitir el procesamiento seguro de datos en entornos de nube privada y pública. Mediante la orquestación inteligente de datos y la exposición selectiva de datos protegidos, una arquitectura de nube híbrida garantiza que la información confidencial permanezca segura mientras...

RegData sigue ofreciendo soporte para análisis avanzados y cargas de trabajo de IA. Refuerza aún más este enfoque con compatibilidad con implementaciones híbridas y multicloud, lo que permite a las organizaciones elegir la infraestructura que mejor se adapte a sus necesidades operativas y de cumplimiento.

En esta arquitectura, la protección multicapa desempeña un papel fundamental al integrar documentos estructurados y no estructurados, así como gráficos de conocimiento, en un ecosistema unificado. Esta integración garantiza la protección uniforme de todos los tipos de datos.

y accesible para uso autorizado. El resultado es un sistema que protege sistemáticamente la información confidencial, a la vez que habilita las capacidades de IA en diversos entornos, ofreciendo mayor seguridad y opciones de implementación flexibles.




Figura 12.4: Arquitectura de nube híbrida para una IA financiera segura

Este diagrama ilustra una arquitectura de nube híbrida que permite el procesamiento seguro de IA financiera en entornos de nube privada/local y pública. La visualización muestra cómo se gestionan los datos confidenciales.

permanece protegido en la infraestructura local/de nube privada (incluidas bases de datos, archivos y medios heredados) mientras aprovecha los potentes servicios de inteligencia artificial de nube pública a través de capas de protección de RegData. La puerta de enlace API garantiza que solo los datos semánticamente protegidos (tokenizados, seudonimizados o anonimizados) crucen a entornos de nube pública, donde MongoDB proporciona una orquestación unificada de datos y los LLM públicos ofrecen capacidades avanzadas de IA. Esto

El enfoque híbrido maximiza tanto el cumplimiento de la seguridad como el rendimiento de la IA al mantener seguros los datos confidenciales mientras se accede a servicios de IA en la nube de vanguardia a través de una protección de datos integral durante todo el proceso.

Consideraciones regulatorias y de cumplimiento

Las instituciones financieras deben cumplir con requisitos regulatorios complejos al implementar IA con protección de datos semánticos. Esta sección describe las consideraciones clave y las mejores prácticas.

Alineación del marco regulatorio

Las arquitecturas de protección semántica deben alinearse con el complejo panorama regulatorio y los marcos detallados en «IA [Capítulo 4](#), confiable, cumplimiento normativo y gobernanza de datos». Como se explica en el análisis de dicho capítulo sobre la gestión de los requisitos regulatorios en diferentes industrias y jurisdicciones, las organizaciones deben abordar múltiples marcos regulatorios que se solapan, como los siguientes:

- RGPD: Garantiza el manejo adecuado de los datos personales con principios como la minimización de datos y la limitación de la finalidad[1]
- FINMA: Aborda los requisitos regulatorios financieros suizos en materia de seguridad de datos y confidencialidad del cliente[2]
- MAS: Cumple con las pautas de la Autoridad Monetaria de Singapur para la gobernanza de la IA y la protección de datos[3]
- Ley de IA de la UE: cumple con los requisitos de la Unión Europea en materia de gestión de riesgos de IA, transparencia y rendición de cuentas en IA de alto riesgo.

aplicaciones[4]

- BCE: Cumple los estándares del Banco Central Europeo en materia de resiliencia operativa y seguridad de datos[5]

El enfoque de protección semántica respalda directamente los principios de IA confiables, en particular la transparencia, la responsabilidad y la gobernanza sólida de datos, al garantizar que se mantenga la protección de datos confidenciales incluso al tiempo que se permite la explicabilidad de la IA y el cumplimiento normativo.

Esta alineación demuestra cómo las soluciones técnicas pueden poner en funcionamiento los marcos éticos y regulatorios que son esenciales para la implementación responsable de la IA.

Auditabilidad y explicabilidad

El cumplimiento normativo requiere capacidades integrales de auditoría, incluyendo un registro detallado de accesos que registre quién accedió a datos específicos, cuándo se produjo el acceso y con qué propósito. También exige la verificación de la protección para demostrar que los datos confidenciales se protegieron adecuadamente durante el procesamiento de la IA. Además, la trazabilidad de las decisiones es esencial, garantizando registros de auditoría claros que documenten cómo se generaron las recomendaciones generadas por la IA.

User Activity

This dashboard describes the activity of user **John Smith** between **01/06/2025** and **30/06/2025**.



Figura 12.5: Consumo de datos sensibles, por usuario

Esta visualización del panel muestra cómo las instituciones financieras pueden monitorear y demostrar el cumplimiento de diversos requisitos regulatorios en sus sistemas de IA. La interfaz muestra métricas clave, como la cobertura de protección, los registros de acceso y el estado de cumplimiento de diferentes regulaciones y tipos de datos.

El panel de control muestra cómo un usuario determinado obtuvo acceso a datos confidenciales. Esto podría ocurrir cuando se consumen aplicaciones internas como un CRM o una herramienta transaccional, o datos enviados a LLM.

Entonces es posible saber en qué LLM se utilizaron estos datos sensibles y el resultado de la respuesta: cuántas veces el usuario tuvo acceso a los datos en su totalidad, cuántas veces no tuvo acceso o cuántas veces no tuvo acceso.

En ocasiones, solo accedieron a datos protegidos. En esta captura de pantalla, también podemos ver el tipo de datos confidenciales que consumió el usuario (nombre, correo electrónico, **BAN**, (texto libre), comentarios y más).

Este panel es posible gracias a que RegData monitoriza todas las solicitudes de acceso a datos sensibles, así como su respuesta. De esta forma, es posible generar informes personalizados que demuestran el uso responsable de los datos sensibles, así como su uso seguro en LLM externos o públicos.

Resumen

Este capítulo mostró cómo la alianza MongoDB, RegData y Voyage AI aborda el desafío crítico que enfrentan las instituciones financieras: aprovechar las capacidades de IA, manteniendo al mismo tiempo una rigurosa protección de datos y el cumplimiento normativo. Se presentó el concepto de protección semántica de datos, que va más allá de los enfoques tradicionales de cifrado y enmascaramiento que inutilizan los datos para las aplicaciones de IA. La protección semántica de datos preserva el significado, el contexto y el formato de la información, a la vez que elimina o reemplaza los valores sensibles, lo que permite a los modelos de IA generar resultados significativos sin comprometer la seguridad.

Sin embargo, la protección semántica por sí sola no es suficiente para obtener resultados de IA de alta calidad en aplicaciones financieras. El capítulo enfatizó que la protección semántica contextual es esencial para brindar respuestas de IA significativas. Mientras que la protección semántica básica simplemente reemplaza datos confidenciales con alternativas semánticamente equivalentes (un número de teléfono con otro número de teléfono, el nombre de una ciudad con otro nombre de ciudad), la protección semántica contextual se adapta en función del significado y

Contexto de uso para mantener la relevancia analítica. Por ejemplo, en una aplicación de reubicación, la protección semántica contextual reemplazaría una ciudad objetivo por otra con las mismas normas y regulaciones fiscales, lo que permitiría a la IA ofrecer asesoramiento preciso sobre el coste de la vida y los impuestos locales, manteniendo la privacidad. Este sofisticado enfoque, combinado con la plataforma de datos unificada de MongoDB, las técnicas de protección de RegData y las integraciones específicas de dominio de Voyage AI, crea una solución integrada que aborda los requisitos de seguridad y rendimiento en el exigente entorno de los servicios financieros.

En el próximo capítulo, exploraremos cómo los copilotos GenAI pueden transformar la gestión patrimonial al abordar el dilema fundamental de escalar las relaciones personalizadas con los clientes sin comprometer la calidad del servicio. Examinaremos cómo la asistencia basada en IA puede ayudar a los gestores de relaciones a pasar de tareas administrativas a interacciones de alto valor con los clientes, a la vez que se generan mejoras significativas en los ingresos mediante la automatización inteligente.

Referencias

1. Lo que necesita saber sobre los 7 principios del RGPD: <https://usercentrics.com/knowledge-hub/principles-of-gdpr/>
2. FINMA: Cómo interpretar los datos de identificación del cliente (CID): <https://bigid.com/blog/finma-dando-sentido-a-los-datos-de-identificación-de-clientes-cid/>
3. Navegando por los riesgos de los modelos de IA: Ideas clave de las directrices del MAS: <https://www.coriniumintelligence.com/content/nav>

[Riesgos de los modelos de IA de Igating: información clave de las directrices de MAS](#)

4. Todo lo que necesita saber (hasta ahora) sobre la Ley de IA de la UE:

<https://www.isms.online/iso-42001/todo-lo-que-necesita-saber-hasta-ahora-sobre-la-ley-de-ai-de-la-ue/>

5. Ley de Resiliencia Operativa Digital (DORA):

https://www.eiopa.europa.eu/digital-operational-resilience-act-dora_es

13

Impulsando el éxito del cliente en la banca con GenAI Copilots

El sector de la gestión patrimonial se encuentra en una encrucijada. Si bien los gestores de relaciones han sido tradicionalmente la piedra angular de los servicios financieros personalizados, ahora se enfrentan a un reto sin precedentes: cómo ampliar las relaciones estrechas y personalizadas con los clientes sin comprometer la calidad del servicio que impulsa la fidelización y el crecimiento empresarial. Empresas como QuantumBlack, AI by McKinsey, han estado siguiendo este cambio y sus implicaciones para los líderes empresariales y tecnológicos.

La transformación digital del sector bancario se ha acelerado drásticamente en las últimas décadas, pasando de las interacciones en sucursales a experiencias omnicanal que conectan a los clientes dondequiera que estén. Las expectativas de los clientes de un servicio inmediato y personalizado nunca han sido tan altas, mientras que las presiones regulatorias y la competencia exigen mayor eficiencia y un alcance más amplio. Esta evolución ha generado tanto oportunidades como tensiones; los bancos deben atender a más clientes en áreas geográficas más amplias, manteniendo al mismo tiempo el toque personal que distingue a los servicios premium de gestión patrimonial.

Pero persiste un desafío fundamental: los gerentes de relaciones humanas solo pueden gestionar eficazmente un número limitado de relaciones significativas con los clientes. El modelo tradicional se basa en gran medida en la memoria personal, la investigación manual y las interacciones individuales que simplemente no escalan. A medida que las carteras de clientes crecen y la complejidad del mercado se incrementa, los gerentes de relaciones dedican más tiempo a tareas administrativas y menos a aportar valor genuino a las relaciones con los clientes.

Al final de este capítulo comprenderás lo siguiente:

- Cómo la paradoja de la gestión de las relaciones patrimoniales crea una oportunidad para la transformación de la IA
- Por qué la gestión de relaciones tradicional depende en gran medida del esfuerzo manual y la memoria personal, lo que limita la escalabilidad
- Cómo los copilotos de GenAI pueden transformar la productividad del gerente de relaciones del 20-30% del tiempo de interacción con el cliente a más del 70%
- La arquitectura técnica que impulsa las recomendaciones de IA en tiempo real y la generación automatizada de seguimiento
- Cómo implementar cuatro canales de producción de IA esenciales para aplicaciones GenAI de nivel de producción
- Por qué las barreras de seguridad contra las alucinaciones y los marcos de cumplimiento son fundamentales para los servicios financieros
- Casos de uso reales en análisis de centros de llamadas, soporte de agentes virtuales y detección de fraudes
- Cómo fomentar la adopción organizacional mediante la planificación estratégica de la infraestructura y la participación de los usuarios
- El impacto empresarial de la implementación de GenAI: aumento del 10 al 25 % en los ingresos por gerente de relaciones y del 5 al 15 % en los clientes activos administrados

La paradoja de la gestión de relaciones patrimoniales. Los gestores de relaciones patrimoniales

han servido durante mucho tiempo como puente personalizado entre los clientes con un alto patrimonio y las instituciones financieras.

Ofrecen a su clientela de élite un servicio de primera clase:

asesoramiento financiero personalizado, recomendaciones de inversión, servicios de planificación fiscal y más. Sin embargo, también se

enfrentan a una presión sin precedentes para aumentar el número de clientes bajo su

Este doble mandato coloca a los gestores de relaciones en una situación

sin salida. Por un lado, las instituciones bancarias requieren escalabilidad y

crecimiento de ingresos. Por otro, la capacidad humana para una gestión

de relaciones personalizada no puede escalar sin sacrificar la calidad del servicio.

La gestión patrimonial tradicional depende en gran medida de la memoria

personal y el esfuerzo manual del gestor de relaciones. Por ejemplo, evalúa

personalmente las posiciones, los riesgos y las oportunidades de la

cartera, contacta manualmente a sus clientes, investiga manualmente noticias

relevantes y actualizaciones del mercado, recopila información ad hoc durante

las conversaciones y se basa en ideas y estrategias amplias y

generalizadas en lugar de personalizadas.

El extenso trabajo de QuantumBlack, IA de McKinsey con clientes ha revelado

que los gestores de relaciones suelen dedicar solo entre el 20 % y el 30 % de

su tiempo a interactuar con los clientes, mientras que entre el 70 % y el 80 %

se dedica a la investigación, la preparación y el papeleo. Esto representa

una enorme oportunidad de transformación mediante la IA.

Escalando una gestión de relaciones exitosa GenAI copilot

Los copilotos GenAI están transformando la forma en que trabajan los gestores de relaciones, permitiéndoles captar y gestionar más clientes sin comprometer (y a menudo mejorando) la calidad del servicio. El copiloto GenAI se integra en el escritorio del gestor de relaciones, atiende las llamadas de los clientes y aprovecha los amplios repositorios de datos del banco, provenientes de diversas fuentes, para ofrecer recomendaciones hiperpersonalizadas en tiempo real, pasos a seguir y oportunidades de venta adicional.

Por ejemplo, un copiloto GenAI, impulsado por soluciones avanzadas de IA como MongoDB e Iguazio (una empresa de plataformas de IA adquirida por QuantumBlack, AI by McKinsey), ayuda a los gestores de relaciones a identificar inversiones que se ajusten a la cartera de un cliente. El copiloto también comparte proactivamente investigaciones relevantes, realiza análisis de sentimientos basados en la redacción, el tono de voz y el contexto del cliente, determina y clasifica la intención para identificar oportunidades potenciales e incluso destaca eventos vitales relevantes que generan recomendaciones para productos bancarios adicionales (como abrir una nueva cuenta estudiantil para el hijo del cliente, basándose en que acaba de cumplir 18 años).

Banking Relationship Manager Co-Pilot Flow




Figura 13.1: Flujo de trabajo del copiloto GenAI en tiempo real: desde la detección de voz hasta el seguimiento automatizado

Este diagrama de flujo muestra el flujo de trabajo operativo integral de un gestor de relaciones bancarias copiloto GenAI durante las interacciones en vivo con los clientes. El proceso comienza con la detección de la fuente de audio mediante la detección de actividad de voz (VAD), seguida de la transcripción en tiempo real mediante la tecnología Whisper. A continuación, el sistema analiza el sentimiento y clasifica la intención del cliente mediante el procesamiento del lenguaje natural (PLN) impulsado por LLM. Con base en este análisis, el copiloto accede a múltiples fuentes de datos, incluyendo inversiones pasadas, documentación bancaria, bases de datos de investigación y algoritmos de agrupamiento de inversiones, para generar tres tipos de recomendaciones inteligentes: oportunidades de venta adicional mediante LLM y generación aumentada por recuperación (RAG), sugerencias de inversión personalizadas mediante RAG y agrupamiento, y artículos de investigación relevantes me

El flujo de trabajo ilustra cómo la IA orquesta el procesamiento de datos complejos y la toma de decisiones en tiempo real para mejorar la eficacia del gerente de relaciones.

Toda esta información se presenta al gerente de relaciones, quien puede decidir si la comparte o no con el cliente en tiempo real. Después

la llamada, el copiloto genera automáticamente un correo electrónico personalizado que resume la llamada, junto con cualquier documento adicional necesario en función de la discusión que se mantuvo, lo que permite al gerente de relaciones simplemente verificar, editar y enviar los documentos con el clic de un botón.

Al proporcionar automáticamente esta información a los gestores de relaciones, el copiloto GenAI les ahorra tiempo de preparación, permitiéndoles dedicar más tiempo de su día a interacciones que generen valor con los clientes. Basándonos en nuestro trabajo con clientes, observamos que las cifras pueden variar drásticamente, pasando del 20-30% del tiempo dedicado a ellos a más del 70%. El resultado es un aumento potencial del 10% al 25% en los ingresos por gestor de relaciones y un incremento del 5% al 15% en los clientes activos gestionados.

Cómo la gestión de relaciones El copiloto GenAI funciona bajo el capó

La aplicación GenAI Copilot funciona aprovechando una amplia gama de fuentes de datos del banco, incluyendo bases de datos estructuradas como MongoDB Atlas, una plataforma de datos unificada que contiene datos históricos y en tiempo real. Incorpora continuamente datos internos y externos de grabaciones de llamadas, interacciones pasadas por correo electrónico, chat y mensajes de texto, y redes sociales.

actividad de los medios, noticias públicas, cartera del cliente y el historial de transacciones para construir y mantener un perfil de cliente dinámico.

La base de conocimientos del banco, acumulada a lo largo del tiempo, incluye detalles como el estado civil, las experiencias vividas, el historial de sentimientos, la actividad crediticia y de préstamos, el perfil de riesgo y las preferencias de compra, que se integran a partir de fuentes de datos e interacciones internas y externas.

También se integran datos específicos del sector bancario, como información sobre productos, políticas y sistemas operativos.




Figura 13.2: Arquitectura de inteligencia del cliente impulsada por IA: desde las fuentes de datos hasta las experiencias bancarias personalizadas

Este diagrama ilustra cómo los copilotos de GenAI transforman diversas fuentes de datos en información inteligente sobre los clientes mediante un sistema integral de creación de perfiles. A la izquierda, múltiples flujos de datos, incluyendo grabaciones de llamadas, comunicaciones, redes sociales, noticias públicas e historial de transacciones, alimentan un motor centralizado de creación de perfiles.

El sistema crea ricas bases de conocimiento que abarcan el estado familiar,

Preferencias financieras, perfiles de riesgo y patrones de comportamiento. Esta información impulsa aplicaciones basadas en eventos que ofrecen cuatro capacidades fundamentales de IA: comunicación hiperpersonalizada en todos los canales, recomendaciones de inversión adaptadas a las preferencias individuales y productos actuales, notas de investigación basadas en interacciones pasadas e inteligencia de mercado, y respuestas automáticas a las preguntas de los clientes que liberan a los gestores de relaciones de las consultas rutinarias.

Esta arquitectura demuestra cómo los sistemas de IA bancaria modernos unifican datos estructurados y no estructurados para facilitar la interacción con el cliente en tiempo real y a gran escala.

Toda esta información fluye hacia aplicaciones basadas en eventos y canales de venta en tiempo real. El copiloto de GenAI aprovecha estos datos en tiempo real para recomendar estrategias al agente humano. El resultado para el gestor de relaciones es una comunicación hiperpersonalizada, ideas de inversión a medida, notas de investigación relevantes y respuestas a las consultas de los clientes.

Los flujos de trabajo de IA que respaldan esta arquitectura están diseñados para procesar la voz de las llamadas de los clientes en tiempo real con IA, brindar a los administradores de relaciones información y sugerencias, y automatizar los seguimientos en función de la conversación que se desarrolla en tiempo real.

¿Qué se necesita para convertir en productos aplicaciones de IA como GenAI Copilot para gestores de relaciones? Aquí es donde la fábrica de GenAI... Entra.

Fábrica GenAI: Impulsando a copilotos, agentes y aplicaciones GenAI

Una arquitectura de IA que admita el uso del copiloto a escala se basa en cuatro canales:

- Canalizaciones de datos para procesar los datos sin procesar (eliminando riesgos, mejorando la calidad, codificando, etc.).
- Canales de aplicaciones para procesar solicitudes entrantes, enriquecer con datos de la plataforma de datos unificada de MongoDB que admite datos estructurados, no estructurados y vectoriales, ejecutar la lógica del agente y aplicar varias barreras de seguridad y tareas de monitoreo.
- Canalizaciones de desarrollo y CI/CD para ajustar y validar modelos, probar la aplicación para detectar desafíos de riesgo de precisión e implementar automáticamente la aplicación.
- Un sistema de gobernanza y monitoreo que recopila telemetría de aplicaciones y datos para identificar el uso de recursos, el rendimiento de las aplicaciones, los riesgos, etc. Los datos de monitoreo se pueden utilizar para mejorar aún más el rendimiento de las aplicaciones.

Iguazio + MongoDB: Build & Scale Gen AI Apps Efficiently




Figura 13.3: Arquitectura de fábrica de IA integrada de Iguazio y MongoDB para aplicaciones GenAI a escala de producción

Este completo diagrama de arquitectura ilustra cómo la plataforma de fábrica de IA de Iguazio se integra con MongoDB para ofrecer aplicaciones GenAI de nivel empresarial a escala. El sistema abarca cuatro capas operativas críticas: canales de datos que transforman las fuentes de datos sin procesar mediante las capacidades de procesamiento de Iguazio en la plataforma de datos unificada de MongoDB, que gestiona las características del usuario, los datos estructurados y las incrustaciones vectoriales en un único sistema; canales de aplicaciones con clasificación y orquestación con estado y controles de seguridad, cadenas de preguntas y respuestas para la extracción de entidades y la recuperación de documentos, y cadenas de preguntas estructuradas impulsadas por agentes de IA; un canal de aprendizaje automático (ML) y CI/CD que proporciona ajuste, validación e implementación automatizados mediante flujos de trabajo de Git e Iguazio; y sistemas integrales de monitorización y retroalimentación con capacidades de validación y alertas en tiempo real. La arquitectura demuestra cómo el enfoque de almacenamiento de datos convergente de MongoDB elimina la complejidad de gestionar múltiples tecnologías de bases de datos al admitir datos estructurados, no estructurados y vectoriales de forma nativa en una sola plataforma, mientras que Iguazio orquesta los complejos flujos de trabajo de IA, la gestión de sesiones y el procesamiento de respuestas necesarios para las aplicaciones de servicios financieros en producción. Este enfoque integrado permite la orquestación de canales, la escalabilidad y las capacidades de gobernanza esenciales para el cumplimiento de la industria de servicios financieros (FSI) y al mismo tiempo mantiene el rendimiento y la confiabilidad que exigen las operaciones bancarias.

Además, la fábrica de IA debe admitir implementaciones tanto locales como híbridas y permitir una migración sencilla de una a otra.

Un entorno a otro, para abordar los estrictos requisitos regulatorios, de privacidad y seguridad de datos del sector financiero y para permitir flexibilidad en un mundo dinámico. Las implementaciones locales ofrecen control total sobre los datos e infraestructura sensibles, lo cual es necesario para cumplir con mandatos de cumplimiento como el RGPD o la Ley de IA de la UE. Al mismo tiempo, los modelos híbridos permiten a los bancos aprovechar la escalabilidad y la innovación de la IA en la nube, a la vez que mantienen las cargas de trabajo sensibles en sus instalaciones.

Cómo la fábrica de IA aborda las necesidades de ingeniería FSI

Al implementar una fábrica de IA, los bancos, las compañías de seguros y otras instituciones financieras pueden beneficiarse de diversas maneras.

Una de las principales ventajas es que los usuarios acceden a la orquestación de pipelines con una ingeniería mínima. La fábrica simplifica el desarrollo y la gestión de flujos de trabajo integrales, robustos y repetibles en cuatro pipelines: datos, aplicaciones, desarrollo y LiveOps. Esto se realiza de forma sencilla y resiliente, sin requerir grandes esfuerzos de ingeniería.

La fábrica de IA también amplía las opciones para una implementación escalable y rápida. Permite crear e implementar modelos a escala empresarial, con millones de clientes bancarios, regiones globales y equipos, de forma optimizada y sin fricciones ni ineficiencias de costos en entornos en la nube, locales o híbridos. Al combinarse con bases de datos como MongoDB, por ejemplo, se pueden gestionar grandes volúmenes de datos y complejas transformaciones de datos.

con facilidad, manteniendo altos niveles de rendimiento y garantizando confiabilidad y precisión.

La unificación de datos de múltiples fuentes también se vuelve más viable.

Las aplicaciones GenAI involucran múltiples tipos de datos, como geoespaciales, gráficos, tablas y vectores. Cada tipo de dato requiere consideraciones como seguridad, escalabilidad y gestión de metadatos. Esto genera complejidad en la gestión de datos. Una fábrica de IA, combinada con la plataforma unificada de MongoDB, puede gestionar todo tipo de datos (estructurados, no estructurados y vectoriales) en una única solución. Esto garantiza consistencia, un rendimiento más rápido y una sobrecarga significativamente menor.

La versatilidad de las fábricas también es una gran ventaja. Una vez construidas, pueden adaptarse a múltiples casos de uso sin los gastos generales ni las dificultades que supone una reconstrucción. Si se requieren cambios, la arquitectura es modular y los componentes se pueden intercambiar o reemplazar fácilmente sin necesidad de rediseñar por completo.

La optimización de GPU y cómputo se vuelve más fácil de gestionar. Dado que el cómputo, y en especial las GPU, se está volviendo costoso y difícil de conseguir, la fábrica garantiza la asignación, el uso compartido y el escalado automático eficientes de los recursos computacionales, incluyendo la distribución y el paralelismo.

La orquestación de MLOps mejora porque una fábrica de IA ayuda a trasladar modelos y aplicaciones de IA del prototipo a la producción de forma rápida, segura y confiable.

La fábrica mejora el rendimiento y la integridad de los resultados al mitigar riesgos empresariales y éticos como alucinaciones, sesgos, toxicidad y resultados imprecisos, garantizando así un alto rendimiento, precisión y fiabilidad. Esto se logra mediante la implementación de una gestión y gobernanza centralizadas para todo el ciclo de vida de la IA, incluyendo medidas de seguridad integradas.

Durante todo el proceso de desarrollo, capacitación e implementación proceso.



Barandillas de alucinaciones

La protección contra alucinaciones, por ejemplo, puede implementarse desde el principio, incluso en la canalización de datos. Esto requiere un flujo de trabajo RAG y la plataforma de datos unificada de MongoDB.

Los datos estructurados y confiables (como manuales de productos, preguntas frecuentes, políticas de precios, datos de clientes, etc.) se convierten en incrustaciones y se almacenan en MongoDB. Cuando un usuario realiza una consulta, el registro relevante se recupera de la base de datos y se estructura como texto natural. Esto garantiza que la respuesta esté basada en hechos reales, minimizando las alucinaciones.

Las fábricas de IA mejoran el cumplimiento, la privacidad y la seguridad al implementar medidas de protección para el acceso seguro a los modelos, la explicabilidad, el registro para auditoría, la alineación con el RGPD y las regulaciones de la Autoridad Reguladora de la Industria Financiera (FINRA) y la equidad.

Muchos sistemas bancarios aún funcionan con stacks heredados. Las fábricas de IA mejoran la integración entre sistemas nuevos y heredados al abstraer la complejidad mediante puentes API, wrappers o conectores optimizados, de forma sencilla y fluida.

Incluso después de pruebas de concepto exitosas, la mayoría de las empresas aún no logran escalar la IA ni generar un impacto comercial real. La fábrica de IA ayuda a garantizar la entrega y la gestión de calidad de producción, para que las empresas obtengan un retorno real de la inversión (ROI).

Una fábrica de IA es una infraestructura a prueba de futuro con modularidad y escalabilidad que se puede adaptar a cualquier necesidad de operacionalización de IA, como los agentes de IA.

Los agentes son sistemas de IA autónomos que pueden percibir su entorno, tomar decisiones y realizar acciones para alcanzar un objetivo específico.

En lugar de seguir tareas específicas, pueden seguir un conjunto de objetivos, adaptarse a la evolución de las entradas y operar de forma independiente o en equipo. Esto ayuda a agilizar la toma de decisiones, mejorar la experiencia del cliente y optimizar la resiliencia operativa en toda la cadena de valor de los servicios financieros.

Para los servicios financieros, los agentes de IA pueden automatizar flujos de trabajo complejos, actuar como asistentes financieros siempre disponibles, monitorear continuamente las transacciones y detectar fraudes, sugerir estrategias de inversión, personalizar el asesoramiento financiero y más.

Casos de uso líderes en FSI donde GenAI aporta un valor real. El valor de GenAI

para la banca privada y las instituciones

financieras va más allá de la gestión de relaciones. También puede extenderse a casos de uso como los siguientes:

- Análisis inteligente del centro de llamadas: uso de IA para transcribir, resumir y analizar llamadas de soporte en tiempo real para identificar sentimientos, puntos débiles del producto y oportunidades de venta adicional, y para enviar información a aplicaciones posteriores para obtener conocimientos estratégicos.
- Soporte de agente virtual: Implementación de agentes impulsados por IA para gestionar consultas de rutina, liberando a los agentes humanos para casos complejos.

- Recomendaciones de productos hiperpersonalizadas: combinación de datos de comportamiento con información del cliente para recomendar
Tarjetas de crédito, préstamos o productos de inversión personalizados
- Predicción de fraude y detección de anomalías: detección de patrones de transacciones sospechosas en tiempo real, mejorando los tiempos de respuesta

Veamos un ejemplo en detalle.

Caso práctico: Una aplicación inteligente de análisis de centros de llamadas basada en GenAI. Un importante y exitoso banco europeo desarrolló una aplicación de análisis de centros de llamadas GenAI para optimizar las operaciones, simplificar la capacitación de los agentes, optimizar la experiencia del cliente y reducir costos. La aplicación GenAI, implementada localmente, resumió las llamadas de los clientes, analizó opiniones y temas, y eliminó información personal identificable (PII). Los datos se incorporaron a aplicaciones posteriores, como soporte de agentes en vivo, perfiles de clientes, contenido generado automáticamente, recomendaciones personalizadas, ofertas personalizadas, etc.

Esto resultó en una mejora del doble en el tiempo de ejecución, una diarización de llamadas 60 veces más rápida y una mejora del triple en el uso de la GPU. Estos agentes también pueden acceder a la plataforma de datos MongoDB para extraer información que facilita la recuperación y el uso de la información.

¿Y ahora qué? Cómo las empresas pueden tener éxito con GenAI

El éxito con las soluciones GenAI no se limita a implementar la tecnología adecuada. Se basa, más bien, en la interacción con las personas, la alineación de la alta dirección, la creación de procesos adecuados y la implementación de estrategias de gobernanza. Integrar GenAI en los flujos de trabajo de los gestores de relaciones, o de cualquier otro departamento, de forma cooperativa es fundamental para su éxito, además de impulsar el éxito tanto de la empresa como del empleado.

Por lo tanto, se recomienda implementar las siguientes prácticas en personas, procesos y tecnología:

- Planificación estratégica de infraestructura: Desarrollo de una estrategia de implementación personalizada en la nube, local o híbrida, basada en las necesidades regulatorias, de cumplimiento y de recursos. La infraestructura de datos debe diseñarse para aprovechar al máximo los sistemas existentes, garantizando al mismo tiempo una integración fluida con los procesos existentes.
- Gobernanza sólida y alineación regulatoria: incorporar políticas internas y alinearse con regulaciones como la Ley de IA de la UE, para acelerar el progreso y minimizar los riesgos.
- Impulsar la adopción entre los usuarios: involucrar a los gestores de relaciones de alto rendimiento en el desarrollo de la funcionalidad y la experiencia de usuario de la herramienta. Esto garantiza y fomenta un sentido de pertenencia. Esto incluye destacar el potencial para mejorar los conocimientos, desarrollar las capacidades profesionales, aumentar la productividad e impulsar los ingresos, y realizar pruebas piloto con profesionales de alto rendimiento para generar resultados rápidos, generar credibilidad e impulsar el impulso entre pares en toda la organización.

Al incorporar soluciones GenAI como copilotos en su estrategia digital, los bancos pueden transformar las relaciones y la posición de los clientes.

se preparan para un crecimiento sostenible que impulse los ingresos en un panorama cada vez más competitivo y volátil.

Resumen

La transformación de la gestión patrimonial mediante copilotos GenAI representa un cambio fundamental: pasar del dilema de escalar un servicio personalizado a una solución impulsada por IA que mejora tanto la eficiencia como la experiencia del cliente. Dado que los gestores de relaciones dedican actualmente más de la mitad de su tiempo a la investigación y el papeleo en lugar de a la interacción con los clientes, los copilotos GenAI ofrecen una solución clara para revertir esta situación, permitiendo a los gestores centrarse en actividades generadoras de valor mientras la IA se encarga del procesamiento de datos, el análisis de opiniones y las tareas administrativas.

La base técnica de esta transformación requiere un enfoque integral de fábrica de IA, que abarque canalizaciones de datos, orquestación de aplicaciones, flujos de trabajo de desarrollo y marcos de gobernanza. La plataforma de datos unificada de MongoDB permite el procesamiento en tiempo real de datos estructurados y no estructurados, necesarios para las respuestas contextuales de IA, mientras que las barreras de seguridad integradas garantizan el cumplimiento de las regulaciones de servicios financieros y protegen contra alucinaciones.

Las implementaciones en el mundo real han demostrado un impacto comercial significativo, con aumentos potenciales de ingresos de entre el 10 % y el 25 % por gerente de relaciones y aumentos del 5 % al 15 % en clientes activos administrados, junto con mejoras operativas como mejoras en el tiempo de ejecución 2x y un procesamiento de llamadas 60 veces más rápido.

El siguiente capítulo explora cómo generar valor comercial con IA en seguros, examinando la integración estratégica de la IA dentro del sector.

El sector asegurador impulsa resultados empresariales significativos. Más allá de las aplicaciones bancarias, demuestra cómo diseñar flujos de trabajo de aplicaciones optimizados con IA que se alineen con los objetivos del negocio asegurador, abarcando la evolución de las arquitecturas de datos y las aplicaciones prácticas de la IA en la suscripción, el procesamiento de siniestros y la experiencia del cliente para transformar las operaciones de seguros.

14

Generando valor comercial con IA en seguros

Al diseñar flujos de trabajo de aplicaciones optimizados con IA, es importante tener en cuenta los objetivos generales de su negocio. ¿Qué problemas de negocio está resolviendo y cuáles son los desafíos más urgentes que enfrenta su organización?

Las diferentes partes interesadas de su organización pueden abordar la implementación de la IA desde diversas perspectivas. Los equipos de tecnología que impulsan la consolidación y modernización de plataformas pueden evaluar las soluciones priorizando la tecnología, comparando las plataformas en función de sus capacidades técnicas y costo. Los equipos de ciencia de datos y análisis pueden centrarse en probar o confirmar hipótesis de datos. Los propietarios de productos empresariales pueden priorizar la mejora de las características y capacidades de las aplicaciones, con la esperanza de optimizar el procesamiento de datos con IA.

Independientemente de su función, el reto reside en ayudar a su organización a aprovechar la IA para lograr avances significativos en los resultados empresariales. Esto requiere abordar múltiples dimensiones, incluyendo una comprensión clara de los objetivos empresariales para alinear las iniciativas de IA con los objetivos organizacionales, un profundo conocimiento de los datos y flujos de trabajo relevantes para garantizar que la IA respalde eficazmente los procesos empresariales clave.

y la aplicación inteligente de tecnologías de IA para optimizar tareas que requieren un uso intensivo de datos y lograr nuevas eficiencias.

Nuestro objetivo final es poder recopilar, comprender, interactuar y generar datos más rápidamente aplicando las capacidades de IA adecuadas en los puntos correctos de la organización.

Esta versión elimina la segmentación de roles específicos y la hace aplicable a cualquier persona involucrada en decisiones de implementación de IA, al tiempo que mantiene los mismos conceptos y estructura clave.

Al final de este capítulo comprenderás lo siguiente:

- Cómo han evolucionado las arquitecturas de datos desde sistemas heredados a infraestructuras preparadas para IA, y cómo implementar un enfoque de almacenamiento de datos convergente que unifique datos estructurados y no estructurados.
- El espectro de tecnologías de IA disponibles para las organizaciones de seguros, desde el aprendizaje automático tradicional hasta los sistemas de IA agentes, y sus aplicaciones prácticas en la suscripción, el procesamiento de reclamaciones y la experiencia del cliente.
- Por qué la implementación de IA impulsada por dominios se alinea con los objetivos comerciales y cómo diseñar entidades de dominio raíz que brinden el rico contexto necesario para la toma de decisiones inteligente
- Ejemplos reales de organizaciones de seguros que implementan con éxito soluciones de IA
- La importancia estratégica de integrar la IA directamente en las aplicaciones comerciales en lugar de tratarla como una iniciativa separada

La evolución de las arquitecturas de datos

Hemos estado inmersos en un proceso de desarrollo de arquitecturas de datos en el sector de seguros. Esta evolución ha pasado por tres fases distintas:

- **Sistemas heredados:** estos se caracterizaban por bases de datos relacionales monolíticas que eran lentas y costosas, con esquemas rígidos que tardaban en adaptarse y tenían una escalabilidad limitada.
- **Era de los microservicios:** esto introdujo almacenes de datos de dominio con Ciclos de desarrollo más rápidos, utilizando JSON para datos tanto en movimiento como en reposo, API y eventos para comunicación y esquemas específicos del dominio
- **Integración de IA:** ahora estamos entrando en una era en la que necesitamos diseñar datos específicamente para IA, con aplicaciones comerciales inteligentes y agentes inteligentes que operan en almacenes de datos convergentes.




Figura 14.1: Evolución de la arquitectura de datos: de sistemas heredados a infraestructura preparada para IA

La Figura 14.1 ilustra la evolución trifásica de las arquitecturas de datos en seguros. Los sistemas heredados muestran una estructura tradicional de tres niveles (IU, aplicación y datos) con bases de datos relacionales monolíticas. La era de